


POLITECNICO DI MILANO
Corso di Laurea in Ingegneria Matematica

Elementi di

PROBABILITÀ



$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

MARCO ZAMBONI

A.A. 2024/2025

Indice

I	Teoria	5
1	Cenni di Teoria della Misura	1
1.1	Sigma-Algebra	1
1.2	Misure e Spazi Misurabili	2
1.2.1	Alcune misure fondamentali	4
2	Cosa vuol dire Probabilità?	7
2.1	Terna di Kolmogorov	7
2.2	La Probabilità	8
2.3	Nozione di Convergenza Insiemistica	11
2.4	Assegnare una Probabilità con Ω Discreto	12
2.4.1	Esempi Notevoli di Modelli Discreti	13
3	Assegnare una Probabilità con Ω Qualsiasi	15
3.1	Caso “Semplice”: Classi di Eventi	15
3.2	Probabilità Condizionata	16
3.2.1	Indipendenza Stocastica	22
3.2.2	Indipendenza Condizionata	24
3.3	Caso con $\Omega = \mathbb{R}$ o $\mathbb{R}^+$ o $[a, b]$	24
3.3.1	Funzione di Ripartizione	26
4	Funzioni: Creiamo un Linguaggio Comune	32
4.1	Composizione di Funzioni	34
5	Variabili Aleatorie	37
5.1	Legge di una Variabile Aleatoria	41
5.2	Relazioni fra Variabili Aleatorie: Uguaglianza Quasi Certa ed in Legge	43
6	Integrale di Lebesgue	46
6.1	Definizione per Funzioni Elementari	46
6.2	Generalizzazione della Definizione a Funzioni Generiche	47
6.3	Spazio $\mathcal{L}^1$	51
6.4	Caso di Interesse con $E = \mathbb{R}, \mathbb{R}^n$ e Confronto con Integrale di Riemann	52
7	Valore Atteso: Integrale Rispetto ad una Misura di Probabilità	55
7.1	Valore atteso per Variabili Aleatorie Semplici	55
7.2	Generalizzazione a Variabili Aleatorie Generiche	55
7.3	Proprietà del Valore Atteso	57
7.4	Spazio L^p	60
7.5	Varianza	62
7.6	Regola del Valore Atteso	63
8	Variabili Aleatorie Discrete	65

9 Variabili Aleatorie Assolutamente Continue	67
9.1 Riassunto Utile e Considerazioni Pratiche	70
10 Variabili Aleatorie Indipendenti	72
10.1 Variabili Aleatorie Unidimensionali	72
10.2 Variabili Aleatorie Multidimensionali: Sigme-Algebre Prodotto	74
10.3 Teorema di Fubini–Tonelli	76
10.4 Famiglie di Variabili Aleatorie Indipendenti	79
11 Vettori Aleatori	82
11.1 Vettori Discreti	82
11.2 Vettori Assolutamente Continui	85
11.3 Covarianza	89
11.3.1 Coefficiente di Correlazione Lineare	91
11.4 Vettore Media e Matrice di Varianza	92
11.5 Funzione di Ripartizione Multidimensionale	94
12 Funzione Caratteristica	95
12.1 Applicazioni Notevoli	100
13 Gaussiane Multivariate	103
14 Leggi Condizionali	109
14.1 Introduzione Intuitiva	109
14.2 Trattazione Formale	111
14.2.1 Caso di Indipendenza	112
14.2.2 Caso Deterministico	113
14.2.3 Caso Discreto	113
14.2.4 Caso Continuo	114
14.2.5 Caso Gaussiano	115
14.3 Attesa Condizionata	116
14.3.1 Attesa Condizionata in L^2 e Ottimizzazione	121
14.4 Varianza Condizionata	122
15 Convergenze di Variabili Aleatorie	125
15.1 Convergenze per Variabili Reali con lo Stesso Dominio	125
15.1.1 Convergenza Quasi Certa	125
15.1.2 Convergenza in L^p ed in Probabilità	127
15.2 Teoremi Limite: Legge Debole e Forte dei Grandi Numeri	130
15.2.1 Applicazione: Funzione di Ripartizione Empirica	135
15.3 Convergenza in Legge	137
15.4 Relazione tra le Convergenze	143
II Appendici	147
A Dispense Integrative	149
A.1 Calcolo Combinatorio	150
A.1.1 Permutazioni	150
A.1.2 Disposizioni	150
A.1.3 Combinazioni	150

A.2	Logaritmo Complesso	151
A.3	Radice Quadrata di una Matrice	152
B	Distribuzioni Discrete	153
B.1	Uniforme Discreta	154
B.2	Bernoulli	155
B.3	Binomiale	156
B.4	Poisson	157
B.5	Geometrica	158
B.6	Ipergeometrica	159
C	Distribuzioni Continue	160
C.1	Uniforme Continua	161
C.2	Esponenziale	162
C.3	Normale	163
C.4	Gamma	164

Parte I

Teoria

1 Cenni di Teoria della Misura

1.1 Sigma-Algebra

Definito Ω come un insieme, di questo ci interessano famiglie di sottoinsiemi. Per esempio possiamo avere l'Insieme delle Parti di Ω , ovvero l'insieme che contiene tutti gli insiemi di Ω .

$$\mathcal{P}(\Omega) = 2^\Omega = \{A : A \subseteq \Omega\}$$

ESEMPIO : Insieme delle parti di $\Omega = \{0, 1\}$:

$$\mathcal{P}(\{0, 1\}) = \{\{0\}, \{1\}, \{0, 1\}, \emptyset\}$$

Oppure possiamo considerare famiglie di sottoinsiemi differenti di $\Omega = \mathbb{R}$, per esempio:

- $\{\mathbb{N}\}$
- $\{(a, b) : -\infty < a < b < \infty\}$ (Tutti gli intervalli aperti)
- $\{\emptyset, (a, b) : -\infty < a < b < \infty\}$

Una caratteristica fondamentale che devono avere queste sottofamiglie, è che siano σ -Algebre.

DEFINIZIONE 1.1: $\mathcal{A} \subseteq \mathcal{P}(\Omega)$, famiglia di sottoinsiemi di Ω , è una σ -algebra se:

1. $\Omega \in \mathcal{A}$
2. Se $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$ (chiusa al passaggio per complementare)
3. $A_1, \dots, A_n \in \mathcal{A} \Rightarrow \bigcup_{k=1}^n A_k \in \mathcal{A}$ (chiusa rispetto all'unione finita)
4. $(A_n : n \geq 1) \subseteq \mathcal{A} \Rightarrow \bigcup_{n=1}^\infty A_n \in \mathcal{A}$ (chiusa rispetto unione numerabile)

ESEMPIO : Alcuni esempi possono di sigma algebre di $\Omega = \{0, 1\}$ possono essere:

- $\{\emptyset, \{0\}, \{1\}, \{0, 1\}\}$
- $\{\emptyset, \{0, 1\}\}$
- $\{\emptyset, \mathbb{R}\}$ (σ -algebra banale)
- $\{\emptyset, \mathbb{R}, (-\infty, 0], (0, +\infty)\}$

Mentre se prendiamo $\{\emptyset, \{(a, b) : -\infty < a < b < \infty\}\}$, questa non risulta essere una sigma-algebra, in quanto possiamo prendere l'intervallo $[1, 2)$, il quale ha come complementare $[1, 2)^c = (-\infty, 1) \cup [2, \infty)$, il quale non si riesce a scrivere come intervallo del tipo $[a, b) : -\infty < a < b < \infty$.

Si noti che il punto 4 della definizione di σ -algebra è pleonastico. Questo deriva dalle regole di De Morgan, che ricordiamo essere (su famiglie finite e numerabili):

$$(\bigcup_{\alpha} A_{\alpha})^c = \bigcap_{\alpha} A_{\alpha}^c \quad \text{e} \quad (\bigcap_{\alpha} A_{\alpha})^c = \bigcup_{\alpha} A_{\alpha}^c$$

Si ha dunque che se:

$$A_1, \dots, A_n \in \mathcal{A} \xrightarrow{(2)} A_1^c, \dots, A_n^c \in \mathcal{A} \xrightarrow{(3)} \bigcup_{k=1}^n A_k^c \in \mathcal{A} \xrightarrow{(2)} \left(\bigcup_{k=1}^n A_k^c \right)^c \in \mathcal{A} \stackrel{(D.M.)}{=} \bigcap_{k=1}^n A_k$$

Possiamo quindi andare a ripulire la definizione stessa, attraverso la seguente proposizione:

PROPOSIZIONE 1.2: Se per una classe $\mathcal{C}$ di sottoinsiemi di Ω vale che:

1. $\Omega \in \mathcal{C}$
2. $A \in \mathcal{C} \Rightarrow A^c \in \mathcal{C}$
3. $(A_n)_{n \geq 1} \subseteq \mathcal{C} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{C}$

Allora se $A_1, \dots, A_n \in \mathcal{C}$ anche $\bigcup_{k=1}^n A_k \in \mathcal{C}$.

Dimostrazione. Sapendo che valgono 1. 2. e 3. e che vale che $\emptyset \in \mathcal{C}$ mi costruisco una successione numerabile $\in \mathcal{C}$:

$$(B_k)_{k \geq 1} \subseteq \mathcal{C} : \begin{cases} B_k = A_k, & \text{se } 1 \leq k \leq n \\ B_k = \emptyset, & \text{se } k \geq n+1 \end{cases}$$

Allora:

$$\bigcup_{k=1}^{\infty} B_k \in \mathcal{C} \Rightarrow \bigcup_{k=1}^{\infty} B_k = A_1 \cup \dots \cup A_n \cup \emptyset \cup \dots \cup \emptyset = A_1 \cup \dots \cup A_n$$

□

Possiamo quindi finalmente ripulire la definizione di σ -algebra alla luce della proposizione 1.2:

DEFINIZIONE 1.3: $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ famiglia di sottoinsiemi di Ω è una σ -algebra se:

1. $\Omega \in \mathcal{A}$
2. Se $A \in \mathcal{A} \Rightarrow A^c \in \mathcal{A}$
3. $(A_n)_{n \geq 1} \subseteq \mathcal{A} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{A}$

Questo implica che se $\mathcal{A}$ è una σ -algebra, questa è chiusa anche ad unioni finite e ad intersezioni finite e numerabili.

1.2 Misure e Spazi Misurabili

Uno spazio misurabile $(\Omega, \mathcal{A})$ è una coppia formata da un insieme Ω ed una σ -algebra $\mathcal{A}$ di sottoinsiemi. Osserviamo che si possono sempre trovare σ -algebre banali, come $\mathcal{A} = \{\emptyset, \Omega\}$ oppure $\mathcal{A} = \mathcal{P}(\Omega) = 2^{\Omega}$. O addirittura possiamo costruire una σ -algebra a partire da un sottoinsieme:

$$A \subseteq \Omega \rightarrow \mathcal{A} = \sigma(A) = \{ \emptyset, \Omega, A, A^c \}$$

DEFINIZIONE 1.4: Una Misura μ su $\mathcal{E}$ è una funzione $\mu : \mathcal{E} \rightarrow \mathbb{R}^+ \cup \{+\infty\}$ tale che:

- M.1) $\mu(\emptyset) = 0$
- M.2) Vale la σ -additività, ovvero che:

$$(E_n)_{n \geq 1} \subseteq \mathcal{E} \text{ tale che } E_h \cap E_k = \emptyset \quad \forall k \neq h : \quad \mu\left(\bigcup_{n=1}^{\infty} E_n\right) = \sum_{n=1}^{\infty} \mu(E_n)$$

DEFINIZIONE 1.5: μ è una misura finita se $\mu(E) < +\infty$

DEFINIZIONE 1.6: μ è una misura σ -finita se $\exists (E_n)_{n \geq 1} \subseteq \mathcal{E}$ tale che:

1. $E = \bigcup_{n=1}^{\infty} E_n$
2. $\mu(E_n) < +\infty \quad \forall n \geq 1$

Si osservi che in quest'ultima definizione non abbiamo imposto alcuna restrizione sul fatto che gli insiemi vadano presi a due a due disgiunti; nel caso siano anche disgiunti, non abbiamo sicurezza che la serie sia finita. Notiamo inoltre che la misura di E non deve essere per forza finita per essere σ -finita; l'essere σ -finito è un caso più generale dell'essere finiti.

ESEMPIO : Misura di Lebesgue

$E = \mathbb{R} \quad ; \quad \mu = m \quad \text{dove:}$

$$m([a, b)) = b - a = \int_a^b dx$$

Ovvero associo ad un intervallo la sua lunghezza. Mi aspetto quindi che " $m(\mathbb{R}) = +\infty$ " ossia che la "misura della retta reale si infinita". Se notiamo che possiamo scrivere $\mathbb{R}$ come:

$$\mathbb{R} = \bigcup_{n=1}^{\infty} [-n, n) = \bigcup_{n=1}^{\infty} E_n$$

e che $m([-n, n)) = 2n \Rightarrow \mu(E_n) = m([-n, n)) = 2n < +\infty$.

Abbiamo quindi dimostrato che la Misura di Lebesgue è σ -finita.

Osservo che $\mathbb{R}^+$ può essere scritto come unione *disgiunta* di intervalli a misura finita:

$$\mathbb{R}^+ = \bigcup_{n=0}^{\infty} [n, n+1),$$

dove $[n, n+1) \cap [k, k+1) = \emptyset \quad \forall n \neq k$.

Inoltre

$$\mu([n, n+1)) = 1 < +\infty \quad \forall n \in \mathbb{N},$$

quindi μ è σ -finita anche su $\mathbb{R}^+$.

PROPOSIZIONE 1.7: Sia μ una misura su $(E, \mathcal{E})$, allora valgono le seguenti proprietà:

P.1) $\mu(A \cup B) = \mu(A) + \mu(B) \quad \forall A \cap B = \emptyset \quad A, B \in \mathcal{E}$


P.2) $\mu(A) \leq \mu(B)$ quando $A \subseteq B$

Dimostrazione. $A, B \in \mathcal{E}$ e posso scrivere che $A \cup B = A \cup B \cup \emptyset \cup \dots \cup \emptyset = \bigcup_{n=1}^{\infty} E_n$, dove:

$$E_n = \begin{cases} E_1 = A \\ E_2 = B \\ E_3 = \emptyset, \text{ se } k \geq 3 \end{cases}$$

$$P.1) \mu(A \cup B) = \mu\left(\bigcup_{n=1}^{\infty} E_n\right) \stackrel{M.2}{=} \sum_{n \geq 1} \mu(E_n) = \mu(E_1) + \mu(E_2) + \sum_{n \geq 3} \mu(E_n) = \mu(A) + \mu(B) + \sum_{n \geq 3} 0 = \mu(A) + \mu(B)$$

P.2) Partiziono B come: $B = A \cup (B \cap A^c)$, la quale è unione disgiunta ($A \cap (B \cap A^c) = \emptyset$).



$$\stackrel{P.1}{\Rightarrow} \mu(B) = \mu(A \cup (B \cap A^c)) = \mu(A) + \mu(B \cap A^c) \geq \mu(A)$$

In quanto la misura è non negativa.

□

1.2.1 Alcune misure fondamentali

★ Una misura fondamentale nella Teoria della misura è la **Massa di Dirac** in un punto α_0 .

Preso $\alpha_0 \in E$, si ha che $\forall A \subseteq E$:

$$\mu(A) = \begin{cases} 1, & \text{se } \alpha_0 \in A \\ 0, & \text{se } \alpha_0 \notin A \end{cases}$$

Questa risulta essere una misura finita.

Se infatti prendo $E = \mathbb{R}; \alpha_0 = 0; A = [-3, 5) \Rightarrow \mu(A) = 1$

Se prendessi invece $B = [-3, -1) \Rightarrow \mu(B) = 0$.

Notiamo inoltre che se scrivessi $\mathbb{R}$ come fatto nell'esempio della misura di Lebesgue, non avrei insiemi disgiunti, e di conseguenza non potrei dire che $\mathbb{R}$ ha misura infinita.

★ Consideriamo adesso un'altra misura: la **Misura Puramente Atomica**. Preso E numerabile, ovvero: $E = \{\alpha_n : n \geq 0\}$, associo a $(\alpha_n)_n$ un'altra successione $(p_n)_{n \geq 0}$ tale che $p_n \geq 0$. Siccome E è misurabile avremo che

$$A = \bigcup_{k: \alpha_k \in A} \{\alpha_k\}$$

Posso quindi definire la misura:

$$\mu(A) = \sum_{k: \alpha_k \in A} p_k$$

È come se si vedono gli elementi della successione che sono in A , e ne sommo i relativi pesi p_k ; essendo quest'ultimi non negativi la serie non dipenderà dall'ordine, quindi avremo o convergenza o divergenza.

ESEMPIO : Caso finito.

$$E = \{1, \dots, 6\} \xrightarrow{\text{Associo}} \left(\frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}, \frac{1}{6}\right)$$

$$\{\alpha_1, \dots, \alpha_6\} \xrightarrow{\text{Associo}} (p_1, \dots, p_6)$$

Sia $A \subseteq E : A = \{2, 4, 6\}$

$$\Rightarrow \mu(A) = \sum_{k: \alpha_k \in A} p_k = p_2 + p_3 + p_6 = \frac{1}{6} + \frac{1}{6} + \frac{1}{6} = \frac{1}{2}$$

Questo caso risulta parecchio semplificato perché l'insieme è finito.

ESEMPIO : Caso Numerabile.

$$E = \mathbb{N}^* = \mathbb{N} \setminus \{0\} = \{\alpha_n : n \geq 1\} = \{n : n \geq 1\} \xrightarrow{\text{Associo}} p_n = n \quad \forall n \geq 1$$

Sia $A \subseteq E$, tale che $A = \{n_k : k \geq 1\}$, ovvero che sia una sotto-successione. La misura in questione risulta essere quindi:

$$\mu(A) = \sum_{k=1}^{\infty} p_k = \sum_{k=1}^{\infty} \frac{1}{n_k}$$

La quale diverge se la si calcola in E , rendendo la misura *non* finita:

$$\mu(E) = \sum_{n=1}^{\infty} p_n = \sum_{n=1}^{\infty} \frac{1}{n} = +\infty$$

Tuttavia si può partizionare l'insieme E , andando ad identificare gli insiemi $E_k = \{k\}$, avendo così che $\mu(E_k) = 1/k < +\infty \quad \forall k \geq 1$.

Se inoltre ci si accorge che

$$\bigcup_{k \geq 1} E_k = \bigcup \{k\} = \mathbb{N}^* = E$$

allora si può concludere che μ sia una misura σ -finita.

Questo esempio dimostra un fatto fondamentale: se ho una successione numerabile, posso sempre invadere l'insieme nella modalità appena eseguita, verificando sempre che μ sia una misura σ -finita.

Si noti che preso $E = \{\alpha_n : n \geq 1\}$, ovvero un insieme numerabile, e $(p_n)_{n \geq 1} : p_n \geq 0 \quad \forall A \in \mathcal{P}(E)$, allora si avrà sempre che

$$\mu(A) = \sum_{k: \alpha_k \in A} p_k$$

e di conseguenza, si avrà che: $\mu(E) = \sum_n p_n$ dimostrando che μ è finita $\iff \sum_n p_n < +\infty$.

Si noti inoltre che possiamo scrivere la misura come:

$$\mu(A) = \sum_{k: \alpha_k \in A} p_k = \sum_{n=1}^{\infty} p_n \cdot \delta_{\alpha_n}(A)$$

ossia che possiamo vederla come una *combinazione lineare* di masse di Dirac.

★ La **Misura di Lebesgue** è già stata introdotta, tuttavia questa può essere estesa anche a casi non monodimensionali. Si ha infatti che:

1. Su $\mathbb{R}$: $m_1([a, b)) = b - a$ (Lunghezza)
2. Su $\mathbb{R}^2$: $m_2(B(0, r)) = \pi r^2$ (Area)
3. Su $\mathbb{R}^3$: $m_2(B(0, r)) = \frac{4}{3}\pi r^3$ (Volume)

Anticipiamo che m non può essere definita su tutti i sottoinsiemi di $\mathbb{R}$ perché sono "troppi"; non potremo quindi usare come σ -algebra $\mathcal{P}(\mathbb{R})$. Più avanti approfondiremo la questione, andando ad individuare una σ -algebra che sia adatta ai nostri scopi.

2 Cosa vuol dire *Probabilità*?

2.1 Terna di Kolmogorov

Per capire cosa voglia dire *Probabilità*, dobbiamo prima capire dove *si può fare Probabilità*. Introduciamo quindi la Terna Assiomatica della Probabilità (o di Kolmogorov). Un modello probabilistico è quindi un oggetto matematico, composto da tre elementi:

$$(\Omega, \mathcal{A}, \mathbb{P})$$

Dove abbiamo già visto che $(\Omega, \mathcal{A})$ è uno spazio misurabile, ma cosa è $\mathbb{P}$? Andiamo a studiare tutti e 3 gli elementi nel dettaglio.

Lo **Spazio Campionario** Ω è l'insieme che contiene tutti i possibili risultati del fenomeno (o esperimento) aleatorio che ci interessa. Tutti gli elementi di Ω sono denotati da $\omega \in \Omega$ dove ω è definito *risultato* o *realizzazione* dell'esperimento.

ESEMPIO : Di seguito alcuni esempi su come si può costruire lo spazio campionario:

1. Se lancio una moneta e guardo che faccia esce, lo spazio: campionario può essere

$$\Omega = \{t, c\} = \{1, 0\}$$

2. Se lancio 2 monete in successione invece potrei avere:

$$\Omega = \{(t, t), (t, c), (c, t), (c, c)\} = \{0, 1\} \times \{0, 1\}$$

3. Lancio due monete e voglio considerare il numero di teste:

$$\Omega_1 = \{0, 1, 2\} \quad \text{oppure} \quad \Omega_2 = \{0, 1\} \times \{0, 1\}$$

Entrambi gli spazi campionari mi danno lo stesso numero di informazioni sul numero di teste; vanno bene entrambi allo stesso modo per rappresentare l'esperimento.

4. Accendo una lampadina ed osservo quando si spegne:

$$\Omega_1 = \mathbb{R}^+ = [0, +\infty) \quad \text{oppure} \quad \Omega_2 = [0, 2T^*]$$

T^* rappresenta la vita massima della lampadina (ammesso che ne siamo a conoscenza).

Già da questi banali esempi abbiamo capito che Ω non è univoco: dipende dall'esperimento¹.

La **Sigma-Algebra** $\mathcal{A}$ è la famiglia degli eventi relativi all'esperimento aleatorio di cui si è interessati a calcolarne la probabilità (anche se non sappiamo ancora cos'è una probabilità). Indichiamo con *Evento* una proposizione logica che so se è vera o falsa *dopo* che ho svolto l'esperimento aleatorio.

Evento $\xleftrightarrow{\text{Corrisponde}}$ Sottoinsieme di Ω formato dai risultati che realizzano l'evento stesso

ESEMPIO : Riprendendo gli esempi di prima:

1. Se lancio il dado e vedo cosa esce, potrei avere $\Omega = \{1, 2, 3, 4, 5, 6\}$. Un evento potrebbe essere "lancio il dado

¹Ove possibile, è sempre meglio scegliere $\Omega \subseteq \mathbb{R}$ oppure $\Omega \subseteq \mathbb{R}^n$

ed esce un numero pari", che può essere rappresentato dal sottoinsieme $A \subseteq \Omega : A = \{2, 4, 6\}$.

Se effettivamente esce un numero pari (es. 2): $2 \in A \Rightarrow A$ si è realizzato

Se effettivamente esce un numero dispari (es. 3): $3 \notin A \Rightarrow A^c$ si è realizzato

2. Se lancio due volte una moneta e considero l'evento $A = \text{"esce testa al primo lancio"}$, avremo che $\Omega = \{0, 1\} \times \{0, 1\} = \{(0, 0), (0, 1), (1, 0), (1, 1)\}$ e quindi $A = \{(1, 0), (1, 1)\}$
3. Osservo una lampadina e segno quando questa muore, allora avremo che $\Omega = [0, +\infty)$. Se si considera l'evento $A = \text{"La lampadina dopo 2 ore è ancora accesa"}$ si avrà che $A = (2, +\infty)$

Ma come mai c'è la necessità modellistica che $\mathcal{A}$ debba per forza essere una σ -algebra?

Se prendiamo in considerazione un esperimento dove si lancia ripetutamente una moneta, e considero l'evento $A_n = \text{"all'ennesimo lancio esce testa per la prima volta"}$, allora possiamo prendere

$$\Omega = \{(0, 0, 0, 0, 1, 0, 1, \dots), \dots, \dots\} = \{(a_n)_{n \geq 1} : a_n \in \{0, 1\} \quad \forall n \geq 1\}$$

$$\Rightarrow A_{\bar{n}} = \{(a_k)_{k \geq 1} : a_h = 0 \quad \forall h = 1, \dots, \bar{n} - 1; \quad a_{\bar{n}} = 1\} \quad \text{con } \bar{n} \text{ fissato}$$

Se invece considerassimo l'evento $B = \text{"Prima o poi esce testa"}$, siamo costretti a modellizzarlo come

$$B = \{(\mathbf{0})\}^c = \bigcup_{n=1}^{\infty} A_n$$

La quale è un'unione numerabile di eventi: ecco che compare la necessità che la nostra famiglia di eventi $\mathcal{A}$ sia chiusa rispetto all'unione numerabile, e quindi che sia una σ -algebra.

Per completezza diamo anche la definizione di Algebra.

DEFINIZIONE 2.1: Una famiglia $\mathcal{A}_0$ di sottoinsiemi di Ω si definisce algebra se valgono:

1. $\Omega \in \mathcal{A}_0$
2. Se $A \in \mathcal{A}_0 \Rightarrow A^c \in \mathcal{A}_0$
3. $A_1, \dots, A_n \in \mathcal{A}_0 \Rightarrow \bigcup_{k=1}^n A_k \in \mathcal{A}_0$

È evidente che una σ -algebra risulta essere un'algebra, ma non vale il viceversa

2.2 La Probabilità

Finalmente ora abbiamo tutti gli strumenti necessari per dare la definizione formale di cosa sia una probabilità.

DEFINIZIONE 2.2: Sia $(\Omega, \mathcal{A})$ uno spazio misurabile (o probabilizzabile). Una probabilità $\mathbb{P}$ è una misura finita su $\mathcal{A}$ tale che $\mathbb{P}(\Omega) = 1$, ovvero che:

1. $\mathbb{P}(\emptyset) = 0$
2. $\forall (A_n)_{n \geq 1} \subseteq \mathcal{A}$ successione di eventi incompatibili a 2 a 2 (ossia: $A_h \cap A_k = \emptyset \quad \forall h \neq k$) si ha che :

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

3. $\mathbb{P}(\Omega) = 1$

Si osservi che la condizione 2. vale solo per famiglie numerabili. Anticipando un concetto che esploreremo più avanti, se questa valesse anche per famiglie più che numerabili, otterrei un assurdo:

$$\Omega = [0, 1] = \bigcup_{x \in [0, 1]} \{x\} \quad \rightarrow \quad 1 = \mathbb{P}([0, 1]) \neq \sum_{x \in [0, 1]} \mathbb{P}(\{x\}) = 0$$

In quanto la probabilità di un atomo $\{x\}$ è zero: $\mathbb{P}(\{x\}) = 0 \quad \forall x \in [0, 1]$

PROPOSIZIONE 2.3: Se $\mathbb{P} : \mathcal{A} \rightarrow \mathbb{R}^+ \cup \{+\infty\}$ tale che valgono:

- (a) $\mathbb{P}(\Omega) = 1$
- (b) vale la σ -additività

Allora $\mathbb{P}(\emptyset) = 0$ e quindi la funzione $\mathbb{P}$ è una misura di probabilità (o probabilità).

Dimostrazione. Posso scrivere che $\Omega = \Omega \cup \emptyset \cup \dots \emptyset \cup \dots = \bigcup_n A_n$, con:

$$A_n = \begin{cases} A_1 = \Omega \\ A_k = \emptyset, \quad \text{se } k \geq 2 \end{cases}$$

Allora:

$$\begin{aligned} 1 &\stackrel{a}{=} \mathbb{P}(\Omega) \stackrel{b}{=} \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \mathbb{P}(A_1) + \sum_{n=2}^{\infty} \mathbb{P}(A_n) = \mathbb{P}(\Omega) + \sum_{n=2}^{\infty} \mathbb{P}(\emptyset) = 1 + \sum_{n=2}^{\infty} \mathbb{P}(\emptyset) \\ &\Rightarrow \sum_{n=2}^{\infty} \mathbb{P}(\emptyset) = 0 \\ &\Rightarrow \mathbb{P}(\emptyset) = 0 \end{aligned}$$

Siccome $\mathbb{P}()$ è non negativa. □

Come avevamo ripulito la definizione di σ -algebra, grazie a questa proposizione possiamo ripulire la definizione di Probabilità:

DEFINIZIONE 2.4: Una funzione $\mathbb{P} : \mathcal{A} \rightarrow \mathbb{R}^+ \cup \{+\infty\}$ tale che valgono:

- (a) $\mathbb{P}(\Omega) = 1$
- (b) vale la σ -additività

È una Probabilità su $\mathcal{A}$ (o misura di probabilità).

TEOREMA 2.5 Proprietà Di Una Probabilità : Se $\mathbb{P}$ è una Probabilità su $(\Omega, \mathcal{A})$ allora valgono le seguenti proprietà:

P.1) $\mathbb{P}(\emptyset) = 0$

P.2) $A_1, \dots, A_n \in \mathcal{A} : A_h \cap A_k \neq \emptyset, \quad \forall h \neq k$ si ha che: (finita additività)

$$\mathbb{P}(A_1 \cup \dots \cup A_n) = \sum_{k=1}^n \mathbb{P}(A_k)$$

P.3) $A, A' \in \mathcal{A} \text{ e } A \subseteq A' \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(A')$

P.4) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$

P.5) $A, A' : A' \setminus A = A' \cap A^c \Rightarrow \mathbb{P}(A' \setminus A) = \mathbb{P}(A') - \mathbb{P}(A \cap A')$

P.6) $A, A' \in \mathcal{A} : \mathbb{P}(A \cup A') = \mathbb{P}(A) + \mathbb{P}(A') - \mathbb{P}(A \cap A')$

P.7) $A_1, \dots, A_n \in \mathcal{A} : \quad \quad \quad (\text{sub-additività})$

$$\mathbb{P}(A_1 \cup \dots \cup A_n) \leq \sum_{k=1}^n \mathbb{P}(A_k)$$

P.8) $(A_n)_{n \geq 1} \subseteq \mathcal{A} : \quad \quad \quad (\sigma\text{-sub-additività})$

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n)$$

P.9) $A_1, \dots, A_n \in \mathcal{A} : \quad \quad \quad (\text{disuguaglianza di Bonferroni})$

$$\mathbb{P}(A_1 \cap \dots \cap A_n) \geq \mathbb{P}(A_1) + \dots + \mathbb{P}(A_n) - (n-1)$$

Dimostrazione. P.1) Dimostrata con Proposizione 4.2

P.2) Dimostrata in generale per le misure: 1.7 P.1)

P.3) Dimostrata in generale per le misure: 1.7 P.2)

P.4) Posso partizionare Ω come $\Omega = A \cup A^c$, che è un'unione disgiunta per definizione.

$$1 \stackrel{a}{=} \mathbb{P}(\Omega) = \mathbb{P}(A) + \mathbb{P}(A^c) \Rightarrow \mathbb{P}(A^c) = 1 - \mathbb{P}(A)$$

P.5) $A, A' : A' \setminus A = A' \cap A^c$. Partiziono: $A' = (A' \cap A) \cup (A' \cap A^c)$, che è unione disgiunta.

$$\Rightarrow \mathbb{P}(A') = \mathbb{P}(A' \cap A) + \mathbb{P}(A' \setminus A)$$

P.6) $A \cup B = (A \setminus B) \cup (B \setminus A) \cup (A \cap B)$

$$\begin{aligned} \Rightarrow \mathbb{P}(A \cup B) &= \mathbb{P}(A \setminus B) + \mathbb{P}(B \setminus A) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) - \mathbb{P}(A \cap B) + \mathbb{P}(B) - \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B) \end{aligned}$$

P.7) Dimostro per induzione.

- $n=2$:

$$\mathbb{P}(A_1 \cup A_2) \stackrel{P.6}{=} \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2) \leq \mathbb{P}(A_1) + \mathbb{P}(A_2)$$

- Suppongo vera per $n-1$, dimostro per n : $A_1 \cup \dots \cup A_n = (A_1 \cup \dots \cup A_{n-1}) \cup A_n$

$$\begin{aligned} \Rightarrow \mathbb{P}(A_1 \cup \dots \cup A_n) &\stackrel{n=2}{\leq} \mathbb{P}(A_1 \cup \dots \cup A_{n-1}) + \mathbb{P}(A_n) \\ &\stackrel{n-1}{\leq} \mathbb{P}(A_1) + \dots + \mathbb{P}(A_{n-1}) + \mathbb{P}(A_n) \end{aligned}$$

P.8) Non la dimostriamo ^a

P.9) Per induzione:

- $n=2$: $\mathbb{P}(A_1 \cap A_2) \stackrel{P.6}{=} \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cup A_2)$
Dove so che $0 \leq \mathbb{P}(A) \leq \mathbb{P}(\Omega) = 1$, perchè $A \in \mathcal{A}$ e $A \in \Omega$

$$\Rightarrow \mathbb{P}(A_1 \cap A_2) \leq \mathbb{P}(A_1) + \mathbb{P}(A_2) - 1 = \mathbb{P}(A_1) + \mathbb{P}(A_2) - (2 - 1)$$

- Suppongo vera per $n-1$, dimostro per n : $(A_1 \cap \dots \cap A_{n-1}) \cap A_n = B \cap A_n$. Allora si avrà che:

$$\begin{aligned} \mathbb{P}(A_1 \cap \dots \cap A_n) &= \mathbb{P}(B \cap A_n) \stackrel{n=2}{\geq} \mathbb{P}(B) + \mathbb{P}(A_n) - 1 \\ &\stackrel{n-1}{\geq} \mathbb{P}(A_1) + \dots + \mathbb{P}(A_n) - [(n-1) - 1] + \mathbb{P}(A_n) - 1 \\ &= \mathbb{P}(A_1) + \dots + \mathbb{P}(A_{n-1}) + \mathbb{P}(A_n) - (n-1) + 1 - 1 \end{aligned}$$

□

^aPer i più curiosi, potrà essere successivamente dimostrata grazie al Teorema 2.6

2.3 Nozione di Convergenza Insiemistica

Supponendo che esista uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, data una successione di eventi $(A_n)_{n \geq 1} \subseteq \mathcal{A}$ possiamo definire le due convergenze:

- Si dice che la successione *converge crescendo*, $A_n \uparrow \bar{A}$, se: $\begin{cases} A_{n+1} \supseteq A_n \\ \bar{A} = \bigcup_{n=1}^{\infty} A_n \end{cases}$
- Si dice che la successione *converge decrescendo*, $A_n \downarrow \underline{A}$, se: $\begin{cases} A_{n+1} \subseteq A_n \\ \underline{A} = \bigcap_{n=1}^{\infty} A_n \end{cases}$

Definita questa nozione di convergenza, possiamo dare ulteriori proprietà di una Probabilità:

TEOREMA 2.6: Sia $\mathbb{P}$ una probabilità su $(\Omega, \mathcal{A})$, allora valgono le seguenti affermazioni:

P.10) Se $A_n \uparrow \bar{A}$ allora:

$$\mathbb{P}(\bar{A}) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow +\infty} \mathbb{P}(A_n)$$


P.11) Se $A_n \downarrow \underline{A}$ allora:

$$\mathbb{P}(\underline{A}) = \mathbb{P}\left(\bigcap_{n=1}^{\infty} A_n\right) = \lim_{n \rightarrow +\infty} \mathbb{P}(A_n)$$

Dimostrazione. Dimostreremo solo la proprietà (P.10), in quanto per la seconda il procedimento risulta essere il medesimo.

Per ipotesi si ha che $A_n \uparrow \bar{A}$ e $\bar{A} = \bigcup_n A_n$. Vogliamo usare la σ -additività, e per farlo costruiamo la successione B_k definita come:

$$\begin{cases} B_1 = A_1 \\ B_2 = A_2 \setminus A_1 \\ \vdots \\ B_k = A_k \setminus A_{k-1} \end{cases}$$



Dove si ha che

- I B_k sono disgiunti a 2 a 2;
- $A_n = \bigcup_{k=1}^n B_k$ (quindi vale la finita additività);
- $\bar{A} = \bigcup_n A_n = \bigcup_k B_k$.

$$\begin{aligned} \Rightarrow \mathbb{P}(\bar{A}) &= \mathbb{P}\left(\bigcup_{n=1}^{\infty} A_n\right) \stackrel{(2)}{=} \mathbb{P}\left(\bigcup_k B_k\right) \stackrel{(\sigma\text{-additività})}{=} \sum_{k=1}^{\infty} \mathbb{P}(B_k) \\ &= \lim_{n \rightarrow +\infty} \sum_{k=1}^n \mathbb{P}(B_k) \stackrel{(2)}{=} \lim_{n \rightarrow +\infty} \sum_{k=1}^n \mathbb{P}(A_n) \end{aligned}$$

□

2.4 Assegnare una Probabilità con Ω Discreto

Definito uno spazio di Probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, se avessimo un Ω qualsiasi, $\mathcal{A}$ potrebbe essere molto grande. Difatti già se prendessimo $\Omega = \{1, \dots, N\}$ e $\mathcal{A} = \mathcal{P}(\Omega)$ avremmo che la cardinalità di $\mathcal{A}$ risulterebbe essere $|\mathcal{A}| = 2^N$.

Imponiamo quindi (per il momento) che Ω sia discreto, ovvero finito o al più numerabile. D'ora in avanti, qualora Ω fosse discreto, prenderemo $\mathcal{A} = \mathcal{P}(\Omega)$, salvo diversa indicazione.

TEOREMA 2.7: Sia $\Omega = \{\omega_n : n \in I\}$ con $I \subseteq \mathbb{N}$, allora vale che:

1. Ogni probabilità $\mathbb{P}$ su $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$ è caratterizzata dai suoi valori sugli atomi $\{\omega_n\}$ con $n \geq 1$, ovvero che:

$$p_n = \mathbb{P}(\{\omega_n\}) \quad n \geq 1$$

2. Sia $(p_n)_{n \geq 1}$ una successione di numeri reali: $\exists! \mathbb{P} : \mathcal{P}(\Omega) \rightarrow [0, 1]$ misura di probabilità tale che:

$$\mathbb{P}(\{\omega_n\}) = p_n \quad \forall n \geq 1 \quad \Longleftrightarrow \quad \begin{cases} p_n \geq 0 \\ \sum_{n \in I} p_n = 1 \end{cases}$$

Dimostrazione. 1) $A \in \mathcal{P}(\Omega) : A = \bigcup_{n \in J} \{w_n\}$ con $J \subseteq I$

Allora avremo che: $\mathbb{P}(A) \stackrel{\sigma\text{-add}}{=} \sum_{n \in J} \mathbb{P}(\{w_n\}) = \sum_{n \in J} p_n.$

2) $(\Rightarrow)$ Siccome $p_n = \mathbb{P}(w_n) \in [0, 1] \Rightarrow p_n \geq 0$ risulta essere sempre vera. Inoltre siccome $\Omega = \bigcup_{n \in I} \{w_n\}$ si ha che:

$$\mathbb{P}(\Omega) \stackrel{\sigma\text{-add}}{=} \sum_{n \in I} \mathbb{P}(\{w_n\}) = \sum_{n \in I} p_n \stackrel{\mathbb{P}(\Omega)=1}{=} 1$$

$$(\Leftarrow) \quad \begin{cases} p_n \geq 0 \\ \sum_{n \in I} p_n = 1 \end{cases} \quad \text{con} \quad A = \bigcup_{n \in J} \{w_n\}.$$

Definisco $\mathbb{P}(A) = \sum_{n \in J} p_n$. Si dimostra che $\mathbb{P}$ è una misura di probabilità, ovvero che $\mathbb{P}(\Omega) = 1$ e vale la σ -additività (che non dimostreremo):

$$\Omega = \bigcup_{n \in I} \{w_n\} \Rightarrow \mathbb{P}(\Omega) = \sum_{n \in I} p_n = 1$$

□

2.4.1 Esempi Notevoli di Modelli Discreti

Esistono molti modelli discreti, ma ne riportiamo i più comuni.

★ Si prenda l'esempio nel quale si pescano delle palline numerate, dove: si hanno N palline numerate (indistinguibili per il resto), $\Omega = \{1, \dots, N\}$ e $\mathcal{A} = \mathcal{P}(\Omega)$.

Come trovo $\mathbb{P}$?

Una soluzione sarebbe quella di cercare $p_1, \dots, p_N$, consapevoli del fatto che $p_n = \mathbb{P}(\{n\})$.

$$\begin{cases} p_1 = p_2 = \dots = p_n = c \\ p_n \geq 0 \\ \sum_{n=1}^N p_n = 1 \end{cases} \Rightarrow \begin{cases} c \geq 0 \\ \sum_{n=1}^N c = Nc = 1 \end{cases} \Rightarrow c = \frac{1}{N}$$

Dove la prima condizione deriva direttamente da come è stato costruito l'esperimento, mentre le altre due sono necessarie affinché sia una probabilità. Questo che abbiamo appena costruito è il **Modello Uniforme** $(\Omega, \mathcal{P}(\Omega), \mathbb{P}_{uni})$, che formalizzato risulta essere:

$$A \in \mathcal{P}(\Omega), \quad \mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{\text{Casi favorevoli}}{\text{Casi possibili}}$$

Dove:

$$|\Omega| \leq +\infty \iff (p_n)_{n \geq 1} : p_n = \frac{1}{N} = \frac{1}{|\Omega|}$$

★ Costruiamo adesso il **Modello Binomiale**. Siano:

$$\Omega = \{0, \dots, n\}, n \in \mathbb{N}; \quad p \in [0, 1]; \quad \mathcal{A} = \mathcal{P}(\Omega)$$

Dunque $|\Omega| = n + 1$ e $|\mathcal{A}| = 2^{n+1}$. Si avrà il modello binomiale $(\Omega, \mathcal{P}(\Omega), \mathbb{P}_{bin})$ se e solo se:

$$p_k = \binom{n}{k} p^k (1-p)^{n-k} \quad k : 0, \dots, n$$

Si può mostrare (non tanto facilmente) che: $\begin{cases} \sum_{k=0}^n p_k = 1 \\ p_k \geq 0 \end{cases}$ concludendo che $\mathbb{P}_{bin}$ è una probabilità.

★ L'ultimo esempio è il **Modello di Poisson**, dove:

$$\Omega = \mathbb{N}, \quad \mathcal{A} = \mathcal{P}(\Omega); \quad \boxed{p_n = e^{-\lambda} \frac{\lambda^n}{n!}}$$

3 Assegnare una Probabilità con Ω Qualsiasi

In questo capitolo cercheremo di affrontare la casistica in cui il nostro spazio campionario non sia per forza discreto, come fatto in precedenza. Per aiutarci in ciò, distingueremo due casistiche: un caso "semplice" ed un caso più complesso con $\Omega \subseteq \mathbb{R}$.

3.1 Caso "Semplice": Classi di Eventi

In questa trattazione avremo sì Ω generico, ma ci interesserà solo una classe ristretta di eventi $\mathcal{C}$, che quindi contiene sottoinsiemi di Ω .

DEFINIZIONE 3.1: Data $\mathcal{C} \in \mathcal{P}(\Omega)$ una classe (o famiglia) di sottoinsiemi si definisce $\sigma(\mathcal{C})$ la più piccola σ -algebra che contiene $\mathcal{C}$, e la si denota con "σ-algebra generata dalla classe $\mathcal{C}$ "

PROPOSIZIONE 3.2: Per qualsiasi classe $\mathcal{C}$ di sottoinsiemi di Ω , esiste sempre $\sigma(\mathcal{C})$

Si osservi che anche se $\mathcal{C} \subseteq \mathcal{P}(\Omega)$ (dove l'insieme delle parti è una σ -algebra), questo non implica che $\mathcal{C}$ contenga una σ -algebra di Ω .

Per costruire $\sigma(\mathcal{C})$ si parte dall'insieme $\mathcal{F}$ definito come: $\mathcal{F} = \{\mathcal{A}_\alpha : \mathcal{A}_\alpha \supseteq \mathcal{C}\}$, ovvero l'insieme che contiene tutte le σ -algre che contengono $\mathcal{C}$. A questo punto, la σ -algebra generata da $\mathcal{C}$ risulta essere

$$\sigma(\mathcal{C}) = \bigcap_{\alpha} \mathcal{A}_\alpha$$

Dove l'intersezione rimane una σ -algebra ed è per costruzione la più piccola.

DEFINIZIONE 3.3: Si dice che $\mathcal{C} = \{C_k : k \in I\} \subseteq \mathcal{P}(\Omega)$ è una partizione discreta di Ω se:

1. $I \subseteq \mathbb{N}$ (ossia che I è finito o al più numerabile)
2. $C_k \cap C_h = \emptyset \quad \forall h \neq k$
3. $\bigcup_{k \in I} C_k = \Omega$

Si presti attenzione che $\mathcal{C}$ è una famiglia di insiemi C_k (visti come insiemi unici), tuttavia se faccio l'unione di (per esempio) $C_1 \cup C_2$, questo potrebbe non stare in $\mathcal{C}$.

Da un punto di vista modellistico, partizionare Ω ci permette di far "realizzare" almeno un (ed uno solo, in quanto sono disgiunti) evento della classe $\mathcal{C}$.




Figura 3.1: Esempio grafico di una partizione

ESEMPIO : Consideriamo $\mathbb{R}^+ = \bigcup_{n=1}^{\infty} [n-1, n)$ con $C_n = [n-1, n)$.

Allora $\mathcal{C} = \{C_n : n \in [1, +\infty)\}$ è una partizione di $\mathbb{R}^+$ diversa da $\mathcal{P}(\Omega)$. Siamo quindi riusciti ad isolare una classe al più numerabile.

PROPOSIZIONE 3.4: Quando $\mathcal{C}$ è una partizione discreta di Ω , allora:

$$\mathcal{A} = \sigma(\mathcal{C}) = \left\{ A \subseteq \Omega \mid A = \bigcup_{j \in J} C_j, \quad J \subseteq I \right\}$$

Questa proposizione ci permette di vedere gli elementi della partizione come "atomi": in un certo senso sono l'unità più piccola. Non posso far altro che unire due elementi C_h e C_k , non posso scindere in parti più piccole.

ESEMPIO : Nell'esempio precedente, posso solo dire quale intervallo si è *acceso*, ma non ho un livello di dettaglio maggiore.

Abbiamo quindi capito che dato un Ω qualsiasi con $\mathcal{C}$ sua partizione discreta, allora ci conviene prendere $\mathcal{A} = \sigma(\mathcal{C})$. Ma come assegno $\mathbb{P}$?

TEOREMA 3.5: Dato Ω qualsiasi e $\mathcal{C}$ una sua partizione discreta, allora:

1. Ogni $\mathbb{P}$ su $(\Omega, \sigma(\mathcal{C}))$ è univocamente determinata da

$$p_n = \mathbb{P}(C_n)$$

Infatti $\forall A \in \sigma(\mathcal{C}), \quad A \stackrel{(3.4)}{=} \bigcup_{j \in J} C_j, \quad J \subseteq I :$

$$\mathbb{P}(A) = \mathbb{P}\left(\bigcup_{j \in J} C_j\right) \stackrel{\sigma\text{-add}}{=} \sum_{j \in J} \mathbb{P}(C_j) = \sum_{j \in J} p_j$$

2. Data una successione $(p_n)_{n \geq 1}$ di numeri reali, allora:

$$\exists! \mathbb{P} : \sigma(\mathcal{C}) \rightarrow [0, 1] \quad t.c. \quad \mathbb{P}(C_n) = p_n \quad \Longleftrightarrow \quad \begin{cases} p_n \geq 0 \quad \forall n \in I \\ \sum_{n \in I} p_n = 1 \end{cases}$$


3.2 Probabilità Condizionata

La probabilità (che di per se è una misura di quanto un evento è lecito pensare che accada), è influenzata dalla quantità di informazioni che abbiamo a disposizione. La probabilità condizionata misura quanto un evento A diventa probabile una volta che sappiamo che un altro evento B è accaduto.

Non è più una probabilità "assoluta", ma una probabilità relativa ad un contesto (o ad un'informazione aggiuntiva che abbiamo).

Poniamoci nell'esperimento dove si lanciano 2 dadi, se volessimo calcolare la probabilità dell'evento $A = \text{"la somma dei dadi è 12"}$, allora potremmo calcolarla banalmente come $\mathbb{P}(A) = \frac{|A|}{|\Omega|} = 1/36$.

Se però consideriamo l'evento $E = \text{"Sul primo dado esce 6"}$, e volessi capire $\mathbb{P}(A)$ dato che l'evento E si è verificato, è come se E "diventasse" il nostro "nuovo" Ω .



Come è facile intuire dal disegno avremo che la probabilità condizionata risulta essere:

$$\mathbb{P}(A \text{ "dato che si è verificato" } E) = \frac{|A \cap E|}{|E|} = \frac{|\{6, 6\}|}{6} = \frac{1}{6}$$

Se inoltre aggiungessimo l'evento $F = \text{"Uno dei due dadi ha dato 6"}$, ci aspetteremmo per buon senso che $\mathbb{P}(A \text{ "dato" } E) > \mathbb{P}(A \text{ "dato" } F)$, siccome sapere che si è verificato l'evento E ci dà più informazioni rispetto all'evento F (banalmente conosco su quale dei due dadi è uscito 6).

Andiamo a formalizzare questi concetti in una solida teoria.

DEFINIZIONE 3.6: Dato $(\Omega, \mathcal{A}, \mathbb{P})$ spazio di probabilità e sia $E \subseteq \mathcal{A}$ un evento non trascurabile, i.e $\mathbb{P}(E) > 0$. Allora $\forall A \in \mathcal{A}$ la probabilità condizionata di A dato E è il numero $\mathbb{P}(A|E)$:

$$\mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)}$$

Dalla definizione vediamo immediatamente che è fondamentale che $\mathbb{P}(E) \neq 0$, altrimenti la scrittura non avrebbe senso matematico.

Andando a riprendere l'esempio fatto precedentemente, ora che abbiamo un concetto formale di probabilità condizionata, e non più solo intuitivo, possiamo andare a calcolare le probabilità e confermare se i ragionamenti fatti in precedenza erano validi.

$$\mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} = \frac{\mathbb{P}(\{6, 6\})}{\mathbb{P}(\{6, k\}; k \in \{1, \dots, 6\})} = \frac{\frac{|A \cap E|}{|\Omega|}}{\frac{|E|}{|\Omega|}} = \frac{|A \cap E|}{|E|} = \frac{1}{6}$$

Facendo lo stesso ragionamento con l'evento F :

$$\mathbb{P}(A|F) = \frac{\mathbb{P}(A \cap F)}{\mathbb{P}(F)} = \frac{|A \cap F|}{|F|} = \frac{1}{11} < \frac{1}{6}$$

dimostrando che l'intuizione che avevamo avuto sul fatto che $\mathbb{P}(A|E) > \mathbb{P}(A|F)$ era corretta.

Osserviamo anche che dato un evento generico $E \in \mathcal{A}$ non trascurabile, allora possiamo definire $\mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)}$. Questo ci porta a dei casi limite:

- Supponendo che $A \subseteq E$: $\mathbb{P}(A|E) = \frac{\mathbb{P}(A \cap E)}{\mathbb{P}(E)} = \mathbb{P}(A|E) = \frac{\mathbb{P}(E)}{\mathbb{P}(E)} = 1$
- Se A ed E sono incompatibili¹: $\mathbb{P}(A|E) = 0$.

¹Overo che $E \cap A = \emptyset$

PROPOSIZIONE 3.7: Sia $E \in \mathcal{A}$ un evento non trascurabile. Allora la mappa:

$$A \mapsto \mathbb{P}(A | E) := \mathbb{P}_E(A)$$

è una misura di probabilità su $\mathcal{A} \rightarrow [0, 1]$.


Questa proposizione ci permette di vedere la probabilità condizionata come una misura di probabilità, facendo così valere tutte le proprietà studiate sin ora.

ESEMPIO : Vale la proprietà $\mathbb{P}(A^c | E) = 1 - \mathbb{P}(A | E)$, che scrivendola con la notazione più compatta diventa: $\mathbb{P}_E(A^c) = 1 - \mathbb{P}_E(A)$

Arrivati a questo punto vorremmo *unire* i concetti di partizione e probabilità condizionata.

Vedremo infatti che si può partire da due partizioni di uno stesso spazio campionario Ω , per ottenerne una terza, più *fine*, che ne rappresenta tutte le possibili intersezioni. Inoltre, vorremo studiare come le probabilità associate a tali eventi intersezione possono essere calcolate a partire dalle probabilità condizionate.

Possiamo rappresentare la struttura delle probabilità condizionate tramite un albero, in cui dal nodo radice Ω si diramano i rami verso gli eventi A_n , e da ciascun A_n partono i sotto-rami verso gli eventi B_k .



Dove in rosso troviamo le probabilità degli eventi sottostanti, e per semplicità di notazione si è usato $q_{t|h} = \mathbb{P}(B_t | A_h)$.


Ponendo la questione in maniera formale:

Sia $(A_n : n \in I)$ una partizione discreta di Ω formata da eventi non trascurabili. Analogamente, sia $(B_k : k \in I)$ un'altra partizione discreta dello stesso spazio campionario Ω . Ciascuna partizione suddivide Ω in eventi disgiunti e la loro unione ricopre tutto lo spazio.

Dalle due partizioni possiamo ottenere una partizione *più fine*, data dalle loro intersezioni:

$$(A_n \cap B_k : n, k \in I),$$

che costituisce ancora una partizione discreta di Ω .



Supponiamo di conoscere le probabilità $p_n = \mathbb{P}(A_n)$, $q_{k|n} = \mathbb{P}(B_k | A_n)$.

La domanda naturale è: *come posso determinare la probabilità dell'intersezione $\mathbb{P}(A_n \cap B_k)$? Ha senso (ed è corretto) calcolarla come:*

$$\mathbb{P}(A_n \cap B_k) = \mathbb{P}(A_n) \cdot \mathbb{P}(B_k | A_n)?$$

dato che A_n sono tutti eventi non trascurabili, e di conseguenza vale la formula della probabilità condizionata?

TEOREMA 3.8: Siano $(A_n : n \in I)$ e $(B_n : n \in I)$ partizioni discrete di eventi non trascurabili di Ω . Siano:

$$(p_n : n \geq 1) : p_n \geq 0 \quad e \quad \sum_{n \in I} p_n = 1 \quad \forall n \geq 1$$

$$(q_{k|n} : k \geq 1) : q_{k|n} \geq 0 \quad e \quad \sum_{k \in I} q_{k|n} = 1 \quad \forall k \geq 1$$

$$\Rightarrow \exists! \mathbb{P} \text{ su } \mathcal{A} = \sigma((A_n \cap B_k) : n, k \in I) \quad \text{t.c.} \quad \mathbb{P}(A_n) = p_n \quad e \quad \mathbb{P}(B_k | A_n) = q_{k|n}$$

Dimostrazione. Solo per prova orale. □

Grazie a questo teorema possiamo costruirci un modello conoscendo le probabilità condizionate!! ☺

ESEMPIO : Si consideri un cesto contenente $n \geq 2$ palline nere e $b \geq 2$ palline bianche. Supponiamo di effettuare due estrazioni senza reimmissione. Consideriamo gli eventi:


$N_1 = \text{"Alla prima estrazione pesco una nera"}$

$N_1^c = \text{"Alla prima estrazione pesco una bianca"} = B_1$

$N_2 = \text{"Alla seconda estrazione pesco una nera"}$

$N_2^c = \text{"Alla seconda estrazione pesco una bianca"} = B_2$

Si avranno le seguenti probabilità condizionate:



Quindi si avrà che, per esempio:

$$\mathbb{P}(N_1 \cap B_2) = \frac{b}{n+b-1} \cdot \frac{n}{n+b}$$

Ma se invece volessimo conoscere $\mathbb{P}(N_2)$? Oppure $\mathbb{P}(N_1 | N_2)$?

Per rispondere alla domanda nell'esempio, introduciamo le seguenti formule.

TEOREMA 3.9: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e consideriamo una partizione discreta $(E_n)_{n \in I} \subseteq \mathcal{A}$ di Ω , dove $I \in \mathbb{N}$. Allora valgono le seguenti:


$$1. \forall A \in \mathcal{A} : \boxed{\mathbb{P}(A) = \sum_{n \in I} \mathbb{P}(A \cap E_n)} \quad (\text{Formula di disintegrazione})$$

2. Se inoltre $\mathbb{P}(E_n) > 0 \forall n \in I$, allora:

$$\boxed{\mathbb{P}(A) = \sum_{n \in I} \mathbb{P}(A | E_n) \cdot \mathbb{P}(E_n)} \quad (\text{Formula delle probabilità totali})$$

Dimostrazione. Siccome E_n è una partizione di Ω , posso vedere A come

$$\begin{aligned} A &= A \cap \Omega = A \cap \left(\bigcup_{n \in I} E_n \right) \\ &= \bigcup_{n \in I} (A \cap E_n) \end{aligned}$$



1. Per σ -additività si ha che (o anche finita additività):

$$\mathbb{P}(A) = \mathbb{P} \left(\bigcup_{n \in I} (A \cap E_n) \right) = \sum_{n \in I} \mathbb{P}(A \cap E_n) \quad (3.1)$$

2. Osservo che se $\mathbb{P}(E_n) > 0 \forall n \in I$, allora:

$$\mathbb{P}(A \cap E_n) = \mathbb{P}(E_n) \cdot \mathbb{P}(A | E_n) \quad \forall n \in I$$

Sostituendo banalmente questa equazione nella (3.1), otteniamo la formula delle probabilità totali. $\square$

Si può intuire che la formula delle probabilità totali, la si usa quando si ha incertezza "sulla prima estrazione", ed è come se pesassi con i pesi $\mathbb{P}(E_n)$.

ESEMPIO: Continuiamo l'esempio precedente.

Ci siamo interrogati su come potessimo calcolare $\mathbb{P}(N_2)$ e $\mathbb{P}(N_1 | N_2)$, ed ora abbiamo la soluzione: con le probabilità totali.

Possiamo vedere la nostra partizione $(E_n : n \in I)$ con $I = \{1, 2\}$ tale che:

$$\begin{cases} E_1 = N_1 \\ E_2 = N_1^c = B_1 \end{cases}$$

Allora i calcoli diventano facili:

$$\begin{aligned} \mathbb{P}(N_2) &= \mathbb{P}(N_2 | N_1) \cdot \mathbb{P}(N_1) + \mathbb{P}(N_2 | B_1) \cdot \mathbb{P}(B_1) \\ &= \frac{n-1}{n+b-1} \cdot \frac{n}{n+b} + \frac{n}{n+b-1} \cdot \frac{b}{n+b} \\ &= \frac{n \cdot (n+b-1)}{(n+b)(n+b-1)} \end{aligned}$$

$$= \frac{n}{n+b}$$

$$\begin{aligned}\mathbb{P}(N_1 | N_2) &= \frac{\mathbb{P}(N_1 \cap N_2)}{\mathbb{P}(N_2)} = \frac{\mathbb{P}(N_1 | N_2) \cdot \mathbb{P}(N_1)}{\mathbb{P}(N_2)} = \frac{\frac{n-1}{b+n-1} \cdot \frac{n}{b+n}}{\frac{n}{n+b}} \\ &= \frac{n-1}{b+n-1}\end{aligned}$$

Senza saperlo, in quest'ultimo calcolo, ci siamo ricavati una formula fondamentale nel calcolo delle probabilità, ovvero la formula di Bayes.

TEOREMA 3.10: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e sia $(E_n)_{n \in I}$ una partizione discreta di Ω tale che tutti i E_n siano non trascurabili.

Allora, $\forall A \in \mathcal{A}$ dove $\mathbb{P}(A) > 0$:

$$\mathbb{P}(E_h | A) = \frac{\mathbb{P}(A | E_h) \cdot \mathbb{P}(E_h)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A | E_h) \cdot \mathbb{P}(E_h)}{\sum_{n \in I} \mathbb{P}(A | E_n) \cdot \mathbb{P}(E_n)}$$

Dimostrazione. Definizione di $\mathbb{P}(E_h | A)$ " + " formula delle probabilità totali. Sostanzialmente già svolta nel teorema. $\square$

TEOREMA 3.11: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e siano

$$A_1, \dots, A_n \in \mathcal{A} : \quad \mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_{n-1}) > 0$$

Allora si avrà che:

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdot \mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1})$$

Questa è detta *Formula di Moltiplicazione*.

Dimostrazione. È evidente che:

$$A_1 \cap \dots \cap A_{n-1} \subseteq A_1 \cap \dots \cap A_{n-2} \subseteq \dots \subseteq A_1 \cap A_2 \subseteq A_1$$

Allora per monotonia della probabilità: $\mathbb{P}(A_1 \cap \dots \cap A_k) > 0 \quad \forall k \in [2, n-1]$.

Di conseguenza avremo che, per la definizione di probabilità condizionata:

$$\begin{aligned}&\mathbb{P}(A_1) \cdot \mathbb{P}(A_2 | A_1) \cdot \mathbb{P}(A_3 | A_1 \cap A_2) \cdots \mathbb{P}(A_n | A_1 \cap \dots \cap A_{n-1}) = \\ &= \cancel{\mathbb{P}(A_1)} \frac{\mathbb{P}(A_1 \cap A_2)}{\cancel{\mathbb{P}(A_1)}} \cdot \frac{\mathbb{P}(A_1 \cap A_2 \cap A_3)}{\cancel{\mathbb{P}(A_1 \cap A_2)}} \cdots \frac{\mathbb{P}(A_1 \cap \dots \cap A_n)}{\cancel{\mathbb{P}(A_1 \cap \dots \cap A_{n-1})}}\end{aligned}$$

$\square$

Dalla dimostrazione risulta evidente come mai nelle ipotesi del teorema chiediamo che $\mathcal{A} : \quad \mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_{n-1}) > 0$.

3.2.1 Indipendenza Stocastica

In questo sottocapito andremo a studiare una delle "qualità" più utili (e che ci semplifica la vita) che possono avere due eventi: l'indipendenza stocastica.

DEFINIZIONE 3.12: Dato $(\Omega, \mathcal{A}, \mathbb{P})$, due eventi $A, B \in \mathcal{A}$ si dicono stocasticamente indipendenti (o indipendenti) se:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

A livello di notazione si indica con $A \perp\!\!\!\perp B$.

Come si può intuire, il concetto di indipendenza e di probabilità condizionata sono fortemente collegati, difatti se ipotizziamo che $\mathbb{P}(A), \mathbb{P}(B) > 0$, e che $A \perp\!\!\!\perp B$, allora:

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(A)\mathbb{P}(B)}{\mathbb{P}(B)} = \mathbb{P}(A)$$

In parole povere: se $A \perp\!\!\!\perp B$, B non andrà ad influenzare in alcun modo A (e viceversa).

ESEMPIO : Ritornando all'esempio dell'estrazione senza reimmissione: N_1 e N_2 non sono indipendenti, in quanto:

$$\mathbb{P}(N_2 | N_1) = \frac{n-1}{n+b-1} \neq \mathbb{P}(N_2) = \frac{n}{n+b}$$

Se invece fossimo nel caso in cui estraiamo con reimmissione, allora avremmo che $N_1 \perp\!\!\!\perp N_2$ in quanto:

$$\mathbb{P}(N_1 \cap N_2) = \mathbb{P}(N_2 | N_1) \cdot \mathbb{P}(N_1) = \frac{n}{n+b} = \mathbb{P}(N_1) \cdot \mathbb{P}(N_2)$$

A questo punto possiamo fare alcune osservazioni importanti.

★ Possiamo avere la presenza di due casi limite, con $\mathbb{P}(A)$ degenerare e $\forall B$ (ovviamente potremmo scambiare A con B):

1. Se $\mathbb{P}(A) = 0 \Rightarrow \mathbb{P}(A \cap B) \leq \mathbb{P}(A) = 0 \Rightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$
A livello modellistico questo ci dice che, qualunque sia B , questo è indipendente da un evento che ha probabilità 0 di verificarsi.
2. Se $\mathbb{P}(A) = 1$, allora possiamo scrivere $B = (A \cap B) \cup (A^c \cap B)$ e di conseguenza:

$$\mathbb{P}(B) = \mathbb{P}(A \cap B) + \underbrace{\mathbb{P}(A^c \cap B)}_{=0, \text{ dato che } \mathbb{P}(A^c)=0}$$

$$\Rightarrow \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(B) = \mathbb{P}(A \cap B)$$

Anche in questo caso, se la probabilità di un evento A è 1, qualsiasi altro evento consideriamo sarà indipendente A .

★ Se ipotizziamo che $A \cap B = \emptyset$, e che $\mathbb{P}(A), \mathbb{P}(B) > 0$, allora A e B **non** saranno mai indipendenti. Questo perchè:

$$\mathbb{P}(A \cap B) = 0 \neq \mathbb{P}(A)\mathbb{P}(B) > 0$$

Questo fatto ci pone davanti ad una realtà che può sembrare ingannevole: il fatto che due eventi siano indipendenti non ha niente a che fare col fatto che quest'ultimi siano disgiunti. La disgiunzione è una **forte** nozione di correlazione (se accade uno, non può accadere l'altro).

★ Se $A \perp\!\!\!\perp B \Rightarrow A \perp\!\!\!\perp B^c, A^c \perp\!\!\!\perp B, A^c \perp\!\!\!\perp B^c$

Possiamo esprimere questo concetto passando dalle σ -algebre generate dai due eventi:

$$A \perp\!\!\!\perp B \iff \sigma(A) \perp\!\!\!\perp \sigma(B)$$

Ossia che:

DEFINIZIONE 3.13: $\mathcal{F}, \mathcal{G}$ due σ -algebre su Ω sono indipendenti se:

$$\forall F \in \mathcal{F} \text{ e } \forall G \in \mathcal{G} : G \perp\!\!\!\perp F$$

Per convincerci di questo fatto, dimostriamo per esempio che se $A \perp\!\!\!\perp B \Rightarrow A \perp\!\!\!\perp B^c$:

Scrivendo $A = (A \cap B) \cup (A \cap B^c)$, allora $\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c)$. Di conseguenza avremo che:

$$\begin{aligned} \mathbb{P}(A \cap B^c) &= \mathbb{P}(A) - \mathbb{P}(A \cap B) = \mathbb{P}(A) - \mathbb{P}(A) \cdot \mathbb{P}(B) \\ &= \mathbb{P}(A)[1 - \mathbb{P}(B)] \\ &= \mathbb{P}(A)\mathbb{P}(B^c) \end{aligned}$$

Questa "dimostrazione" si può effettuare similmente per tutte le altre casistiche.

DEFINIZIONE 3.14: Sia I un insieme di indici, $(A_i)_{i \in I} \subseteq \mathcal{A}$ è una famiglia di eventi (mutualmente) indipendenti se:

$$\forall J \subseteq I \text{ t.c. } 2 \leq |J| < +\infty, \text{ vale che: } \mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j)$$

▲ I può essere qualsiasi, la condizione deve essere verificata $\forall J \subseteq I$ finito.

ESEMPIO : Sia $\{A_1, A_2, A_3\} \subseteq \mathcal{A}$. Di conseguenza $I = \{1, 2, 3\}$. Dobbiamo verificare la condizione $\forall J : 2 \leq |J| < +\infty$.

Ossia per:

- $\{1, 2\} \longrightarrow \mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2)$
- $\{1, 3\} \longrightarrow \mathbb{P}(A_1 \cap A_3) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_3)$
- $\{2, 3\} \longrightarrow \mathbb{P}(A_2 \cap A_3) = \mathbb{P}(A_2) \cdot \mathbb{P}(A_3)$
- $\{1, 2, 3\} \longrightarrow \mathbb{P}(A_1 \cap A_2 \cap A_3) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2) \cdot \mathbb{P}(A_3)$

Vediamo quindi benissimo dall'esempio che la condizione di indipendenza di una famiglia di eventi, risulta essere molto complicata da verificare, in quanto le condizioni che devono essere verificate crescono esponenzialmente con la cardinalità n di I ; in particolare $\#_{\text{condizioni da verificare}} = 2^n - n - 1$.

Si osservi inoltre che se $A_1, \dots, A_n$ è una famiglia di eventi indipendenti, allora:

$$\forall k : 1, \dots, n \quad \sigma(A_k) \perp\!\!\!\perp \sigma(A_{\hat{k}}) \quad \text{dove } A_{\hat{k}} = \{A_1, \dots, A_{k-1}, A_{k+1}, \dots, A_n\}$$

3.2.2 Indipendenza Condizionata

Per concludere il capitolo, possiamo "mettere assieme" i concetti di indipendenza stocastica e probabilità condizionata. Questo non ci deve sorprendere, perché come abbiamo visto con la proposizione (3.7), possiamo trattare la probabilità condizionata $\mathbb{P}_E$ come una probabilità.

DEFINIZIONE 3.15: Siano $A, B, E \in \mathcal{A}$; $\mathbb{P}(E) > 0$. Si dice che A e B sono indipendenti condizionatamente dato E , se A e B sono indipendenti rispetto alla probabilità $\mathbb{P}_E$, ovvero:

$$\mathbb{P}_E(A \cap B) = \mathbb{P}_E(A) \cdot \mathbb{P}_E(B)$$

Questo è un concetto non banale da intuire, per questo si presti attenzione al seguente esempio.

ESEMPIO ▲: Vi siano un'urna A (contenente 2 palline nere e 1 bianca) e una B (contenente 2 palline bianche e 1 nera), e si lanci una moneta:

- Se esce Testa $\Rightarrow$ si estrae dall'urna A due volte con reimmissione.
- Se esce Croce $\Rightarrow$ si estrae dall'urna B due volte con reimmissione.

Siano quindi i seguenti eventi:

- A = "Esce Testa" = "Estraggo da A "
- B = "Esce Croce" = "Estraggo da B "
- B_1 = "Alla prima pesca Bianca"
- B_2 = "Alla seconda pesca Bianca"

Allora se per ipotesi fissassimo l'urna, scopriremmo che gli eventi B_1 e B_2 sono indipendenti, infatti:

$$\begin{aligned}\mathbb{P}(B_1 \cap B_2 \mid A) &= \mathbb{P}(B_1 \mid A) \cdot \mathbb{P}(B_2 \mid A) = \frac{1}{3} \cdot \frac{1}{3} \\ \mathbb{P}(B_1 \cap B_2 \mid B) &= \frac{2}{3} \cdot \frac{2}{3}\end{aligned}$$

Tuttavia, se non fissiamo più un'urna e volessimo calcolare la probabilità dell'intersezione, avremmo che:

$$\begin{aligned}\frac{5}{18} &= \mathbb{P}(B_1 \cap B_2) = \mathbb{P}(B_1 \cap B_2 \mid A)\mathbb{P}(A) + \mathbb{P}(B_1 \cap B_2 \mid B)\mathbb{P}(B) \\ &\neq \mathbb{P}(B_1)\mathbb{P}(B_2) = \frac{1}{4}\end{aligned}$$

Anche intuitivamente ci accorgiamo che i due eventi non sono indipendenti (condizionatamente), perché per esempio sapere che è uscita una pallina bianca, ci dà più informazioni sul fatto che è più probabile che sia uscita un'urna piuttosto che un'altra.

Da questo esempio ci accorgiamo come l'indipendenza sia una **proprietà relativa alla probabilità**: due eventi possono risultare indipendenti o meno a seconda della misura di probabilità che è scelta (i.e. $\mathbb{P}$ o $\mathbb{P}_E$).

3.3 Caso con $\Omega = \mathbb{R} \circ \mathbb{R}^+ \circ [a, b]$

Nel capitolo 2.4 abbiamo analizzato come assegnare una probabilità quando lo spazio campionario Ω è discreto, finito o al più numerabile. In tali casi, la costruzione della misura di probabilità risulta piuttosto

semplice: è infatti sufficiente assegnare una probabilità ad ogni evento elementare e sfruttare la proprietà di σ -additività per estendere la misura a tutta la σ -algebra generata.

Abbiamo poi visto, nella Sezione 3.1, che anche quando Ω è un insieme qualsiasi è possibile restringere l'attenzione ad una classe di eventi $\mathcal{C}$ che costituisce una partizione discreta di Ω . Utilizzando la σ -algebra generata da $\mathcal{C}$, si può così definire una misura di probabilità esattamente come nel caso discreto: in sostanza, è come se ci si riportasse a uno scenario in cui lo spazio campionario è numerabile.

Come è naturale aspettarsi, il caso in cui $\Omega = \mathbb{R}, \mathbb{R}^+$ o un intervallo $[a, b]$ riveste un ruolo di particolare interesse pratico. Tuttavia, la situazione cambia radicalmente: non è infatti possibile considerare come eventi tutti i sottoinsiemi di Ω , poiché l'insieme delle parti $\mathcal{P}(\mathbb{R})$ è “troppo grande”. Esistono sottoinsiemi di $\mathbb{R}$, come l'insieme di Vitali², per i quali non è possibile definire una misura coerente con gli assiomi della teoria della misura.

Per risolvere questo problema, (anche in questo caso) restringeremo l'attenzione ad una particolare famiglia di insiemi “ben comportati”, detta σ -algebra di Borel, indicata con $\mathcal{B}(\mathbb{R})$. Su questa collezione riusciremo a definire in modo rigoroso una misura di probabilità coerente (come la misura di Lebesgue), che ci permetterà di studiare le variabili aleatorie continue e la probabilità su spazi infiniti.

DEFINIZIONE 3.16: Dato $\Omega = \mathbb{R}$, si chiama $\mathcal{B}(\mathbb{R}) := \mathcal{B}$ la σ -algebra di Borel, definita come segue:

$$\mathcal{B}(\mathbb{R}) = \sigma(\mathcal{C}) \quad \text{dove} \quad \mathcal{C} = \left\{ (-\infty, x]; x \in \mathbb{R} \right\}$$

Notiamo che $\mathcal{B}(\mathbb{R})$ è “molto grossa”, difatti non è numerabile. Tutti gli insiemi che non appartengono a $\mathcal{B}(\mathbb{R})$ sono insiemi patologici, dei quali non faremo una trattazione.

Inoltre è importante notare che punti, intervalli, semirette, ..., appartengono a $\mathcal{B}(\mathbb{R})$, difatti:

- $(x, +\infty) = ((-\infty, x])^c \in \mathcal{B}(\mathbb{R})$
- $y < x, \quad (y, x] = (-\infty, x] \setminus (-\infty, y] \in \mathcal{B}(\mathbb{R})$
- $\{x\} = \bigcap_n (x - \frac{1}{n}, x + \frac{1}{n}) \in \mathcal{B}(\mathbb{R})$
- $[x, +\infty) = \bigcap_n (x - \frac{1}{n}, +\infty) \in \mathcal{B}(\mathbb{R})$

TEOREMA 3.17: Si può generare $\mathcal{B}(\mathbb{R})$ da tutti gli spazi topologici, non solo da $\mathbb{R}$.

Per esempio dalla classe degli intervalli aperti $\bar{\mathcal{C}}$:

$$\mathcal{B}(\mathbb{R}) = \sigma(\bar{\mathcal{C}}) \quad \text{dove} \quad \bar{\mathcal{C}} = \left\{ (a, b) \mid -\infty < a < b < +\infty \right\}$$

Oppure da altre partizioni non numerabili:

$$\mathcal{B}(\mathbb{R}) = \sigma(\tilde{\mathcal{C}}) \quad \text{dove} \quad \tilde{\mathcal{C}} = \left\{ (-\infty, q) \mid q \in \mathbb{Q} \right\}$$

²Un insieme di Vitali è un sottoinsieme di $[0, 1]$ costruito scegliendo un rappresentante per ciascuna classe di equivalenza del rapporto $x \sim y \iff x - y \in \mathbb{Q}$. Tale insieme non è misurabile secondo Lebesgue: non è possibile assegnargli una misura coerente.

DEFINIZIONE 3.18: Sia $\Omega = \mathbb{R}^n$, allora posso definire:

$$\mathcal{B}(\mathbb{R}^n) = \sigma(\mathcal{C}_n) \quad \text{dove} \quad \mathcal{C}_n = \left\{ B(x, r) \mid \{y, x \in \mathbb{R}^n, r > 0 : |y - x| \leq r\} \right\}$$

Abbiamo quindi afferrato che il nostro spazio di probabilità sarà costruito sui Boreliani: $(\Omega, \mathcal{B}(\mathbb{R}), \mathbb{P})$.

Ma come posso assegnare $\mathbb{P}$ sui Boreliani per modelli continui?

L'idea, anche in questo caso, è di caratterizzare $\mathbb{P}$ su una classe Π e poi estenderla su tutta $\sigma(\Pi) = \mathcal{B}(\mathbb{R})$; ma come garantiamo che questa estensione sia possibile e sia unica?

TEOREMA 3.19 Criterio di unicità di Caratheodory : Siano $\mathbb{P}$ e $\mathbb{Q}$ due misure su $(\Omega, \mathcal{A})$ e sia $\Pi \subseteq \mathcal{A}$ una classe di sottoinsiemi di Ω tale che:

1. $\sigma(\Pi) = \mathcal{A}$
2. Π chiusa rispetto all'intersezione finita

Allora vale che

$$\text{Se } \mathbb{P}(A) = \mathbb{Q}(A) \quad \forall A \in \Pi \quad \Rightarrow \quad \mathbb{P}(A) = \mathbb{Q}(A) \quad \forall A \in \sigma(\Pi)$$

In questo caso Π si definisce Π -sistema.

Grazie al criterio di unicità di Caratheodory possiamo definire una probabilità su un Π -sistema, ed essere certi che la sua estensione alla corrispondente σ -algebra è unica. Si noti che una σ -algebra è un Π -sistema, ma il viceversa non è vero.

ESEMPIO $\blacktriangle$: A questo punto ci vogliamo chiedere se $\mathcal{C} = \left\{ (-\infty, x]; x \in \mathbb{R} \right\}$ sia un Π -sistema per i Boreliani $\mathcal{B}(\mathbb{R}) = \sigma\left(\left\{ (-\infty, x]; x \in \mathbb{R} \right\}\right)$. Verifichiamo quindi che $\mathcal{C}$ sia chiusa per intersezione finita.

$$(-\infty, x_1] \cap (-\infty, x_2] \cap \cdots \cap (-\infty, x_n] = (-\infty, \min\{x_1, \dots, x_n\}] \in \mathcal{C}$$

In quanto ottengo ancora una semiretta.

Abbiamo quindi dimostrato che $\mathcal{C} = \left\{ (-\infty, x]; x \in \mathbb{R} \right\}$ è un Π -sistema per i Boreliani.

Grazie a questo esempio abbiamo trovato un Π -sistema che genera $\mathcal{B}(\mathbb{R})$, sul quale è possibile definire una $\mathbb{P}$.

3.3.1 Funzione di Ripartizione

DEFINIZIONE 3.20: Data $\mathbb{P} : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1]$ misura di Probabilità, si identifica la *Funzione di Ripartizione* la funzione F tale che:

$$F : \mathbb{R} \rightarrow [0, 1]$$

Definita come segue:

$$F(x) := \mathbb{P}((-\infty, x]) \quad \forall x \in \mathbb{R}$$

In un certo senso è come se stessimo sostituendo la probabilità dell'atomo (nel caso discreto), con quella della semiretta (nel caso continuo).

TEOREMA 3.21: Valgono che:

1. $F : \mathbb{R} \rightarrow \mathbb{R}$ è una funzione di ripartizione di una probabilità $\mathbb{P} : \mathcal{B}(\mathbb{R}) \rightarrow [0, 1]$ se e solo se:

- (a) F è non decrescente
- (b) F è continua da destra
- (c) Valgono i limiti:

$$\lim_{x \rightarrow +\infty} F(x) = 1 \quad \text{e} \quad \lim_{x \rightarrow -\infty} F(x) = 0$$

2. $\forall x < y \in \mathbb{R}$:

- $\mathbb{P}((x, y]) = F(y) - F(x)$
- $\mathbb{P}([x, y]) = F(y) - \lim_{z \rightarrow x^-} F(z) = F(y) - F(x^-)$
- $\mathbb{P}([x, y)) = F(y^-) - F(x^-)$
- $\mathbb{P}((x, y)) = F(y^-) - F(x)$
- $\mathbb{P}(\{x\}) = F(x) - F(x^-)$

(Se è continua = 0, altrimenti vi è un salto)

3. F caratterizza $\mathbb{P}$ completamente:

$$F_1(x) = F_2(x) \quad \forall x \in \mathbb{R} \quad \Longleftrightarrow \quad \mathbb{P}_1(A) = \mathbb{P}_2(A) \quad \forall A \in \mathcal{B}(\mathbb{R})$$

O in notazione più compatta:

$$F_1 = F_2 \quad \Longleftrightarrow \quad \mathbb{P}_1 = \mathbb{P}_2$$

Dimostrazione. Dimosteremo il teorema solo parzialmente.

(1.a) $(\Rightarrow)$ Se $x < y \Rightarrow (-\infty, x] \subseteq (-\infty, y]$, allora: $F(x) = \mathbb{P}((-\infty, x]) \leq \mathbb{P}((-\infty, y]) = F(y)$.

(1.b) Se ho $x_n \downarrow x$, allora devo dimostrare che $F(x_n) \xrightarrow{n \rightarrow +\infty} F(x)$. Dove $F(x_n) = \mathbb{P}((-\infty, x_n])$.

Il fatto che $x_n \downarrow x$ assicura che

$$(-\infty, x_n) \downarrow \bigcap_n (-\infty, x_n] = (-\infty, x]$$

Per continuità della probabilità si ha che:

$$\begin{aligned} \lim_{n \rightarrow +\infty} F(x_n) &= \lim_{n \rightarrow +\infty} \mathbb{P}((-\infty, x_n]) = \lim_{n \rightarrow +\infty} \bigcap_n \mathbb{P}((-\infty, x_n]) \\ &= \mathbb{P}((-\infty, x]) = F(x) \end{aligned}$$

(1.c) Per il primo limite: $x_n \uparrow +\infty \Rightarrow (-\infty, x_n] \uparrow \mathbb{R}$.

$$\begin{aligned} \Rightarrow \quad 1 &= \mathbb{P}(\mathbb{R}) = \mathbb{P}\left(\bigcup_n (-\infty, x_n]\right) = \lim_{n \rightarrow +\infty} \mathbb{P}((-\infty, x_n]) \\ &= \lim_{n \rightarrow +\infty} F(x_n) \end{aligned}$$

Per il secondo limite: $x_n \downarrow -\infty \Rightarrow (-\infty, x_n] \downarrow \emptyset$.

$$\Rightarrow \quad 0 = \mathbb{P}(\emptyset) = \mathbb{P}\left(\bigcap_n (-\infty, x_n]\right) = \lim_{n \rightarrow +\infty} \mathbb{P}((-\infty, x_n])$$

$$= \lim_{n \rightarrow +\infty} F(x_n)$$

(2) Dimostriamone alcuni:

$$\bullet (x, y] = (-\infty, y] \setminus (-\infty, x]$$

$$\Rightarrow \mathbb{P}((x, y]) = \mathbb{P}((-\infty, y]) - \mathbb{P}((-\infty, x]) = F(y) - F(x)$$

$$\bullet (x, y) = \bigcup_n (x, y - \frac{1}{n})$$

$$\begin{aligned} \Rightarrow \mathbb{P}((x, y)) &= \mathbb{P}\left(\bigcup_n \left(x, y - \frac{1}{n}\right)\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left(x, y - \frac{1}{n}\right) \\ &\stackrel{\text{Punto prec.}}{=} \lim_{n \rightarrow \infty} \left(F\left(y - \frac{1}{n}\right) - F(x)\right) \\ &= F(y^-) - F(x) \end{aligned}$$

$$\bullet \{y\} = (x, y] \setminus (x, y)$$

$$\begin{aligned} \Rightarrow \mathbb{P}(\{y\}) &= \mathbb{P}((x, y] \setminus (x, y)) = F(y) - F(x) - F(y^-) + F(x) \\ &= F(y) - F(y^-) \end{aligned}$$

Dove possiamo essere sicuri che sia positiva, in quanto $F(y^-) \leq F(y)$ è sempre vera.

(3) F determina $\mathbb{P}$ perchè la classe delle semirette $\left\{ (-\infty, x] \mid x \in \mathbb{R} \right\}$ è un Π -sistema e vale il criterio di Caratheodory. $\square$

Pur essendo nel caso in cui $\Omega = \mathbb{R}$, possiamo riconoscere quando una probabilità è discreta; questo ci permetterà di semplificarci di molto la vita nel calcolo delle probabilità, e della funzione di ripartizione.

TEOREMA 3.22: $\mathbb{P}$ su $\mathcal{B}(\mathbb{R})$ è una misura di probabilità discreta se:

1. $\exists T \subseteq \mathbb{R}$ discreto

2. $\exists p : T \rightarrow \mathbb{R}$, definita densità discreta, tale che:
$$\begin{cases} p(x) \geq 0 & \forall x \in T \\ \sum_{x \in T} p(x) = 1 \end{cases}$$

Allora, data $\mathbb{P}$ discreta, si avrà che:

$$\mathbb{P}(A) = \sum_{x \in A \cap T} p(x) \quad \forall A \in \mathcal{B}(\mathbb{R})$$

e di conseguenza il calcolo della funzione di ripartizione si riduce a:

$$F(t) = \mathbb{P}((-\infty, t]) = \sum_{x \in (-\infty, t] \cap T} p(x) = \sum_{x \in T: x \leq t} p(x)$$

Introduciamo il supporto $S = \left\{ x \in T : p(x) > 0 \right\} \subseteq T \subseteq \mathbb{R}$ discreto.

La funzione di ripartizione rappresenta uno strumento utile per individuare la tipologia della distribuzione di probabilità, consentendo di stabilire se essa sia discreta, continua o né l'una né l'altra (mista).

PROPOSIZIONE 3.23: $\mathbb{P} : \mathcal{B}(\mathbb{R}) \rightarrow [0, T]$ è una probabilità discreta con supporto S e densità discreta p , se e solo se la Funzione di ripartizione F è tale che:


$$\sum_{x \in S} [F(x) - F(x^-)] = 1$$

Dove:

- $S = \left\{ \text{Punti di discontinuità di } F \right\} = \left\{ x : F(x) \neq F(x^-) \right\}$
- $p(x) = F(x) - F(x^-)$

Facciamo alcuni esempi per capire meglio come funzionano le funzioni di ripartizione:

★ Sia $\mathbb{P} = \mathbb{P}_{\text{UNIFORME}}$ su $S = \{1, \dots, 6\} \Rightarrow p(x) = \frac{1}{6} \quad \forall x \in S$



Grazie alla Proposizione 3.23, notiamo che $\mathbb{P}_{\text{UNIFORME}}$ risulta essere una probabilità discreta.


★ Sia $\alpha_0 \in \mathbb{R}$ e $\mathbb{P} = \delta_{\alpha_0}$, allora avremo che:

$$\mathbb{P}(A) = \begin{cases} 1 & \text{se } \alpha_0 \in A \\ 0 & \text{se } \alpha_0 \notin A \end{cases} \quad \forall A \in \mathcal{B}(\mathbb{R})$$

Di conseguenza la funzione di ripartizione sarà:


$$F(x) = \begin{cases} \mathbb{P}((-\infty, x]) = 0 & \text{se } x < \alpha_0 \\ \mathbb{P}((-\infty, x]) = 1 & \text{se } x \geq \alpha_0 \end{cases}$$

In quanto se $x < \alpha_0$ allora l'intervallo $(-\infty, x]$ non conterrà α_0 , e di conseguenza avrà probabilità 0. Il grafico della funzione di ripartizione risulterà quindi essere:



Anche in questo caso notiamo che, grazie alla Proposizione 3.23, δ_{α_0} risulta essere una probabilità discreta.

★ Sia $F(x) = (1 - e^{-\lambda x}) \cdot \mathbb{I}_{[0, +\infty)}$ con $\lambda > 0$. Questa è una funzione di ripartizione?
Il grafico di F risulta essere:




Grazie al Teorema 3.21, vediamo che F rispetta tutti i punti (1.a), (1.b) e (1.c), di conseguenza F è una funzione di ripartizione. Si noti che $\mathbb{P}(\{t\}) = F(t) - F(t^-) = 0 \quad \forall t \in \mathbb{R}$ in quanto è una funzione continua, non possiamo quindi dire che sia caratterizzata da una probabilità discreta.

Guardandola da un punto di vista modellistico, si potrebbe notare che F è “perfetta” per rappresentare il tempo di durata di una lampadina (per esempio).


★ Sia $\alpha_0 \in (0, 1)$ e $F(t) = \begin{cases} 1 - e^{-\lambda t}, & t \geq 1/2 \\ 0, & t < 1/2 \end{cases}$.

In questo caso $\alpha_0 = 1 - e^{-\lambda \frac{1}{2}}$.



F risulta essere una funzione di ripartizione, ma non è né continua né discreta: ha delle caratteristiche di entrambe, ma allo stesso tempo “perde” delle caratteristiche di entrambe.

★ Si consideri $F(t) = \frac{t-a}{b-a} \mathbb{I}_{[a, b]}(t) + \mathbb{I}_{[b, +\infty)} \quad \forall t \in \mathbb{R}; a < b \in \mathbb{R}$ fissati.



$$a = 0.8; b = 2.8$$


Si dimostra che F è una funzione di ripartizione grazie al Teorema 3.21. Anche in questo caso la condizione per identificare la probabilità caratterizzata da F come discreta non è valida.

4 Funzioni: Creiamo un Linguaggio Comune

In questo breve capitolo faremo un ripasso sulle funzioni, il quale ci permetterà di fissare un linguaggio comune per non fare confusione. Questo sarà fondamentale per dare la definizione di Variabile Aleatoria.

Consideriamo Ω come dominio, ed $\mathcal{F}$ il codominio. Allora possiamo definire una funzione X :

$$\begin{aligned} X : \Omega &\longrightarrow \mathcal{F} \\ w \in \Omega &\longmapsto X(w) = x \in \mathcal{F} \end{aligned}$$



Avremo quindi che l'*immagine di A* è definita come:

$$X(A) = \{ x \in \mathcal{F} \mid \exists \omega \in A : x = X(\omega) \} \subseteq \mathcal{F}$$

e la *controimmagine* come:

$$X^{-1}(B) = \{ w \in \Omega \mid X(w) \in B \} \subseteq \Omega$$


Possiamo anche considerare la classe di tutte le possibili immagini e controimmagini:

$$\begin{aligned} \{ X(A) \mid A \subseteq \Omega \} &\subseteq \mathcal{P}(\mathcal{F}) \\ \{ X^{-1}(B) \mid B \subseteq \mathcal{F} \} &\subseteq \mathcal{P}(\Omega) \end{aligned}$$

Già a questo punto ci accorgiamo di una caratteristica importante: $X(\Omega) \subseteq \mathcal{F}$, ma $X^{-1}(\mathcal{F}) = \Omega$. Capiamo quindi che avremo delle proprietà “migliori” lavorando con la controimmagine, in quanto la controimmagine del codominio restituisce tutto lo spazio Ω .

ESEMPIO: Partiamo da un esempio banale, ma che ci permette di iniziare a metabolizzare un linguaggio che può sembrare poco intuitivo.

Sia $\Omega = \mathbb{R} = \mathcal{F}$, e consideriamo $X : \mathbb{R} \rightarrow \mathbb{R}$, tale che $X(w) = w^2$



Possiamo notare alcune cose:

1. $X(\Omega) = X(\mathbb{R}) = \mathbb{R}^+ \neq \mathbb{R}$
2. $A \subseteq \Omega, A = (0, 1) \Rightarrow X((0, 1)) = (0, 1)$
 $B \subseteq \mathcal{F}, B = (0, 1) \Rightarrow X^{-1}((0, 1)) = (-1, 0) \cup (0, 1)$
3. $A^c = (0, 1)^c = (-\infty, 0] \cup [1, +\infty)$
 $\Rightarrow X(A^c) = [0, +\infty)$, tuttavia $(X(A))^c \Rightarrow X(A^c) \neq (X(A))^c$
4. $B = (0, 1) \subseteq \mathcal{F} \Rightarrow B^c = (-\infty, 0] \cup [1, +\infty)$
 Allora avremo che:

- $X^{-1}(B^c) = (-\infty, -1] \cup \{0\} \cup [1, +\infty)$
- $(X^{-1}(B))^c = (-\infty, -1] \cup \{0\} \cup [1, +\infty)$

$\Rightarrow X^{-1}(B^c) = (X^{-1}(B))^c$, ossia che le operazioni commutano!

5. $C = (-1, 0) \subseteq \mathcal{F}; B \cap C = (0, 1) \cap (-1, 0) = \emptyset$, dove:

- $X^{-1}(B \cap C) = \emptyset$
- $X^{-1}(C) = \emptyset$
- $X^{-1}(B) \cap X^{-1}(C) = \emptyset$

Anche per l'intersezione notiamo che la controimmagine si “comporta bene”

Da questo esempio possiamo generalizzare, e dire che in generale valgono le seguenti:

1. Dato $B \subseteq \mathcal{F}$: $\boxed{X(X^{-1}(B)) \subseteq B}$
2. Dato $A \subseteq \Omega$: $\boxed{X^{-1}(X(A)) \supseteq A}$
3. $\boxed{X^{-1}(B^c) = (X^{-1}(B))^c}$
4. Dato $(B_\alpha)_\alpha \subseteq \mathcal{P}(\mathcal{F})$, allora:

- $\boxed{X^{-1}\left(\bigcup_{\alpha} B_{\alpha}\right) = \bigcup_{\alpha} X^{-1}(B_{\alpha})}$
- $\boxed{X^{-1}\left(\bigcap_{\alpha} B_{\alpha}\right) = \bigcap_{\alpha} X^{-1}(B_{\alpha})}$

Fino ad ora abbiamo utilizzato una classica notazione di “analisi”. Introduciamo ora una notazione più “probabilistica”, che ci permetterà in futuro di snellire le varie espressioni.

Definiamo la controimmagine come:

$$X^{-1}(B) = \left\{ w \in \Omega \mid X(w) \in B \right\} =: (X \in B)$$

e lo leggiamo come “X cade in B”, oppure “X appartiene a B”.

Ovviamente i risultati scritti in precedenza valgono anche con la nuova notazione, diventano:

$$\left. \begin{array}{l} X^{-1}(B^c) = (X \in B^c) = (X \notin B) \\ \parallel \\ X^{-1}(B^c) \stackrel{3.}{=} (X^{-1}(B))^c = (X \in B)^c \end{array} \right\} \Rightarrow (X \in B)^c = (X \notin B)$$

Grazie a questa nuova notazione, possiamo dire che l'*operazione logica* corrisponde all'*operazione insiemistica*.

ESEMPIO: Facciamo due esempi per capire meglio quanto può essere potente una notazione del genere.

- Prendiamo una funzione X , la quale può assumere i valori 0 oppure 1. Avremo quindi che $X^{-1}(\{1\}) = (X = 1)$.

$$(X = 1)^c = (X \notin \{1\}) = (X \neq 1) = (X = 0)$$

- $X^{-1}((0, +\infty)) = (X \in (0, +\infty)) = (X > 0)$. Allora:

$$(X > 0)^c = (X \notin (0, +\infty)) = (X \leq 0)$$

Si vede perfettamente che se un oggetto è rappresentato su $\mathbb{R}$, il suo complementare insiemistico corrisponde al complementare logico su $\mathbb{R}$.


4.1 Composizione di Funzioni

Arrivati al secondo anno di Ingegneria Matematica non dovrebbe sorprenderci che le funzioni si possono comporre; rivediamo comunque l'argomento per creare una notazione comune.

Date le funzioni $X : \Omega \rightarrow E$ e $h : E \rightarrow \mathcal{F}$, allora possiamo creare la composizione

$$Y(w) = (h \circ X)(w)$$

dove $Y : \Omega \rightarrow \mathcal{F}$.



Vediamo che anche in questo caso si può utilizzare la “notazione probabilistica” introdotta prima, difatti dato un $C \subseteq \mathcal{F}$ possiamo scrivere:

$$Y^{-1}(C) = (h \circ X)^{-1}(C) = X^{-1}(h^{-1}(C)) =: (X \in h^{-1}(C))$$

Come ben sappiamo si possono definire la somma ed il prodotto di due funzioni, e si nota che, dati $\mathcal{F} = \mathbb{R}$, $X_1 : \Omega \rightarrow \mathbb{R}$, $X_2 : \Omega \rightarrow \mathbb{R}$:



$$\begin{array}{ll} (X_1 + X_2) : \Omega \rightarrow \mathbb{R} & \text{è tale che: } (X_1 + X_2) := X_1(w) + X_2(w) \\ (X_1 \cdot X_2) : \Omega \rightarrow \mathbb{R} & \text{è tale che: } (X_1 \cdot X_2) := X_1(w) \cdot X_2(w) \end{array}$$

ESEMPIO: Proponiamo un esempio banale, che però inizia a farci capire (forse) dove vogliamo arrivare...

Sia $\Omega = \{(t, t), (t, c), (c, c), (c, t)\} = \{w = (w_1, w_2) \mid w_k \in \{t, c\}, k = 1, 2\}$. E definiamo le seguenti funzioni:


$$X_1(w) = \begin{cases} 1 & \text{se } w_1 = t \\ 0 & \text{se } w_1 = c \end{cases} ; \quad X_2(w) = \begin{cases} 1 & \text{se } w_2 = t \\ 0 & \text{se } w_2 = c \end{cases}$$

Allora cosa possiamo dire sulla funzione $(X_1 + X_2)(w)$? Proviamo a capirlo creando dei grafici e studiando il comportamento delle funzioni:



Nel primo grafico si è sfruttato il fatto che il valore di w_2 non influisce in alcun modo su X_1 ; in modo del tutto analogo, per X_2 si è ragionato osservando che il suo valore non dipende da w_1 .

Siccome abbiamo già visto che $(X_1 + X_2)(w) := X_1(w) + X_2(w)$, allora ci basta sommare i valori per ogni w , riuscendo a trovare che la funzione somma si comporta come segue:



$$\Rightarrow (X_1 + X_2)(w) = \begin{cases} 0, & w_1 = w_2 = c, \\ 1, & \text{altrove,} \\ 2, & w_1 = w_2 = t. \end{cases}$$

A questo punto possiamo andare a ragionare sulle controimmagini, per esempio:

- $(X_2 = 0) \stackrel{\text{def.}}{=} (w \in \Omega \mid X_2(w) = 0) = \{(t, c), (c, c)\}$
- $(X_1 = 0) \stackrel{\text{def.}}{=} (w \in \Omega \mid X_1(w) = 0) = \{(t, t), (c, t)\}$
- $(X_1 + X_2 = 1) = \{(t, c), (c, c)\}$
- $(X_1 \leq \frac{1}{2}) = (X_1 = 0) = \{(t, t), (c, t)\}$
- $(X_1 \leq \frac{1}{2}) \cup (X_2 > 0) = (X_1 = 0) \cup (X_2 = 1) = \{(c, t), (c, c), (c, t)\} = ((X_1 = 1) \cap (X_2 = 0))^c$

È importante notare di nuovo come la scrittura “ $(X_2 = 0)$ ” vada letta come “gli elementi $w \in \Omega$ tali che l’applicazione di X_2 renda 0”. Stiamo quindi imponendo il valore della funzione a zero, e stiamo cercando quali elementi del dominio restituiscano 0.

Passiamo ora dalla notazione con (t, c) , a quella con $(1, 0)$, ed andiamo a considerare il caso di lanci ripetuti. Avremo quindi che:

$$\Omega = \{0, 1\}^{\mathbb{N}} = \left\{ (w_k)_{k \geq 1} : w_k \in \{0, 1\} \forall k \geq 1 \right\}$$

Ω risulta quindi essere equipollente ad $\mathbb{N}$ (e quindi non numerabile), composto dalle successioni di $(0, 1)$. Introduciamo ora:

$$X_n(\underline{w}) = w_n$$

dove $\underline{w}$ rappresenta una singola successione (come vettore), e la funzione restituisce l'ennesimo valore di quest'ultima^a.

Quindi, $\forall n \geq 1 : X_n : \Omega \rightarrow \{0, 1\}$

Allora si avrà per esempio che:

- $(X_2 = 0) = \{w \in \{0, 1\}^{\mathbb{N}} : w_2 = 0\}$
- $(X_1 X_2 = 0) = \{w \in \{0, 1\}^{\mathbb{N}} : w_1 = 0 \text{ oppure } w_2 = 0\} = \{w \in \{0, 1\}^{\mathbb{N}} : w_1 = w_2 = 1\}^c$
- Se volessimo modellizzare l'evento "non esce mai croce":
 $\bigcap_{n=1}^{\infty} (X_n = 1) = \{1, 1, 1, \dots, 1, 1, \dots\}$

^aPer esempio: $\underline{w} = (1, 0, 0, 1, 1, 0, \dots) \Rightarrow X_4(\underline{w}) = 1$

5 Variabili Aleatorie

Questo capitolo è dedicato a uno dei pilastri fondamentali della teoria della probabilità: le variabili aleatorie. Tale approfondimento ci permetterà di comprendere il motivo per cui si è reso necessario rivedere le funzioni e definire una notazione più adatta al contesto probabilistico.

Abbiamo già introdotto che cosa è una misura e cosa sia uno spazio misurabile, ma quando possiamo dire che una *funzione* è *misurabile*?

DEFINIZIONE 5.1: Siano $(E, \mathcal{E})$, $(F, \mathcal{F})$ due spazi misurabili; $f : E \rightarrow F$ si dice misurabile se $\forall B \in \mathcal{F} : f^{-1}(B) \in \mathcal{E}$.

Come notazione useremo: $f : E \rightarrow F$ misurabile, oppure $f : (E, \mathcal{E}) \rightarrow (F, \mathcal{F})$

Come abbiamo già notato in precedenza, per qualsiasi funzione vale che:

$$\{X^{-1}(B) \mid B \subseteq \mathcal{F}\} \subseteq \mathcal{P}(\Omega)$$

Tuttavia se parliamo di *funzioni misurabili* siamo in grado di creare una condizione più forte sull'insieme delle controimmagini¹:

$$\{X^{-1}(B) \mid B \subseteq \mathcal{F}\} \subseteq \mathcal{E} \subsetneq \mathcal{P}(\Omega)$$

DEFINIZIONE 5.2 ▲: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità e $(F, \mathcal{F})$ uno spazio misurabile. Allora X è una variabile aleatoria se:

$$X : \Omega \rightarrow F \text{ è misurabile}$$

Ossia che $\forall B \in \mathcal{F} : X^{-1}(B) =: (X \in B) \in \mathcal{A}$

Questa è una definizione generale, ma tipicamente per i nostri scopi avremo che:

$$F = \mathbb{R}, \mathbb{R}^n \text{ e } \mathcal{F} = \mathcal{B}(\mathbb{R}), \mathcal{B}(\mathbb{R}^n)$$

Facciamo alcuni esempi per approfondire al questione:

★ Siano $\Omega = \{1, \dots, 6\}^2 = \{w \in (h, k) : h, k \in \{1, \dots, 6\}\}$, $\mathcal{A} = \mathcal{P}(\Omega)$, $F = \mathbb{R}$ e $\mathcal{F} = \mathcal{B}(\mathbb{R})$.

È evidente che questa costruzione si rifà all'esperimento del lancio di 2 dadi. Possiamo quindi una funzione che ci restituisce la somma dei due risultati:

$$X(w) = h + k$$

Ci chiediamo, *questa funzione è una variabile aleatoria?* Per esserlo, dobbiamo dimostrare $\forall B \in \mathcal{F} : (X \in B) \in \mathcal{A}$.

Siccome la σ -algebra di partenza è l'insieme delle parti, la condizione di misurabilità è sempre verificata, in quanto $(X \in B) \in \mathcal{P}(\Omega)$.

¹Si ricorda che $\mathcal{E} \subsetneq \mathcal{P}(\Omega)$

Abbiamo appena capito che **tutte le volte che Ω è discreto** (e quindi $\mathcal{A} = \mathcal{P}(\Omega)$), avremo che **la condizione di misurabilità è verificata automaticamente**, e quindi possiamo parlare di variabile aleatoria.

Se avessimo invece preso $\tilde{\mathcal{A}} = \{\emptyset, \Omega\}$, la nostra funzione $X(w) = h + k$ non sarebbe più risultata misurabile. È facile da dimostrare, prendendo per esempio $B = \{2\}$: $(X \in B) = (X = 2) = \{(1, 1)\} \notin \tilde{\mathcal{A}}$. X non sarebbe quindi stata una variabile aleatoria.


⇒ Tutto dipende dalle σ -algebre!!!

★ Prendiamo $\Omega = \mathbb{R}^+$, $F = \mathbb{R}$, $\mathcal{A} = \mathcal{B}(\mathbb{R}^+)$, $\mathcal{F} = \mathcal{B}(\mathbb{R})$. Consideriamo

$$X : \mathbb{R}^+ \rightarrow \mathbb{R} \quad \text{tale che} \quad X(w) = \lfloor w \rfloor + 1$$

dove con $\lfloor x \rfloor$ si intende la parte intera di x .

Di nuovo ci chiediamo se questa possa essere una variabile aleatoria, ossia $\forall B \in \mathcal{F} : (X \in B) \stackrel{?}{\in} \mathcal{A}$? Per aiutarci, andiamo a vedere come si comporta graficamente la funzione X :



Grazie al grafico notiamo che $X(\Omega) = \mathbb{N}^*$, e di conseguenza possiamo scrivere che:

$$(X \in B) = \bigcup_{k \geq 1; k \in B} (X = k)$$

Per capire meglio la scrittura, poniamo per esempio $B = (\frac{3}{2}, \frac{9}{2})$, allora ai avrà che:

$$(X \in B) = (X = 2) \cup (X = 3) \cup (X = 4) = [1, 2) \cup [2, 3) \cup [3, 4)$$

In generale possiamo quindi scrivere che:

$$\begin{aligned} (X = k) &= (w : X(w) = \lfloor w \rfloor + 1 = k) = (w : \lfloor w \rfloor = k - 1) \\ &= [k, k + 1) \quad \forall k \geq 1 \end{aligned}$$

Di conseguenza avremo che la condizione di misurabilità risulta soddisfatta, difatti:

$$(X \in B) = \bigcup_{k \geq 1; k \in B} (X = k) = \bigcup_{k \geq 1; k \in B} [k, k + 1) \in \mathcal{B}(\mathbb{R}^+) = \mathcal{A} \quad \forall B \in \mathcal{F} = \mathcal{B}(\mathbb{R})$$

Da questo esempio capiamo che **se l'immagine di X è numerabile e lavoro sui Boreliani, allora X è una variabile aleatoria.**

Ora che abbiamo introdotto e capito cosa è una variabile aleatoria, andiamo ad elencare tutte le sue principali proprietà.

TEOREMA 5.3 Proprietà delle Variabili Aleatorie^a: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e $(E, \mathcal{E}), (F, \mathcal{F})$ due spazi misurabili. Allora valgono le seguenti:

1. $X : \Omega \rightarrow \mathbb{R}$:

$$\text{V.A. reale} \iff (X \leq t) = (X \in (-\infty, t)) \in \mathcal{A} \quad \forall t \in \mathbb{R}$$

2. $X = \mathbb{I}_A : \Omega \rightarrow \mathbb{R}$:

$$\text{V.A. reale} \iff A \in \mathcal{A}$$

3. $\underline{X} = (X_1, \dots, X_n) : \Omega \rightarrow \mathbb{R}^n$:

$$\text{Vettore A.} \iff X_k : \Omega \rightarrow \mathbb{R} \text{ è V.A. } \forall k = 1, \dots, n$$

4. Siano $X : \Omega \rightarrow E, h : E \rightarrow F$ misurabili: $\Rightarrow Y = h \circ X : \Omega \rightarrow F$ è una V.A.

Ovvero che: $(Y \in C) = (h \circ X \in C) = (X \in h^{-1}(C))$, con $C \in \mathcal{F}$. Siccome h è misurabile: $h^{-1}(C) \in \mathcal{E}$, e X è misurabile: $\Rightarrow (X \in h^{-1}(C)) \in \mathcal{A}$

5. Sia $X_k : \Omega \rightarrow \mathbb{R}$ V.A. $\forall k = 1, \dots, n$. Sia $h : \mathbb{R}^n \rightarrow \mathbb{R}$:

$$\stackrel{3.+4.}{\Rightarrow} h(X_1, \dots, X_n) = h \circ \underline{X} : \Omega \rightarrow \mathbb{R} \text{ è una V.A.}$$

6. Siano $X, Y : \Omega \rightarrow \mathbb{R}$ variabili aleatorie reali:

$$\Rightarrow X + Y, X - Y, XY, \frac{X}{Y} \mathbb{I}_{[Y \neq 0]}, X \vee Y, X \wedge Y \text{ Sono V.A.}$$

7. Sia $X_n : \Omega \rightarrow \mathbb{R}$ una successione di variabili aleatorie:

$$\Rightarrow \sup_n X_n, \inf_n X_n, \lim_{n \rightarrow +\infty} X_n, \liminf_n X_n, \limsup_n X_n \text{ Sono V.A.}$$

(Dove si ricorda che il “lim inf” e “lim sup” esistono sempre, mentre il “lim” non è detto).

^aIn generale delle funzioni misurabili

DEFINIZIONE 5.4: La funzione $h : (\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n)) \rightarrow (\mathbb{R}^k, \mathcal{B}(\mathbb{R}^k))$ si definisce *Funzione Boreliana*.

TEOREMA 5.5: Se $h : \mathbb{R}^n \rightarrow \mathbb{R}^k$ è continua $\Rightarrow h$ è boreliana

ESEMPIO : Proponiamo tre esempi per vedere quanto queste proprietà possano semplificarci la vita nel riconoscere se una funzione è una variabile aleatoria.

- Sia $X : \mathbb{R} \rightarrow \mathbb{R}$ tale che $X(w) = w^2$. Siccome X è continua, allora per il Teorema 5.5 risulta essere Boreliana $\Rightarrow X$ è una variabile aleatoria.
- Sia $\underline{X} : \mathbb{R} \rightarrow \mathbb{R}^2$ tale che $\underline{X}(w) = \begin{bmatrix} w \\ w^2 \end{bmatrix}$. Questo risulta essere un vettore aleatorio, siccome le sue componenti sono variabili aleatorie.

- Sia $X : \Omega \rightarrow \mathbb{R}$ variabile aleatoria. Allora la composizione $Y = X^2 + \lfloor X \rfloor$ risulta essere una variabile aleatoria.

Cerchiamo ora di fare uno sforzo concettuale (neanche troppo grosso).

Prendiamo in considerazione la variabile aleatoria $X : \Omega \rightarrow F$, allora possiamo definire la σ -algebra generata da X :

$$\sigma(X) := \left\{ (X \in B) \mid B \in \mathcal{F} \right\} \subseteq \mathcal{P}(\Omega)$$

Che rappresenta l'insieme di *tutti i sottoinsiemi di Ω che si ottengono “tirando indietro”* (controimmagine) gli insiemi misurabili B di $\mathcal{F}$.

Possiamo però spingerci oltre ed affermare che

$$\sigma(X) \subseteq \mathcal{A}$$

in quanto X è una variabile aleatoria.

Si può dare un'intuizione logica di questo fatto: $\mathcal{A}$ contiene tutti gli eventi “osservabili nel mondo”; $\sigma(X)$ contiene solo gli eventi descrivibili in funzione di X (cioè “attraverso” i valori di X). È quindi logico ed inevitabile che $\sigma(X) \subseteq \mathcal{A}$.

Si può dimostrare che $\sigma(X)$ è una σ -algebra, ed è inoltre la più piccola σ -algebra rispetto a cui X risulta essere misurabile. Questo vuol dire che **se vogliamo che X sia una variabile aleatoria, allora la σ -algebra minima necessaria è proprio $\sigma(X)$.**

ESEMPIO : Sia $X = \mathbb{I}_A : \Omega \rightarrow \{0, 1\}$ la funzione indicatrice di un insieme $A \subseteq \Omega$. Poiché la σ -algebra su $\{0, 1\}$ è $\mathcal{F} = \mathcal{P}(\{0, 1\}) = \{ \emptyset, \{0\}, \{1\}, \{0, 1\} \}$, si ha:

$$X^{-1}(\emptyset) = \emptyset, \quad X^{-1}(\{0\}) = A^c, \quad X^{-1}(\{1\}) = A, \quad X^{-1}(\{0, 1\}) = \Omega.$$

Pertanto

$$\sigma(X) = \{ \emptyset, \Omega, A, A^c \},$$

che risulta essere la σ -algebra generata dalla partizione $\{A, A^c\}$, e quindi è molto più piccola di $\mathcal{P}(\Omega)$.

Possiamo cercare di dare un'interpretazione intuitiva a questo esempio. La σ -algebra generata da X contiene *solo le informazioni osservabili tramite X* . Nel caso dell'indicatrice $X = \mathbb{I}_A$, la funzione “vede” unicamente se ci troviamo *dentro oppure fuori* dall'insieme A .


L'unica partizione dello spazio che X è in grado di distinguere è dunque $\{A, A^c\}$. Gli unici eventi che si possono formare combinando A e A^c sono: $\emptyset, A, A^c, \Omega$.

Per questo motivo si ha che $\sigma(X)$ è molto più piccola di $\mathcal{P}(\Omega)$: mentre $\mathcal{P}(\Omega)$ contiene *tutti* i sottoinsiemi di Ω , la σ -algebra $\sigma(X)$ ne contiene soltanto quattro, ossia

$$\sigma(X) = \{ \emptyset, \Omega, A, A^c \}.$$

5.1 Legge di una Variabile Aleatoria

Nel momento in cui si definisce una variabile aleatoria $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F, \mathcal{F})$, si dispone di un meccanismo che associa ad ogni esito elementare $\omega \in \Omega$ un valore $X(\omega)$ nello spazio F . Tuttavia, la probabilità $\mathbb{P}$ è originariamente definita sullo spazio campionario $(\Omega, \mathcal{A})$, non direttamente sui valori assunti da X .



Sorge dunque la necessità di *trasferire la misura di probabilità* dallo spazio degli esiti allo spazio dei valori della variabile aleatoria, in modo da poter calcolare probabilità del tipo

$$\mathbb{P}(X \in B), \quad B \in \mathcal{F}.$$

Tale misura indotta, che traduce la distribuzione di probabilità di $\mathbb{P}$ attraverso X , viene chiamata *legge (o distribuzione) di X* .

DEFINIZIONE 5.6: Sia $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F, \mathcal{F})$ una variabile aleatoria. Si definisce *legge di X* la funzione:

$$P^X : \mathcal{F} \rightarrow [0, 1] \quad \text{tale che} \quad P^X(B) = \mathbb{P}(X \in B) \quad \forall B \in \mathcal{F}$$

PROPOSIZIONE 5.7: La legge di una variabile aleatoria $P^X : \mathcal{F} \rightarrow [0, 1]$ è una probabilità

Dimostrazione. Ci basta dimostrare che $P^X(F) = 1$ e che valga la σ -additività.

- $P^X(F) \stackrel{\text{def}}{=} \mathbb{P}(X \in F) = \mathbb{P}(\Omega) = 1$
- Dato $(B_n)_{n \geq 1} \subseteq \mathcal{F}$ tali che $B_h \cap B_k = \emptyset \quad \forall h \neq k$, allora avremo che:

$$P^X \left(\bigcup_{n=1}^{\infty} B_n \right) = \mathbb{P} \left(X \in \bigcup_{n=1}^{\infty} B_n \right) = \mathbb{P} \left(\bigcup_{n=1}^{\infty} (X \in B_n) \right) = \sum_{n=1}^{\infty} \mathbb{P}(X \in B_n) = \sum_{n=1}^{\infty} P^X(B_n)$$

□

Questa proposizione è fondamentale, in quanto se $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F, \mathcal{F})$ è una variabile aleatoria, allora possiamo vedere $(F, \mathcal{F}, P^X)$ come uno spazio di probabilità.

Essendo P^X una probabilità, possiamo quindi definire la funzione di ripartizione associata alla variabile aleatoria X :

DEFINIZIONE 5.8: Sia $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ una variabile aleatoria reale, allora si definisce *Funzione di Ripartizione di X* la funzione:

$$F_X : \mathbb{R} \rightarrow [0, 1] \quad \text{data da} \quad F_X(t) = P^X((-\infty, t]) = \mathbb{P}(X \leq t)$$

ESEMPIO : Facciamo qualche esempio per capire meglio.

★ Sia X la somma dei risultati di due dadi, allora avremo che:

$$\Omega = \{1, \dots, 6\}^2, \quad \mathcal{A} = 2^\Omega, \quad \mathbb{P} = \mathbb{P}_{\text{UNIF}}; \quad \begin{aligned} X : \Omega &\rightarrow \mathbb{R} \\ (h, k) &\mapsto h + k, \quad \text{Im}(X) = \{2, \dots, 12\} \end{aligned}$$


Si vuole trovare F_X e dire se P^X è discreta o meno.

1. Si ha chiaramente che $P^X(\{k\}) = \mathbb{P}(X \in \{k\}) = \mathbb{P}(X = k)$ con $k = 2, \dots, 12$.

Quindi:

$$P^X(\{k\}) = \mathbb{P}(\{(h, l) \in \Omega \mid h + l = k\}) = \begin{cases} \frac{k-1}{36}, & \text{se } k \in [2, 6] \\ \frac{13-k}{36}, & \text{se } k \in [7, 12] \end{cases}$$

Il perché di questo fatto risulta essere chiaro andando a costruire il reticolo delle somme ed il corrispondente istogramma delle frequenze.



Si vede che per i risultati di X fino a 7, la frequenza (e quindi la probabilità) aumenta sempre di più; il contrario vale per i valori delle somme tra 7 e 12, la quale frequenza diminuisce.

La funzione di ripartizione di X risulta essere quindi:

$$F_X(t) = \mathbb{P}(X \leq t) = \begin{cases} \sum_{k=2}^{\lfloor t \rfloor} P^X(\{k\}), & \text{se } t \geq 2 \\ 0 & \text{se } t < 2 \end{cases}$$

2. Inoltre P^X risulta essere una probabilità discreta in quanto F_X rispetta tutte le condizioni della Proposizione 3.23.

★ Siano $\Omega = F = \mathbb{R}$, $\mathcal{A} = \mathcal{F} = \mathcal{B}(\mathbb{R})$. Si consideri $\mathbb{P} \sim \mathcal{E}(\lambda)$, ossia che: $F(t) = (1 - e^{-\lambda t})\mathbb{I}_{[0, +\infty)}(t)$. Sia inoltre $X : \mathbb{R} \rightarrow \mathbb{R}$ tale che $X(w) = \lfloor w \rfloor + 1$.

Si vuole trovare P^X , e chiarire se sia discreta o meno.

Come abbiamo già visto, $\text{Im}(X) = \mathbb{Z}$; si osservi inoltre che $\mathbb{P}((-\infty, 0]) = F(0) = 0$.

Avremo quindi che $\forall k \geq 1$:

$$P^X(\{k\}) = \mathbb{P}(X = k) = \mathbb{P}(w \in \mathbb{R} \mid \lfloor w \rfloor = k - 1) = \mathbb{P}([k - 1, k))$$

$$\begin{aligned}
&= F(k^-) - F((k-1)^-) \stackrel{\text{continuità}}{=} F(k) - F(k-1) \\
&= (e^{-\lambda})^{k-1} (1 - e^{-\lambda})
\end{aligned}$$

La quale è una *legge Geometrica* di parametro $(1 - e^{-\lambda})$: $X \sim G(1 - e^{-\lambda})$, che per definizione è rappresenta una probabilità discreta.

5.2 Relazioni fra Variabili Aleatorie: Uguaglianza Quasi Certa ed in Legge

Nel calcolo delle probabilità, quando si opera con variabili aleatorie, non sempre è necessario che due funzioni coincidano esattamente in ogni punto dello spazio campionario per essere considerate “uguali” dal punto di vista probabilistico. Ciò che conta, infatti, non è il comportamento puntuale della funzione in ogni singolo esito $\omega \in \Omega$, ma il comportamento su insiemi che hanno probabilità positiva.

Per questo motivo si introduce il concetto di uguaglianza quasi certa (o uguaglianza $\mathbb{P}$ -quasi ovunque), che consente di considerare trascurabili (dal punto di vista probabilistico) le differenze che si verificano su un insieme di probabilità nulla.

Questa nozione (come avremo modo di approfondire più avanti) è fondamentale perché, nella teoria della misura e dell'integrazione, le funzioni che differiscono solo su insiemi di misura nulla vengono considerate equivalenti: la probabilità è essa stessa una misura, e quindi eredita questa stessa logica.

L'uguaglianza quasi certa permette dunque di trattare come “identiche” due variabili che, pur non coincidendo puntualmente, hanno lo stesso comportamento probabilistico e generano gli stessi risultati integrali.

Introdurremo anche un altro tipo di uguaglianza, ovvero quella in Legge, che ci permetterà di considerare variabili aleatorie che hanno domini differenti.

ESEMPIO : Se prendiamo due funzioni uguali ovunque, tranne che in un punto, queste risulteranno essere uguali quasi certamente, in quanto la misura (probabilità) di un punto è zero.




Figura 5.1: Esempio di due funzioni uguali quasi certamente

Cerchiamo ora di dare delle definizioni formali a questi concetti.

DEFINIZIONE 5.9: Siano $X, Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ due variabili aleatorie. X ed Y sono uguali se:

$$X(\omega) = Y(\omega) \quad \forall \omega \in \Omega$$

DEFINIZIONE 5.10 Uguaglianza in Legge : Siano $X : (\Omega_1, \mathcal{A}_1, \mathbb{P}_1) \rightarrow (F, \mathcal{F})$ e $Y : (\Omega_2, \mathcal{A}_2, \mathbb{P}_2) \rightarrow (F, \mathcal{F})$ due variabili aleatorie. Si dice che hanno la stessa legge se:

$$P^X = P^Y$$

Ossia che: $\forall B \in \mathcal{F} \quad P^X(B) = P^Y(B)$

Si presti attenzione al fatto che nella Definizione 5.10, X e Y **possono partire da spazi differenti, ma comunque devono arrivare nello stesso spazio misurabile**; per quanto riguarda la Definizione 5.9, se le variabili aleatorie partissero da spazi differenti, la definizione perderebbe di senso.

Questo può essere interpretato come un primo campanello d'allarme sul fatto che l'uguaglianza "classica" sia troppo stringente, e quindi necessitiamo di un altri tipi di uguaglianze meno vincolanti.

DEFINIZIONE 5.11 Uguaglianza quasi certa : Siano $X : \Omega \rightarrow F$, e $Y : \Omega \rightarrow F$ due variabili aleatorie. Si dice che X ed Y sono quasi certamente uguali se:

$$\exists A \in \mathcal{A} \text{ con } \mathbb{P}(A) = 1 \quad \text{tale che:} \quad X(w) = Y(w) \quad \forall w \in A$$

O alternativamente, solo nel caso in cui $F = \mathbb{R}, \mathbb{R}^n$, X ed Y sono uguali q.c. se: $\mathbb{P}(X = Y) = 1$

Si noti che l'uguaglianza quasi certa è legata alla probabilità sulla quale le due variabili aleatorie sono definite; se cambio lo spazio di probabilità, potrebbe essere che X e Y non siano più q.c. uguali.

Anche in questo caso, affinché la definizione abbia senso matematico, è necessario che le due variabili aleatorie abbiano lo stesso dominio.

Da un punto di vista modellistico, X e Y **risultano indistinguibili alla probabilità** $\mathbb{P}$.

ESEMPIO : Siano $\Omega = F = \mathbb{R}$, $\mathcal{A} = \mathcal{F} = \mathcal{B}(\mathbb{R})$. Si consideri $\mathbb{P} \sim \mathcal{E}(\lambda)$, e si prendano le tre V.A. definite come segue:

$$\left. \begin{array}{l} X_1(w) = w \\ X_2(w) = |w| \\ X_3(w) = w \cdot \mathbb{I}_{\mathbb{R} \setminus \mathbb{Q}} \end{array} \right\} \Rightarrow X_1 \neq X_2 \neq X_3$$

Tuttavia $X_1 \stackrel{q.c.}{=} X_2 \stackrel{q.c.}{=} X_3$, difatti si ha che:

$$(X_1 = X_3) = (\mathbb{R} \setminus \mathbb{Q})$$

$$\Rightarrow \mathbb{P}(X_1 = X_3) = \mathbb{P}(\mathbb{R} \setminus \mathbb{Q}) = \mathbb{P}(\mathbb{R}) - \mathbb{P}(\mathbb{Q}) = 1 - 0 = 1 \Rightarrow X_1 \stackrel{q.c.}{=} X_3$$

dato che $\mathbb{P}(\mathbb{Q}) = \mathbb{P}(\bigcup_{n=1}^{\infty} \{q_n\}) = \sum_{n=1}^{\infty} \mathbb{P}(\{q_n\}) = 0$.

Allo stesso modo si dimostra che $X_1 \stackrel{q.c.}{=} X_2$ e di conseguenza $X_2 \stackrel{q.c.}{=} X_3$

Possiamo chiederci arrivati a questo punto: *quale è la relazione tra i tipi di uguaglianze che abbiamo visto?*

PROPOSIZIONE 5.12: $X = Y \Rightarrow X \stackrel{q.c.}{=} Y \Rightarrow P^X = P^Y$

Dimostrazione. La prima implicazione è triviale, pertanto lasciata al lettore. LOL
Per quanto riguarda la seconda, $\forall B \in \mathcal{F}$:

$$\begin{aligned} P^X(B) &= \mathbb{P}(X \in B) = \mathbb{P}(X \in B \cap X = Y) + \mathbb{P}(X \in B \cap X \neq Y) \\ &= \mathbb{P}(X \in B \cap X = Y) = \mathbb{P}(Y \in B \cap X = Y) = \mathbb{P}(Y \in B) \\ &= P^Y(B) \end{aligned}$$

□

Si faccia attenzione ad alcune osservazioni.

★ Per conoscere P^X è sufficiente conoscere $X(w) \forall w \in A$, dove $\mathbb{P}(A) = 1$.
Quindi se avessimo una variabile aleatoria Y definita come

$$Y(w) = \begin{cases} X(w), & \text{se } w \in A, \text{ con } \mathbb{P}(A) = 1 \\ 0 & \text{se } w \notin A \end{cases}$$

potremmo senz'altro concludere che $Y \stackrel{q.c.}{=} X$.

★ In generale possiamo dire che una qualunque proprietà che dipende da $w \in \Omega$ vale “quasi certamente” se:

$$\exists A \in \mathcal{A}, \mathbb{P}(A) = 1 \quad \text{tale che la proprietà valga } \forall w \in A$$

ESEMPIO: Si consideri:

$$\Omega = F = \mathbb{R}; \quad \mathcal{A} = \mathcal{F} = \mathcal{B}; \quad \mathbb{P} \sim \mathcal{U}([0, 1]) \Rightarrow F(t) = t \cdot \mathbb{I}_{[0,1]} + \mathbb{I}_{(1,+\infty)}$$

Consideriamo ora $X(w) = w, \forall w \in \Omega = \mathbb{R}$. Si ha che $\text{Im}(X) = \mathbb{R}$, tuttavia:

$$\mathbb{P}(X \in [0, 1]) = \mathbb{P}(w \in \mathbb{R} \mid X(w) = w \in [0, 1]) = \mathbb{P}([0, 1]) = F(1) - F(0) = 1$$

$\Rightarrow$ Possiamo affermare che $X \in [0, 1]$ sia una proprietà che vale quasi certamente

6 Integrale di Lebesgue

Finalmente arriviamo a uno dei capitoli più fecondi e profondi della teoria della misura e dell'integrazione: l'Integrale di Lebesgue.

In precedenza abbiamo costruito con cura lo spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ e approfondito i concetti di misura, sigma-algebra e variabile aleatoria. Ora entriamo in campo con uno strumento che supera i limiti della tradizionale integrazione di Riemann: consente di trattare funzioni più “irregolari”, serie di funzioni, scambi di limite e integrale, e fornisce un linguaggio comune per analisi matematica, probabilità e teoria delle funzioni.

In questo capitolo vedremo come definire l'integrale di una funzione misurabile rispetto a una misura — in particolare la misura di probabilità — e illustreremo perché la sua struttura (attraverso funzioni semplici, limiti monotoni, e la proprietà «quasi ovunque») risulti essenziale nella moderna teoria della probabilità e dell'analisi.

Abbandonando la sola visione geometrica “area sotto la curva” tipica dell'integrazione di Riemann, l'approccio di Lebesgue ci mostra come dividere il codominio della funzione in “strati” orizzontali e misurare quanto si spende in ciascuno di essi. Questo cambio di prospettiva rende l'integrazione molto più flessibile, ci consente di definire il valore atteso $E[X]$ di variabili aleatorie in modo robusto, e di applicare teoremi fondamentali come il teorema della convergenza dominata o monotona.

Con questo nuovo strumento potremo affrontare variabili che prima risultavano fuori dalla portata, funzioni definite su spazi astratti, e avanzare verso gli spazi $\mathcal{L}^p$ e le applicazioni in probabilità e analisi funzionale. Prepariamoci dunque a entrare nel cuore dell'argomento: comprenderemo prima la definizione di integrale per funzioni semplici non-negative, fino ad estenderlo a funzioni generalizzate, e vedremo le sue proprietà essenziali.

6.1 Definizione per Funzioni Elementari

D'ora in avanti, per rimanere più generali possibili, consideriamo $(E, \mathcal{E}, \mu)$ spazio di misura, e supponiamo che μ , sia una misura σ -finita¹ (Definizione 1.6).

DEFINIZIONE 6.1 Funzione Elementare : $f : E \rightarrow (0, +\infty)$ è una funzione elementare se:

$$\exists n \geq 1, \quad A_1, \dots, A_n \subseteq \mathcal{E} \text{ t.c. } A_h \cap A_k = \emptyset \quad \forall h \neq k, \quad \bigcup_{k=1}^n A_k = E, \quad a_1 \dots a_n \geq 0 \text{ tale che:}$$

$$f(x) = \sum_{k=1}^n a_k \mathbb{I}_{A_k}(x)$$

A prima vista può sembrare una definizione complicata, mentre in realtà è abbastanza semplice. Supponiamo per comodità che $n = 6$, allora possiamo partizionare $\mathcal{E}$ in sei diversi sottoinsiemi (disgiunti). La nostra funzione in quegli insiemi prende dei valori, che sono $a_1, a_2, \dots, a_6$.

¹ $\mathbb{P}$ è una misura σ -finita.




Figura 6.1: Prima un esempio di con $E \neq \mathbb{R}$, poi con $E = \mathbb{R}$

Se semplifichiamo maggiormente le cose, e consideriamo il caso in cui $E = \mathbb{R}$, allora il grafico sulla destra esprime perfettamente il concetto di funzione semplice.

DEFINIZIONE 6.2: Per ogni $f \geq 0$ elementare si definisce l'Integrale di Lebesgue di f su E rispetto alla misura μ il seguente numero (oppure $+\infty$)^a:

$$\int_E f d\mu := \sum_{k=1}^n a_k \mu(A_k) \geq 0$$

^aPotrebbe valere $+\infty$ siccome μ è una misura σ -finita, e non finita

PROPOSIZIONE 6.3: L'integrale di Lebesgue è lineare e monotono, ossia:

- siano $a, b \geq 0$; $f, g \in \mathbb{E}^+$ (ossia lo spazio delle funzioni elementari positive):

$$\Rightarrow af + bg \in \mathbb{E}^+ \quad \text{e} \quad \int_E (af + bg) d\mu = a \int_E f d\mu + b \int_E g d\mu$$

- siano $f, g \in \mathbb{E}^+$; $f \leq g$:

$$\Rightarrow \int_E f d\mu \leq \int_E g d\mu$$

6.2 Generalizzazione della Definizione a Funzioni Generiche

Ora che abbiamo definito l'integrale per funzioni elementari positive, vogliamo chiaramente cercare di estendere la definizione in maniera rigorosa a una funzione generale.

Iniziamo vedendo che possiamo scrivere una qualsiasi funzione positiva, come una successione di funzioni in $\mathbb{E}^+$, potendo così estendere facilmente la Definizione 6.2 a questa nuova classi di funzioni.

PROPOSIZIONE 6.4: Per ogni $f : E \rightarrow [0, +\infty]$, $\exists$ una successione $f_n : E \rightarrow [0, +\infty)$ tale che:

$$1. f_n \in \mathbb{E}^+, \quad \forall n \geq 1$$

$$2. f_n \uparrow f, \text{ ossia che: } \lim_{n \rightarrow +\infty} f_n(x) = f(x) \quad \text{e che} \quad f_{n+1} \geq f_n \quad \forall x \in E$$

DEFINIZIONE 6.5: Per ogni $f : E \rightarrow [0, +\infty]$ l'Integrale di Lebesgue di f su E rispetto alla misura μ è dato da:

$$\int_E f \, d\mu = \lim_{n \rightarrow +\infty} \int_E f_n \, d\mu$$

Facciamo alcune osservazioni fondamentali.

★ Siccome valgono entrambi i punti 1. e 2. della Proposizione 6.4, allora avremo che: $\int_E f_{n+1} \, d\mu \geq \int_E f_n \, d\mu$.

$\Rightarrow \left(\int_E f_n \, d\mu \right)_{n \geq 1}$ è una successione monotona non decrescente

$$\Rightarrow \exists \lim_{n \rightarrow +\infty} \int_E f_n \, d\mu = \begin{cases} 0 \leq L < +\infty \\ +\infty \end{cases}$$

Il limite non può essere < 0 , in quanto $f_n \in \mathbb{E}^+$, quindi al limite può valere 0, ed è chiaro che $\int_E 0 \, d\mu = 0$

★ Si può dimostrare che il limite presente nella Definizione 6.5 non dipende dalla particolare successione approssimante f_n che si usa per approssimare f , ovvero che:

$$\text{Se: } \exists \tilde{f}_n \uparrow f \quad \Rightarrow \quad \lim_{n \rightarrow +\infty} \int_E \tilde{f}_n \, d\mu = \lim_{n \rightarrow +\infty} \int_E f_n \, d\mu$$

Di conseguenza $\int_E f \, d\mu$ risulta essere ben definito.

★ Potremmo legittimamente chiederci quale possa essere una successione f_n che riesca ad approssimare crescendo f .

Costruiamo la seguente successione di funzioni, per ogni $n \geq 1$ e $k = 0, \dots, n \cdot 2^n - 1$, definita come segue:

$$f_n(x) = \begin{cases} \frac{k}{2^n}, & \text{se } \frac{k}{2^n} \leq f(x) < \frac{k+1}{2^n}, \\ n, & \text{se } f(x) \geq n \end{cases}$$

Notiamo già il principio di quella che è stata l'intuizione fondamentale di Lebesgue: nella costruzione di questa successione, l'attenzione non è posta sul *dominio* della funzione, come avveniva nell'integrale di Riemann, ma sul suo *codominio*.


Nel metodo di Riemann, infatti, si suddivide l'intervallo di definizione della funzione (cioè il dominio) in piccoli sottointervalli, e si sommano le aree dei rettangoli aventi base in ciascun sottointervallo e altezza data dal valore della funzione in un punto di esso.

L'idea di Lebesgue, invece, è radicalmente diversa: invece di "tagliare" l'asse delle ascisse, si suddivide l'asse delle ordinate, cioè l'insieme dei valori che la funzione assume. In questo modo si costruiscono, per ogni livello del codominio, gli insiemi di punti del dominio in cui la funzione assume valori compresi in un certo intervallo, e si considera la misura di questi insiemi.

Questa inversione di prospettiva è ciò che permette all'integrale di Lebesgue di trattare funzioni molto più generali, di gestire limiti di successioni di funzioni e di garantire risultati di convergenza (che vedremo) che l'integrale di Riemann non poteva assicurare.

Per essere più chiari, fissiamo $n = 1$. Allora avremo che:

$$f_1(x) = \begin{cases} 0 (= a_1) & \text{se } 0 \leq f(x) < \frac{1}{2} \quad (= A_1), \\ \frac{1}{2} (= a_2) & \text{se } \frac{1}{2} \leq f(x) < 1 \quad (= A_2), \\ 1 (= a_3) & \text{se } f(x) \geq 1 \quad (= A_3). \end{cases}$$




Rimarchiamo che il dominio viene suddiviso in funzione del codominio, non il contrario.

Andando avanti con il ragionamento, vediamo come si comporta la nostra successione con $n = 2$. Avremo che:

$$f_2(x) = \begin{cases} 0, & \text{se } 0 \leq f(x) < \frac{1}{4}, \\ \frac{1}{4}, & \text{se } \frac{1}{4} \leq f(x) < \frac{1}{2}, \\ \frac{1}{2}, & \text{se } \frac{1}{2} \leq f(x) < \frac{3}{4}, \\ \frac{3}{4}, & \text{se } \frac{3}{4} \leq f(x) < 1, \\ 1, & \text{se } 1 \leq f(x) < \frac{5}{4}, \\ \frac{5}{4}, & \text{se } \frac{5}{4} \leq f(x) < \frac{3}{2}, \\ \frac{3}{2}, & \text{se } \frac{3}{2} \leq f(x) < \frac{7}{4}, \\ \frac{7}{4}, & \text{se } \frac{7}{4} \leq f(x) < 2, \\ 2, & \text{se } f(x) \geq 2. \end{cases}$$

Il cui grafico risulta essere:



Vediamo graficamente che più n aumenta, più f_n si avvicina ad f . Inoltre sia f_1 che f_2 risultano essere funzioni elementari. Questa non è una dimostrazione rigorosa che $f_n \uparrow f$ e che $f_n \in \mathbb{E}^+$, tuttavia ci mostra intuitivamente come funziona il processo “avvicinamento” da parte della successione verso la funzione.

★ Restano vere le proprietà di linearità e monotonia anche per l'integrale definito per funzioni qualsiasi positive, ossia che: $\forall a, b > 0, \forall f, g : E \rightarrow [0, +\infty]$, allora si ha che:

- $\int_E (af + bg) d\mu = a \int_E f d\mu + b \int_E g d\mu$
- $0 \leq f \leq g \Rightarrow 0 \leq \int_E f d\mu \leq \int_E g d\mu$

Come abbiamo detto in precedenza, per l'integrale di Lebesgue riusciamo a far valere dei criteri di convergenza che non valevano per l'integrale di Riemann:

TEOREMA 6.6 Beppo Levi o Convergenza Monotona : Sia $f_n \uparrow f$, $f_n \geq 0 \forall n \geq 1$, $f \geq 0$, allora vale che:

$$\int_E f_n d\mu \uparrow \int_E f d\mu.$$

Questo risultato è quindi caratteristico dell'integrale di Lebesgue e *non vale* in generale per l'integrale di Riemann.

Infatti, l'integrale di Riemann non gode di buone proprietà di continuità rispetto alla convergenza puntuale: per scambiare limite e integrale è necessario che la convergenza sia *uniforme*.

Intuitivamente si può pensare alla convergenza monotona, come una convergenza dove ogni “grafico” f_n si avvicina a f *punto per punto*, ma in modo *indipendente* per ciascun x ; la convergenza può essere più lenta o più rapida a seconda del punto considerato. Invece per la convergenza monotona si ha che l'intero grafico di f_n si “schiaccia” su quello di f in modo omogeneo, come se esistesse un unico $\varepsilon > 0$ valido per *tutti* i punti del dominio.

Inoltre, il limite di una successione di funzioni Riemann-integrabili può non essere Riemann-integrabile, anche quando le funzioni f_n sono monotone e non negative.

ESEMPIO : Consideriamo le funzioni $f_n : [0, 1] \rightarrow \mathbb{R}$ definite da

$$f_n(x) = \begin{cases} 1, & \text{se } x \in [0, \frac{1}{n}] , \\ 0, & \text{altrimenti.} \end{cases}$$

Allora $f_n(x) \uparrow f(x)$ con

$$f(x) = \begin{cases} 1, & \text{se } x = 0, \\ 0, & \text{se } x > 0. \end{cases}$$

Ogni f_n è Riemann-integrabile e si ha

$$\int_0^1 f_n(x) dx = \frac{1}{n} \rightarrow 0.$$

Tuttavia, la funzione limite f è nulla quasi ovunque, ma *non è Riemann-integrabile*, poiché presenta una discontinuità in un insieme di misura nulla che però non permette di definire il limite dell'integrale come quello delle funzioni f_n nel senso di Riemann.

Il teorema di Beppo Levi richiederebbe che

$$\int_0^1 f_n(x) dx \uparrow \int_0^1 f(x) dx,$$

ma qui l'integrale a destra non è nemmeno definito in senso di Riemann, mentre in senso di Lebesgue si ha $\int_0^1 f = 0$ e dunque il teorema risulta valido solo per l'integrale di Lebesgue.

Ad ora siamo riusciti a definire l'integrale di Lebesgue per funzioni positive. Per estendere la definizione a qualsiasi funzione, ci basta fare un semplice trick matematico:

DEFINIZIONE 6.7: Data $f : E \rightarrow \mathbb{R}$ definiamo:

- $f_+ := f \vee 0$ parte positiva di f
- $f_- := -(f \vee 0) = -f \wedge 0$ parte negativa di f

Grazie a questa definizione notiamo che sia la parte positiva che la parte negativa sono funzioni entrambe positive, ossia che $f_-, f_+ : E \rightarrow [0, +\infty]$. Inoltre possiamo riscrivere f attraverso queste due nuove funzioni:

$$f = f_+ - f_- \quad \text{e anche che} \quad |f| = f_+ + f_-$$

Siccome f_-, f_+ sono entrambe funzioni positive, allora esistono gli integrali $\int_E f_+ d\mu, \int_E f_- d\mu$ definiti secondo la Definizione 6.5; potrebbero però valere $+\infty$.

6.3 Spazio $\mathcal{L}^1$

Siccome possiamo integrare sia la parte positiva che la parte negativa, ma questi potrebbero divergere a ∞ , abbiamo la necessità di distinguere quando una funzione *ammette* integrale, e quando invece la funzione è *integrabile*.

DEFINIZIONE 6.8 Ammissione dell'integrale : Data $f : E \rightarrow \mathbb{R}$, si dice che f ammette integrale se

$$\int_E f_+ d\mu < +\infty \quad \text{oppure} \quad \int_E f_- d\mu < +\infty$$

In tal caso:

$$\int_E f d\mu = \int_E f_+ d\mu - \int_E f_- d\mu = \begin{cases} +\infty \\ -\infty < c < +\infty \\ -\infty \end{cases}$$

DEFINIZIONE 6.9 Funzione Integrabile : Data $f : E \rightarrow \mathbb{R}$ si dice integrabile se

$$\int_E f_+ d\mu < +\infty \quad \text{e} \quad \int_E f_- d\mu < +\infty$$

In tal caso:

$$\boxed{\int_E f d\mu = \int_E f_+ d\mu - \int_E f_- d\mu} \in (-\infty, +\infty)$$

DEFINIZIONE 6.10: Definiamo lo spazio $\mathcal{L}^1$ come:

$$\mathcal{L}^1(E, \mathcal{E}, \mu) = \left\{ f : E \rightarrow \mathbb{R} \mid f \text{ è integrabile nel senso della Definizione 6.9} \right\}$$

Date queste tre definizioni fondamentali, possiamo alcune osservazioni:

- $\mathcal{L}^1(E, \mathcal{E}, \mu)$ è uno spazio lineare; questa proprietà discende direttamente dalla linearità dell'integrale di Lebesgue:

$$a, b \in \mathbb{R}; f, g \in \mathcal{L}^1(E, \mathcal{E}, \mu) \quad \Rightarrow \quad af + bg \in \mathcal{L}^1(E, \mathcal{E}, \mu)$$

perchè:
$$\int_E (af + bg) d\mu = a \int_E f d\mu + b \int_E g d\mu$$

- C'è coerenza fra tutte e tre le definizioni di integrale: $6.2 \equiv 6.5 \equiv 6.9$
- Se due funzioni sono uguali quasi ovunque, allora anche queste avranno stesso integrale:

$$f, g \in \mathcal{L}^1; \mu(f \neq g) = 0 \Rightarrow \int_E f d\mu = \int_E g d\mu$$

TEOREMA 6.11 Lebesgue o Convergenza Dominata : Se sono verificate le condizioni:

1. $f_n(x) \xrightarrow{n \rightarrow +\infty} f(x) \quad \forall x \in E$
2. $\exists g \in \mathcal{L}^1$ tale che $|f_n| \leq g \quad \forall n \geq 0$

Allora si ha che:

$$f, f_n \in \mathcal{L}^1 \quad \text{e} \quad \lim_{n \rightarrow +\infty} \int_E f_n d\mu = \int_E f d\mu$$

In altre parole, la condizione di dominanza da parte di g permette di scambiare limite ed integrale in modo sicuro.

Si presti particolare attenzione al fatto che si possono utilizzare altre scritture per la formula vista nel Teorema di Lebesgue:

$$\lim_{n \rightarrow +\infty} \int_E f_n d\mu = \int_E f d\mu \iff \lim_{n \rightarrow +\infty} \left| \int_E f_n d\mu - \int_E f d\mu \right| = 0 \iff \int_E |f_n - f| d\mu \xrightarrow{n \rightarrow +\infty} 0$$

Fino ad ora abbiamo visto sempre l'integrale calcolato su tutto il dominio E , ma potremmo anche calcolarlo su sottoinsiemi di E misurabili attraverso la seguente formula:

DEFINIZIONE 6.12: $\forall A \in \mathcal{E}$ si ha che:

$$\int_A f d\mu = \int_E f \cdot \mathbb{I}_A d\mu \quad \forall f \in \mathcal{L}^1$$


6.4 Caso di Interesse con $E = \mathbb{R}, \mathbb{R}^n$ e Confronto con Integrale di Reimann

Tutta la teoria sviluppata fino ad ora è estremamente generale, tuttavia nelle applicazioni pratiche (o quantomeno per questo corso) si tenderà ad avere un caso specifico con:

- $E = \mathbb{R}, \mathbb{R}^n$
- $\mu = m$, misura di Lebesgue su $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ oppure $(\mathbb{R}^2, \mathcal{B}(\mathbb{R}^2))$.

ESEMPIO : Prendiamo la Definizione 6.12 ed appliciamola al caso di interesse.

Sia $f(x) = c \mathbb{I}_{[a,b]}(x)$, $c \geq 0$.



La funzione f è elementare e perciò integrabile:

$$\int_{[a,b]} f d\mu = \int_{\mathbb{R}} c \mathbb{I}_{[a,b]}(x) dm = 0 \cdot m(\mathbb{R} \setminus [a,b]) + c \cdot m([a,b]) = c(b-a) = c \int_a^b dx.$$

$\Rightarrow f$ è Riemann-integrabile.

Dall'esempio notiamo che può esistere una relazione tra l'integrale di Lebesgue e l'integrale di Reimann.

PROPOSIZIONE 6.13: Se $h : [a, b] \rightarrow \mathbb{R}$ limitata e Riemann-integrabile $\Rightarrow h$ è Lebesgue-integrabile rispetto a m su $\mathcal{B}$ e vale che i due integrali coincidono:

$$\int_a^b h(x) dx = \int_{[a,b]} h dm$$

Osserviamo che possiamo scrivere:

$$|h| = h_+ + h_- \quad \Rightarrow \quad \int_{\mathbb{R}} |h| dm = \int_{\mathbb{R}} h_+ dm + \int_{\mathbb{R}} h_- dm$$

Di conseguenza, se h è integrabile, allora anche $|h|$ è integrabile. Questo è valido solo per l'integrazione secondo Lebesgue, in quanto siamo sicuri che h_+ e h_- sono integrabili se lo è h . Per quanto riguarda l'integrazione di Reimann non possiamo decomporre h nella differenza tra la sua parte positiva e negativa ed integrare; questo perché se una funzione h è integrabile, allora non è detto che $|h|$ sia integrabile². Se invece ipotizziamo che $|h|$ sia integrabile:

$$\begin{aligned} \left| \int_{\mathbb{R}} h dm \right| &= \left| \int_{\mathbb{R}} h_+ dm - \int_{\mathbb{R}} h_- dm \right| \leq \left| \int_{\mathbb{R}} h_+ dm \right| + \left| \int_{\mathbb{R}} h_- dm \right| \\ &= \int_{\mathbb{R}} h_+ dm + \int_{\mathbb{R}} h_- dm \\ &= \int_{\mathbb{R}} |h| dm < +\infty \end{aligned}$$

Unendo queste due condizioni che abbiamo appena ricavato, **scopriamo una proprietà fondamentale dell'integrale di Lebesgue, che non vale per quello di Riemann.**

$$\boxed{h \in \mathcal{L}^1(\mathbb{R}, \mathcal{B}, m) \iff |h| \in \mathcal{L}^1(\mathbb{R}, \mathcal{B}, m)}$$

Possiamo quindi ridefinire lo spazio $\mathcal{L}^1$ come:

$$\boxed{\mathcal{L}^1(E, \mathcal{E}, \mu) = \left\{ f : E \rightarrow \mathbb{R} \mid |f| \text{ è integrabile} \right\}}$$

²Si prenda il classico esempio di $\frac{\sin x}{x}$

È quindi corretto vedere l'integrale di Lebesgue come una “generalizzazione” dell'integrale di Riemann?

In un certo senso sì, per gli integrali propri. Infatti, ogni funzione Riemann-integrabile su $[a, b]$ è anche Lebesgue-integrabile, e i due integrali coincidono, come abbiamo visto con la Proposizione 6.13.

L'integrale di Lebesgue è però definito per un insieme molto più ampio di funzioni, poiché si basa sulla misura degli insiemi di punti in cui la funzione assume determinati valori, piuttosto che sulla suddivisione del dominio in intervalli come nel caso di Riemann. In questo modo, l'integrale di Lebesgue risulta adatto a trattare funzioni non limitate, con infiniti punti di discontinuità, o definite su spazi di misura generali, pur mantenendo le proprietà fondamentali di linearità e monotonia dell'integrale classico.

ESEMPIO : Prendiamo la funzione di Dirichlet $\mathbb{I}_{\mathbb{Q}}(x)$, che è ben nota per non essere Riemann-integrabile, tuttavia:

$$\int_{\mathbb{R}} \mathbb{I}_{\mathbb{Q}}(x) \, dm = m(\mathbb{Q}) = m\left(\bigcup_n \{q_n\}\right) = \sum_{n \geq 1} m(\{q_n\}) = 0$$

Nel caso degli integrali impropri, l'integrale di Lebesgue **rappresenta un'estensione** rigorosa dell'integrale di Riemann **solo nei casi di convergenza assoluta**. Infatti, se un integrale improprio di Riemann converge assolutamente, allora esso coincide con l'integrale di Lebesgue.

Esistono casi dove però Lebesgue non ammette convergenza e Riemann sì (in maniera impropria), per esempio in tutte quelle funzioni che hanno oscillazioni e “compensazione di segno”: se $\int |f| = +\infty$, l'integrale non è definito, anche se quello improprio di Riemann converge.

ESEMPIO : Un esempio classico è $f(x) = \frac{\sin x}{x}$ su $[0, +\infty)$, che è integrabile in senso di Riemann improprio, ma non in senso di Lebesgue.

Possiamo quindi concludere questa trattazione generalizzando e dicendo che:

- Nel caso in cui $E = \mathbb{R}$, $\mathcal{E} = \mathcal{B}(\mathbb{R})$, $\mu = m$, allora se $f \geq 0$ e Riemann-integrabile su illimitati $\Rightarrow f$ è Lebesgue integrabile;
- Nel caso in cui $E = \mathbb{R}^n$, $\mathcal{E} = \mathcal{B}(\mathbb{R}^n)$, $\mu = m_n$, definiamo la misura di Lebesgue n-dimensionale come

$$m_n = ([a_1, b_1] \times \cdots \times [a_n, b_n]) = \prod_{k=1}^n (b_k - a_k)$$

e se f è Riemann-integrabile e limitata su $\mathbb{R}^n$, allora f è Lebesgue-integrabile, e i due integrali coincidono:

$$\int_{([a_1, b_1] \times \cdots \times [a_n, b_n])} f(x_1, \dots, x_n) \, dm_n = \int_{([a_1, b_1] \times \cdots \times [a_n, b_n])} f(x_1, \dots, x_n) \, dx_1 \dots dx_n$$

7 Valore Atteso: Integrale Rispetto ad una Misura di Probabilità

Nel capitolo precedente abbiamo studiato profondamente l'integrazione di Lebesgue rispetto ad una misura μ che sia σ -finita. In questo capitolo riformuleremo tutte le nozioni viste precedentemente, ma nel caso in cui si integri rispetto ad una misura di probabilità.

È così che andremo a definire il *valore atteso*, che rappresenta, in sostanza, la media dei possibili valori di una variabile aleatoria reale, pesata secondo le rispettive probabilità di occorrenza.

In questo capitolo costruiremo progressivamente la nozione di valore atteso. Il *modus operandi* sarà lo stesso che è stato utilizzato nel capitolo precedente: definiremo prima l'integrale (o valore atteso) per variabili aleatorie semplici, poi per variabili non negative, per poi arrivare ad una generalizzazione a variabili generiche.

ESEMPIO : Qualora una variabile aleatoria X rappresenti la distribuzione di massa di un oggetto, il valore atteso $E[X]$ ne individua il baricentro.

7.1 Valore atteso per Variabili Aleatorie Semplici

DEFINIZIONE 7.1: Sia $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B})$ una variabile aleatoria semplice, ossia che assume un numero finito di valori $x_1, \dots, x_n \geq 0$. Questa può essere scritta come:

$$X(w) = \sum_{k=1}^n x_k \mathbb{I}_{A_k}(w) = \sum_{k=1}^n x_k \mathbb{I}_{(X=x_k)}(w)$$

Allora possiamo definire il valore atteso di X come:

$$E[X] = x_1 \cdot \mathbb{P}(A_1) + \dots + x_n \cdot \mathbb{P}(A_n) = \sum_{k=1}^n x_k \cdot \mathbb{P}(A_k) \quad \Rightarrow \quad E[X] := \int_{\Omega} X(w) \mathbb{P}(dw) = \int_{\Omega} X \, d\mathbb{P}$$

7.2 Generalizzazione a Variabili Aleatorie Generiche

Come afferma la Proposizione 6.4, data una funzione positiva semplice (o elementare), allora possiamo trovare una successione di funzioni elementari che converge alla funzione in maniera crescente. Utilizziamo la Definizione 6.5 per estendere il concetto di valore atteso a variabili aleatorie positive, utilizzando la successione che avevamo già introdotto.

DEFINIZIONE 7.2 $E[X]$ per Variabili Positive : Sia $X : \Omega \rightarrow [0, +\infty]$ una variabile aleatoria positiva, allora definiamo il valore atteso come:

$$E[X] \stackrel{6.5}{=} \lim_{n \rightarrow +\infty} E[X_n] = \lim_{n \rightarrow +\infty} \sum_{k=1}^{n2^n-1} \frac{k}{2^n} \cdot \mathbb{P}\left(\frac{k}{2^n} \leq X < \frac{k+1}{2^n}\right) + n \cdot \mathbb{P}(X \geq n)$$

Dove $X_n = \begin{cases} \frac{k}{2^n}, & \frac{k}{2^n} \leq X < \frac{k+1}{2^n} \\ n, & X \geq n \end{cases}; \quad k = 0, \dots, n2^n - 1$

Si osservi già che se $\mathbb{P}(X = +\infty) = c > 0 \Rightarrow E[X] = +\infty$, infatti:

$$(X > +\infty) \subseteq (X \geq n) \Rightarrow c = \mathbb{P}(X = +\infty) \leq \mathbb{P}(X \geq n)$$

e allora:

$$\begin{aligned} E[X_n] &= \sum_{k=1}^{n2^n-1} \frac{k}{2^n} \cdot \mathbb{P}\left(\frac{k}{2^n} \leq X < \frac{k+1}{2^n}\right) + n \cdot \mathbb{P}(X \geq n) \\ &\geq n \cdot \mathbb{P}(X \geq n) \geq n \cdot \mathbb{P}(X = +\infty) = n \cdot c \end{aligned}$$

$$\Rightarrow E[X] = \lim_{n \rightarrow +\infty} E[X_n] \geq \lim_{n \rightarrow +\infty} nc = +\infty$$

Di nuovo, come abbiamo fatto nel capitolo precedente, scomponiamo una V.A. reale nella sua parte positiva e negativa, riuscendo così a definire il suo integrale, finito od infinito.

DEFINIZIONE 7.3 Ammissione del Valore Atteso : Sia $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria, e siano $X_+ := X \vee 0$, $X_- := (-X) \vee 0$. Allora X ammette Valore Atteso se:

$$E[X_+] < +\infty \quad \text{oppure} \quad E[X_-] < +\infty$$

In tal caso:

$$E[X] = E[X_+] - E[X_-] = \begin{cases} +\infty \\ |c| < +\infty \\ -\infty \end{cases}$$

DEFINIZIONE 7.4 Integrabilità di X : Sia $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria. Questa si definisce integrabile se:

$$E[X_+] < +\infty \quad \text{e} \quad E[X_-] < +\infty$$

In tal caso:

$$E[X] = E[X_+] - E[X_-] \in \mathbb{R}$$

Possiamo di nuovo ridefinire lo spazio $\mathcal{L}^1$ su uno spazio di probabilità:

$$\begin{aligned} \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P}) &= \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid E[|X|] < +\infty \right\} \\ &= \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid \int_{\Omega} |X| d\mathbb{P} < +\infty \right\} \end{aligned}$$

7.3 Proprietà del Valore Atteso

Cerchiamo di riassumere tutte le proprietà che possiede $E[X]$, ed andiamo a definirne di ulteriori rispetto all'integrazione rispetto ad una misura σ -finita.

TEOREMA 7.5 Proprietà del Valore Atteso : Riassumiamo tutte le proprietà del Valore Atteso $E[X]$:

1. $\mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P})$ è uno spazio vettoriale:

$$\forall X, Y \in \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P}), \alpha, \beta \in \mathbb{R} \Rightarrow \alpha X + \beta Y \in \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P})$$

Inoltre, $E : \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P}) \longrightarrow \mathbb{R}$ è una mappa lineare, positiva e monotona:

- $E[\alpha X + \beta Y] = \alpha E[X] + \beta E[Y]$ (Lineare)
- $\forall X \geq 0 \Rightarrow E[X] \geq 0$ (Positiva)
- $Y \in \mathcal{L}^1, Y \geq X \geq 0 \Rightarrow X \in \mathcal{L}^1 \quad E[Y] \geq E[X] \geq 0$ (Monotona)

2. $X \geq 0, E[X] = 0 \Rightarrow X = 0$ quasi certamente

3. $X, Y \geq 0, \alpha, \beta \geq 0 \Rightarrow \alpha E[X] + \beta E[Y]$

4. $X \in \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P}) \iff |X| \in \mathcal{L}^1(\Omega, \mathcal{A}, \mathbb{P})$ e $|E[X]| \leq E[|X|]$

5. $X = Y$ q.c. $\Rightarrow E[X] = E[Y]$

6. Convergenza Monotona (Beppo Levi):

Sia $(X_n)_{n \geq 1}$ tale che $X_{n+1} \geq X_n \geq 0$ quasi certamente, $X \geq 0$ v.a., tali che: $\lim_{n \rightarrow \infty} X_n = X$ quasi certamente :

$$\Rightarrow \lim_{n \rightarrow \infty} E[X_n] = E[X] = E \left[\lim_{n \rightarrow \infty} X_n \right]$$

7. Convergenza Dominata (Lebesgue): Sia $(X_n)_{n \geq 1}, X$ v.a., tali che: $\lim_{n \rightarrow \infty} X_n = X$ quasi certamente e si abbia che $\exists Y \in \mathcal{L}^1 : |X_n| \leq Y$ quasi certamente:

$$\Rightarrow X_n, X \in \mathcal{L}^1 \quad \text{e} \quad \lim_{n \rightarrow \infty} E[X_n] = E[X] = E \left[\lim_{n \rightarrow \infty} X_n \right]$$

Ossia che: $E \left[\lim_{n \rightarrow \infty} |X_n - X| \right] = 0$

Tutti i risultati di questo teorema valgono per una μ generica σ -finita, e quindi anche nel caso particolare in cui $\Omega = \mathbb{R}, \mathcal{A} = \mathcal{B}, \mu = \mathbb{P}$. Inoltre tutti i risultati che valgono per i valori attesi $E[X]$, valgono quasi certamente, questo significa che se $Y = X$ q.c. valgono anche per $E[Y]$.

Siccome in questo capitolo stiamo trattando il caso specifico in cui $\mu = \mathbb{P}$, e la probabilità è una misura finita e non semplicemente σ -finita, l'integrale (quindi $E[X]$) gode di altre proprietà specifiche:

COROLLARIO 7.6: Siccome $\mathbb{P}$ è una misura finita, allora $E[X]$ gode anche delle seguenti proprietà:

8. $X = c$ quasi certamente $\Rightarrow X \in \mathcal{L}^1$ e $E[X] = c$
9. $E[X] > 0 \Rightarrow \mathbb{P}(X > 0) > 0$
10. $E[|X|] = E[X_+] + E[X_-]$

11. $a \leq X \leq b$ quasi certamente $\Rightarrow a \leq E[X] \leq b$

Dimostrazione. 8. $X = c$ quasi certamente $\xRightarrow{7.5(5)} E[X] = E[c] = c \cdot \mathbb{P}(\Omega) = c$

9. $E[X] = E[X_+] - E[X_-] > 0 \Rightarrow E[X_+] > E[X_-] \geq 0$. Allora $E[X_+] > 0$
 $\Rightarrow \int_{\{X>0\}} X d\mathbb{P} > 0 \Rightarrow \mathbb{P}(X > 0) > 0$

10. Ovia.

11. Sia $a \leq X \leq b \Rightarrow |X| \leq |a| \vee |b| \xRightarrow{7.5(1)+(8)} E[|X|] \leq E[|a| \vee |b|] = |a| \vee |b|$.
 Di conseguenza $X \in \mathcal{L}^1$, quindi è lecito calcolarne il valore atteso.
 Dato che $E[X - a] \geq 0 \Rightarrow E[X] \geq a$. Stesso ragionamento per b

□

Due considerazioni importanti su questo teorema e corollario:

- Tutte le uguaglianze o disequazioni che riguardano $E[\cdot]$, non sono intese in senso “quasi certo”, bensì in senso certo. Questo perché $E[\cdot] \in \mathbb{R}$, non è una funzione.
- Si noti come le proprietà esposte nel Corollario 7.6 siano intuitivamente valide solo perchè $\mathbb{P}(\Omega) = 1$. Per esempio le costanti (8.) non si integrano su illimitati di $\mathbb{R}$ rispetto a m , e nemmeno le funzioni limitate (11.) sono sempre integrabili su domini illimitati.

Prendiamo in esame un'applicazione estremamente utile, ovvero dove Ω è discreto. *Esiste una maniera operativa per poter calcolare il valore atteso, “senza passare” dall'integrale?*


Sia Ω discreto, ossia: $\Omega = \{w_n : n \geq 1\}$. Si prenda $\mathcal{A} = 2^\Omega$ e $X \in \mathcal{L}^1$. Allora per il Teorema 2.7 si ha che $\mathbb{P} \leftrightarrow (p_n)_{n \geq 1} : p_n = \mathbb{P}(\{w_n\})$.

Allora è vero che:

$$E[X] = \int_{\Omega} X d\mathbb{P} = \sum_{n \geq 1} X(w_n) \cdot p_n$$

Dimostrazione. Sia $X : \Omega \rightarrow [0, +\infty]$ ed Ω numerabile. Definiamo la seguente successione di funzioni:

$$X_k(w) = \begin{cases} X(w), & \text{se } w \in \{w_1, \dots, w_k\} \\ 0 & \text{se } w \notin \{w_1, \dots, w_k\} \end{cases}$$



X_k può quindi assumere un numero finito di valori, quindi:

$$E[X_k] = \sum_{h=1}^k X(w_h) p_h$$

Dove:

- X_k è una successione di funzioni crescenti, in quanto $X_{k+1} \geq X_k$,
- Per costruzione: $\lim_{k \rightarrow +\infty} X_k(w) = X(w) \quad \forall w \in \Omega$

Si può quindi usare il Teorema di Beppo Levi:

$$E[X] = \lim_{k \rightarrow +\infty} E[X_k] = \lim_{k \rightarrow +\infty} \sum_{h=1}^k X(w_h) \mathbb{P}(w_h) = \lim_{k \rightarrow +\infty} \sum_{h=1}^k X(w_h) p_h$$

In particolare si ha che:

$$E[|X|] = \sum_{h=1}^{\infty} |X(w_h)| p_h$$

Di conseguenza: $X \in \mathcal{L}^1(\Omega, 2^\Omega, \mathbb{P}) \iff \sum_{h=1}^{\infty} |X(w_h)| p_h < +\infty$ □

Questa applicazione al caso discreto è molto utile in campo applicativo, in quanto se, per esempio, si ha una variabile aleatoria distribuita come una Poisson, allora possiamo calcolare in maniera estremamente facile il suo valore atteso:

Sia $\Omega = \mathbb{N}$; $\mathcal{A} = 2^\mathbb{N}$; $\mathbb{P} = \text{Poisson}(\lambda)$, $\lambda > 1$, ovvero che $p_k = \frac{e^{-\lambda} \lambda^k}{k!} \quad \forall k \geq 0$.

Si consideri la variabile aleatoria $X : \Omega \rightarrow \mathbb{R} : X(k) = k!$, $k \in \mathbb{N}$. Allora possiamo calcolare $E[X]$ come segue:

$$E[X] = \sum_{k=0}^{\infty} X(k) \cdot p_k = \sum_{k=0}^{\infty} k! p_k = e^{-\lambda} \sum_{k=0}^{\infty} \lambda^k = +\infty$$

Abbiamo quindi calcolato in questo caso che il valore atteso è ∞ , anche se $\mathbb{P}(X = +\infty) = 0$.

Abbiamo appena dimostrato che anche se X assume valori reali, non è detto che il valore atteso sia finito, ma soprattutto che:

$$\mathbb{P}(X = +\infty) = 0 \not\Rightarrow E[X] < +\infty$$

Ovviamente anche la Definizione 6.12 è valida nel caso in cui si integri rispetto ad una misura di probabilità:

DEFINIZIONE 7.7: $\forall A \in \mathcal{A} :$

$$\int_A X(w) d\mathbb{P} = \int_\Omega (X \mathbb{I})_A d\mathbb{P} = E[X \mathbb{I}_A]$$

In particolare:

$$\forall A \in \mathcal{A} : \quad \mathbb{P}(A) = 1 \cdot \mathbb{P}(A) + 0 \cdot \mathbb{P}(A^c) = \int_\Omega \mathbb{I}_A d\mathbb{P} = \int_A d\mathbb{P} = E[\mathbb{I}_A]$$

TEOREMA 7.8 Disuguaglianza di Markov : Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e sia $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria reale.

$$\Rightarrow \quad \forall a > 0 : \quad \mathbb{P}(|X| \geq a) \leq \frac{E[|X|]}{a}$$

Dimostrazione. Grazie alla Definizione 7.7 sappiamo che:

$$\mathbb{P}(|X| \geq a) = E[\mathbb{I}_{(|X| \geq a)}]$$

Inoltre, affinché $w \in (|X| \geq a) \Rightarrow |X(w)| \geq a \iff \frac{|X(w)|}{a} \geq 1$.
Quindi l'identità dell'insieme $|X| \geq a$ risulta essere:

$$\mathbb{I}_{(|X| \geq a)}(w) = \begin{cases} 1 \leq \frac{|X(w)|}{a}, & \text{se } w \in (|X| \geq a) \\ 0, & \text{se } w \notin (|X| \geq a) \end{cases}$$

Dunque:

$$\mathbb{I}_{(|X| \geq a)}(w) \leq \frac{|X(w)|}{a} \cdot \mathbb{I}_{(|X| \geq a)} \stackrel{\mathbb{I}_{(|X| \geq a)} \leq 1}{\leq} \frac{|X(w)|}{a} \cdot 1$$

Di conseguenza, per monotonia del valore atteso avremo che:

$$\mathbb{P}(|X| \geq a) = E[\mathbb{I}_{(|X| \geq a)}] \leq E\left[\frac{|X|}{a}\right] = \frac{E[|X|]}{a}$$

□

7.4 Spazio L^p

Consideriamo due variabili aleatorie $X, Y : \Omega \rightarrow \mathbb{R}$ definite sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$. Può accadere che

$$X(w) \neq Y(w) \quad \text{per alcuni } w \in \Omega,$$

ma che le due siano uguali quasi certamente, cioè $\mathbb{P}(X = Y) = 1$. In termini di misura, come abbiamo già detto, questo significa che la differenza tra X e Y è rilevante solo su un insieme di probabilità nulla.

Tuttavia, molte proprietà fondamentali, come

$$E(X) = \int_{\Omega} X \, d\mathbb{P},$$

non cambiano se si modifica X su un insieme di probabilità zero. Se lavorassimo direttamente con le funzioni, potremmo quindi avere due funzioni *diverse come oggetti puntuali*, ma che rappresentano la stessa “realtà probabilistica”, poiché hanno la stessa integrale, la stessa distribuzione e coincidono quasi ovunque.

Per questo motivo, nella teoria della misura e della probabilità non ha senso distinguere funzioni che differiscono solo su insiemi di misura nulla. Si nota a questo punto che $X \stackrel{\text{q.c.}}{=} Y$ è una vera e propria **relazione di equivalenza**, in quanto è riflessiva, simmetrica e transitiva.

Ha senso andare a lavorare non più con le funzioni, ma con le classi di equivalenza. Possiamo quindi definire un nuovo spazio sul quale lavorare:

DEFINIZIONE 7.9: Si definisce la classe di equivalenza rispetto alla relazione di equivalenza quasi certa:

$$[X] = \{Y \in \mathcal{L}^1 : Y = X \text{ q.c.}\}.$$

L'insieme $\mathcal{L}^1$ quozientato rispetto all'uguaglianza quasi certa, si definisce spazio

$$L^1 = \mathcal{L}^1 / \sim = \left\{ \text{Insieme delle classi di equivalenza } [X] \mid X \in \mathcal{L}^1 \right\}$$

L^1 è quindi l'insieme di tutte le classi di equivalenza di funzioni integrabili (in senso di Lebesgue) che coincidono quasi certamente. In altre parole, in L^1 non lavoriamo più con le singole funzioni, ma con le classi di equivalenza, poiché le differenze su insiemi di misura nulla non hanno effetto né sull'integrale, né sulle proprietà analitiche rilevanti.

In teoria della misura e della probabilità, L^1 è lo spazio naturale dove vive l'integrale di Lebesgue.

⚠ Abbiamo quindi capito che $\mathcal{L}^1$ e L^1 sono due insiemi ben differenti, tuttavia in questo corso andremo ad utilizzare un piccolo *abuso di notazione*: scriveremo infatti che $X \in L^1$, al posto che scrivere $[X] \in L^1$.

È come se utilizzassimo la scrittura

$$L^1(\Omega, \mathcal{A}, \mathbb{P}) = \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid E[|X|] < +\infty \right\}$$

ma tenendo sempre ben saldo a mente che non stiamo lavorando con funzioni, ma con le loro classi di equivalenza **⚠**

Osserviamo inoltre che L^1 è uno spazio vettoriale, ossia che:

$$X_1 \stackrel{\text{q.c.}}{=} X_2; Y_1 \stackrel{\text{q.c.}}{=} Y_2; X_1, X_2, Y_1, Y_2 \in L^1 \Rightarrow \forall \alpha, \beta \in \mathbb{R} \quad \alpha X_1 + \beta Y_1 = \alpha X_2 + \beta Y_2$$

Possiamo estendere questo concetto ad uno più generale:

DEFINIZIONE 7.10: Definiamo lo spazio $\mathcal{L}^p$, $\forall 1 \leq p < +\infty$ come segue:

$$\mathcal{L}^p = \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid E[|X|^p] < +\infty \right\}$$

Allo stesso modo di prima definiamo:

$$L^p = \left\{ \text{Insieme delle classi di equivalenza } [X] \mid |X|^p \in \mathcal{L}^1 \right\}$$

⚠ Con lo stesso abuso di notazione precedente, utilizzeremo

$$L^p(\Omega, \mathcal{A}, \mathbb{P}) = \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid E[|X|^p] < +\infty \right\}$$

Come è facile immaginarsi, se una variabile aleatoria è costante $X = c$, allora $X \in L^p$, $\forall 1 \leq p < +\infty$ e $E[|X|^p] = |c|^p$

TEOREMA 7.11: Valgono le seguenti proprietà, nel caso in cui integriamo per una misura di probabilità:

$$1. L^2 = \left\{ X : \Omega \rightarrow \mathbb{R} \text{ V.A.} \mid E[|X|^2] < +\infty \right\} \subseteq L^1$$

2. L^2 è uno spazio vettoriale: $X, Y \in L^2 \Rightarrow \forall \alpha, \beta \in \mathbb{R} \quad \alpha X + \beta Y \in L^2$

3. Disuguaglianza di Cauchy–Schwarz:

$$X, Y \in L^2 \Rightarrow X \cdot Y \in L^1 \text{ e } |E[X \cdot Y]| \leq \sqrt{E[X^2] \cdot E[Y^2]}$$

4. $\forall 1 \leq p \leq q < +\infty$ vale che $L^q \subseteq L^p$

Si presti particolare attenzione che questo teorema è valido solo nel caso in cui si sta integrando rispetto ad una misura di probabilità (la quale è una misura finita). Si possono definire gli spazi L^p su un generico spazio di misura $(E, \mathcal{E}, \mu)$. Non è infatti detto che se si prende una misura σ -finita allora, per esempio, $L^p \subseteq L^q$ se $p \leq q$.

ESEMPIO : Si prenda in esame la funzione $f(x) = \frac{1}{x}$ nel dominio $(1, +\infty) =: D$, e la si integri rispetto la misura di Lebesgue m .

Avremo che:

$$\int_{(1, +\infty)} |f(x)| \, dm = \int_1^{+\infty} \frac{1}{x} \, dx = +\infty \quad \Rightarrow \quad f \notin L^1(D, \mathcal{B}(D), m)$$

Tuttavia:

$$\int_{(1, +\infty)} |f(x)|^2 \, dm = \int_1^{+\infty} \frac{1}{x^2} \, dx < +\infty \quad \Rightarrow \quad f \in L^2(D, \mathcal{B}(D), m)$$

Abbiamo dimostrato che non è vero che $L^2 \subseteq L^1$ nel caso in cui si integri rispetto ad una misura σ -finita.

7.5 Varianza

La varianza è una delle grandezze fondamentali della teoria della probabilità e della statistica, poiché misura la **dispersione** dei valori assunti da una variabile aleatoria rispetto al suo valore medio. Se il valore atteso descrive il “centro” della distribuzione, la varianza ne quantifica invece la **variabilità**, indicando quanto i possibili esiti si discostano, in media, da tale centro.

Comprendere la varianza significa quindi analizzare quanto è stabile o incerta una grandezza aleatoria: una varianza piccola implica che i valori osservati sono concentrati attorno alla media, mentre una varianza elevata segnala una forte variabilità e dunque una maggiore incertezza.




Figura 7.1: Stessa media, varianza crescente: la curva si allarga al crescere della dispersione.

Diamo quindi la definizione formale di Varianza.

DEFINIZIONE 7.12 ▲: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e sia $X \in L^2(\Omega, \mathcal{A}, \mathbb{P})$. Definiamo la Varianza di X il numero:

$$\text{Var}(X) := \sigma^2 := E[(X - E[X])^2]$$

Si osservi che dato che stiamo integrando rispetto ad una misura di probabilità, allora dato che $X \in L^2$ implica che $X \in L^1$, e quindi $E[X] < +\infty$.

TEOREMA 7.13 Proprietà della Varianza: Per ogni variabile aleatoria $X \in L^2$, valgono le seguenti proprietà:

1. $\text{Var}(X) = E[(X - E[X])^2] \geq 0$
2. $\text{Var}(X) = 0 \iff \exists c \in \mathbb{R} \text{ tale che } X \stackrel{\text{q.c.}}{=} c \text{ e } E[X] = c \iff P^X \sim \delta_c$
3. Disuguaglianza di Chebychev:

$$\mathbb{P}(|X - E[X]| \geq a) \leq \frac{\sigma^2}{a^2} \quad \forall a > 0$$

4. $\text{Var}(X) = E[X^2] - E[X]^2$
5. $\text{Var}(aX + b) = a^2 \text{Var}(X) \quad \forall a, b \in \mathbb{R}$

Dimostrazione. Dimostriamo solo la 3. e 5.

3. Vedendo che $(|X - E[X]| \geq a) = (|X - E[X]|^2 \geq a^2)$, possiamo usare la disuguaglianza di Markov (Teorema 7.8) con $Y = |X - E[X]|^2 = (X - E[X])^2$:

$$\begin{aligned} \mathbb{P}(|Y| \geq a^2) \leq \frac{E[Y]}{a^2} &\iff \mathbb{P}((X - E[X])^2 \geq a^2) = \mathbb{P}((X - E[X])^2 \geq a^2) \\ &\leq \frac{E[(X - E[X])^2]}{a^2} = \frac{\sigma^2}{a^2} \end{aligned}$$

5. $\text{Var}(aX + b) = E[(aX + b - E[aX + b])^2] = E[(aX - aE[X])^2] = a^2 \text{Var}(X)$

□

7.6 Regola del Valore Atteso

Vediamo adesso un metodo per calcolare in modo concreto il valore atteso nelle applicazioni reali: la regola del valore atteso

Questa regola ci permette di semplificare il calcolo del valore atteso quando la variabile aleatoria può essere espressa in funzione di un'altra. Si tratta di uno strumento fondamentale nella pratica, poiché consente di passare da un approccio puramente teorico a uno operativo, applicabile a problemi reali di previsione, stima e decisione.

Se guardiamo al problema con solo la "lente della teoria della misura", allora quello che stiamo per fare è definire un modo per calcolare l'integrale di funzioni misurabili e delle loro composizioni: nulla di più, nulla di meno.

DEFINIZIONE 7.14 **▲ Regola del valore Atteso :** Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e $(E, \mathcal{E})$ uno spazio misurabile. Si considerino $X : \Omega \rightarrow \mathbb{R}$ variabile aleatoria e $h : E \rightarrow \mathbb{R}$ oppure $[0, +\infty]$ misurabile. Allora vale che:


1. $h(X) \in L^1(\Omega, \mathcal{A}, \mathbb{P}) \iff h \in L^1(E, \mathcal{E}, P^X)$
2. Sia nel caso in cui $h : E \rightarrow [0, +\infty]$, sia nel caso in cui $h \in L^1(\cdot)$, si ha che:

$$E[h(X)] = \int_{\Omega} h(X) d\mathbb{P} = \int_E h dP^X := E^X(h)$$

Questo teorema è molto importante nel calcolo del valore atteso, poiché afferma che svolgere l'integrale su Ω equivale a calcolarlo su E . Infatti, in molti casi il dominio Ω può essere un insieme astratto composto da oggetti qualsiasi, su cui non è definita l'integrabilità.

Imponendo $E = \mathbb{R}$, il calcolo si trasforma in un integrale su $\mathbb{R}$, rendendolo possibile o comunque più agevole.

ESEMPIO : Prendiamo per esempio il caso in cui $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B})$ e $h : \mathbb{R} \rightarrow \mathbb{R}$.



Se si assume che $h = \text{Id}(x) : \mathbb{R} \rightarrow \mathbb{R}$ definita come $\text{Id}(x) = x$, allora abbiamo un modo estremamente concreto di calcolare il valore atteso di una variabile aleatoria, ossia:

$$E[h(X)] = \int_{\Omega} \text{Id}(X) d\mathbb{P} = \int_{\mathbb{R}} \text{Id}(x) dP^X = \int_{\mathbb{R}} x dP^X \Rightarrow E[X] = \int_{\mathbb{R}} x dP^X$$

Questo teorema ci permette di capire un altro fatto fondamentale: **il valore atteso è una proprietà esclusivamente delle legge** di una variabile aleatoria. Presi infatti $X_1 : (\Omega_1, \mathcal{A}_1, \mathbb{P}_1) \rightarrow (\mathbb{R}, \mathcal{B})$, $X_2 : (\Omega_2, \mathcal{A}_2, \mathbb{P}_2) \rightarrow (\mathbb{R}, \mathcal{B})$, e $h = \text{Id}(x) : \mathbb{R} \rightarrow \mathbb{R}$ allora:

$$\text{se } P^{X_1} = P^{X_2} \Rightarrow E[X_1] = \int_{\Omega_1} x dP^{X_1} = \int_{\Omega_2} x dP^{X_2} = E[X_2]$$

8 Variabili Aleatorie Discrete

In questo capitolo ci occuperemo delle variabili aleatorie reali discrete, una delle famiglie più importanti nel calcolo delle probabilità. Si tratta di variabili la cui probabilità è concentrata su singoli valori, in numero finito o numerabile, e che possono essere considerate come un'estensione delle variabili semplici. Vedremo come i concetti generali introdotti in precedenza si concretizzano e si semplificano nel caso discreto.

DEFINIZIONE 8.1: $X : \Omega \rightarrow \mathbb{R}$ è una Variabile Aleatoria Discreta se la sua legge P^X è una probabilità discreta su $\mathcal{B}(\mathbb{R})$ (Teorema 3.22), ossia che:

1. $\exists T \subseteq \mathbb{R}$ discreto
2. $\exists p_X : T \rightarrow \mathbb{R}$, definita densità discreta, tale che:

$$P^X(B) = \sum_{t \in B \cap T} p_X(t) \quad \forall B \in \mathcal{B}(\mathbb{R})$$

Definiamo il supporto $S = \{t \in T : p_X(t) > 0\} \subseteq T$ discreto.

DEFINIZIONE 8.2 Definizioni Equivalenti alla 8.1: X è una variabile aleatoria discreta:

$$\begin{aligned} &\iff \sum_{t \in S} (F_X(t) - F_X(t^-)) = 1 \quad \text{con} \quad S = \{\text{punti di discontinuità}\} \\ &\iff \exists T \subseteq \mathbb{R} \text{ discreto, tale che } \mathbb{P}(X \in T) = 1 \\ &\iff \exists Y \text{ variabile aleatoria, con } \text{Im}(Y) \subseteq T \text{ tale che: } X \stackrel{\text{q.c.}}{=} Y \end{aligned}$$

ESEMPIO: Sia X una variabile aleatoria tale che $\mathbb{P}(X \in T) = 1$, allora di conseguenza $\exists A \in \mathcal{A}$, $\mathbb{P}(A) = 1$, tale che $X(w) \in T$.

Possiamo costruire la variabile aleatoria Y tale che: $Y(w) = \begin{cases} X(w), & \forall w \in (X \in T) \\ x_0 \in T, & \forall w \in (X \in T)^c \end{cases}$

La quale ha che $\text{Im}(Y) \subseteq T$ per costruzione. Sempre per costruzione si ha che:

$$(X = Y) = (X \in T) \Rightarrow \mathbb{P}(X = Y) = \mathbb{P}(X \in T) = 1$$

L'esempio mostra come, se una variabile aleatoria X assume valori in un insieme discreto T con probabilità uno, allora sia sempre possibile costruire un'altra variabile aleatoria Y che coincida con X su $(X \in T)$ ed assume un valore fissato $x_0 \in T$ al di fuori di tale insieme.

Così facendo si ottiene una formulazione più rigorosa: ogni variabile aleatoria la cui legge è concentrata su un insieme discreto può essere rappresentata, a meno di eventi di probabilità nulla, da una variabile *effettivamente discreta*. Questo permette di lavorare senza perdita di generalità con variabili che assumono valori solo in T .

PROPOSIZIONE 8.3 Regola del Valore Atteso Discreto : Sia X una variabile aleatoria discreta definita su $(\Omega, \mathcal{A}, \mathbb{P})$, con T e p la sua densità discreta.

Allora: $\forall h : \mathbb{R} \rightarrow [0, +\infty]$ oppure $\forall h \in L^1(\mathbb{R}, \mathcal{B}, P^X)$ si ha che:

$$E[h(X)] = \int_{\mathbb{R}} h(x) dP^X = \sum_{t \in S} h(t) \cdot p_X(t)$$

Per il punto 1. della Regola del Valore atteso (7.14), si ha evidentemente che per una variabile aleatoria discreta:

$$\begin{aligned} h(X) \in L^1(\Omega, \mathcal{A}, \mathbb{P}) &\iff h \in L^1(\mathbb{R}, \mathcal{B}, P^X) \\ &\iff \int_{\mathbb{R}} |h(t)| dP^X < +\infty \\ &\iff \sum_{t \in S} |h(t)| p_X(t) < +\infty \end{aligned}$$

Di conseguenza, possiamo osservare due fatti importanti:

1. $X \in L^1(\Omega, \mathcal{A}, \mathbb{P}) \iff h(t) = \text{Id}(t), \quad \sum_{t \in S} |t| p_X(t) < +\infty.$
Se quindi $X \in L^1$ allora:

$$E[X] = \sum_{t \in S} t p_X(t)$$

2. $X \in L^2(\Omega, \mathcal{A}, \mathbb{P}) \iff h(t) = t^2, \quad E[h(X)] = E[X^2] = \sum_{t \in S} t^2 p_X(t) < +\infty.$

Allora possiamo calcolare la $\text{Var}(X)$ vedendo $h(t) = (t - E[t])^2$:

$$\text{Var}(X) = E[(X - \mu)^2] = E[h(X)] = \sum_{t \in S} (t - \mu)^2 p_X(t)$$

ESEMPIO : Facciamo due esempi per metabolizzare i concetti.

★ Sia $X \sim \mathcal{U}(\{1, \dots, n\})$. Allora P^X è discreta, con $T = \{1, \dots, n\}$ e $p_X(t) = \frac{1}{n} \quad \forall t \in T$. Allora:

$$E[X] = \sum_{t \in T} t p_X(t) = \sum_{k=1}^n k p_X(k) = \sum_{k=1}^n k \frac{1}{n} = \frac{n(n+1)}{2n} = \frac{n+1}{2}$$

$$\text{Var}(X) = \sum_{k=1}^n \left(k - \frac{n+1}{2} \right)^2 \frac{1}{n} = E[X^2] - E[X]^2 = \sum_{k=1}^n \frac{k^2}{n} - \left(\frac{n+1}{2} \right)^2 = \dots = \frac{n^2 - 1}{12}$$

★ Se invece consideriamo $X : \mathbb{N} \rightarrow \mathbb{R}, \quad \Omega = \mathbb{N}, \quad \mathcal{A} = 2^{\mathbb{N}}, \quad \mathbb{P} \sim \text{Po}(\lambda)$ con $\lambda > 1$ tale che $X(k) = k!$. Allora possiamo calcolare il valore atteso; definendo $h(k) = k$; allora $h(X(k)) = X(k) = k!$ e $S = \{0!, 1!, 2!, \dots\}$

$$E[X] = \sum_{k=0}^{+\infty} k! \frac{e^{-\lambda} \lambda^k}{k!} = +\infty$$

9 Variabili Aleatorie Assolutamente Continue

Dopo aver analizzato il caso discreto, passiamo ora a studiare una diversa e fondamentale categoria di variabili aleatorie: quelle *assolutamente continue*. A differenza delle variabili discrete, la loro probabilità non è concentrata su singoli punti, bensì si distribuisce in modo continuo su un insieme di valori reali. In questo contesto, la probabilità che la variabile assuma un valore esatto è nulla, mentre assume significato la probabilità che essa cada all'interno di un intervallo.

Questa rappresentazione permette di esprimere tutte le proprietà probabilistiche di X in termini analitici, utilizzando strumenti del calcolo integrale.

Nel seguito introdurremo le principali caratteristiche delle variabili assolutamente continue, analizzando la funzione di densità, la funzione di ripartizione e le loro relazioni, per poi studiare alcuni esempi classici.

Prima di dare la definizione di variabile aleatoria continua, dobbiamo definire cosa sia una Probabilità assolutamente continua.

DEFINIZIONE 9.1: Un Probabilità su $\mathcal{B}(\mathbb{R})$ si dice Assolutamente Continua se

$$\exists f : \mathbb{R} \rightarrow [0, +\infty]$$

boreliana, definita *densità continua* di $\mathbb{P}$, tale che la funzione di ripartizione F di $\mathbb{P}$ si scrive come segue:

$$F(x) = \mathbb{P}((-\infty, x]) = \int_{-\infty}^x f(t) dt \quad \left(= \int_{(-\infty, x]} f dm \right)$$

Si noti che se f è una densità continua, allora vale che:

$$\int_{\mathbb{R}} f(t) dt = 1$$

Difatti:

$$\int_{\mathbb{R}} f dm = \int_{-\infty}^{+\infty} f(t) dt = \lim_{n \rightarrow +\infty} \underbrace{\int_{-\infty}^n f(t) dt}_{F(n)} = \lim_{n \rightarrow +\infty} F(n) = 1$$

TEOREMA 9.2 Caratterizzazione di una Densità Continua : Valgono i seguenti:

1. $f : \mathbb{R} \rightarrow \mathbb{R}$ è una densità continua di una probabilità $\mathbb{P}$ assolutamente continua se e solo se:
 - (a) f è Boreliana
 - (b) $f \geq 0$
 - (c) $\int_{\mathbb{R}} f(x) dx = 1$
2. Se vale (1.), allora:

$$\mathbb{P}(A) = \int_A f dm = \int_{\mathbb{R}} f(t) \cdot \mathbb{I}_A(t) dm \quad \forall A \in \mathcal{B}(\mathbb{R})$$

3. $\mathbb{P}$ su $\mathcal{B}(\mathbb{R})$ assolutamente continua è caratterizzata dalla sua densità, ossia:

$$f_1 = f_2 \text{ quasi certamente} \iff \mathbb{P}_1 = \mathbb{P}_2$$

PROPOSIZIONE 9.3: Se la funzione di ripartizione $F \in C^0 \cap C^1$ a tratti, allora $\exists f$ densità continua tale che

$$f = \begin{cases} f(t) = F'(t), & \text{se } \exists F' \\ f(t) = 0 & \text{altrove} \end{cases}$$

e quindi $\mathbb{P}$ associata ad F è assolutamente continua.


ESEMPIO: Facciamo due esempi:

★ Sia $F(t) = (1 - e^{-\lambda t})\mathbb{I}_{(0,+\infty)}$ con associata la sua probabilità $\mathbb{P}$.

Allora siccome F è ovunque derivabile tranne che nello zero, si ha che $\mathbb{P}$ è assolutamente continua e la sua densità vale:

$$f(t) = \begin{cases} \lambda e^{-\lambda t}, & \text{se } t > 0 \\ 0, & \text{se } t \leq 0 \end{cases}$$

★ Sia $F(t) = \frac{t-a}{b-a}\mathbb{I}_{[a,b]}(t) + \mathbb{I}_{(b,+\infty)}$.



Si vede disegnando la funzione che $F \in C^1$ a tratti ed è continua, allora $\mathbb{P}$ è assolutamente continua e vale che:

$$f(t) = \begin{cases} \frac{1}{b-a}, & \text{se } t \in [a, b] \\ 0, & \text{altimenti} \end{cases} = \frac{1}{b-a}\mathbb{I}_{[a,b]}(t)$$

Si noti che nell'ultimo esempio si poteva tranquillamente prendere $\tilde{f}(t) = \frac{1}{b-a}\mathbb{I}_{(a,b)}(t)$, tanto a noi interessa la classe di equivalenza del rappresentante (che è per esempio $f(t)$).

Inoltre, se $\mathbb{P}$ è assolutamente continua, allora $F(t) = \int_{-\infty}^t f(x) dx$ è una funzione continua.

DEFINIZIONE 9.4: $X : \Omega \rightarrow \mathbb{R}$ è Assolutamente Continua se P^X è una misura di probabilità Assolutamente Continua, e definiamo f_X la sua densità.

Si osservi che data $a \leq X \leq b$ quasi certamente, con $a, b \in \mathbb{R}$, allora:

$$\mathbb{P}(X \in [a, b]) = 1 \iff f_X(t) = 0 \text{ quasi certamente } \forall t \in [a, b]^c$$

TEOREMA 9.5 Regola del Valore Atteso Continuo : Sia $X : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria assolutamente continua con legge P^X e densità f_X .

Sia $h : \mathbb{R} \rightarrow \mathbb{R}$ boreliana, allora:

1. La composizione $h(X)$ è tale che

$$\begin{aligned} h(X) \in L^1(\Omega, \mathcal{A}, \mathbb{P}) &\iff h \in L^1(\mathbb{R}, \mathcal{B}, P^X) \\ &\iff h \cdot f_X \in L^1(\mathbb{R}, \mathcal{B}, m) \\ &\iff \int_{\mathbb{R}} |h(x)| \cdot f(x) dx < +\infty \end{aligned}$$

2. Se $h \in L^1(P^X)$, oppure se $h : \mathbb{R} \rightarrow [0, +\infty]$, allora:

$$E[h(X)] = \int_{\Omega} h(X) d\mathbb{P} = \int_{\mathbb{R}} h dP^X \stackrel{a}{=} \int_{\mathbb{R}} h(x) f_X(x) dx$$

^aIn questa uguaglianza (e nella seconda implicazione del punto 1.) si usa il fatto che se X è assolutamente continua, allora $dP^X = f_X \cdot dm$. Per chi voglia approfondire, questo deriva dal Teorema di Radon-Nikodým.

Possiamo osservare (come abbiamo fatto nel caso discreto) due fatti importanti:

$$\begin{aligned} 1. X \in L^1(\Omega, \mathcal{A}, \mathbb{P}) &\iff \int_{\mathbb{R}} |t| f_X(t) dt < +\infty \implies E[X] = \int_{\mathbb{R}} t f_X(t) dt. \\ 2. X \in L^2(\Omega, \mathcal{A}, \mathbb{P}) &\iff \int_{\mathbb{R}} t^2 f_X(t) dt < +\infty \implies Var(X) = \int_{\mathbb{R}} (t - \mu)^2 f_X(t) dt \end{aligned}$$

TEOREMA 9.6: Sia $\mathbb{P}$ su $\mathcal{B}$ assolutamente continua con densità f , e sia $A \in \mathcal{B}$ tale che $m(A) = 0$.

$$\implies \mathbb{P}(A) = 0$$

Dimostrazione.

$$\mathbb{P}(A) = \int_A f dm = \int_{\mathbb{R}} f \mathbb{I}_A dm$$

Dove per ipotesi si ha che:

$$m(A) = \int_{\mathbb{R}} \mathbb{I}_A dm = 0 \implies \mathbb{I}_A \in [0]$$

ovvero che $\mathbb{I}_A = 0$ quasi ovunque.

Di conseguenza:

$$\int_{\mathbb{R}} f \mathbb{I}_A dm = 0 = \mathbb{P}(A)$$

□

ESEMPIO: Sia $X \sim \mathcal{U}([a, b])$, ossia che

$$f_X(t) = \frac{1}{b-a} \cdot \mathbb{I}_{[a,b]}(t)$$

Allora $X \in L^1$ e $a \leq E[X] \leq b$, infatti:

$$E[X] = \int_a^b \frac{t}{b-a} dt = \frac{b+a}{2} \in [a, b]$$

ESEMPIO : Sia $X \sim \mathcal{E}(\lambda)$, ossia che

$$f_X(t) = \lambda e^{-\lambda t} \mathbb{I}_{\{t \geq 0\}}$$

Ci chiediamo, $X \stackrel{?}{\in} L^1$? Ricordandoci che:

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx; \quad \text{Se } \alpha = n+1 \Rightarrow \Gamma(n+1) = n! \quad \text{con } n \geq 0$$

Allora possiamo calcolare il valore atteso:

$$E[X] = \int_0^{+\infty} t \lambda e^{-\lambda t} dt \stackrel{t\lambda=x}{=} \frac{1}{\lambda} \int_0^{+\infty} x e^{-x} dx = \frac{\Gamma(2)}{\lambda} = \frac{1}{\lambda} < +\infty$$

Abbiamo appena dimostrato che se $X \sim \mathcal{E}(\lambda)$, $\lambda > 0$, allora $X \in L^1$.

ESEMPIO : Si prenda $X : \Omega \rightarrow \mathbb{R}$ distribuita con una densità di Cauchy:

$$f_X(t) = \frac{1}{\pi} \frac{1}{(1+t^2)}$$

Ci chiediamo di nuovo, $X \stackrel{?}{\in} L^1$?

$$E[|X|] = \int_{\mathbb{R}} |t| f_X(t) dt = \frac{1}{\pi} \int_{\mathbb{R}} \frac{|t|}{1+t^2} dt = \frac{2}{\pi} \int_0^{\infty} \frac{t}{1+t^2} dt = +\infty$$

Ne segue quindi che $X \notin L^1$. Addirittura si ha che la densità di Cauchy non possiede nessun momento assoluto p -esimo finito, difatti:

$$E[|X|^p] < +\infty \iff p < 1$$

dato che all'infinito si ha che

$$\frac{|t|^p}{1+t^2} \sim \frac{1}{t^{2-p}}$$

9.1 Riassunto Utile e Considerazioni Pratiche

Sia $f_X : \mathbb{R} \rightarrow [0, +\infty]$ tale che sia una densità continua. Ci chiediamo: *esiste sempre finito il valore atteso $E[X]$?*

Abbiamo tre casi da vedere:

$$\star f_X(t) = 0 \text{ su } [a, b]^c \iff \mathbb{P}(X \in [a, b]) = 1 = P^X([a, b]) \iff a \leq X \leq b$$

$$\Rightarrow X \in L^1 \text{ e } a \leq E[X] \leq b$$

Il solo fatto che f_X si annulli sul complementare di un intervallo chiuso, mi implica che esista il valore atteso.

$$\star f_X(t) = 0 \text{ su } (-\infty, 0) = [0, +\infty)^c \iff \mathbb{P}(X \in [0, +\infty)) = 1$$

$$\Rightarrow \exists \text{ il valore atteso, ma si hanno due possibilità: } \begin{cases} +\infty \\ c \in \mathbb{R}^+ \end{cases} \Rightarrow X \in L^1(\mathbb{P})$$

$$\star f_X(t) \neq 0 \quad \forall t \in \mathbb{R}$$

In questo caso bisogna prima verificare che $E[X]$ esista

$$\text{Se } E[|X|] = \int_{\mathbb{R}} |t| f_X(t) dt < +\infty \quad \Rightarrow \quad X \in L^1$$

e nel caso calcolarlo come

$$E[X] = \int_{\mathbb{R}} t f_X(t) dt$$

Riassumiamo ora le relazioni tra le condizioni per decretare se una V.A. è continua.

Dato uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ e una variabile aleatoria $X : \Omega \rightarrow \mathbb{R}$.

Allora X è Assolutamente Continua:

$$\iff P^X \text{ ammette densità } f, \quad P^X(B) = \int_B f(x) dx \quad \forall B \in \mathcal{B}$$

$$\iff F_X(t) = \int_{-\infty}^t f(x) dx \quad \forall t \in \mathbb{R}$$

$$\implies F_X \in C^0, \quad \text{ovvero } P^X(\{x\}) = \mathbb{P}(X = x) = F_X(x) - F_X(x_-) = 0$$

$$\iff F_X \in C^0 \cap C^1 \text{ a tratti}$$

In quest'ultimo caso:

$$f(x) = \begin{cases} F'_X(x), & \text{dove } F_X \text{ è derivabile} \\ \text{valore arbitrario,} & \text{altrimenti.} \end{cases}$$

10 Variabili Aleatorie Indipendenti

Dal concetto di indipendenza tra *eventi* discende naturalmente quello di *indipendenza tra variabili aleatorie*, che rappresenta la condizione in cui le variabili considerate non si influenzano reciprocamente. Introduciamo diversi criteri utili a stabilire formalmente l'indipendenza, alcuni dei quali permetteranno di apprezzare il ruolo del valore atteso oltre la semplice interpretazione come indicatore numerico.

Mostreremo inoltre come sia possibile costruire variabili aleatorie indipendenti a partire da variabili arbitrarie, e come tale proprietà consenta di estendere la teoria precedente ai *prodotti cartesiani* tra domini, dando origine alle corrispondenti σ -algebre prodotto e alle relative misure di probabilità.

Tale struttura consentirà di introdurre le *leggi congiunte*, ottenute a partire dalle *leggi marginali* mediante l'applicazione del fondamentale *teorema di Fubini-Tonelli*. Questo ci condurrà infine verso lo studio dei *vettori aleatori*, ossia variabili aleatorie a valori multidimensionali, che rappresentano il naturale passo successivo nell'analisi delle relazioni stocastiche tra più componenti casuali.

10.1 Variabili Aleatorie Unidimensionali

Immaginiamo quindi di avere uno stesso esperimento dal quale si osservano due o più grandezze. Avremo quindi uno stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ sul quale sono definite due variabili aleatorie:

$$X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1, \mathcal{F}_1)$$

$$Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_2, \mathcal{F}_2)$$

Vogliamo quindi studiare quale sia la relazione tra X ed Y .

DEFINIZIONE 10.1: Dato $(\Omega, \mathcal{A}, \mathbb{P})$ e $(F_1, \mathcal{F}_1)$, $(F_2, \mathcal{F}_2)$ spazi misurabili, e le variabili aleatorie

$$X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1, \mathcal{F}_1)$$

$$Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_2, \mathcal{F}_2)$$

Allora X ed Y sono indipendenti se:

$$\forall A \in \mathcal{F}_1, \forall B \in \mathcal{F}_2 \text{ si ha che: } \mathbb{P}((X \in A) \cap (Y \in B)) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B)$$

PROPOSIZIONE 10.2: Si ha che:

$$X \perp\!\!\!\perp Y \iff \sigma(X) \perp\!\!\!\perp \sigma(Y)$$

Si ricorda la Definizione 3.13

ESEMPIO : Si immagini di avere un contenitore con N palline nere e B palline bianche; si estraiga con reimmissione una pallina per k volte.

Possiamo definire $X_k = \begin{cases} 1, & \text{se } k\text{-esima estrazione esce nera} \\ 0, & \text{altrimenti} \end{cases}$

Ci chiediamo, X_1 e X_2 sono indipendenti?

Si noti innanzitutto che $\Omega = \{B, N\} \times \{B, N\}$, e che dato $(w_1, w_2) \in \Omega$ allora conosciamo tutte

le probabilità degli eventi $\mathbb{P}(\{B, N\}) = \frac{BN}{(B+N)^2}$, $\mathbb{P}(\{B, B\})$

Devo verificare che sia valido che

$$\mathbb{P}((X_1 \in A) \cap (X_2 \in B)) = \mathbb{P}(X_1 \in A) \cdot \mathbb{P}(X_2 \in B)$$

dove

$$A, B \in 2^{\{0,1\}} = \left\{ \{0\}, \{1\}, \{0, 1\}, \emptyset \right\} = \sigma(\{1\})$$

Ipotizzando che $A = B = \{1\}$, allora avremo che:

$$\mathbb{P}((X_1 = 1) \cap (X_2 = 1)) = \mathbb{P}(\{N, N\}) = \frac{N}{N+B} \frac{N}{N+B} = \mathbb{P}(X_1 = 1) \cdot \mathbb{P}(X_2 = 1) \quad \checkmark$$

Ipotizzando che $A = B = \{0\}$, allora avremo che:

$$\mathbb{P}((X_1 = 0) \cap (X_2 = 0)) = \mathbb{P}(\{B, B\}) = \frac{B}{N+B} \frac{B}{N+B} = \mathbb{P}(X_1 = 0) \cdot \mathbb{P}(X_2 = 0) \quad \checkmark$$

Posso quindi controllare solo che le controimmagini siano indipendenti per concludere che lo siano tutti gli eventi appartenenti alle σ -algebre delle V.A.

TEOREMA 10.3 Condizioni Equivalenti all'Indipendenza : Siano $(\Omega, \mathcal{A}, \mathbb{P})$, $(F_1, \mathcal{F}_1)$, $(F_2, \mathcal{F}_2)$ assegnati, e siano $X_1 : \Omega \rightarrow F_1$ e $X_2 : \Omega \rightarrow F_2$ variabili aleatorie.

Sono equivalenti le seguenti:

1. $\boxed{X \perp\!\!\!\perp Y}$

2. Date $h : (F_1, \mathcal{F}_1) \rightarrow (E_1, \mathcal{E}_1)$, e $g : (F_2, \mathcal{F}_2) \rightarrow (E_2, \mathcal{E}_2)$

$$\boxed{h(X) \perp\!\!\!\perp g(Y)}$$

3. $\forall h : F_1 \rightarrow \mathbb{R}$ e $\forall g : F_2 \rightarrow \mathbb{R}$ entrambe non negative o limitate $\Rightarrow h(X), g(Y)$ ammettono valore atteso e:

$$\boxed{E[h(X) \cdot g(Y)] = E[h(X)] \cdot E[g(Y)]}$$

4. $\forall h \in L^1(F_1, \mathcal{F}_1, P^X)$ e $\forall g \in L^1(F_2, \mathcal{F}_2, P^Y)$

$$\boxed{E[h(X) \cdot g(Y)] = E[h(X)] \cdot E[g(Y)] = \int_{F_1} h(x) dP^X \cdot \int_{F_2} g(y) dP^Y}$$

Inoltre, applicando quello che già sappiamo dai capitoli precedenti:

$$\begin{aligned} \forall h \in L^1(F_1, \mathcal{F}_1, P^X) \\ \forall g \in L^1(F_2, \mathcal{F}_2, P^Y) \end{aligned} \iff \int_{F_1} |h| dP^X < +\infty \quad \text{e} \quad \int_{F_2} |g| dP^Y < +\infty$$

e quindi:

$$\begin{aligned} E[|h(X)| \cdot |g(Y)|] &= \int_{F_1} |h| dP^X \cdot \int_{F_2} |g| dP^Y = \int_{\Omega} |h(X)| d\mathbb{P} \cdot \int_{\Omega} |g(Y)| d\mathbb{P} \\ &= \int_{\Omega} |h(X) \cdot g(Y)| d\mathbb{P} \end{aligned}$$

$$\Rightarrow h(X), g(Y) \in L^1(\mathbb{P}) \quad \text{e} \quad E[h(X) \cdot g(Y)] = E[h(X)] \cdot E[g(Y)]$$

Possiamo riassumere ciò che abbiamo appena trovato nel seguente corollario:

COROLLARIO 10.4: Se $X, Y \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ e vale che $X \perp\!\!\!\perp Y$:

$$\Rightarrow X \cdot Y \in L^1 \quad \text{e} \quad E[XY] = E[X]E[Y]$$

Dimostrazione. Dal Teorema 10.3.4, con $h, g = \text{Id}$:

$$X \in L^1(\mathbb{P}) \iff \text{Id} \in L^1(P^X)$$

$$Y \in L^1(\mathbb{P}) \iff \text{Id} \in L^1(P^Y)$$

Essendo indipendenti:

$$E[h(X) \cdot g(Y)] = E[X \cdot Y] = E[X] \cdot E[Y]$$

□

Osserviamo che dal Teorema 10.3.2 possiamo ricavare che se $X \perp\!\!\!\perp Y$ e $X = W$ quasi certamente, allora avrò che $W \perp\!\!\!\perp Y$.

10.2 Variabili Aleatorie Multidimensionali: Sigme-Algre Prodotto

Abbiamo visto l'indipendenza tra variabili aleatorie, ma potremmo estendere il ragionamento ai vettori.

Date quindi due variabili aleatorie, costruiamo il vettore che ha per componenti le due V.A.

$$\begin{aligned} X : (\Omega, \mathcal{A}, \mathbb{P}) &\rightarrow (F_1, \mathcal{F}_1) \\ Y : (\Omega, \mathcal{A}, \mathbb{P}) &\rightarrow (F_2, \mathcal{F}_2) \end{aligned} \quad \Longrightarrow \quad \begin{pmatrix} X \\ Y \end{pmatrix} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1 \times F_2, ??)$$

A questo punto ci chiediamo:


- Questo è una variabile aleatoria come vettore?
- La legge congiunta $P^{(X,Y)}$ dove è definita nel caso?

È evidente che tutta la questione può essere ridotta alla seguente domanda: *Dati F_1, F_2 e facendone il prodotto cartesiano $F = F_1 \times F_2$, quale è la σ -algebra "naturale" di questo nuovo dominio F ?*

A prima vista potrebbe sembrare logico prendere $\mathcal{F}_1 \times \mathcal{F}_2$ come σ -algebra di definizione dello spazio di arrivo; questo però non è possibile, in quanto $\mathcal{F}_1 \times \mathcal{F}_2$ **non è** una σ -algebra.

$$\mathcal{F}_1 \times \mathcal{F}_2 = \left\{ C \subseteq F_1 \times F_2 : C = A \times B, \quad A \in \mathcal{F}_1, \quad B \in \mathcal{F}_2 \right\}$$

Questo risulta evidente già nel caso semplice in cui $F_1 = F_2 = \mathbb{R}$. Difatti, presi come da figura $A_1, B_1 \in \mathcal{F}_1$ e $A_2, B_2 \in \mathcal{F}_2$, possiamo costruire gli insiemi prodotto $A = A_1 \times A_2$ e $B = B_1 \times B_2$.



È facile notare che l'intersezione $A \cap B$, può essere espressa come prodotto cartesiano, e dunque è un sottoinsieme di $\mathcal{F}_1 \times \mathcal{F}_2$:

$$A \cap B = (A_1 \cap B_1) \times (A_2 \cap B_2) \in \mathcal{F}_1 \times \mathcal{F}_2$$

Questo purtroppo non è possibile farlo per l'unione $A \cup B$, che anche graficamente si vede che non risulta essere un rettangolo:

$$A \cup B = (A_1 \times A_2) \cup (B_1 \times B_2) \notin \mathcal{F}_1 \times \mathcal{F}_2$$

È quindi evidente che $\mathcal{F}_1 \times \mathcal{F}_2$ non è una σ -algebra, in quanto non è chiusa per unioni (né per complementazione).

Siamo però fortunati lo stesso: $\mathcal{F}_1 \times \mathcal{F}_2$ risulta essere un Π -sistema (Teorema 3.19) per $F = F_1 \times F_2$; ecco che si risolve il problema che avevamo: possiamo finalmente definire una nuova σ -algebra sulla quale il nostro vettore $(X, Y)^T$ risulta essere misurabile.

DEFINIZIONE 10.5 Sigma-Algebra Prodotto : Dati $(F_1, \mathcal{F}_1)$, $(F_2, \mathcal{F}_2)$ spazi misurabili si definisce σ -algebra prodotto (o prodotto tensore):

$$\mathcal{F}_1 \otimes \mathcal{F}_2 = \sigma(\mathcal{F}_1 \times \mathcal{F}_2)$$

Possiamo rispondere ai dubbi esposti all'inizio della sezione, definendo il vettore aleatorio sui seguenti spazi:

$$\begin{pmatrix} X \\ Y \end{pmatrix} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1 \times F_2, \mathcal{F}_1 \otimes \mathcal{F}_2)$$

Posso considerare $P^{(X,Y)}$ la legge di $(X, Y)^T$, la quale è una misura di probabilità su $(\mathcal{F}_1 \otimes \mathcal{F}_2)$. P^X e P^Y sono dette leggi marginali, e sono le leggi delle componenti.

TEOREMA 10.6: Siano $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1, \mathcal{F}_1)$ e $Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_2, \mathcal{F}_2)$ e sia $h : (F_1 \times F_2, \mathcal{F}_1 \otimes \mathcal{F}_2) \rightarrow \mathbb{R}$, allora valgono:

1. $\mathcal{B}(\mathbb{R}) \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^2)$. In generale: $\mathcal{B}(\mathbb{R}) \otimes \cdots \otimes \mathcal{B}(\mathbb{R}) = \mathcal{B}(\mathbb{R}^n)$
2. $\begin{pmatrix} X \\ Y \end{pmatrix} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1 \times F_2, \mathcal{F}_1 \otimes \mathcal{F}_2)$ è un vettore aleatorio
3. Si ha che "le sezioni sono misurabili":

$$\begin{aligned} h(x, \cdot) : (F_2, \mathcal{F}_2) &\rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})) & \forall x \in F_1 \\ h(\cdot, y) : (F_1, \mathcal{F}_1) &\rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R})) & \forall y \in F_2 \end{aligned}$$

Dove la notazione $h(\cdot, y)$ indica che è una variabile solo di x , e fisso la y .

ESEMPIO : Sia $h(x, y) = \mathbb{I}_C(x, y)$ dove $C = \{(x, y) \in \mathbb{R}^2 \mid x^2 + y^2 = 1\}$. Allora si ha che:

$$C_x := \{y \in \mathbb{R} : (x, y) \in C\} = \{y \in \mathbb{R} : x^2 + y^2 = 1\} = \begin{cases} \{\sqrt{1-x^2}, -\sqrt{1-x^2}\}, & |x| < 1, \\ \{0\}, & |x| = 1, \\ \emptyset, & |x| > 1. \end{cases}$$

$$C_y := \{x \in \mathbb{R} : (x, y) \in C\} = \{x \in \mathbb{R} : x^2 + y^2 = 1\} = \begin{cases} \{\sqrt{1-y^2}, -\sqrt{1-y^2}\}, & |y| < 1, \\ \{0\}, & |y| = 1, \\ \emptyset, & |y| > 1. \end{cases}$$

Di conseguenza le sezioni risultano essere

$$h(x, \cdot) = \mathbb{I}_{[\sqrt{1-x^2}, -\sqrt{1-x^2}]}(y), \quad h(\cdot, y) = \mathbb{I}_{[\sqrt{1-y^2}, -\sqrt{1-y^2}]}(x)$$

e quindi misurabili.

10.3 Teorema di Fubini-Tonelli

Siano $X : (\Omega, \mathcal{A}, P) \rightarrow (F_1, \mathcal{F}_1)$ e $Y : (\Omega, \mathcal{A}, P) \rightarrow (F_2, \mathcal{F}_2)$ due variabili aleatorie, e

$$(X, Y)^\top : (\Omega, \mathcal{A}, P) \longrightarrow (F_1 \times F_2, \mathcal{F}_1 \otimes \mathcal{F}_2)$$

la variabile aleatoria vettoriale associata. Indichiamo con P^X , P^Y e $P^{(X,Y)}$ rispettivamente le leggi marginali di X e Y e la legge congiunta.

Ci chiediamo: *esiste una relazione tra le marginali e la congiunta?*

Senza troppi formalismi, andiamo a cercare di capire intuitivamente quale potrebbe essere. Per definizione, abbiamo che

$$\begin{aligned} P^X(A) &= \mathbb{P}(X \in A), & \forall A \in \mathcal{F}_1 \\ P^Y(B) &= \mathbb{P}(Y \in B), & \forall B \in \mathcal{F}_2 \end{aligned}$$

e, più in generale,

$$P^{(X,Y)}(C) = \mathbb{P}((X, Y) \in C), \quad C \in \mathcal{F}_1 \otimes \mathcal{F}_2.$$

Pertanto, prendendo $A \in \mathcal{F}_1$ e $B \in \mathcal{F}_2$ ed “alzandoli”, ovvero si considera $F_1 \times B \subseteq F_1 \times F_2$ e $A \times F_2 \subseteq F_1 \times F_2$, allora:

$$\begin{aligned} P^{(X,Y)}(A \times F_2) &= \mathbb{P}(X \in A, Y \in F_2) = \mathbb{P}(X \in A) = P^X(A) \\ P^{(X,Y)}(F_1 \times B) &= \mathbb{P}(X \in F_1, Y \in B) = \mathbb{P}(Y \in B) = P^Y(B). \end{aligned}$$

Quindi, **a partire dalla legge congiunta, è sempre possibile ricavare le leggi marginali.**

Ma è vero il viceversa?

Siccome si ha che:

$$P^{(X,Y)}(A \times B) = \mathbb{P}(X \in A, Y \in B)$$

non si può dedurre la congiunta dai soli valori delle marginali $P^X(A)$ e $P^Y(B)$. Le marginali descrivono i comportamenti di X e Y presi separatamente, ma non contengono informazione sulla loro dipendenza.

Esiste un unico caso in cui è possibile ricostruire la legge congiunta a partire dalle marginali: quando X e Y sono indipendenti. In tal caso,

$$P(X \in A, Y \in B) = P(X \in A) P(Y \in B),$$

cioè

$$P^{(X,Y)}(A \times B) = P^X(A) P^Y(B) \quad \forall A \in \mathcal{F}_1, B \in \mathcal{F}_2$$

Adesso che abbiamo capito intuitivamente dove si vuole arrivare, costruiamo il tutto con una teoria solida.

Siano $(E_1, \mathcal{E}_1)$, $(E_2, \mathcal{E}_2)$ spazi misurabili, e siano μ_1, μ_2 delle misure σ -finite rispettivamente definite su $(E_1, \mathcal{E}_1)$, $(E_2, \mathcal{E}_2)$. Possiamo costruire lo spazio di misura $(E_1 \times E_2, \mathcal{E}_1 \otimes \mathcal{E}_2)$.

Esiste una misura μ su $(E_1 \times E_2, \mathcal{E}_1 \otimes \mathcal{E}_2)$ tale che $\mu(A \times B) = \mu_1(A) \cdot \mu_2(B) \quad \forall A \times B \in \mathcal{E}_1 \times \mathcal{E}_2$?

TEOREMA 10.7 Teorema di Fubini-Tonelli: Siano $(E_1, \mathcal{E}_1)$, $(E_2, \mathcal{E}_2)$ spazi misurabili, e siano μ_1, μ_2 delle misure σ -finite rispettivamente definite su $(E_1, \mathcal{E}_1)$, $(E_2, \mathcal{E}_2)$, allora:

1. $\exists! \mu = \mu_1 \otimes \mu_2$ detta misura prodotto definita su $(\mathcal{E}_1 \otimes \mathcal{E}_2)$ tale che:

$$\mu(A \times B) = \mu_1 \otimes \mu_2(A \times B) = \mu_1(A) \cdot \mu_2(B) \quad \begin{array}{l} \forall A \in \mathcal{E}_1, \forall B \in \mathcal{E}_2 \\ \forall A \times B \in \mathcal{E}_1 \times \mathcal{E}_2 \end{array}$$

2. $\forall h : (E_1 \times E_2, \mathcal{E}_1 \otimes \mathcal{E}_2) \rightarrow [0, +\infty]$:

- Le seguenti mappe sono misurabili e non negative:

$$x \mapsto \int_{E_2} h(x, y) \mu_2(dy), \quad y \mapsto \int_{E_1} h(x, y) \mu_1(dx)$$

- Vale che:

$$\int_{E_1 \times E_2} h(x, y) d(\mu_1 \otimes \mu_2) = \int_{E_1} \left(\int_{E_2} h(x, y) d\mu_2 \right) d\mu_1$$

3. $\forall h \in L^1(E_1 \times E_2, \mathcal{E}_1 \otimes \mathcal{E}_2, \mu_1 \otimes \mu_2)$:

- Si ha che $h(x, \cdot) \in L^1(E_2, \mathcal{E}_2, \mu_2) \quad \mu_1$ -quasi ogni x
 $h(\cdot, y) \in L^1(E_1, \mathcal{E}_1, \mu_1) \quad \mu_2$ -quasi ogni y
- Le seguenti mappe sono integrabili:

$$\begin{aligned} x \mapsto \int_{E_2} h(x, y) d\mu_2 &\in L^1(E_1, \mathcal{E}_1, \mu_1) \\ y \mapsto \int_{E_1} h(x, y) d\mu_1 &\in L^1(E_2, \mathcal{E}_2, \mu_2) \end{aligned}$$

e vale che

$$\int_{E_1 \times E_2} h(x, y) d(\mu_1 \otimes \mu_2) = \int_{E_1} \left(\int_{E_2} h(x, y) d\mu_2 \right) d\mu_1 = \int_{E_2} \left(\int_{E_1} h(x, y) d\mu_1 \right) d\mu_2$$

Possiamo notare che grazie a questo teorema importantissimo abbiamo che:

$$\begin{aligned} h \in L^1(\mu_1 \otimes \mu_2) &\iff \int_{E_1 \times E_2} |h| d(\mu_1 \otimes \mu_2) < +\infty \\ &\iff \int_{E_1} \left(\int_{E_2} |h| d\mu_2 \right) d\mu_1 < +\infty \end{aligned}$$

Inoltre, il teorema è stato enunciato per misure generali σ -finite; questo vuol dire che possiamo specializzare il teorema a misure di probabilità, le quali sono misure finite.

Si considerino $\mathbb{P}_1, \mathbb{P}_2$ due misure di probabilità rispettivamente su $(E_1, \mathcal{E}_1), (E_2, \mathcal{E}_2)$.

$$\xrightarrow{\text{F.T.}} \exists! \mathbb{P}_1 \otimes \mathbb{P}_2 \text{ su } (E_1 \times E_2, \mathcal{E}_1 \otimes \mathcal{E}_2) \quad \text{t.c.} \quad \mathbb{P}_1 \otimes \mathbb{P}_2(A \times B) = \mathbb{P}_1(A) \cdot \mathbb{P}_2(B)$$

e valgono tutte le altre tesi del Teorema di Fubini-Tonelli.

Si osservi infine un fatto interessante:

- Se $A = E_1 \Rightarrow \mathbb{P}_1 \otimes \mathbb{P}_2(E_1 \times B) = \mathbb{P}_1(E_1) \cdot \mathbb{P}_2(B) = \mathbb{P}_2(B)$
- Se $B = E_2 \Rightarrow \mathbb{P}_1 \otimes \mathbb{P}_2(A \times E_2) = \mathbb{P}_1(A) \cdot \mathbb{P}_2(E_2) = \mathbb{P}_1(A)$

TEOREMA 10.8 F.T. su $\mathbb{R}^n$ con m_n : Sia dato il teorema di Fubini-Tonelli su $\mathbb{R}^n$ con m_n .

Consideriamo $(\mathbb{R}^{n_1}, \mathcal{B}^{n_1}, m_{n_1}), (\mathbb{R}^{n_2}, \mathcal{B}^{n_2}, m_{n_2})$ e $(\mathbb{R}^{n_1} \times \mathbb{R}^{n_2}, \mathcal{B}^{n_1} \otimes \mathcal{B}^{n_2}) = (\mathbb{R}^{n_1+n_2}, \mathcal{B}^{n_1+n_2})$.

Allora:

$$1) m_{n_1} \otimes m_{n_2} = m_{n_1+n_2} \Rightarrow m_n = \underbrace{m \otimes \cdots \otimes m}_{n \text{ volte}}$$

La formula diventa, con $\underline{x} = (x_1, \dots, x_{n_1})$ e $\underline{y} = (y_1, \dots, y_{n_2})$:

$$\begin{aligned} \int_{\mathbb{R}^{n_1+n_2}} h(\underline{x}, \underline{y}) dm_{n_1+n_2} &= \int_{\mathbb{R}^{n_2}} \left(\int_{\mathbb{R}^{n_1}} h(\underline{x}, \underline{y}) dm_{n_1}(\underline{x}) \right) dm_{n_2}(\underline{y}) \\ &= \int_{\mathbb{R}^{n_2}} \left(\int_{\mathbb{R}^{n_1}} h(x_1, \dots, x_{n_1}, y_1, \dots, y_{n_2}) dx_1 \cdots dx_{n_1} \right) dy_1 \cdots dy_{n_2} \end{aligned}$$

COROLLARIO 10.9: Siano $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_1, \mathcal{F}_1)$ e $Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (F_2, \mathcal{F}_2)$. Allora:

$$X \perp\!\!\!\perp Y \iff P^{(X,Y)} = P^X \otimes P^Y$$

Dimostrazione. ($\Rightarrow$) Se $X \perp\!\!\!\perp Y$, allora vuol dire che

$$P^{(X,Y)}(A \times B) = P^X(A) \cdot P^Y(B); \quad \forall A \in \mathcal{F}_1, \forall B \in \mathcal{F}_2$$

Per il Teorema di Fubini-Tonelli si ha quindi che $\exists! P^{(X,Y)} \equiv P^X \otimes P^Y$.

($\Leftarrow$) Se si ha che $P^{(X,Y)} = P^X \otimes P^Y$, allora:

$$\mathbb{P}(X \in A, Y \in B) = P^{(X,Y)}(A \times B) = P^X(A) \cdot P^Y(B) = \mathbb{P}(X \in A) \cdot \mathbb{P}(Y \in B) \quad \forall A \in \mathcal{F}_1, \forall B \in \mathcal{F}_2$$

□

Grazie al Teorema di Fubini–Tonelli, ed ai suoi corollari, abbiamo capito che se si hanno P^X su $\mathcal{F}_1$ e P^Y su $\mathcal{F}_2$, e so per ragioni modellistiche che queste sono associate ad esperimenti che non si influenzano, allora posso **sempre** costruire uno spazio di probabilità $(F_1 \times F_2, \mathcal{F}_1 \otimes \mathcal{F}_2, P^X \otimes P^Y)$, il quale permette ad X ed Y di avere un dominio comune.

Tuttavia X ed Y sono ancora definiti su spazi diversi, e per parlare di indipendenza si ha la necessità che le due variabili aleatorie siano definite sullo stesso spazio; possiamo introdurre due nuove variabili aleatorie definite sullo spazio prodotto tali che:

$$\begin{aligned} X_1 &:= \text{Id}_{F_1} & X_1(x, y) &= x \\ X_2 &:= \text{Id}_{F_2} & X_2(x, y) &= y \end{aligned}$$

Allora si può dimostrare che $(X, Y)^T$ ha componenti indipendenti, e che:

$$X_1 \sim X; \quad X_2 \sim Y; \quad P^{(X_1, X_2)} = P^X \otimes P^Y$$

Di conseguenza, grazie al Teorema di F–T su $\mathbb{R}^n$:

$$E[X_1 \cdot X_2] = \int_{\mathbb{R}^2} xy \, d(P^X \otimes P^Y) = \left(\int_{\mathbb{R}} x \, dP^X \right) \left(\int_{\mathbb{R}} y \, dP^Y \right) = E[X] \cdot E[Y]$$

▲ Si presti attenzione ad un dettaglio sottile ma importante (e bellissimo). Potrebbe sembrare che questo risultato lo avessimo già trovato grazie al Teorema 10.3 ed al suo Corollario, tuttavia in quel teorema si presupponeva che le variabili aleatorie X ed Y vivessero nello stesso spazio, e quindi si sono usate le proprietà misurali già note per ricavare l'aspettativa del prodotto.

In questo secondo approccio, X e Y **vivono su spazi diversi**; abbiamo quindi dovuto costruire come prima cosa uno spazio comune sul quale abbia senso calcolare l'aspettativa. Introducendo X_1 e X_2 (che vivono entrambe sullo spazio prodotto), siamo certi che $E[X_1 \cdot X_2]$ sia formalmente definito, e si sfrutta il Teorema di Fubini–Tonelli per ricavare il risultato. ▲

10.4 Famiglie di Variabili Aleatorie Indipendenti

DEFINIZIONE 10.10: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, siano $(F_k, \mathcal{F}_k) \ \forall k = 1, \dots, n$ spazi misurabili, e $X_1, \dots, X_n$ variabili aleatorie tali che $X_k : \Omega \rightarrow F_k \ \forall k = 1, \dots, n$. Allora diciamo che $X_1, \dots, X_n$ sono indipendenti se:

$$\mathbb{P} \left(\bigcap_{j=1}^n X_j \in B_j \right) = \prod_{j=1}^n \mathbb{P}(X_j \in B_j) \quad \forall B_j \in \mathcal{F}_j$$

Questa condizione si può riscrivere come:

$$P^{(X_1, \dots, X_n)}(B_1 \times \dots \times B_n) = P^{X_1}(B_1) \dots P^{X_n}(B_n) \quad \forall B_1 \times \dots \times B_n \in \mathcal{F}_1 \times \dots \times \mathcal{F}_n$$

Oppure, in maniera ancora più essenziale:

$$P^{(X_1, \dots, X_n)} = \bigotimes_{j=1}^n P^{X_j}$$

Da questa definizione si conclude direttamente che *sottofamiglie finite di Famiglie Indipendenti sono anch'esse famiglie indipendenti*, ossia:

$$\forall J \subseteq \{1, \dots, n\} \text{ tale che } |J| \geq 2 : \quad \mathbb{P} \left(\bigcap_{j \in J} X_j \in B_j \right) = \prod_{j \in J} \mathbb{P}(X_j \in B_j)$$

Questo può essere intuito prendendo $B_k = F_k$, allora:

$$\begin{aligned} \mathbb{P}(X_1 \in B_1, \dots, X_k \in F_k, \dots, X_n \in B_n) &= \mathbb{P}(X_1 \in B_1) \cdots \underbrace{\mathbb{P}(X_k \in F_k)}_{=1} \cdots \mathbb{P}(X_n \in B_n) \\ &= \mathbb{P}(\dots, X_{k-1} \in B_{k-1}, X_{k+1} \in B_{k+1}, \dots) \end{aligned}$$

ESEMPIO : Rimaniamo nel caso semplice in cui $n = 3$, e sia X_1, X_2, X_3 una famiglia di variabili aleatorie indipendenti.

Allora: $X_1 \perp\!\!\!\perp X_2, X_1 \perp\!\!\!\perp X_3, X_2 \perp\!\!\!\perp X_3$

ESEMPIO : Vediamo con un esempio che non basta che n variabili aleatorie siano indipendenti tra di loro per generare una famiglia di eventi indipendenti.

Si prenda $X \sim \mathcal{U}(\{-1, 1\}) \Rightarrow \begin{aligned} X = 1 &\text{ con } \mathbb{P}(X = 1) = 0.5 \\ X = 0 &\text{ con } \mathbb{P}(X = 0) = 0.5 \end{aligned}$

Ed allo stesso modo sia $Y \sim \mathcal{U}(\{-1, 1\})$, e sia $X \perp\!\!\!\perp Y$.

Definiamo ora che $Z = X \cdot Y$. Si dimostra che $Z \perp\!\!\!\perp X$ e $Z \perp\!\!\!\perp Y$, tuttavia X, Y, Z non sono una famiglia di variabili aleatorie indipendenti. Vediamo perchè.

Poiché X e Y assumono solo i valori $\{-1, 1\}$, possiamo determinare Z come segue:

X	Y	$Z = X \cdot Y$
1	1	1
1	-1	-1
-1	1	-1
-1	-1	1

Da cui risulta

$$\mathbb{P}(Z = 1) = \mathbb{P}(Z = -1) = \frac{1}{2} \Rightarrow Z \sim \mathcal{U}(\{-1, 1\})$$

La condizione di indipendenza congiunta richiede che per ogni $x, y, z \in \{-1, 1\}$:

$$\mathbb{P}(X = x, Y = y, Z = z) = \mathbb{P}(X = x) \mathbb{P}(Y = y) \mathbb{P}(Z = z).$$

Ma, ad esempio, per $(x, y, z) = (1, 1, -1)$ si ha:

$$\mathbb{P}(X = 1, Y = 1, Z = -1) = 0, \quad \mathbb{P}(X = 1) \mathbb{P}(Y = 1) \mathbb{P}(Z = -1) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8},$$

quindi l'uguaglianza non vale. Ne segue che X, Y, Z non sono indipendenti congiuntamente.

Formalizziamo il concetto visto in quest'ultimo esempio.

PROPOSIZIONE 10.11: Se $X_1, \dots, X_n$ sono variabili aleatorie indipendenti, allora $\forall J_1, J_2 \subseteq J$ tali che $|J_1|, |J_2| \geq 2$ e $J_1 \cap J_2 = \emptyset$

$$\Rightarrow (X_{j_1})_{j_1 \in J_1} \text{ e } (X_{j_2})_{j_2 \in J_2} \text{ sono indipendenti}$$

Quindi se si hanno $X_1, \dots, X_n$ variabili aleatorie indipendenti: $(X_1, X_2) \perp\!\!\!\perp (X_3, X_4) \perp\!\!\!\perp (X_h, X_k)$ con $h \neq k \neq 1 \neq 2 \neq 3 \neq 4$

DEFINIZIONE 10.12: $(X_n)_{n \geq 1}$ è una successione di variabili aleatorie indipendenti se $\forall k \geq 2$: $(X_1, \dots, X_n)$ sono una famiglia di variabili aleatorie indipendenti.

11 Vettori Aleatori

Dopo aver analizzato le proprietà fondamentali delle variabili aleatorie reali, in questo capitolo estendiamo la trattazione al caso di vettori aleatori.

L'utilizzo di variabili aleatorie multidimensionali consente di modellare fenomeni in cui più quantità casuali interagiscono tra loro, rendendo possibile lo studio delle loro dipendenze, delle distribuzioni congiunte e delle proprietà di indipendenza.

Partiremo prima a riassumere le proprietà generali, per poi focalizzarci sui vettori discreti e poi quelli continui.

DEFINIZIONE 11.1: $\underline{X}$ è un vettore aleatorio di dimensione n se è una variabile aleatoria in $\mathbb{R}^n$ e

$$\underline{X} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$$

TEOREMA 11.2 Ripasso delle Proprietà: Per un vettore aleatorio sono valide le seguenti:

1. $\mathcal{B}^n = \underbrace{\mathcal{B} \otimes \cdots \otimes \mathcal{B}}_{n \text{ volte}}$
2. $\underline{X}$ è misurabile $\iff (X_1, \dots, X_n)$ sono variabili aleatorie reali
3. Sia $\underline{X} : \Omega \rightarrow \mathbb{R}^n$, e $\underline{h} : \mathbb{R}^n \rightarrow \mathbb{R}^k$ boreliana $\implies \underline{Y} = \underline{h}(\underline{X})$ è un vettore aleatorio in $\mathbb{R}^k$
4. $\underline{X} \stackrel{\text{q.c.}}{=} \underline{Y} \iff X_k = Y_k \forall k = 1, \dots, n$
5. $P^{\underline{X}}$ dipende da $[\underline{X}]$; ossia che se due vettori sono uguali quasi certamente, allora hanno la stessa legge.
6. Le componenti $X_1, \dots, X_n$ di $\underline{X}$ sono indipendenti $\iff P^{\underline{X}} = \bigotimes_{j=1}^n P^{X_j}$
7. $X_1, \dots, X_n \in L^p(\Omega) \iff \underline{X} \in L^p(\Omega)$
8. $X_1, X_2 \in L^2(\Omega, \mathcal{A}, \mathbb{P}) \implies X_1 \cdot X_2 \in L^1(\Omega, \mathcal{A}, \mathbb{P})$ e $|E[X_1 \cdot X_2]| \leq \sqrt{E[X_1^2] \cdot E[X_2^2]}$
9. Se $X_1, X_2 \in L^1(\Omega)$ e $X_1 \perp\!\!\!\perp X_2 \implies X_1 \cdot X_2 \in L^1(\Omega)$ e $E[X_1 \cdot X_2] = E[X_1] \cdot E[X_2]$

11.1 Vettori Discreti

Lo studio dei vettori aleatori discreti permette di estendere in modo naturale i concetti già visti per le variabili discrete — come funzione di massa, distribuzioni marginali e condizionate, indipendenza e valore atteso — al caso multidimensionale.

DEFINIZIONE 11.3: Dato $(\Omega, \mathcal{A}, \mathbb{P})$ spazio di probabilità, il vettore aleatorio $\underline{X} : \Omega \rightarrow \mathbb{R}^n$ è un vettore discreto se $P^{\underline{X}}$ è una probabilità discreta su $\mathcal{B}^n$, ossia che $\exists T \subseteq \mathbb{R}^n$ discreto, ed $\exists p_{\underline{X}} : T \rightarrow [0, 1]$ tale che:

$$\sum_{\underline{t} \in T} p_{\underline{X}}(\underline{t}) = 1 \quad \text{e} \quad P^{\underline{X}}(B) = \sum_{\underline{t} \in T \cap B} p_{\underline{X}}(\underline{t}) \quad \forall B \in \mathcal{B}^n$$


TEOREMA 11.4 Condizioni Equivalenti alla 11.3: $\underline{X}$ è un vettore discreto:

- $\iff \exists T \subseteq \mathbb{R}$ discreto tale che $\mathbb{P}(\underline{X} \in T) = 1$
- $\iff \exists \underline{Y}$ con $\text{Im}(Y) = T$ tale che $\underline{X} \stackrel{\text{q.c.}}{=} \underline{Y}$
- $\iff X_1, \dots, X_n$ sono variabili aleatorie discrete, ovvero che P^{X_k} è discreto $\forall k = 1, \dots, n$

Dimostrazione. Dimostriamo solo la terza implicazione in direzione ($\Leftarrow$).

Per dimostrare che dati X_k discreto con S_{X_k} il suo supporto $\forall k = 1, \dots, n$ ci basta trovare un $T \subseteq \mathbb{R}^n$ tale che $\mathbb{P}(\underline{X} \in T) = 1$.

Per avere un'idea grafica di cosa significhi questo, mettiamoci nel caso semplice in cui abbiamo solo X_1, X_2 e quindi $T = S_{X_1} \times S_{X_2}$, dove $S_{X_1} = \{1, 2, 3\}$; $S_{X_2} = \{\frac{1}{2}, \frac{3}{2}\}$.



Ovviamente per n componenti si estende a $T = S_{X_1} \times \dots \times S_{X_n}$.

Dunque:

$$\begin{aligned}
 \mathbb{P}(\underline{X} \in T) &= \mathbb{P}(\underline{X} \in S_{X_1} \times \dots \times S_{X_n}) = \mathbb{P}(X_1 \in S_{X_1}, \dots, X_n \in S_{X_n}) \\
 &= \mathbb{P}\left(\bigcap_{k=1}^n (X_k \in S_{X_k})\right) \stackrel{\text{De Morgan}}{=} 1 - \mathbb{P}\left(\bigcup_{k=1}^n (X_k \in S_{X_k})^c\right) \\
 &= 1 - \underbrace{\sum_{k=1}^n \mathbb{P}(X_k \notin S_{X_k})}_0 = 1
 \end{aligned}$$

□

PROPOSIZIONE 11.5: Sia $\underline{X}$ un vettore aleatorio discreto n -dimensionale con $T = T_1 \times \dots \times T_n$. Allora vale che:

1. Per la regola del valore atteso:

$$E[h(\underline{X})] = \int_{\Omega} h(\underline{X}) d\mathbb{P} = \int_{\mathbb{R}^n} h(\underline{t}) dP^{\underline{X}} = \sum_{\underline{t} \in T} h(\underline{t}) p_{\underline{X}}(\underline{t})$$

Dove: $h \in L^1(P^{\underline{X}}) \iff \sum_{\underline{t} \in T} |h(\underline{t}) p_{\underline{X}}(\underline{t})| < +\infty$

2. Il rapporto tra la legge congiunta, e le marginali è il seguente:

$$p_{X_k}(t_k) = \sum_{t_1 \in T_1; \dots; t_{k-1} \in T_{k-1}; t_{k+1} \in T_{k+1}; \dots; t_n \in T_n} p_{\underline{X}}(t_1, \dots, t_k, \dots, t_n)$$

$$3. X_1, \dots, X_n \text{ sono indipendenti}^a \iff p_{\underline{X}}(t_1, \dots, t_n) = p_{X_1}(t_1) \cdots p_{X_n}(t_n) \quad \forall \underline{t} \in T$$

^aD'ora in avanti si utilizzerà un piccolo abuso di notazione: scriveremo che " $X_1, \dots, X_n$ sono indipendenti" per intendere che siano una famiglia di V.A. indipendenti. Non è sufficiente infatti che $X_1, \dots, X_n$ siano indipendenti a coppie, ma vi è la necessità che seguano la definizione di famiglia di V.A. indipendenti.

È importante notare che il secondo punto ci dice come possiamo calcolare una legge marginale a partire dalla congiunta. Per ottenere la legge di X_k è infatti sufficiente fissare il valore di X_k e fare la somma della legge congiunta su tutte le altre componenti del vettore.

ESEMPIO : Per intenderci mettiamoci nel caso in cui $n = 2$. Consideriamo due variabili aleatorie discrete (X_1, X_2) , con

$$T_1 = \{1, 2, 3\}, \quad T_2 = \{a, b\},$$

e legge congiunta data dalla seguente tabella:

	$X_2 = a$	$X_2 = b$
$X_1 = 1$	0.1	0.2
$X_1 = 2$	0.3	0.1
$X_1 = 3$	0.2	0.1

La legge marginale di X_1 si ottiene sommando la probabilità congiunta su tutti i possibili valori di X_2 :

$$p_{X_1}(t_1) = \sum_{t_2 \in T_2} p_{\underline{X}}(t_1, t_2).$$

In particolare:

$$p_{X_1}(1) = p_{\underline{X}}(1, a) + p_{\underline{X}}(1, b) = 0.1 + 0.2 = 0.3,$$

$$p_{X_1}(2) = p_{\underline{X}}(2, a) + p_{\underline{X}}(2, b) = 0.3 + 0.1 = 0.4,$$

$$p_{X_1}(3) = p_{\underline{X}}(3, a) + p_{\underline{X}}(3, b) = 0.2 + 0.1 = 0.3.$$

Quindi la legge marginale di X_1 risulta:

$$p_{X_1} : T_1 \rightarrow [0, 1] : \quad p_{X_1}(1) = 0.3, \quad p_{X_1}(2) = 0.4, \quad p_{X_1}(3) = 0.3.$$

ESEMPIO : Prendiamo come esperimento il lancio di 3 dadi, sia quindi $\underline{X} = (X_1, X_2, X_3)$ e sia $X_K =$ Risultato del k -esimo dado.

Grazie al Teorema 11.4 possiamo dire che $\underline{X}$ è un vettore aleatorio discreto, in quanto le sue componenti sono V.A. discreto. Inoltre, per ragioni modellistiche le X_1, X_2, X_3 risultano essere indipendenti, e quindi:

$$p_{\underline{X}}(h_1, h_2, h_3) = p_{X_1}(h_1) \cdot p_{X_2}(h_2) \cdot p_{X_3}(h_3) \quad \forall h_k \in \{1, \dots, 6\}, k = 1, 2, 3$$

Quindi per esempio: $p_{\underline{X}}(1, 1, 1) = p_{X_1}(1) \cdot p_{X_2}(1) \cdot p_{X_3}(1) = \frac{1}{6^3}$.

Definiamo ora $Y := X_1 + X_2$, la quale risulta essere discreta perché somma di discrete. Siccome possiamo vedere Y come $Y = h(X_1, X_2)$, allora è evidente che $Y \perp\!\!\!\perp X_3$, siccome $(X_1, X_2) \perp\!\!\!\perp X_3$.

Consideriamo ora il vettore $(X_1, Y)^T$ discreto, in quanto ha componenti discrete. Ci chiediamo a questo punto, X_1 e Y sono indipendenti?

Siccome conosciamo le marginali possiamo andare a calcolare la congiunta, di seguito una tabella che riassume i risultati:

$X_1 \backslash Y$	2	3	4	5	6	7	8	9	10	11	12	$p_{X_1}(x)$
1	1/36	1/36	1/36	1/36	1/36	1/36	0	0	0	0	0	1/6
2	0	1/36	1/36	1/36	1/36	1/36	1/36	0	0	0	0	1/6
3	0	0	1/36	1/36	1/36	1/36	1/36	1/36	0	0	0	1/6
4	0	0	0	1/36	1/36	1/36	1/36	1/36	1/36	0	0	1/6
5	0	0	0	0	1/36	1/36	1/36	1/36	1/36	1/36	0	1/6
6	0	0	0	0	0	1/36	1/36	1/36	1/36	1/36	1/36	1/6
$p_Y(y)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36	

Si vede che X_1 e Y non sono indipendenti, perché per esempio $p_{(X_1, Y)}(2, 2) \neq p_{X_1}(2) p_{X_2}(2)$

11.2 Vettori Assolutamente Continui

La trattazione dei vettori assolutamente continui, come vedremo, sarà inevitabilmente più complessa e meno lineare rispetto a quelli discreti.

Ricordiamo la definizione della misura di Lebesgue n -dimensionale già esposta a pagina 54:

$$m_n = \prod_{j=1}^n [a_j, b_j] = \prod_{k=1}^n (b_k - a_k)$$

Dovremo inizialmente allargare le definizioni esposte nel caso monodimensionale al caso multidimensionale. Iniziamo dalla definizione di probabilità continua (Definizione 9.1).

DEFINIZIONE 11.6: Una misura di probabilità $\mathbb{P}$ su $\mathcal{B}(\mathbb{R}^n)$ si dice assolutamente continua se

$$\exists f : \mathbb{R}^n \rightarrow \mathbb{R}^+$$

boreliana, definita *densità continua*, tale che $\forall A \in \mathcal{B}(\mathbb{R}^n)$:

$$\mathbb{P}(A) = \int_A f(\underline{x}) \, dm_n = \int_{\mathbb{R}^n} f \cdot \mathbb{I}_A \, dm_n = \int_{\mathbb{R}^n} f(\underline{x}) \cdot \mathbb{I}_A(\underline{x}) \, d\underline{x}$$

Si osservi che se $n = 1$, allora la Definizione 11.6 è equivalente alla Definizione 9.1 tramite funzione di ripartizione.

DEFINIZIONE 11.7: $\underline{X} : \Omega \rightarrow \mathbb{R}^n$ è un Vettore Aleatorio Assolutamente Continuo se $P^{\underline{X}}$ è una misura di probabilità su $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ assolutamente continua, e denotiamo la densità congiunta del vettore $\underline{X}$ con $f_{\underline{X}}$

TEOREMA 11.8 Caratterizzazione di una Densità Continua : Valgono i seguenti:

1. $f : \mathbb{R}^n \rightarrow \mathbb{R}$ è una densità continua congiunta di una probabilità $\mathbb{P}$ assolutamente continua su $\mathcal{B}^n$ se e solo se:
 - (a) f è Boreliana
 - (b) $f \geq 0$
 - (c) $\int_{\mathbb{R}^n} f(x) \, dx = 1$

2. Se vale (1.), allora:

$$\mathbb{P}(A) = \int_A f \, dm_n = \int_A f(x) \, dx \quad \forall A \in \mathcal{B}(\mathbb{R}^n)$$

3. $\mathbb{P}$ su $\mathcal{B}(\mathbb{R}^n)$ assolutamente continua è univocamente caratterizzata dalla classe di equivalenza della sua densità continua $[f]$, ossia:

$$f_1 = f_2 \text{ } m_n\text{-quasi ovunque} \iff \mathbb{P}_1 = \mathbb{P}_2$$

ESEMPIO : Si vuole modellizzare da un punto di vista probabilistico il gioco delle freccette. Sia C l'insieme dove viene lanciata a caso la freccetta, definito come

$$C = \left\{ (x, y) \in \mathbb{R}^2 \mid x^2 + y^2 \leq 1 \right\}$$

e sia rappresentino le coordinate del lancio con il vettore (X, Y) . Vogliamo trovare $f_{(X,Y)}$ densità assolutamente continua.

Il fatto che il lancio venga effettuato a caso all'interno del cerchio, ci fa intuire che potremmo essere davanti ad una densità uniforme, del tipo:

$$f_{(X,Y)}(x, y) = c \cdot \mathbb{I}_C(x, y)$$

Allora per il Teorema 11.8, affinché sia una densità continua devono valere le tre condizioni del punto 1.

$$\Rightarrow \begin{cases} f \text{ boreliana} & \Rightarrow f \text{ è boreliana} \\ f \geq 0 & \Rightarrow c \geq 0 \\ \int_{\mathbb{R}^n} c \cdot \mathbb{I}_C(x, y) \, dx dy = 1 & \Rightarrow c \cdot m_2(C) = c\pi 1^2 \Rightarrow c = 1/\pi \end{cases}$$

Questo basta per dire che $f_{(X,Y)}(x, y) = \frac{1}{\pi} \mathbb{I}_C(x, y)$ è una densità congiunta assolutamente continua.

Si osservi che preso un $A \in \mathcal{B}^n$ tale che $m_n(A) = 0$ e $\mathbb{P}$ è una misura di probabilità assolutamente continua su $\mathcal{B}^n$, allora:

$$\mathbb{P}(A) = \int_{\mathbb{R}^n} \mathbb{I}_A(x) f(x) \, dx = 0, \quad \text{siccome} \quad \mathbb{I}_A = 0 \text{ q.o.}$$

Questo vuol dire, per esempio, che se siamo su $\mathbb{R}^2$, la retta ha misura nulla: un vettore in $\mathbb{R}^2$ ha probabilità 0 di prendere valori su una retta.

$\Rightarrow$ Se A è un sottospazio di dimensione $\leq n - 1$, allora $m_n(A) = 0$

ESEMPIO : Si prenda:

$$g : \mathbb{R} \rightarrow \mathbb{R}, \quad g(x) = x^2$$

Allora il Grafico G definito come

$$G = \left\{ (x, g(x)) = (x, x^2) \in \mathbb{R}^2 \mid x \in \mathbb{R}^2 \right\}$$

Avrà misura di Lebesgue 2-dimensionale nulla: $m_2(G) = 0$

$\Rightarrow$ Anche i grafici hanno misura nulla: $m_n(G) = 0$.

ESEMPIO ▲: Vediamo con un esempio, una caratteristica fondamentale dei vettori assolutamente continui. Si consideri:

$$X \sim \mathcal{E}(\lambda), \lambda > 0; \quad f_X(t) = \lambda e^{-\lambda t} \mathbb{I}_{(0,+\infty)}(t)$$

Ovviamente X è assolutamente continuo, ma anche X^2 lo è, difatti^a:

$$f_{X^2}(t) = \frac{\lambda e^{-\lambda\sqrt{t}}}{2\sqrt{t}} \mathbb{I}_{(0,+\infty)}(t)$$

Componendo il vettore $(X, X^2)^\top$, ci chiediamo: *posso dedurre che il vettore sia assolutamente continuo, dato che le sue componenti sono assolutamente continue (come è lecito fare nel caso discreto)?* Ossia:

$$\exists? f_{(X, X^2)} : \mathbb{R}^2 \rightarrow \mathbb{R} \quad \text{tale che} \quad P^{(X, X^2)}(A) = \int_A f_{(X, X^2)} d\mathbf{x} ?$$

La risposta è **assolutamente no**. Infatti:

$$\text{Im}(X, X^2) = \left\{ (x, x^2) \in \mathbb{R}^2 : x \in \mathbb{R} \right\} = G$$

Di conseguenza:

$$\mathbb{P}((X, X^2) \in G) = 1 \quad \Rightarrow \quad P^{(X, X^2)}(G) = 1$$

Ma noi sappiamo dall'esempio precedente che $m_2(G) = 0$, e quindi dovrebbe essere (se il vettore fosse continuo) che $P^{(X, X^2)}(G) = 0$

^aTrovata sapendo che: $F_{X^2}(t) = \mathbb{P}(-\sqrt{t} \leq X \leq \sqrt{t}) = F_X(\sqrt{t}) - F_X(-\sqrt{t}) \Rightarrow f_{X^2}(t) = \frac{d}{dt}(F_{X^2}(t)) = \frac{f_X(\sqrt{t}) - f_X(-\sqrt{t})}{2\sqrt{t}}$

Abbiamo appena dimostrato con un esempio che **non basta che le componenti del vettore siano separatamente continue per concludere che il vettore stesso sia assolutamente continuo**, ossia che esista una densità congiunta.

TEOREMA 11.9: Sia $\underline{X} = (X_1, \dots, X_n)$ un vettore assolutamente continuo, allora valgono che:

$$1. \quad h \in L^1(P^{\underline{X}}) \iff h \cdot f_{\underline{X}} \in L^1(m_n) \iff \int_{\mathbb{R}^n} |h(\underline{x})| f_{\underline{X}}(\underline{x}) d\mathbf{x} < +\infty.$$

Allora, se vale una delle precedenti oppure se $h \geq 0$, si ha per la regola del valore atteso che:

$$E[h(\underline{X})] = \int_{\mathbb{R}^n} h dP^{\underline{X}} = \int_{\mathbb{R}^n} h(\underline{x}) f_{\underline{X}}(\underline{x}) d\mathbf{x}$$

2. Ogni $X_k : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ è una variabile aleatoria assolutamente continua, con densità

$$f_{X_k}(x_k) = \int_{\mathbb{R}^{n-1}} f_{\underline{X}}(x_1, \dots, x_n) dx_1 \cdots dx_{k-1} dx_{k+1} \cdots dx_n$$


3. $(X_1, \dots, X_n)$ formano una famiglia di V.A. indipendenti assolutamente continue, con densità marginali $f_{X_1}, \dots, f_{X_n}$

$$\iff \underline{X} \text{ è assolutamente continuo} \quad \text{e} \quad f_{\underline{X}}(x_1, \dots, x_n) = f_{X_1}(x_1) \cdots f_{X_n}(x_n) \quad \text{quasi ovunque}$$

Si può cercare di dare un'intuizione grafica al punto 2. di quest'ultimo teorema, almeno nel caso

bidimensionale. Ipotizziamo di avere una densità $f_{(X_1, X_2)}$, allora la legge marginale di X_1 può essere calcolata come

$$f_{X_1}(x_1) = \int_{\mathbb{R}} f_{(X_1, X_2)}(x_1, x_2) dx_2$$



Dal punto di vista grafico, la legge congiunta gaussiana può essere rappresentata come una *superficie tridimensionale* sul piano (x_1, x_2) , la cui altezza in ciascun punto rappresenta il valore della densità $f_{X_1, X_2}(x_1, x_2)$.

Graficamente, f_{X_1} corrisponde a *proiettare la superficie tridimensionale* sull'asse x_1 , “collassando” la seconda dimensione. In altre parole, per ogni valore fissato di x_1 si sommano (le aree sotto la curva in direzione x_2) tutti i contributi di probabilità associati ai diversi valori di x_2 . Il risultato è una *curva bidimensionale* lungo l'asse x_1 , che rappresenta la densità marginale $f_{X_1}(x_1)$.

In sintesi, la densità congiunta descrive come la probabilità si distribuisce nell'intero piano (x_1, x_2) , mentre la densità marginale rappresenta la “proiezione” di tale distribuzione su uno dei due assi, ottenuta attraverso un'operazione di integrazione.

TEOREMA 11.10: Siano $X_1 : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$, $X_2 : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^k, \mathcal{B}^k)$ vettori aleatori assolutamente continui, ossia che esistono f_{X_1}, f_{X_2} . Supponiamo inoltre che $X_1 \perp\!\!\!\perp X_2$:
 $\Rightarrow \underline{X}$ è un vettore assolutamente continuo con densità:

$$f_{\underline{X}}(x_1, \dots, x_n, y_1, \dots, y_k) = f_{X_1}(x_1, \dots, x_n) \cdot f_{X_2}(y_1, \dots, y_k) \quad \forall (x_1, \dots, x_n, y_1, \dots, y_k) \in \mathbb{R}^{n+k}$$

ESEMPIO: Sia $\begin{bmatrix} X \\ Y \end{bmatrix}$ un vettore assolutamente continuo con densità:

$$f_{(X, Y)}(x, y) = \frac{1}{\pi} \cdot \mathbb{I}_C(x, y)$$

Ci chiediamo quali siano le densità marginali, e se X, Y siano indipendenti. Posso calcolare la marginali come:

$$f_X(x) = \int_{\mathbb{R}} f_{(X, Y)}(x, y) dy = \begin{cases} 0, & |x| > 1 \\ \frac{2\sqrt{1-x^2}}{\pi} & -1 < x < 1 \end{cases} = \frac{2\sqrt{1-x^2}}{\pi} \mathbb{I}_{[-1, 1]}(x)$$

$$f_Y(y) = \frac{2\sqrt{1-y^2}}{\pi} \mathbb{I}_{[-1,1]}(y)$$

Siccome $f_{(X,Y)}$ risulta essere diverso da zero su un cerchio, mentre $f_X(x) \cdot f_Y(y)$ è diverso da zero su di un quadrato, allora sicuramente X, Y non possono essere indipendenti.

Facciamo un **breve riassunto pratico**.

Nel caso in cui sia dato $\underline{X}$ assolutamente continuo, e si definisca $\underline{Y} := h(\underline{X})$, allora ci sono 3 casistiche nelle quali possiamo ritrovarci:

1. Se h ha immagine discreta $\Rightarrow \underline{Y}$ è una V.A. discreta.

ESEMPIO : Un classico esempio già visto è il caso in cui $\underline{Y} = h(\underline{X}) = [\underline{X}]$

2. Se $h \in C^1$ tale che $h^{-1} \in C^1 \Rightarrow \underline{Y}$ è una V.A. assolutamente continua, e vale che:

$$f_Y(\underline{y}) = f_X(h^{-1}(\underline{y})) \cdot |\det J_{h^{-1}}(\underline{y})|$$

3. Ne continua, ne discreta: un Troll di Montagna.

ESEMPIO : Un classico esempio è il caso in cui $\underline{Y} = h(\underline{X}) = \underline{X}^2$

11.3 Covarianza

La covarianza è un indice che misura come due variabili aleatorie si muovono congiuntamente rispetto ai rispettivi valori medi. In altre parole, essa descrive la tendenza delle due variabili a variare insieme.

Dal punto di vista concettuale, la covarianza può essere vista come un'estensione della varianza al caso di due variabili aleatorie: mentre la varianza misura la dispersione di una singola variabile rispetto alla propria media, la covarianza quantifica la *dipendenza* tra due variabili, cioè quanto le loro variazioni risultano correlate.

Diamo quindi la definizione formale:

DEFINIZIONE 11.11: Sia $\begin{bmatrix} X \\ Y \end{bmatrix} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^2, \mathcal{B}^2)$ un vettore aleatorio tale che $X, Y \in L^2(\Omega)$. Si definisce Covarianza di X e Y il *numero*:

$$Cov(X, Y) = E[(X - E[X]) \cdot (Y - E[Y])]$$

È stato specificato che la Covarianza è un numero, in quanto:

$$\begin{aligned} X, Y \in L^2 &\Rightarrow X \cdot Y \in L^1 \Rightarrow \exists E[X], E[Y] \\ &\Rightarrow (X - E[X]) \in L^2, (Y - E[Y]) \in L^2 \\ &\Rightarrow (X - E[X]) \cdot (Y - E[Y]) \in L^1 \end{aligned}$$

Si osservi che se si definisce $h(x, y) = (x - \mu_x) \cdot (y - \mu_y)$, con $(x, y) \in \mathbb{R}^2$, allora possiamo vedere la covarianza come

$$Cov(X, Y) = E[(X - E[X]) \cdot (Y - E[Y])] = E[h(X, Y)]$$

che per la regola del valore atteso sappiamo essere:

$$Cov(X, Y) = E[h(X, Y)] = \int_{\mathbb{R}^2} h(x, y) dP^{(X, Y)}$$

Ecco perché la covarianza ci dà un'indicazione della relazione che intercorre tra le due variabili aleatorie e perché la si introduce solo a seguito di un approfondito studio dei vettori aleatori.

Come abbiamo visto nei capitoli precedenti, la regola del valore atteso si declina in maniere differenti a seconda del tipo di $P^{(X, Y)}$. Si quindi aprono due casistiche:

- $P^{(X, Y)}$ è una misura di probabilità discreta su $\mathcal{B}^2$ con densità congiunta discreta data dalla funzione $p_{(X, Y)} : T \rightarrow [0, 1]$ e T discreto. Allora il calcolo della covarianza si riduce a:

$$Cov(X, Y) = \sum_{(x, y) \in T} (x - \mu_x)(y - \mu_y) \cdot p_{(X, Y)}(x, y)$$

- $P^{(X, Y)}$ è una misura di probabilità assolutamente continua su $\mathcal{B}^2$, con densità congiunta $f_{(X, Y)}$, allora il calcolo della covarianza si riduce a:

$$Cov(X, Y) = \int_{\mathbb{R}^2} (x - \mu_x)(y - \mu_y) \cdot f_{(X, Y)}(x, y) dx dy$$

Come si può immaginare, la covarianza non ha un segno ben definito, come era per esempio nel caso della varianza. Abbiamo quindi 3 casistiche:

- $Cov(X, Y) > 0$ quando X ed Y sono positivamente correlate: se una cresce, l'altra fa lo stesso.
- $Cov(X, Y) < 0$ quando X ed Y sono negativamente correlate: se una cresce, l'altra decresce.
- $Cov(X, Y) = 0$ quando X ed Y sono scorrelate.

TEOREMA 11.12 Proprietà della Covarianza : $\forall X, Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$ valgono le seguenti:

1. $Cov(X, X) = Var(X)$
2. $Cov(X, Y) = Cov(Y, X)$
3. $Cov(X, Y) = E[X \cdot Y] - E[X] \cdot E[Y]$
4. È una forma bilineare: $a, b, c \in \mathbb{R}$:

$$Cov(aX + bY + c, Z) = aCov(X, Z) + bCov(Y, Z) + 0$$

5. $X \perp\!\!\!\perp Y \Rightarrow Cov(X, Y) = 0$ (Non è valido il viceversa!!)

6. $Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)$

7. Cauchy Schwarz:

$$|Cov(X, Y)| \leq \sqrt{Var(X)}\sqrt{Var(Y)}$$

Dimostrazione. Si dimostrano sono alcune di queste la 6. e 7.

$$\begin{aligned} Var(X + Y) &= E \left[((X + Y - E[X + Y]))^2 \right] = E \left[(X - E[X] + Y - E[Y])^2 \right] \\ &= E \left[(X - E[X])^2 + (Y - E[Y])^2 + 2((X - E[X])(Y - E[Y])) \right] \\ &= Var(X) + Var(Y) + 2Cov(X, Y) \end{aligned}$$

$$\begin{aligned} 0 \leq Var(aX + bY) &= Var(aX) + Var(bY) + 2Cov(aX, bY) = \\ &= a^2 Var(X) + b^2 Var(Y) + 2ab Cov(X, Y) \\ &= \begin{bmatrix} a & b \end{bmatrix} \underbrace{\begin{bmatrix} Var(X) & Cov(X, Y) \\ Cov(X, Y) & Var(Y) \end{bmatrix}}_{=: C \in \mathbb{R}^2} \begin{bmatrix} a \\ b \end{bmatrix} \\ \iff C \geq 0 &\iff \det(C) = Var(X) Var(Y) - Cov^2(X, Y) \geq 0 \\ \iff |Cov(X, Y)| &\leq \sqrt{Var(X)}\sqrt{Var(Y)} \end{aligned}$$

□

Il punto 6. del precedente teorema può essere generalizzato:

Date $X_1, \dots, X_n$ variabili aleatorie in $L^2(\mathbb{P})$, allora¹:

$$\begin{aligned} Var(X_1 + \dots + X_n) &= \sum_{k=1}^n Var(X_k) + \sum_{h \neq k} Cov(X_h, X_k) \\ &= \sum_{k=1}^n Var(X_k) + 2 \sum_{h < k} Cov(X_h, X_k) \end{aligned}$$

Inoltre, dato che se $X \perp\!\!\!\perp Y$, allora $Cov(X, Y) = 0$, possiamo dedurre che (nel caso in cui $X \perp\!\!\!\perp Y$)

$$Var(X + Y) = Var(X) + Var(Y)$$

Si presti attenzione al fatto che, se $X \perp\!\!\!\perp Y$:

$$Var(X - Y) = Var(X) + Var(-Y) = Var(X) + Var(Y)$$

11.3.1 Coefficiente di Correlazione Lineare

Come abbiamo visto, la covarianza ci fornisce una misura di quanto due variabili aleatorie siano correlate, indicando se tendono a crescere o decrescere insieme. Sorge però un problema: la covarianza dipende dall'unità di misura delle variabili considerate.

Ad esempio, se entrambe le variabili descrivono un fenomeno espresso in metri, la covarianza risulterà espressa in metri quadrati; se invece una fosse in chilogrammi e l'altra in secondi, l'unità diventerebbe ancora diversa. Questo rende difficile confrontare covarianze tra coppie di variabili differenti.

¹ $X_1, \dots, X_n$ variabili aleatorie in $L^p(\mathbb{P}) \iff \underline{X} = [X_1, \dots, X_n]^\top \in L^p(\mathbb{P}; \mathbb{R}^n)$

Per ovviare a questo limite, si introduce il coefficiente di correlazione lineare, una versione adimensionale della covarianza che misura esclusivamente l'intensità e la direzione della relazione lineare tra due variabili, indipendentemente dalle loro unità di misura.

DEFINIZIONE 11.13: Siano $X, Y \in L^2(\mathbb{P})$ e $Var(X) := \sigma_X^2 > 0$, $\sigma_Y^2 > 0$. Si definisce Coefficiente di Correlazione Lineare il numero:

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sqrt{\sigma_X^2 \sigma_Y^2}}$$

Definite quindi: $\sigma_X = \left| \sqrt{\sigma_X^2} \right|$ e $\sigma_Y = \left| \sqrt{\sigma_Y^2} \right|$, allora diventa:

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

PROPOSIZIONE 11.14 Proprietà del Coeff. di Correlazione Lineare : Date $X, Y \in L^2$ e $\sigma_X^2 > 0$, $\sigma_Y^2 > 0$, allora valgono le seguenti:

1. $|\rho(X, Y)| \leq 1$ (Conseguenza della 11.12 punto 7.)
2. $|\rho(X, Y)| = 1 \iff \exists a \neq 0, b \in \mathbb{R}$ tali che $Y = aX + b$ quasi certamente, con Y definita retta di regressione lineare.

Dove:

$$a = \frac{Cov(X, Y)}{\sigma_X^2}; \quad b = E[X] - \frac{Cov(X, Y)}{\sigma_X^2} E[X]$$

11.4 Vettore Media e Matrice di Varianza

DEFINIZIONE 11.15 Vettore Media : Sia $\underline{X} = (X_1, \dots, X_n) : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ un vettore aleatorio tale che $\underline{X} \in L^1$. Si definisce vettore delle medie $E[\underline{X}] = \mu_{\underline{X}}$ il vettore:

$$\mu_{\underline{X}} = \begin{bmatrix} \mu_{X_1} \\ \vdots \\ \mu_{X_n} \end{bmatrix}$$

DEFINIZIONE 11.16 Matrice Varianza : Sia $\underline{X}$ un vettore aleatorio in $\mathbb{R}^n$ tale che $\underline{X} \in L^2$. Si definisce matrice di Varianza (o Covarianza) $C_{\underline{X}}$:

$$C_{\underline{X}} = E \left[(\underline{X} - E[\underline{X}]) \cdot (\underline{X} - E[\underline{X}])^T \right] = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \cdots & Cov(X_1, X_n) \\ Cov(X_2, X_1) & Var(X_2) & \cdots & Cov(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_n, X_1) & Cov(X_n, X_2) & \cdots & Var(X_n) \end{bmatrix}$$

Dove: $(C_{\underline{X}})_{ij} = Cov(X_i, X_j)$

Vediamo le principali proprietà di questa matrice.

TEOREMA 11.17: Sia $\underline{\mathbf{X}} = [X_1, \dots, X_n]^\top$ un vettore aleatorio tale che $X_k \in L^2$ per ogni $k = 1, \dots, n$ e siano $\mu_{\underline{\mathbf{X}}}$ il suo vettore media e $C_{\underline{\mathbf{X}}}$ la sua matrice di covarianza.

Allora vale che:

1. $C_{\underline{\mathbf{X}}} \in M(n \times n)$ è simmetrica e semidefinita positiva, ossia che:

$$C_{\underline{\mathbf{X}}}^\top = C_{\underline{\mathbf{X}}} \quad \text{e} \quad \underline{\mathbf{a}} \in \mathbb{R}^n : \quad \langle \underline{\mathbf{a}}, C_{\underline{\mathbf{X}}} \cdot \underline{\mathbf{a}} \rangle_{\mathbb{R}^n} \geq 0$$

Dove $\langle \cdot, \cdot \rangle_{\mathbb{R}^n}$ è il prodotto scalare in $\mathbb{R}^n$

2. $\underline{\mathbf{X}} \in \text{Im}(C_{\underline{\mathbf{X}}}) + \mu_{\underline{\mathbf{X}}}$ quasi certamente
3. Se $\underline{\mathbf{Y}} = A\underline{\mathbf{X}} + \underline{\mathbf{b}}$, $A \in M(k \times n)$, $\underline{\mathbf{b}} \in \mathbb{R}^k \Rightarrow \underline{\mathbf{Y}}$ è un vettore aleatorio in $\mathbb{R}^k$ e vale che:

$$\mu_{\underline{\mathbf{Y}}} = A\mu_{\underline{\mathbf{X}}} + \underline{\mathbf{b}} \quad \text{e} \quad C_{\underline{\mathbf{Y}}} = AC_{\underline{\mathbf{X}}}A^\top \in M(k \times k)$$

Dimostrazione. 1. Per definizione si ha che $C_{ij} = \text{Cov}(X_i, X_j)$. Allora $\forall \underline{\mathbf{a}} \in \mathbb{R}^n$:

$$\begin{aligned} \langle \underline{\mathbf{a}}, C_{\underline{\mathbf{X}}} \cdot \underline{\mathbf{a}} \rangle &= \underline{\mathbf{a}}^\top C_{\underline{\mathbf{X}}} \underline{\mathbf{a}} = \sum_{h,k=1}^n a_k C_{hk} a_h = \sum_{h,k=1}^n a_k \text{Cov}(X_k, X_h) a_h \\ &= \text{Cov} \left(\sum_{k=1}^n a_k X_k, \sum_{h=1}^n a_h X_h \right) \\ &= \text{Var} \left(\sum_{k=1}^n a_k X_k \right) \geq 0 \end{aligned}$$

2. Non la dimostriamo

3. Da definizione:

$$\begin{aligned} C_{\underline{\mathbf{Y}}} &= E \left[(\underline{\mathbf{Y}} - E[\underline{\mathbf{Y}}]) \cdot (\underline{\mathbf{Y}} - E[\underline{\mathbf{Y}}])^\top \right] = E \left[A(\underline{\mathbf{X}} - E[\underline{\mathbf{X}}]) \cdot (A(\underline{\mathbf{X}} - E[\underline{\mathbf{X}}]))^\top \right] \\ &= A \cdot E \left[(\underline{\mathbf{X}} - E[\underline{\mathbf{X}}]) \cdot (\underline{\mathbf{X}} - E[\underline{\mathbf{X}}])^\top \right] \cdot A^\top \\ &= AC_{\underline{\mathbf{X}}}A^\top \end{aligned}$$

□

Poiché $C_{\underline{\mathbf{X}}}$ è una matrice simmetrica e semidefinita positiva, essa ammette una decomposizione spettrale i cui autovettori individuano le *direzioni principali di variabilità* del vettore $\underline{\mathbf{X}}$, mentre i corrispondenti autovalori ne rappresentano le *varianze lungo tali direzioni*.

Ciò significa che, *quasi certamente*, il vettore $\underline{\mathbf{X}}$ assume valori nello spazio $\mu_{\underline{\mathbf{X}}} + \text{Im}(C_{\underline{\mathbf{X}}})$, il quale è ottenuto traslando lo spazio vettoriale $\text{Im}(C_{\underline{\mathbf{X}}})$ del vettore medio $\mu_{\underline{\mathbf{X}}}$.

In altri termini, $\underline{\mathbf{X}} - \mu_{\underline{\mathbf{X}}} \in \text{Im}(C_{\underline{\mathbf{X}}})$ q.c., ossia le fluttuazioni di $\underline{\mathbf{X}}$ rispetto alla media sono sempre contenute nello spazio generato dalle colonne di $C_{\underline{\mathbf{X}}}$.

ESEMPIO: Sia $\underline{X} = (X_1, X_2)^\top$ con $X_2 = X_1$. In tal caso la matrice di covarianza è

$$C_{\underline{X}} = \sigma^2 \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

che ha rango 1. L'immagine di $C_{\underline{X}}$ è dunque la retta generata da $(1, 1)^\top$, e infatti $\underline{X}$ assume valori sulla retta $x_2 = x_1$, traslata di $\mu_{\underline{X}}$. Pertanto, la variabilità di $\underline{X}$ è confinata al sottospazio affine $\mu_{\underline{X}} + \text{Im}(C_{\underline{X}})$.

Inoltre, abbiamo due casi molto evidenti in cui possiamo escludere a priori che $\underline{X}$ non sia assolutamente continuo:

★ Se $\dim(\text{Im}(C_{\underline{X}})) < n \Rightarrow m_n(\text{Im}(C_{\underline{X}})) = 0 \Rightarrow \underline{X}$ non può essere assolutamente continuo.

Questo perchè:

$$\begin{aligned} \underline{X} \in \text{Im}(C_{\underline{X}}) + \mu_{\underline{X}} \text{ q.c.} &\iff \mathbb{P}(\underline{X} \in \text{Im}(C_{\underline{X}}) + \mu_{\underline{X}}) = 1 \\ &\iff P^{\underline{X}}(\text{Im}(C_{\underline{X}}) + \mu_{\underline{X}}) = 1 \end{aligned}$$

Il che è un assurdo, in quanto dovrebbe valere 0, siccome la misura di Lebesgue vale 0.

★ Se $\det(C_{\underline{X}}) = 0 \Rightarrow \text{Im}(C_{\underline{X}}) \leq n - 1 \Rightarrow \underline{X}$ non è assolutamente continuo.

11.5 Funzione di Ripartizione Multidimensionale

Come per il caso monodimensionale, vorremmo trovare una funzione su $\mathbb{R}^n$ che ci dia informazioni sulla probabilità $\mathbb{P}$ sui $\mathcal{B}^n$.


Si può definire la funzione di ripartizione multidimensionale $F: \mathbb{R}^n \rightarrow [0, 1]$ come segue:

$$F(t_1, \dots, t_n) = \mathbb{P}((-\infty, t_1] \times \dots \times (-\infty, t_n])$$

E similmente, se $\underline{X}$ è un vettore aleatorio su $\mathbb{R}^n$:

$$F_{\underline{X}}(t_1, \dots, t_n) = P^{\underline{X}}((-\infty, t_1] \times \dots \times (-\infty, t_n])$$

ESEMPIO: Poniamoci nel caso semplice in cui $n = 2$:



È subito evidente che, se nel caso monodimensionale la retta reale ha un ordinamento totale, questo non è vero nei caso con $n \geq 1$; diventa quindi difficile definire il concetto di monotonia in un senso comodo ai nostri scopi.

Inoltre fare le derivate della fdr multidimensionale diventa estremamente laborioso.

Nasce quindi la necessità modellistica di utilizzare altre funzioni che possano aiutarci a lavorare con i vettori aleatori, come la *funzione caratteristica*, che analizzeremo nel prossimo capitolo.

12 Funzione Caratteristica

Dalla teoria sviluppata finora sappiamo che una probabilità definita su $(\mathbb{R}, \mathcal{B})$ può essere completamente caratterizzata attraverso la funzione di ripartizione e, quando esiste, la densità (sia essa discreta o continua). Abbiamo inoltre visto che, nel caso multidimensionale $(\mathbb{R}^n, \mathcal{B}^n)$, la densità congiunta gioca un ruolo analogo, consentendo di caratterizzare la legge di un vettore aleatorio.

In questo capitolo introdurremo un nuovo strumento di caratterizzazione delle probabilità: la **funzione caratteristica**. Essa presenta una serie di notevoli vantaggi teorici e pratici, poiché consente di trattare in modo unificato sia variabili discrete sia continue, semplifica il calcolo dei valori attesi e dei momenti, e facilita lo studio di proprietà fondamentali quali indipendenza, continuità e combinazioni lineari di variabili aleatorie.

È un principio ricorrente in matematica che spesso sia possibile comprendere o risolvere un problema trasformandolo in un altro spazio, affrontandolo lì e poi riportando la soluzione nello spazio originale.

Tra le trasformazioni più importanti figurano la trasformata di Laplace e la trasformata di Fourier. Sebbene esse siano largamente impiegate nello studio delle equazioni differenziali, si rivelano strumenti straordinariamente potenti anche nell'ambito della teoria della probabilità. Permettono, infatti, di analizzare variabili aleatorie e di fornire dimostrazioni brevi ed eleganti di risultati fondamentali, come il Teorema del Limite Centrale (che vedremo in seguito). Tra le due, la trasformata di Fourier è la più raffinata e versatile, e per questo motivo rappresenta lo strumento di maggiore utilità nelle applicazioni probabilistiche.

DEFINIZIONE 12.1: Sia $\mathbb{P}$ una probabilità su $\mathcal{B}^n$, definiamo la funzione caratteristica di $\mathbb{P}$ la seguente funzione $\varphi : \mathbb{R}^n \rightarrow \mathbb{C}$, definita come segue:

$$\varphi(\underline{u}) = \int_{\mathbb{R}^n} e^{i\langle \underline{u}, \underline{x} \rangle} d\mathbb{P} \quad \forall \underline{u} \in \mathbb{R}^n$$

Come notazione alternativa, per tenere conto che è una trasformazione di una misura di probabilità, si può usare: $\widehat{\mathbb{P}} \equiv \varphi$.

Avendo solo la definizione, possiamo già fare alcune osservazioni fondamentali.

★ φ è a valori complessi, e l'integranda è $e^{i\langle \underline{u}, \underline{x} \rangle}$, dove:

$$\langle \underline{u}, \underline{x} \rangle = \sum_{k=1}^n u_k x_k = \theta \in \mathbb{R}$$

Di conseguenza avremo che la funzione integranda è tale che:

$$e^{i\langle \underline{u}, \underline{x} \rangle} = e^{i\theta} = \cos \theta + i \sin \theta \quad \Rightarrow \quad |e^{i\langle \underline{u}, \underline{x} \rangle}| = \sqrt{\cos^2 \theta + \sin^2 \theta} = 1$$

★ Siccome $h : \mathbb{R}^n \rightarrow \mathbb{C}$, possiamo vederla come:

$$h(\underline{x}) = \Re(h(\underline{x})) + i\Im(h(\underline{x})) := h_1(\underline{x}) + ih_2(\underline{x})$$

Dove si ha quindi che $h_1, h_2 : \mathbb{R}^n \rightarrow \mathbb{R}$, allora:

$$\int_{\mathbb{R}^n} h(\underline{x}) d\mathbb{P} = \int_{\mathbb{R}^n} h_1(\underline{x}) d\mathbb{P} + i \int_{\mathbb{R}^n} h_2(\underline{x}) d\mathbb{P} \quad " = " \quad \left[\int_{\mathbb{R}^n} h_1(\underline{x}) d\mathbb{P} \right]$$

Ossia che possiamo rappresentare geometricamente $\mathbb{C}$ come il piano $\mathbb{R}^2$.¹

★ Tutte le proprietà che abbiamo visto precedentemente per l'integrale di funzioni a valori reali

$$\int_{\mathbb{R}^n} f \, d\mathbb{P}, \quad \text{con} \quad f : \mathbb{R}^n \rightarrow \mathbb{R}$$

valgono anche per funzioni a valori complessi

$$\int_{\mathbb{R}^n} h \, d\mathbb{P}, \quad \text{con} \quad h : \mathbb{R}^n \rightarrow \mathbb{C}$$

In particolare:

$$h \in L^1(\mathbb{P}) \iff h_1 = \Re(h_1), \, h_2 = \Im(h_2) \in L^1(\mathbb{P})$$

In tal caso, posso stimare l'integrale complesso con uno reale:

$$\left| \int_{\mathbb{R}^n} h(\mathbf{x}) \, d\mathbb{P} \right| \leq \int_{\mathbb{R}^n} |h(\mathbf{x})| \, d\mathbb{P}$$

★ Abbiamo già notato che $|e^{i\langle \mathbf{u}, \mathbf{x} \rangle}| = 1$, e unendo questo fatto con l'ultima osservazione, possiamo dire che:

$$|\varphi(\mathbf{u})| = \left| \int_{\mathbb{R}^n} e^{i\langle \mathbf{u}, \mathbf{x} \rangle} \, d\mathbb{P} \right| \leq \int_{\mathbb{R}^n} |e^{i\langle \mathbf{u}, \mathbf{x} \rangle}| \, d\mathbb{P} = \int_{\mathbb{R}^n} d\mathbb{P} = 1$$

Ricavando che la funzione caratteristica è di natura limitata: $|\varphi(\mathbf{u})| \leq 1$.

DEFINIZIONE 12.2: Dato $\mathbf{X} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ vettore aleatorio con legge $P^{\mathbf{X}}$ su $\mathcal{B}^n$, si definisce funzione caratteristica di $\mathbf{X}$ la funzione:

$$\varphi_{\mathbf{X}}(\mathbf{u}) := \hat{P}^{\mathbf{X}}(\mathbf{u}) = \int_{\mathbb{R}^n} e^{i\langle \mathbf{u}, \mathbf{x} \rangle} \, dP^{\mathbf{X}}$$

Grazie alla legge del valore atteso diventa:

$$\begin{aligned} \varphi_{\mathbf{X}}(\mathbf{u}) &= \int_{\mathbb{R}^n} e^{i\langle \mathbf{u}, \mathbf{x} \rangle} \, dP^{\mathbf{X}} = \int_{\mathbb{R}^n} e^{i\langle \mathbf{u}, \mathbf{X} \rangle} \, d\mathbb{P} \\ &= E[e^{i\langle \mathbf{u}, \mathbf{X} \rangle}] \\ &= E[\cos(\langle \mathbf{u}, \mathbf{X} \rangle)] + iE[\sin(\langle \mathbf{u}, \mathbf{X} \rangle)] \end{aligned}$$

Ora che abbiamo dato tutte le definizioni formali, facciamo qualche esempio per capire nel concreto cosa è la funzione caratteristica.

ESEMPIO: Sia $X = \mu \in \mathbb{R}$ quasi certamente, allora $\forall u \in \mathbb{R}$:

$$\varphi_X(u) = E[e^{iuX}] = e^{iu\mu} \cdot P^X(\{\mu\}) = e^{iu\mu} = \cos(u\mu) + i\sin(u\mu)$$

Si noti come la φ_X è una funzione esclusivamente di u , come già era esplicito nella definizione.

¹Tecnicamente infatti $\mathbb{C}$ e $\mathbb{R}^2$ sono omeomorfi come spazi topologici metrici, attraverso la trasformazione $(a + ib) \leftrightarrow (a, b)$

ESEMPIO : Sia $X \sim Po(\lambda)$, $p_X(k) = \frac{\lambda^k}{k!} e^{-\lambda}$, $k \in \mathbb{N}$. Allora la funzione caratteristica si è:

$$\begin{aligned}\varphi_X(u) &= E[\underbrace{e^{iuX}}_{h(X)}] = \sum_{k=0}^{+\infty} e^{iuk} p_X(k) = \sum_{k=0}^{+\infty} e^{iuk} \frac{\lambda^k}{k!} e^{-\lambda} = \sum_{k=0}^{+\infty} \frac{(e^{iu}\lambda)^k}{k!} e^{-\lambda} \\ &= e^{-\lambda} \sum_{k=0}^{+\infty} \frac{(e^{iu}\lambda)^k}{k!} = e^{-\lambda} e^{e^{iu}\lambda} \\ &= e^{\lambda(e^{iu}-1)}\end{aligned}$$

ESEMPIO : Sia $X \sim \mathcal{E}(\lambda)$, $\lambda > 0$, $f_X(u) = \lambda e^{-\lambda x} \mathbb{I}_{[0,+\infty)}(x)$. Allora per ogni $u \in \mathbb{R}$:

$$\varphi_X(u) = E[e^{iuX}] = \int_{\mathbb{R}} e^{iux} f_X(x) dx = \int_0^{+\infty} e^{iux} \lambda e^{-\lambda x} dx = \frac{\lambda}{iu - \lambda}$$

TEOREMA 12.3 Proprietà della Funzione Caratteristica : Sia $\mathbb{P}$ una misura di probabilità su $\mathcal{B}^n$, con $\hat{\mathbb{P}}$ la sua funzione caratteristica. Allora valgono le seguenti:

1. $\hat{\mathbb{P}}$ caratterizza univocamente $\mathbb{P}$.

Ossia che, se $\mathbb{Q}$ è un'altra misura di probabilità su $\mathcal{B}^n$ con $\hat{\mathbb{Q}}$, allora:

$$\mathbb{P}(A) = \mathbb{Q}(A) \quad \forall A \in \mathcal{B}^n \quad \Longleftrightarrow \quad \hat{\mathbb{P}}(\underline{u}) = \hat{\mathbb{Q}}(\underline{u}) \quad \forall \underline{u} \in \mathbb{R}^n$$

2. Data una funzione caratteristica $\varphi : \mathbb{R}^n \rightarrow \mathbb{C}$ di una qualsiasi probabilità $\mathbb{P}$ su $\mathcal{B}^n$, allora è vero che:

- (a) φ è continua
- (b) φ è limitata
- (c) $\varphi(\underline{0}) = 1$

Dimostrazione. Dimosteremo solo la 2.

1. Definiamo la successione $\underline{u}_k \xrightarrow[k \rightarrow +\infty]{} \underline{u}$ in $\mathbb{R}^n$. Dobbiamo dimostrare che $\varphi(\underline{u}_k) \rightarrow \varphi(\underline{u})$.

Senza perdere di generalità, poniamoci nel caso in cui $n = 1$. Per continuità di $u \mapsto e^{iux}$, sappiamo che $e^{iu_k x} \rightarrow e^{iux} \quad \forall x \in \mathbb{R}$. Inoltre sappiamo che $|e^{iu_k x}| \leq 1 \quad \forall k$.

Allora possiamo applicare il Teorema di Lebesgue (della convergenza dominata), e allora posso scambiare integrale e limite, trovando che:

$$\int_{\mathbb{R}^n} e^{iu_k x} d\mathbb{P} \longrightarrow \int_{\mathbb{R}^n} e^{iux} d\mathbb{P} \quad \Rightarrow \quad \varphi(u_k) \rightarrow \varphi(u)$$

□

TEOREMA 12.4: Sia $\underline{X} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ un vettore aleatorio, con funzione caratteristica $\varphi_{\underline{X}}$. Allora valgono le seguenti:

1. Se $\underline{\mathbf{X}} \in L^m(\mathbb{P})$ (ossia che $E[|X_k|^m] < +\infty, \forall k = 1, \dots, n$). Siano $k_1, \dots, k_m \in \{1, \dots, n\}$ allora:

$$\varphi_{\underline{\mathbf{X}}} \in C^m(\mathbb{R}^n, \mathbb{C}) \quad \text{e} \quad \boxed{\frac{\partial^m}{\partial u_{k_1} \dots \partial u_{k_m}} \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{u}}) = i^m E[X_{k_1} \dots X_{k_m} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle}]}$$

2. $\underline{\mathbf{Y}} = A\underline{\mathbf{X}} + \underline{\mathbf{b}}, A \in M(k \times n), \underline{\mathbf{b}} \in \mathbb{R}^k : \Rightarrow \forall \underline{\mathbf{v}} \in \mathbb{R}^k \quad \boxed{\varphi_{\underline{\mathbf{Y}}}(\underline{\mathbf{v}}) = e^{i\langle \underline{\mathbf{v}}, \underline{\mathbf{b}} \rangle} \cdot \varphi_{\underline{\mathbf{X}}}(A^\top \underline{\mathbf{v}})}$

3. $X_1, \dots, X_n$ sono n variabili aleatorie indipendenti $\iff \varphi_{\underline{\mathbf{X}}}(u_1, \dots, u_n) = \varphi_{X_1}(u_1) \dots \varphi_{X_n}(u_n)$

Dimostrazione. Della prima mostreremo solo un'idea di come si svolge la dimostrazione.

1. Siccome $X_k \in L^m(\mathbb{P}) \Rightarrow |X_{k_1} \dots X_{k_m}| \in L^1(\mathbb{P}) \Rightarrow e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} \cdot X_{k_1} \dots X_{k_m} \in L^1(\mathbb{P})$

Osserviamo anzitutto che, per ogni $k \in \{1, \dots, n\}$, $\frac{\partial}{\partial u_k} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} = iX_k e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle}$. Iterando questa identità, per una qualunque m -upla di indici $k_1, \dots, k_m$, otteniamo

$$\frac{\partial^m}{\partial u_{k_1} \dots \partial u_{k_m}} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} = i^m X_{k_1} \dots X_{k_m} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle}$$

Siccome possiamo integrare, e scambiare il segno di integrale e derivata (non dimostrato), otteniamo che:

$$\begin{aligned} \int_{\mathbb{R}^n} \frac{\partial^m}{\partial u_{k_1} \dots \partial u_{k_m}} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} &= \int_{\mathbb{R}^n} i^m X_{k_1} \dots X_{k_m} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} \\ \Rightarrow \frac{\partial^m}{\partial u_{k_1} \dots \partial u_{k_m}} \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{u}}) &= i^m \cdot E[X_{k_1} \dots X_{k_m} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle}] \end{aligned}$$

2. Per definizione abbiamo che:

$$\begin{aligned} \varphi_{\underline{\mathbf{Y}}}(\underline{\mathbf{u}}) &= E[e^{i\langle \underline{\mathbf{Y}}, \underline{\mathbf{u}} \rangle}] = E[e^{i\langle A\underline{\mathbf{X}} + \underline{\mathbf{b}}, \underline{\mathbf{u}} \rangle}] = E[e^{i\langle A\underline{\mathbf{X}}, \underline{\mathbf{u}} \rangle} \cdot e^{i\langle \underline{\mathbf{b}}, \underline{\mathbf{u}} \rangle}] = e^{i\langle \underline{\mathbf{b}}, \underline{\mathbf{u}} \rangle} \cdot E[e^{i\langle A\underline{\mathbf{X}}, \underline{\mathbf{u}} \rangle}] \\ &= e^{i\langle \underline{\mathbf{b}}, \underline{\mathbf{u}} \rangle} \cdot E[e^{i\langle \underline{\mathbf{X}}, A^\top \underline{\mathbf{u}} \rangle}] = e^{i\langle \underline{\mathbf{b}}, \underline{\mathbf{u}} \rangle} \cdot \varphi_{\underline{\mathbf{X}}}(A^\top \underline{\mathbf{u}}) \end{aligned}$$

3. Dimostriamo prima l'implicazione ($\Rightarrow$): sapendo che $X_1, \dots, X_n$ sono indipendenti:

$$\begin{aligned} \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{u}}) &= E[e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle}] = E[e^{i\sum_{k=1}^n u_k X_k}] = E[e^{iu_1 X_1} \dots e^{iu_n X_n}] \stackrel{\text{I.I.}}{=} E[e^{iu_1 X_1}] \dots E[e^{iu_n X_n}] \\ &= \varphi_{X_1}(u_1) \dots \varphi_{X_n}(u_n) \end{aligned}$$

Per quanto riguarda l'implicazione ($\Leftarrow$):

$$\begin{aligned} P^{X_1} \otimes \dots \otimes P^{X_n} &= \int_{\mathbb{R}^n} e^{i\langle \underline{\mathbf{u}}, \underline{\mathbf{X}} \rangle} dP^{X_1} \otimes \dots \otimes P^{X_n} \stackrel{\text{F.T.}}{=} \int_{\mathbb{R}} e^{iu_1 X_1} dP^{X_1} \dots \int_{\mathbb{R}} e^{iu_n X_n} dP^{X_n} \\ &= \varphi_{X_1}(u_1) \dots \varphi_{X_n}(u_n) \stackrel{\text{Per ipotesi}}{=} \widehat{P}^{\underline{\mathbf{X}}} \end{aligned}$$

Si dimostra quindi che: $\widehat{P}^{\underline{\mathbf{X}}} = P^{X_1} \otimes \dots \otimes P^{X_n}$ e siccome la funzione caratteristica caratterizza la probabilità (Teorema 12.3), abbiamo che $\underline{\mathbf{X}}$ ha componenti indipendenti.

□

Il primo punto di questo teorema è particolarmente interessante, infatti questo afferma che possiamo effettuare uno scambio tra la derivata e l'integrale (valore atteso):

$$\frac{\partial^n}{\partial u_{k_1} \cdots \partial u_{k_n}} E[\cdot] = E \left[\frac{\partial^n}{\partial u_{k_1} \cdots \partial u_{k_n}} \cdot \right]$$

Inoltre semplifica di molto il calcolo dei valori attesi, varianze e covarianze, banalmente utilizzando $\varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{0}})$. Infatti, se $X_k \in L^2 \forall k$, allora:

- $E[X_k] = -i\varphi'_{X_k}(0)$
- $E[X_k^2] = -\varphi''_{X_k}(0) \Rightarrow \text{Var}(X_k) = -\varphi''_{X_k}(0) + (-i\varphi'_{X_k}(0))^2$
- $E[X_k \cdot X_j] = -\frac{\partial^2}{\partial u_k \partial u_j} \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{0}}) \Rightarrow \text{Cov}(X_k, X_j) = \frac{-\partial^2}{\partial u_k \partial u_j} \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{0}}) + \varphi'_{X_k}(0) \cdot \varphi'_{X_j}(0)$

COROLLARIO 12.5: Siano $\underline{\mathbf{X}}_1$ un vettore aleatorio in $\mathbb{R}^n$, e $\underline{\mathbf{X}}_2$ un vettore aleatorio in $\mathbb{R}^k$. Sia $\underline{\mathbf{X}} := \begin{bmatrix} \underline{\mathbf{X}}_1 \\ \underline{\mathbf{X}}_2 \end{bmatrix}$, allora:

$$\underline{\mathbf{X}}_1 \perp\!\!\!\perp \underline{\mathbf{X}}_2 \iff \varphi_{\underline{\mathbf{X}}}(\underline{\mathbf{u}}_1, \underline{\mathbf{u}}_2) = \varphi_{\underline{\mathbf{X}}_1}(\underline{\mathbf{u}}_1) \cdot \varphi_{\underline{\mathbf{X}}_2}(\underline{\mathbf{u}}_2)$$

COROLLARIO 12.6: Se $\underline{\mathbf{X}} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$ è a componenti indipendenti, allora:

$$\varphi_{X_1+\dots+X_n}(u) = \varphi_{X_1}(u) \cdots \varphi_{X_n}(u)$$

Dimostrazione. Dal punto 3. del Teorema 12.4, risulta evidente che:

$$\varphi_{X_1+\dots+X_n}(u) = \varphi_{\underline{\mathbf{X}}}(u, \dots, u) = \varphi_{X_1}(u) \cdots \varphi_{X_n}(u)$$

□

TEOREMA 12.7: Sia $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ un vettore aleatorio in $\mathbb{R}^n$ con legge congiunta $P^{(X_1, X_2)}$. Si ponga $Y = X_1 + X_2$, allora valgono le seguenti:

1. P^Y su $\mathcal{B}$ è ben definita, infatti, $\forall B \in \mathcal{B}$:

$$\begin{aligned} P^Y(B) &= \mathbb{P}(Y \in B) = E[\mathbb{I}_{Y \in B}] = E[\mathbb{I}_B(Y)] = E[\mathbb{I}_B(X_1 + X_2)] = E[h(X_1, X_2)] \\ &= \int_{\mathbb{R}^2} \mathbb{I}_B(X_1 + X_2) dP^{(X_1, X_2)}(x_1, x_2) \\ &= \int_{\{(x_1, x_2): x_1+x_2 \in B\}} dP^{(X_1, X_2)}(x_1, x_2) \end{aligned}$$

2. Se $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ è assolutamente continuo $\Rightarrow Y$ è assolutamente continuo e vale che:

$$f_Y(y) = \int_{\mathbb{R}} f_{(X_1, X_2)}(y-t, t) dt$$

Inoltre, se $X_1 \perp\!\!\!\perp X_2$ allora:

$$\int_{\mathbb{R}} f_{X_1}(y-t) f_{X_2}(t) dt =: (f_{X_1} * f_{X_2})(y)$$

Il quale si definisce *Prodotto di Convoluzione*

3. Se $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ è discreto con densità congiunta $p_{(X_1, X_2)} \Rightarrow Y$ è discreto e vale che:

$$p_Y(y) = \sum_{x_2 \in S_{x_2}} p_{(X_1, X_2)}(y - x_2, x_2)$$

Inoltre, se $X_1 \perp\!\!\!\perp X_2$ allora:

$$p_Y(y) = \sum_{x_2 \in S_{x_2}} p_{X_1}(y - x_2) p_{X_2}(x_2)$$

12.1 Applicazioni Notevoli

Andiamo a vedere alcune applicazioni notevoli della funzione caratteristica.

★ Sia $X \sim G(p)$; $p_X(k) = (1-p)^{k-1}p$ con $k \geq 1$. Ci chiediamo: *quanto vale $E[X]$* ? Per definizione abbiamo che la funzione caratteristica risulta essere:

$$\varphi_X(u) = \sum_{k \geq 1} e^{iuk} (1-p)^{k-1} p = \frac{pe^{iu}}{1 - e^{iu}(1-p)}$$

A questo punto, per il punto 1. del Teorema 12.4 possiamo calcolare facilmente il valore atteso:

$$\varphi'_X(u) \Big|_{u=0} = iE[X] \Rightarrow E[X] = \frac{1}{p}$$

Grazie alla funzione caratteristica siamo riusciti a ricavare il valore atteso senza calcolare integrali, ma banalmente facendo una derivata.

★ Sia $X \sim \mathcal{N}(0, 1)$; $f_X(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}$ con $t \in \mathbb{R}$.

Questa è la distribuzione Normale Standard, e si può dimostrare che $E[|X|^m] < +\infty \quad \forall m$. Ricaviamoci la funzione caratteristica:

$$\sqrt{2\pi} \cdot \varphi_X(u) = \int_{\mathbb{R}} e^{iux} e^{-\frac{x^2}{2}} dx = \int_{\mathbb{R}} \cos(ux) e^{-\frac{x^2}{2}} dx + i \int_{\mathbb{R}} \sin(ux) e^{-\frac{x^2}{2}} dx \xrightarrow{0}$$

Inoltre sappiamo che:

$$\begin{aligned} \varphi'_X(u) &= iE[Xe^{iuX}] = \frac{i}{\sqrt{2\pi}} \int_{\mathbb{R}} x \cos(ux) e^{-\frac{x^2}{2}} dx - \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} x \sin(ux) e^{-\frac{x^2}{2}} dx \\ &= -\frac{1}{\sqrt{2\pi}} \left[-e^{-\frac{x^2}{2}} \sin(ux) \Big|_{-\infty}^{+\infty} + \int_{\mathbb{R}} u \cdot \cos(ux) e^{-\frac{x^2}{2}} dx \right] = -\frac{u}{\sqrt{2\pi}} \int_{\mathbb{R}} \cos(ux) e^{-\frac{x^2}{2}} dx = -u \varphi_X(u) \end{aligned}$$

Abbiamo quindi che il calcolo della nostra funzione caratteristica si è trasformato in un problema di Cauchy, dove la condizione iniziale è dettata dal Teorema 12.3:

$$\begin{cases} \varphi'_X(u) = -u\varphi_X(u) \\ \varphi_X(0) = 0 \end{cases} \Rightarrow \boxed{\varphi_X(u) = e^{-\frac{u^2}{2}}}$$

A questo punto calcolare valore atteso e varianza diventa un gioco da ragazzi:

$$\begin{aligned} E[X] &= \frac{1}{i} \varphi'_X(0) = 0 \cdot \varphi_X(0) = 0 \\ \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}^2[X] = -\varphi''_X(0) = \varphi_X(0) - 0^2 \cdot \varphi_X(0) = 1 \end{aligned}$$

★ Sia $X \sim \mathcal{N}(\mu, \sigma^2)$ con $\sigma^2 > 0$. Ossia ci siamo spostati nel caso generale di una variabile aleatoria gaussiana; quanto vale $\varphi_X(u)$?

Possiamo facilmente ricondurci al caso precedente, andando a standardizzare la variabile aleatoria:

$$Z = \frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1) \iff X = \sigma Z + \mu$$

Allora, grazie al punto 2. del Teorema 12.4, il calcolo diventa estremamente semplice:

$$\boxed{\varphi_X(u) = e^{iu\mu} \varphi_Z(\sigma u) = e^{iu\mu} e^{-\frac{\sigma^2 u^2}{2}}}$$

★ Dato un vettore $\underline{X}$, possiamo ricavare la funzione caratteristica delle sue componenti $\varphi_{X_k}(u_k)$, conoscendo solo $\varphi_{\underline{X}}(\underline{u})$?

La risposta è sì. Per fare ciò, definiamo il vettore $\underline{v} = [0, \dots, u_k, \dots, 0]$, dove u è in k -esima posizione. Allora il prodotto scalare $\langle \underline{v}, \underline{X} \rangle = \sum_{h=1}^n v_h X_h = u_k X_k$, e di conseguenza:

$$\varphi_{\underline{X}}(\underline{v}) = E[e^{i\langle \underline{v}, \underline{X} \rangle}] = E[e^{iu_k X_k}] = \varphi_{X_k}(u_k) \Rightarrow \boxed{\varphi_{\underline{X}}(0, \dots, u_k, \dots, 0) = \varphi_{X_k}(u_k)}$$

Abbiamo appena dimostrato che la funzione caratteristica multivariata $\varphi_{\underline{X}}(\underline{u})$, se valutata lungo una direzione che seleziona una sola componente X_k , coincide con la funzione caratteristica della variabile aleatoria scalare X_k .

★ Sia $\underline{X}$ un vettore aleatorio, e sia $\varphi_{\underline{X}}(\underline{u})$, $\underline{u} \in \mathbb{R}^n$ la sua funzione caratteristica. È possibile calcolare la funzione caratteristica $\varphi_{X_1 + \dots + X_n}(u)$ con $u \in \mathbb{R}$ della somma delle componenti di $\underline{X}$?

Anche in questo caso la risposta è sì:

$$\begin{aligned} \varphi_{X_1 + \dots + X_n}(u) &= E[e^{iu \cdot (X_1 + \dots + X_n)}] = E[e^{i(uX_1 + \dots + uX_n)}] = E[e^{i\langle \underline{s}, \underline{X} \rangle}] \quad \text{con } \underline{s} = (u, \dots, u) \\ \Rightarrow \quad \boxed{\varphi_{X_1 + \dots + X_n}(u) &= \varphi_{\underline{X}}(u, \dots, u)} \end{aligned}$$

★ Vogliamo andare a capire come si distribuiscono le somme di variabili aleatorie indipendenti e identicamente distribuite (i.i.d.):

- Siano: $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2) \perp\!\!\!\perp X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$

$$\varphi_{X_1 + X_2}(u) = \varphi_{X_1}(u) \cdot \varphi_{X_2}(u) = e^{iu\mu_1} e^{-\frac{\sigma_1^2 u^2}{2}} \cdot e^{iu\mu_2} e^{-\frac{\sigma_2^2 u^2}{2}} = e^{iu(\mu_1 + \mu_2)} e^{-\frac{(\sigma_1^2 + \sigma_2^2)u^2}{2}}$$

$$\boxed{X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)}$$

- Siano: $X_1 \sim Po(\lambda_1) \perp\!\!\!\perp X_2 \sim Po(\lambda_2)$ con $\lambda_1, \lambda_2 > 0$

$$\varphi_{X_1+X_2}(u) = \varphi_{X_1}(u) \cdot \varphi_{X_2}(u) = e^{\lambda_1(e^{iu}-1)} e^{\lambda_2(e^{iu}-1)} = e^{(\lambda_1+\lambda_2)(e^{iu}-1)}$$

$$\boxed{X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)}$$

- Siano date $X_1, \dots, X_n \sim Be(p)$ famiglia di V.A. indipendenti:

$$\varphi_{X_n}(u) = E[e^{iuX_n}] = e^{iu \cdot 0}(1-p) + e^{iu \cdot 1}(1-p) = (1-p) + e^{iu}p$$

E di conseguenza:

$$\varphi_{X_1+\dots+X_n}(u) = \varphi_{X_1}(u) \cdots \varphi_{X_n}(u) = [1-p+e^{iu}p]^n$$

$$\boxed{X_1 + \cdots + X_n \sim Bin(n, p)}$$

- Siano $X_1 \sim Bin(n_1, p) \perp\!\!\!\perp X_2 \sim Bin(n_2, p)$

$$\varphi_{X_1+X_2}(u) = \varphi_{X_1}(u) \cdot \varphi_{X_2}(u) = (1-p+e^{iu})^{n_1} (1-p+e^{iu})^{n_2} = (1-p+e^{iu})^{n_1+n_2}$$

$$\boxed{X_1 + X_2 \sim Bin(n_1 + n_2, p)}$$

13 Gaussian Multivariate

In questo capitolo estenderemo il concetto di variabile aleatoria gaussiana al caso multidimensionale, introducendo le **variabili gaussiane multivariate** o **vettori aleatori gaussiani**. Si tratta di vettori casuali la cui distribuzione congiunta è di tipo normale.

Le gaussiane multivariate rappresentano una classe di modelli di importanza fondamentale sia dal punto di vista teorico sia applicativo. Da un lato, esse costituiscono il naturale prolungamento della distribuzione normale univariata, conservandone la struttura analitica e le principali proprietà; dall'altro, sono ampiamente utilizzate in statistica, in machine learning e nella modellizzazione di fenomeni multidimensionali di tipo lineare, in quanto completamente descritte da un vettore di media e da una matrice di covarianza.

Nel seguito analizzeremo in dettaglio la loro definizione, le principali proprietà, la forma della densità, la funzione caratteristica e il ruolo della matrice di covarianza nella determinazione della dipendenza tra le componenti.

Iniziamo ricordando che, data una matrice C simmetrica ($C = C^T$) e reale, allora esiste una matrice O ortogonale ($O^T = O^{-1}$) tale che:

$$C = ODO^T \quad \text{con } D \text{ diagonale.}$$

Definiamo ora quando una variabile si dice Gaussiana, senza passare dalla densità, ma utilizzando la funzione caratteristica.

DEFINIZIONE 13.1 Variabile Gaussiana: X è una Variabile Aleatoria Gaussiana se la sua funzione caratteristica è tale che:

$$\varphi_X(u) = e^{iu\mu} e^{-\frac{\sigma^2 u^2}{2}}$$

Siccome φ_X caratterizza univocamente una probabilità, allora di conseguenza si ha che, per una variabile aleatoria gaussiana vale che

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

È evidente che le due definizioni di variabile aleatoria gaussiana (a partire dalla sua funzione caratteristica, o dalla sua funzione di densità) sono equivalenti. Tuttavia, grazie alla definizione attraverso φ_X , possiamo includere nella famiglia delle gaussiane anche il caso degenerare in cui X sia una costante; infatti, se $\sigma^2 = 0$, allora f_X esplode, mentre φ_X non ha problemi.

DEFINIZIONE 13.2 Vettore Gaussiano: Sia $\underline{X} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$ un vettore aleatorio. Si dirà che $\underline{X}$ è un Vettore Aleatorio Gaussiano di parametri

$$\underline{\mu} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_n \end{bmatrix} \in \mathbb{R}^n \quad \text{e} \quad C = (C_{ij})_{i,j=1,\dots,n} \in S^+(n)$$

se:

$$\varphi_{\underline{X}}(\underline{u}) = \exp \left\{ i \langle \underline{\mu}, \underline{u} \rangle - \frac{1}{2} \langle \underline{u}, C \underline{u} \rangle \right\}$$

Dove $S^+(n)$ rappresenta lo spazio delle matrici $n \times n$ simmetriche e semidefinite positive.

Si noti che $\langle \underline{u}, C\underline{u} \rangle$ è una forma quadratica.

PROPOSIZIONE 13.3: $\forall \underline{\mu} \in \mathbb{R}^n$ e $C \in S^+(n)$ esiste un vettore aleatorio $\underline{X} \in \mathbb{R}^n$ tale che:

$$\varphi_{\underline{X}}(\underline{u}) = \exp \left\{ i \langle \underline{\mu}, \underline{u} \rangle - \frac{1}{2} \langle \underline{u}, C\underline{u} \rangle \right\}$$

Dimostrazione. Per dimostrare la proposizione procederemo in due fasi, prima analizzando il caso semplice in cui C sia diagonale, e poi il caso generale.

Se C è diagonale, possiamo definirla come^a:

$$C := \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \ddots & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \cdots & 0 & \sigma_n^2 \end{bmatrix} \quad \text{con} \quad \sigma_k^2 \geq 0 \quad \forall k = 1, \dots, n$$

Definiamo inoltre $\underline{\mu} := \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_n \end{bmatrix}$. Consideriamo ora $X_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(\mu_k, \sigma_k^2)$, e costruiamo $\underline{X} := \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix}$.

Siccome le X_k sono indipendenti:

$$\begin{aligned} \varphi_{\underline{X}}(\underline{u}) &= \varphi_{\underline{X}}(u_1, \dots, u_n) = \varphi_{X_1}(u_1) \cdots \varphi_{X_n}(u_n) = \exp \left\{ i u_1 \mu_1 - \frac{1}{2} u_1^2 \sigma_1^2 \right\} \cdots \exp \left\{ i u_n \mu_n - \frac{1}{2} u_n^2 \sigma_n^2 \right\} \\ &= \exp \left\{ i \sum_{k=1}^n u_k \mu_k - \frac{1}{2} \sum_{k=1}^n u_k^2 \sigma_k^2 \right\} = \exp \left\{ i \langle \underline{\mu}, \underline{u} \rangle - \frac{1}{2} \langle \underline{u}, C\underline{u} \rangle \right\} \end{aligned}$$

Che è il vettore gaussiano

Nel caso generale invece, sapendo che $C = ODO^T$, con D matrice diagonale, che definiamo esattamente come abbiamo definito C nel punto precedente. Allora (grazie al punto precedente) sappiamo che esiste $\underline{Y} \sim \mathcal{N}(\underline{0}, D)$ vettore gaussiano, dove

$$\varphi_{\underline{Y}}(\underline{u}) = \exp \left\{ -\frac{1}{2} \langle \underline{u}, D\underline{u} \rangle \right\}$$

Poniamo $\underline{X} = O\underline{Y} + \underline{\mu}$, allora avremo che (Teorema 12.4):

$$\begin{aligned} \varphi_{\underline{X}}(\underline{u}) &= \exp \{ i \langle \underline{\mu}, \underline{u} \rangle \} \cdot \varphi_{\underline{Y}}(O^T \underline{u}) = \exp \{ i \langle \underline{\mu}, \underline{u} \rangle \} \cdot \exp \left\{ -\frac{1}{2} \langle O^T \underline{u}, DO^T \underline{u} \rangle \right\} \\ &= \exp \left\{ i \langle \underline{\mu}, \underline{u} \rangle - \frac{1}{2} \left\langle \underline{u}, \underbrace{ODO^T}_C \underline{u} \right\rangle \right\} \end{aligned}$$

□

^aSi presti attenzione che i σ_k^2 non sono “ancora” le varianze, ma sono semplicemente i nomi con cui chiamiamo gli elementi di C

DEFINIZIONE 13.4: $\underline{Z}$ è un vettore gaussiano standard n -dimensionale se:

$$\underline{Z} \sim \mathcal{N}(\underline{0}, I_{n \times n}) \quad \text{ossia con:} \quad \underline{\mu} = \underline{0} \quad \text{e} \quad C = I_{n \times n}$$

Si osservi che, nel caso in cui $C \in S^+(n)$ allora possiamo scriverla come

$$C = ODO^T = \underbrace{O\sqrt{D}}_{\sqrt{C}} \underbrace{\sqrt{D}O^T}_{\sqrt{C}^T} = \sqrt{C}\sqrt{C}^T$$

Allora, come facevamo nel caso unidimensionale, è possibile standardizzare un vettore aleatorio gaussiano $\underline{X} \sim \mathcal{N}(\underline{\mu}, C)$, tramite $\underline{X} \sim \sqrt{C}\underline{Z} + \underline{\mu}$. Purtroppo questa non risulta essere un'uguaglianza (come lo era nel caso unidimensionale) puntuale tra i due membri, ma esprime solo che i due vettori hanno la stessa legge¹.

PROPOSIZIONE 13.5 Proprietà di un Vettore Gaussiano : Sia $\underline{X} \sim \mathcal{N}(\underline{\mu}, C)$ con $\underline{\mu} \in \mathbb{R}^n$, $C \in S^+(n)$. Allora:

1. $E[\underline{X}] = \underline{\mu}$ e $Var(\underline{X}) = C$
2. $X_k \sim \mathcal{N}(\mu_k, C_{kk})$
3. Se $\underline{Y} = A\underline{X} + \underline{b}$ con $A \in M(k \times n)$ e $\underline{b} \in \mathbb{R}^k \Rightarrow \underline{Y} \sim \mathcal{N}(A\underline{\mu} + \underline{b}, ACA^T)$
4. $X_1, \dots, X_n$ sono V.A. indipendenti $\iff Cov(X_i, X_j) = 0 \quad \forall i \neq j \iff C$ è diagonale

Dimostrazione. 1. Sia $\underline{X} \sim \sqrt{C}\underline{Z} + \underline{\mu}$ con $\underline{Z} \sim \mathcal{N}(0, 1)$, allora:

$$E[\underline{X}] = \sqrt{C}E[\underline{Z}] + \underline{\mu} = \underline{\mu}$$

$$C_{\underline{X}} = E[(\underline{X} - E[\underline{X}]) \cdot (\underline{X} - E[\underline{X}])^T] = E[\sqrt{C}\underline{Z}\underline{Z}^T\sqrt{C}^T] = \sqrt{C}C_{\underline{Z}}\sqrt{C}^T = \sqrt{C}I\sqrt{C}^T = C$$

2. Dall'applicazione vista a pagina 101, con $\underline{v} = [0, \dots, u_k, \dots, 0]$:

$$\varphi_{X_k}(u_k) = \varphi_{\underline{X}}(\underline{v}) = \exp\left\{i\langle \underline{\mu}, \underline{v} \rangle - \frac{1}{2}\langle \underline{v}, C\underline{v} \rangle\right\} = \exp\left\{iu_k\mu_k - \frac{1}{2}u_k^2C_{kk}\right\} \Rightarrow X_k \sim \mathcal{N}(\mu_k, C_{kk})$$

3. Sia $\underline{v} \in \mathbb{R}^k$ (non ci si confonda, non è lo stesso del punto precedente!), allora:

$$\begin{aligned} \varphi_{X_k}(u_k) &\stackrel{12.4}{=} e^{i\langle \underline{v}, \underline{b} \rangle} \cdot \varphi_{\underline{X}}(A^T \underline{v}) = e^{i\langle \underline{v}, \underline{b} \rangle} \cdot \exp\left\{i\langle \underline{\mu}, A^T \underline{v} \rangle - \frac{1}{2}\langle A^T \underline{v}, C_{\underline{X}}A^T \underline{v} \rangle\right\} \\ &= \exp\left\{i\langle \underline{u}, A\underline{\mu} + \underline{b} \rangle - \frac{1}{2}\langle A^T \underline{v}, AC_{\underline{X}}A^T \underline{v} \rangle\right\} \end{aligned}$$

4. L'implicazione ($\Rightarrow$) è triviale. Per quanto riguarda l'implicazione ($\Leftarrow$), data $C = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ si ha che:

$$\begin{aligned} \varphi_{\underline{X}}(\underline{u}) &= \exp\left\{i\langle \underline{\mu}, \underline{u} \rangle - \frac{1}{2}\langle \underline{u}, C_{\underline{X}}\underline{u} \rangle\right\} = \exp\left\{i\sum_{k=1}^n \mu_k u_k - \frac{1}{2}\sum_{k=1}^n u_k^2 \sigma_k^2\right\} \\ &= e^{iu_1\mu_1 - \frac{1}{2}u_1^2\sigma_1^2} \dots e^{iu_n\mu_n - \frac{1}{2}u_n^2\sigma_n^2} = \varphi_{X_1} \dots \varphi_{X_n} \end{aligned}$$

□

¹Le uguaglianze in legge verranno approfondite nei capitoli successivi, si rimanda a quelli per approfondimenti

Grazie alle proprietà appena illustrate, si evince che dato un vettore gaussiano $\underline{\mathbf{X}}$, allora **ogni suo sottovettore è ancora gaussiano**. Infatti $\exists A \in M(n \times n)$ tale che:

$$\underline{\mathbf{Y}} = A\underline{\mathbf{X}} + \underline{\mathbf{b}} \sim \mathcal{N}(A\underline{\boldsymbol{\mu}}, AC_{\mathbf{X}}A^T)$$

ESEMPIO: Si consideri il vettore gaussiano $\underline{\mathbf{X}} = [X_1, X_2, X_3]^T$ come segue:

$$\underline{\mathbf{X}} \sim \mathcal{N}\left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}\right)$$

E si prenda il sottovettore $\underline{\mathbf{Y}} = [X_1, X_3]^T$. Allora possiamo vedere $\underline{\mathbf{Y}}$ come la trasformazione affine di $\underline{\mathbf{X}}$:

$$\underline{\mathbf{Y}} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \Rightarrow \underline{\mathbf{Y}} \sim \left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}\right)$$

Dall'ultimo esempio notiamo un'altra caratteristica riguardante le componenti di un vettore gaussiano: se ho degli zeri nella matrice di covarianza di un vettore gaussiano, allora vuol dire che le corrispondenti componenti sono indipendenti. Dato quindi $\underline{\mathbf{X}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{\mathbf{X}}, C_{\mathbf{X}})$:

$$X_i \perp\!\!\!\perp X_j \iff C_{ij} = 0$$

⚠ Si faccia attenzione a non leggere in maniera errata la 2. del precedente teorema: è valida solo in un senso! Infatti, date $X_1, \dots, X_n$ variabili aleatorie gaussiane, allora non è detto in generale che il vettore $\underline{\mathbf{X}} = [X_1, \dots, X_n]^T$ sia congiuntamente un vettore gaussiano. Questo è valido solo nel caso in cui $X_1, \dots, X_n$ sia una famiglia di variabili aleatorie indipendenti, e lo esponiamo nella seguente proposizione.

PROPOSIZIONE 13.6:

$$\begin{array}{c} X_1, \dots, X_n \\ \text{sono indipendenti e gaussiani} \end{array} \iff \underline{\mathbf{X}} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}, C)$$

$$\text{Con } \underline{\boldsymbol{\mu}}_{\mathbf{X}} = \begin{bmatrix} \underline{\mu}_1 \\ \underline{\mu}_2 \end{bmatrix}; \quad C_{\mathbf{X}} = \begin{bmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_n^2 \end{bmatrix}$$

Che può anche essere letto in chiave vettoriale.

Siano $\underline{\mathbf{X}}_1 \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_1, C_1)$, $\underline{\mathbf{X}}_1 \in \mathbb{R}^{n_1}$ $\underline{\mathbf{X}}_2 \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_2, C_2)$, $\underline{\mathbf{X}}_2 \in \mathbb{R}^{n_2}$, e si definisca $\underline{\mathbf{X}} = \begin{bmatrix} \underline{\mathbf{X}}_1 \\ \underline{\mathbf{X}}_2 \end{bmatrix} \in \mathbb{R}^{n_1+n_2}$, allora:

$$\underline{\mathbf{X}}_1 \perp\!\!\!\perp \underline{\mathbf{X}}_2 \iff \underline{\mathbf{X}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}_{\mathbf{X}}, C_{\mathbf{X}}) \quad \text{con } \underline{\boldsymbol{\mu}}_{\mathbf{X}} = \begin{bmatrix} \underline{\mu}_1 \\ \underline{\mu}_2 \end{bmatrix}; \quad C_{\mathbf{X}} \text{ a blocchi: } C_{\mathbf{X}} = \left[\begin{array}{c|c} C_1 & 0 \\ \hline 0 & C_2 \end{array} \right]$$

Unendo il punto 3. della Proposizione 13.5 e la Proposizione 13.6 possiamo osservare che una qualsiasi combinazione lineare di variabili aleatorie gaussiane indipendenti, genera una variabile aleatoria a sua volta gaussiana, ossia:

Siano $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$, $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$, tali che $X_1 \perp\!\!\!\perp X_2$:

$$\Rightarrow \quad \forall \alpha, \beta, \gamma \in \mathbb{R} \quad \alpha X_1 + \beta X_2 + \gamma \sim \mathcal{N}(\alpha\mu_1 + \beta\mu_2 + \gamma, \alpha^2\sigma_1^2 + \beta^2\sigma_2^2)$$

TEOREMA 13.7: Sia $\underline{\mathbf{X}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}, C_{\underline{\mathbf{X}}})$ con $\underline{\boldsymbol{\mu}} \in \mathbb{R}^n$, $C \in S^+(n)$, allora:

$$\boxed{\underline{\mathbf{X}} \text{ è assolutamente continuo} \iff \det(C_{\underline{\mathbf{X}}}) \neq 0} \quad (\text{ossia } C_{\underline{\mathbf{X}}} \text{ invertibile})$$

E in tal caso ha densità continua:

$$f_{\underline{\mathbf{X}}}(x_1, \dots, x_n) = \frac{1}{\sqrt{(2\pi)^n \det(C_{\underline{\mathbf{X}}})}} \exp \left\{ -\frac{1}{2} \langle \underline{\mathbf{x}} - \underline{\boldsymbol{\mu}}, C^{-1}(\underline{\mathbf{x}} - \underline{\boldsymbol{\mu}}) \rangle \right\}$$

Dimostrazione. Ricordando che possiamo sempre vedere una gaussiana multivariata $\underline{\mathbf{X}}$ come una trasformazione lineare di una gaussiana standard, ossia che $\underline{\mathbf{X}} \sim \sqrt{C}\underline{\mathbf{Z}} + \underline{\boldsymbol{\mu}}$, con $\det(\sqrt{C}) > 0$, $\underline{\mathbf{Z}} \sim \mathcal{N}(\underline{\mathbf{0}}, I)$. Allora siccome la densità di una normale standard è

$$f_{\underline{\mathbf{Z}}}(\underline{\mathbf{z}}) = \frac{1}{(2\pi)^{n/2}} e^{-\frac{1}{2}\|\underline{\mathbf{z}}\|^2}$$

Allora, grazie al punto 2. del riassunto pratico esposto a pagina 11.2, vedendo $\underline{\mathbf{X}}$ tramite la trasformazione $h(\underline{\mathbf{z}}) = \sqrt{C}\underline{\mathbf{z}} + \underline{\boldsymbol{\mu}} \Rightarrow h^{-1}(\underline{\mathbf{x}}) = \sqrt{C}^{-1}(\underline{\mathbf{x}} - \underline{\boldsymbol{\mu}})$, sappiamo che:

$$f_{\underline{\mathbf{X}}}(\underline{\mathbf{x}}) = f_{\underline{\mathbf{Z}}}(h^{-1}(\underline{\mathbf{x}})) \cdot |\det(J_{h^{-1}}(\underline{\mathbf{x}}))| = f_{\underline{\mathbf{Z}}}(\sqrt{C}^{-1}(\underline{\mathbf{x}} - \underline{\boldsymbol{\mu}})) \frac{1}{\sqrt{\det C}}$$

□

Il teorema appena illustrato risponde alla domanda: *abbiamo delle condizioni per verificare se un vettore gaussiano sia assolutamente continuo?*. Questo può essere declinato nella casistica multidimensionale e unidimensionale:

- Se $n = 1$: $X \sim \mathcal{N}(\mu, \sigma^2)$ allora:
 - Se $\sigma^2 > 0 \Rightarrow X$ è assolutamente continua, con densità:

$$f_X(t) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\frac{(t-\mu)^2}{\sigma^2}}$$
 - Se $\sigma^2 = 0 \Rightarrow X \stackrel{\text{q.c.}}{=} \mu \Rightarrow X$ è discreta e non ammette densità continua.
- Se $n > 1$: $\underline{\mathbf{X}} \sim \mathcal{N}(\underline{\boldsymbol{\mu}}, C_{\underline{\mathbf{X}}})$ allora sappiamo che $\underline{\mathbf{X}} \in \text{Im}(C_{\underline{\mathbf{X}}}) + \underline{\boldsymbol{\mu}}$ quasi certamente. Allora:
 - Se $\det(C_{\underline{\mathbf{X}}}) \neq 0 \Rightarrow \underline{\mathbf{X}}$ è assolutamente continuo
 - Se $\det(C_{\underline{\mathbf{X}}}) = 0 \Rightarrow \underline{\mathbf{X}}$ non è assolutamente continuo.

Questo vuol dire che esiste sicuramente un vettore $\underline{\mathbf{a}} \neq \underline{\mathbf{0}}$ tale che $\underline{\mathbf{a}} \in \ker(C_{\underline{\mathbf{X}}})$, ossia che $C_{\underline{\mathbf{X}}}\underline{\mathbf{a}} = \underline{\mathbf{0}}$. Questo implica che la varianza lungo la direzione $\underline{\mathbf{a}}$ è zero. Ciò significa che $\underline{\mathbf{X}}$ vive interamente su un *sottospazio affine* di dimensione $n - 1$

$$H = \left\{ \underline{\mathbf{x}} \in \mathbb{R}^n \mid \langle \underline{\mathbf{x}} - \underline{\boldsymbol{\mu}}, \underline{\mathbf{a}} \rangle = 0 \right\}$$

siccome la proiezione di $(\underline{\mathbf{X}} - \underline{\boldsymbol{\mu}})$ lungo la direzione $\underline{\mathbf{a}}$, $\langle \underline{\mathbf{X}} - \underline{\boldsymbol{\mu}}, \underline{\mathbf{a}} \rangle$, è uguale a zero quasi certamente. $\underline{\mathbf{X}}$ non si muove lungo la direzione $\underline{\mathbf{a}}$.

ESEMPIO : Si consideri il vettore gaussiano $\underline{\mathbf{X}} = [X_1, X_2]^\top$:

$$\underline{\mathbf{X}} \sim \mathcal{N}\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}\right); \quad A = \left\{ (x_1, x_2) \in \mathbb{R}^2 \mid x_1^2 + x_2^2 \leq 1 \right\}$$

Si vuole calcolare $P^{\underline{\mathbf{X}}}(A)$.

Si nota immediatamente che $\det(C) = 0$. Inoltre si può anche notare che $Cov(X_1, X_2) = 1$, implicando che le due componenti abbiamo una relazione deterministica.

Si ricava $\underline{\mathbf{a}}$ tale che appartenga al $\ker(C)$:

$$C\underline{\mathbf{a}} = \underline{\mathbf{0}} \quad \Rightarrow \quad \underline{\mathbf{a}} = [a_1, -a_1]^\top$$

Quindi $\underline{\mathbf{X}}$ vive sul sottospazio affine tale che la sua proiezione lungo $\underline{\mathbf{a}}$ sia uguale a zero:

$$\langle \underline{\mathbf{X}} - \underline{\boldsymbol{\mu}}, \underline{\mathbf{a}} \rangle = 0 \quad \Rightarrow \quad X_1 = X_2$$


Ossia che vive sul sottospazio:

$$H = \left\{ (x_1, x_2) \in \mathbb{R}^2 \mid x_1 = x_2 \right\}$$

Allora il calcolo della probabilità diventa, definendo $X_1 = X_2 =: Y$:

$$P^{\underline{\mathbf{X}}}(A) = \mathbb{P}(\underline{\mathbf{X}} \in A) = \mathbb{P}\left(-\frac{1}{\sqrt{2}} \leq Y \leq \frac{1}{\sqrt{2}}\right) = \Phi\left(\frac{1}{\sqrt{2}} - 1\right) - \Phi\left(-\frac{1}{\sqrt{2}} - 1\right) \simeq 0.3409$$

In quanto C è il cerchio di raggio 1 centrato in 0, e $\underline{\mathbf{X}}$ vive sulla retta $x_1 = x_2$.



Dall'esempio abbiamo quindi appurato che un vettore può essere gaussiano anche se non è assolutamente continuo, e in questo caso si definisce *Gaussiano Degenerate*. Infatti, nella definizione 13.2 non si accenna ad assoluta continuità, ma si definisce gaussiano un qualsiasi vettore che abbia quella funzione caratteristica.

14 Leggi Condizionali


14.1 Introduzione Intuitiva

In questo capitolo riprenderemo il concetto di probabilità condizionata, motivandone in modo rigoroso l'esistenza e l'unicità, che in precedenza erano state assunte senza dimostrazione. Le definizioni già introdotte verranno riformulate nel linguaggio delle variabili aleatorie, abbandonando progressivamente quello puramente insiemistico, così da poter affrontare una trattazione più astratta e generale.

Infine, attraverso l'analisi di casi particolari, mostreremo come i risultati ottenuti consentano di riconciliare e generalizzare le nozioni già incontrate di densità e probabilità condizionate, fornendo un quadro unificato e coerente.

Prendiamo in esempio il caso in cui $\begin{bmatrix} X \\ Y \end{bmatrix} : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow \mathbb{R}^2$ si discreto con densità discreta congiunta $p_{(X,Y)}$, marginali p_X e p_Y e con supporti S_X, S_Y .

Supponiamo di venire a conoscenza del valore di $X = x$:



Prima di osservare il valore di X (primo grafico), abbiamo una probabilità che vive nello spazio $(\Omega, \mathcal{A}, \mathbb{P})$. Appena effettuata l'osservazione di X (secondo grafico), cambia il nostro spazio di probabilità, infatti la probabilità vive su $(\Omega, \mathcal{A}, \mathbb{P}(\bullet \mid X = x))$. È proprio su questo spazio che effettueremo tutta la nostra trattazione.

L'ultimo grafico ci fa capire che, a seguito dell'esperimento e quindi della “lettura” di Y , non abbiamo più uno spazio di probabilità, ma siamo certi di ciò che è accaduto.

Ora che abbiamo compreso “dove” si svolgeranno nostre analisi, possiamo andare a fare delle considerazioni su quello che già sappiamo. Tenendo in mente che queste valgono $\forall x \in S_X$.

★ La mappa $B \mapsto \mathbb{P}(B \mid X = x)$ definita su $\mathcal{B} \rightarrow [0, 1]$ è una probabilità. Questo era già stato visto nella Proposizione 3.7.

★ Possiamo vedere che

$$\mathbb{P}(Y \in S_Y \mid X = x) = \frac{\mathbb{P}(Y \in S_Y \cap X = x)}{\mathbb{P}(X = x)} = \frac{\mathbb{P}(\Omega \cap X = x)}{\mathbb{P}(X = x)} = 1$$

Quindi Y continua a essere una variabile aleatoria discreta anche sul nuovo spazio di probabilità. Y avrà quindi una legge diversa da P^Y , che è chiamata *legge di Y condizionata ad $X = x$* , definita come:

$$P^{Y|X}(B \mid x) = \mathbb{P}(Y \in B \mid X = x) \quad \forall B \in \mathcal{B}$$

e avrà densità definita come

$$p_{Y|X}(y | x) = \mathbb{P}(Y = y | X = x) = \frac{\mathbb{P}(Y = y, X = x)}{\mathbb{P}(X = x)} = \frac{p_{(X,Y)}(x, y)}{p_X(x)} \quad x \in S_X, y \in S_Y$$

$$\Rightarrow \boxed{p_{Y|X}(y | x) = \frac{p_{(X,Y)}(x, y)}{p_X(x)}} \quad (14.1)$$

Siccome, in questo caso, è una densità discreta, allora varranno le condizioni:

$$\begin{cases} p_{Y|X}(y | x) \geq 0 \\ \sum_{y \in S_Y} p_{Y|X}(y | x) = 1 \end{cases} \quad \forall x \in S_x$$

★ Se si conosce $P^{Y|X}(\bullet | x)$, allora (nell'ipotesi che h sia una funzione limitata) :

$$E[h(y) | X = x] = \sum_{y \in S_Y} h(y) \cdot p_{Y|X}(y | x)$$

Questo ci permette di definire, tutte le volte che ha senso¹, il *valore atteso condizionato di Y dato $X = x$* :

$$E[Y | X = x] = \sum_{y \in S_Y} y p_{Y|X}(y | x)$$

★ Grazie all'equazione 14.1, se la si moltiplica per $p_X(x)$ si ottiene

$$p_X(x) \cdot p_{Y|X}(y | x) = p_{(X,Y)}(x, y)$$

Ovvero che possiamo conoscere solo il lato sinistro dell'equazione per conoscere la densità congiunta del vettore.

Possiamo quindi trovare la legge congiunta del vettore attraverso la densità condizionata, infatti $\forall A \times B \in \mathcal{B} \times \mathcal{B}$

$$\begin{aligned} P^{(X,Y)}(A \times B) &= \sum_{x \in A \cap S_X} \sum_{y \in B \cap S_Y} p_{(X,Y)}(x, y) = \sum_{x \in A \cap S_X} \sum_{y \in B \cap S_Y} p_X(x) \cdot p_{Y|X}(y | x) \\ &= \sum_{x \in A \cap S_X} \left(\sum_{y \in B \cap S_Y} p_{Y|X}(y | x) \right) p_X(x) \end{aligned} \quad p_X(x) \text{ costante in } y$$

Ricavando così la *relazione fondamentale*:

$$\boxed{P^{(X,Y)}(A \times B) = \sum_{x \in S_X} \mathbb{I}_A(x) P^Y(B | X = x) \cdot p_X(x)}$$

Che ovviamente può essere scritto anche come integrale di Lebesgue:

$$P^{(X,Y)} = \int_{\mathbb{R}} \mathbb{I}_A(x) P^Y(B | X = x) dP^X(x) = \int_{\mathbb{R}} \left(\mathbb{I}_A(x) \int_{\mathbb{R}} \mathbb{I}_B(y) dP^{Y|X}(dy | x) \right) dP^X(x)$$

Vediamo un esempio per cercare di capire come utilizzare ciò che abbiamo appena visto.

¹Ossia quando $\begin{cases} Y \geq 0 \\ \sum |y| p_{Y|X}(y | x) < +\infty \end{cases}$

ESEMPIO : Si lancia un dado, e successivamente si lancia una moneta tante volte quanto è il numero uscito sul dado. Siano

D = Risultato del dado T = numero di teste osservate

Vogliamo trovare quale sia la legge di T .

D, T sono variabili aleatorie discrete tali che $T \in \{1, \dots, 6\}$, $D \in \{1, \dots, 6\}$. Inoltre conosciamo la densità della variabile D :

$$p_D(k) = \frac{1}{6} \quad \forall k = 1, \dots, 6$$

Inoltre:

$$\mathbb{P}(T = h \mid D = k) = \binom{k}{h} \frac{1}{2^k} \quad h = 0, \dots, k \quad \Rightarrow \quad p_{T|D}(h \mid k) = \binom{k}{h} \frac{1}{2^k} \sim \text{Bin}\left(k, \frac{1}{2}\right)$$

Possiamo ottenerci la densità congiunta del vettore:

$$p_{(T,D)} = p_D(k) \cdot p_{T|D}(h \mid k) = \frac{1}{6} \binom{k}{h} \frac{1}{2^k} \quad \text{con: } \begin{matrix} 1 \leq k \leq 6 \\ 0 \leq h \leq k \end{matrix}$$

Possiamo quindi ottenere p_T semplicemente facendo:

$$p_T(h) = \sum_{k=h}^6 \frac{1}{6} \binom{k}{h} \frac{1}{2^k}$$

Abbiamo trattato fino ad ora variabili aleatorie discrete, e si potrebbe estendere le nozioni a variabili aleatorie qualsiasi: $Y : \Omega \rightarrow \mathbb{R}^n$.

Tuttavia, con la trattazione appena eseguita, risulta un problema “togliere la discretezza” della variabile, perché per una variabile aleatoria continua si ha che $\mathbb{P}(X = x) = 0$.

Volendo rendere il problema più concreto, si pensi al vettore aleatorio $\begin{bmatrix} X \\ Y \end{bmatrix} = \begin{bmatrix} \text{Altezza} \\ \text{Peso} \end{bmatrix}$ che descrive altezza e peso della popolazione italiana, che sono due variabili continue. Si ha ad esempio che $\mathbb{P}(X = 185) = 0$, ma nella realtà è un valore misurabile. Stiamo quindi cercando di dare valore ad oggetti del tipo:

$$\mathbb{P}(Y > 70 \mid X = 185) = ?$$

14.2 Trattazione Formale

Ora che abbiamo compreso la natura del problema, e abbiamo trattato (in maniera non formale) il caso specifico delle discrete, diamo le definizioni formali.

▲ Una precisazione: nei capitoli precedenti si è usata la notazione vettoriale (es. $\underline{X}$) per raffigurare i vettori. D’ora in avanti questa non verrà più usata per non rendere la scrittura troppo pesante: qualsiasi variabile aleatoria che incontreremo dovrà essere intesa come un vettore, a meno che non sia esplicito il viceversa.

DEFINIZIONE 14.1: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e siano dati i vettori aleatori $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (E, \mathcal{E})$ e $Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^n, \mathcal{B}^n)$. Si chiama *legge condizionale di Y dato $X = x$* , la funzione:

$$P^{Y|X}(\bullet \mid \bullet) : \mathcal{B}^n \longrightarrow [0, 1]$$

tale che:

1. $\forall B \in \mathcal{B}^n$ fissato, la mappa

$$\begin{aligned} x &\longrightarrow P^{Y|X}(B | x) \\ E &\longmapsto [0, 1] \end{aligned}$$

è misurabile rispetto ad $\mathcal{E}$

2. $\forall x \in E$ fissato, la mappa

$$\begin{aligned} B &\longrightarrow P^{Y|X}(B | x) \\ \mathcal{B}^n &\longmapsto [0, 1] \end{aligned}$$

è una misura di probabilità su $\mathcal{B}^n$

3. Vale la *Relazione Fondamentale*:

$$P^{(X,Y)}(A \times B) = \int_E \mathbb{I}_A(x) P^{Y|X}(B | x) dP^X(x) = \int_E \mathbb{I}_A(x) \left(\int_{\mathbb{R}^n} \mathbb{I}_B(y) dP^{Y|X}(dy | x) \right) dP^X(x)$$

Tipicamente avremo che $E = \mathbb{R}^k$, $\mathcal{E} = \mathcal{B}^k$.

Si tenga conto che è valido il *Teorema di disintegrazione della misura*, che noi non vedremo, che assicura che $\exists! P^{Y|X}$ tutte le volte che Y è un vettore in $\mathbb{R}^n$.

La relazione fondamentale può essere vista come una generalizzazione al caso continuo della formula delle probabilità totali. Affinché questa abbia senso sono necessarie le condizioni 1. e 2. della definizione.

Inoltre, sempre dalla relazione fondamentale, si può dedurre il seguente fatto:

$\forall h > 0$ oppure limitata :

$$E[h(X, Y)] = \int_{E \times \mathbb{R}^n} h(x, y) dP^{(X,Y)}(x, y) = \int_E \left(\int_{\mathbb{R}^n} h(x, y) dP^{Y|X}(y | x) \right) dP^X(x)$$

Questo può essere visto come una generalizzazione del teorema di Fubini–Tonelli, in quanto ne estende l'idea fondamentale ma in un contesto molto più astratto, dove la misura integrata non è un prodotto, bensì una disintegrazione.

Nel caso classico, l'integrale viene decomposto come iterato grazie alla struttura della misura prodotto. Qui, invece, la misura congiunta $P^{(X,Y)}$ non è in generale un prodotto, ma può essere *disintegrata* rispetto alla marginale P^X , tramite la famiglia di misure condizionate $P^{Y|X}(\bullet | x)$. La formula permette quindi di esprimere l'aspettazione di una funzione di (X, Y) come un integrale iterato rispetto a tali misure condizionate.

Vediamo allora di legare la probabilità congiunta con la probabilità condizionata in alcuni casi di particolare rilevanza.

14.2.1 Caso di Indipendenza

Se siamo nel caso in cui due variabili aleatorie sono indipendenti:

$$X \perp\!\!\!\perp Y \iff P^{Y|X}(dy | x) = P^Y(dy) \text{ q.c. rispetto a } P^X$$

Questa scrittura ci riporta indietro ad una proprietà che avevamo già visto: una variabile aleatoria è indipendente da un'altra se e solo se la sua legge rimane identica dopo il condizionamento.

14.2.2 Caso Deterministico

Nel caso in cui si abbia un legame deterministico tra X ed Y , ossia che si può esprimere $Y = h(X)$, con $h : E = \mathbb{R}^k \rightarrow \mathbb{R}^n$ Boreliana. Allora se $X = x$, implica che $Y = h(x)$, ovvero:

$$\mathbb{P}(Y \in B \mid X = x) = \mathbb{P}(h(x) \in B) = \begin{cases} 1, & \text{se } h(x) \in B \\ 0, & \text{se } h(x) \notin B \end{cases} \Rightarrow \boxed{P^{Y|X}(B \mid x) = \delta_{h(x)}(B)}$$

Abbiamo quindi una legge “candidata” ad essere la legge condizionale; per determinare che sia realmente questa, c'è bisogno che siano rispettate tutte le condizioni 1. 2. e 3. della Definizione 14.1.

La condizione 1. è vera, in quanto $\forall B \in \mathcal{B}$ fissato, si ha che la funzione

$$P^{Y|X}(B \mid x) = \mathbb{I}_B(h(x)) = \begin{cases} 1, & \text{se } h(x) \in B \\ 0, & \text{se } h(x) \notin B \end{cases} \quad (14.2)$$

e quindi h è boreliana e $\mathbb{I}$ è una funzione misurabile.

Il punto 2. è vero per costruzione, in quanto δ è una misura di probabilità.

Rimane solo da verificare che sia valida la relazione fondamentale:

$$\begin{aligned} P^{(X,Y)}(A \times B) &= E[\mathbb{I}_A(X) \cdot \mathbb{I}_B(Y)] = E[\mathbb{I}_A(X) \cdot \mathbb{I}_B(h(X))] \\ &= \int_E \mathbb{I}_A(x) \cdot \mathbb{I}_B(h(x)) dP^X \stackrel{\text{eq. (14.2)}}{=} \int_E \mathbb{I}_A(x) P^{Y|X}(B \mid x) dP^X \\ &= \int_E \mathbb{I}_A(x) \left(\int_{\mathbb{R}^n} \mathbb{I}_B(y) \cdot \delta_{h(x)}(dy) \right) dP^X \quad \checkmark \end{aligned}$$

Siccome valgono tutte le condizioni, possiamo dire di aver trovato la legge condizionale nel caso in cui le variabili aleatorie abbiano una relazione deterministica.

14.2.3 Caso Discreto

Siano i due vettori aleatori $X \in \mathbb{R}^k$, $Y \in \mathbb{R}^n$, e si costruisca il vettore discreto $[X, Y]^\top \in \mathbb{R}^{k+n}$. Siccome X è discreto, allora anche S_X è discreto, e possiamo definire la legge condizionale come:

$$\boxed{P^{Y|X}(B \mid x) = \begin{cases} \mathbb{P}(Y \in B \mid X = x) & \text{se } x \in S_X \\ \mathbb{Q}(B) & \text{se } x \in S_X^c \end{cases}}$$

Dove $\mathbb{Q}$ è una qualsiasi misura di probabilità su $\mathcal{B}^n$.

Come prima, affinché si possa dire che $P^{Y|X}$ sia la legge condizionale, deve verificare tutte e tre le condizioni della Definizione 14.1.

La 1. è verificata in quanto, variando x , è misurabile per costruzione. Il punto 2. è verificato a sua volta in quanto, variando B , sia nel caso in cui $x \in S_X$, che nel caso in cui $x \in S_X^c$, si ha che $P^{Y|X}$ è una misura di probabilità.

Non ci rimane altro che verificare la 3. Si presti attenzione che faremo una catena di uguaglianze “a salire” dalla definizione:

$$\int_{\mathbb{R}^k} \mathbb{I}_A(x) \left(\int_{\mathbb{R}^n} \mathbb{I}_B(y) dP^{Y|X}(dy \mid x) \right) dP^X(x) = \int_{\mathbb{R}^k} \mathbb{I}_A(x) P^{Y|X}(B \mid x) dP^X(x)$$

$$\begin{aligned}
&= \int_{S_X} \mathbb{I}_A(x) P^{Y|X}(B | x) dP^X(x) + \underbrace{\int_{\mathbb{R}^k \setminus S_X} \underbrace{\mathbb{I}_A(x) Q(B)}_{P^X\text{-q.c. nulla}} dP^X(x)}_0 \\
&= \sum_{x \in S_X \cap A} \mathbb{P}(Y \in B | X = x) p_X(x) + 0 \\
&= \mathbb{P}(Y \in B, X \in A) = P^{(X,Y)}(A \times B) \quad \checkmark
\end{aligned}$$

Siccome valgono tutte le condizioni, abbiamo che $\forall x \in S_X$ la legge condizionale $P^{Y|X}(\bullet | x)$ è una misura di probabilità discreta su $\mathcal{B}^n$, con densità discreta:

$$p_{Y|X}(y | x) = \frac{p_{(X,Y)}(x, y)}{p_X(x)} \quad \forall y \in S_Y$$

Inoltre, $\forall h \geq 0$ oppure limitata:

$$E[h(Y) | X = x] = \sum_{y \in S_Y} h(y) \cdot p_{Y|X}(y | x)$$

14.2.4 Caso Continuo

Si consideri il vettore $[X, Y]^T$ assolutamente continuo, con densità congiunta $f_{(X,Y)}$ e marginali f_X, f_Y . Possiamo definire il supporto di X come: $S_X = \{t \in \mathbb{R}^k : f_X(t) > 0\}$. Si presti particolare attenzione che nella definizione di S_X si intende f_X come il rappresentante delle classi di equivalenza di $[f_X]$: stiamo quindi considerando una vera e propria funzione fissata.

Possiamo definire la densità condizionale di Y dato $X = x$ come:

$$f_{Y|X}(y | x) = \begin{cases} \frac{f_{(X,Y)}(x,y)}{f_X(x)} & \text{se } x \in S_X \\ \tilde{f}(y) & \text{se } x \in S_X^c \end{cases} \quad \text{dove} \quad \begin{cases} \tilde{f}(y) \geq 0 \\ \int_{\mathbb{R}} \tilde{f}(y) dy = 1 \end{cases}$$

Si noti che, se si fissa y , $\tilde{f}(y)$ risulta essere una costante in x . Si può inoltre dimostrare (e noi non lo faremo) che $f_{Y|X}$ risulta essere misurabile e quindi una densità di probabilità su $\mathbb{R}^n$. Allora possiamo definire la legge condizionale:

$$P^{Y|X}(B | x) = \int_{\mathbb{R}^n} \mathbb{I}_B(y) f_{Y|X}(y | x) dy = \int_B f_{Y|X}(y | x) dy$$

La condizione 1. risulta essere vera in quanto, se fisso $B \in \mathcal{B}^n$, la mappa $x \rightarrow P^{Y|X}(B | x)$ è misurabile:

$$P^{Y|X}(B | x) = \underbrace{\int_B \mathbb{I}_{S_X}(x) \frac{f_{(X,Y)}(x, y)}{f_X(x)} dy}_{\text{misurabile}} + \underbrace{\int_B \mathbb{I}_{S_X^c}(x) \tilde{f}(y) dy}_{\text{misurabile}}$$

La condizione 2. risulta verificata per costruzione. Dimostriamo che vale la relazione fondamentale:

$$\begin{aligned}
\int_{\mathbb{R}^k} \mathbb{I}_A(x) P^{Y|X}(B | x) dP^X(x) &= \int_{S_X} \mathbb{I}_A(x) P^{Y|X}(B | x) f_X(x) dx \\
&= \int_{S_X} \mathbb{I}_A(x) \left(\int_B \frac{f_{(X,Y)}(x, y)}{\cancel{f_X(x)}} dy \right) \cancel{f_X(x)} dx \\
&= \int_{S_X} \mathbb{I}_A(x) \left(\int_{\mathbb{R}^n} \mathbb{I}_B(y) f_{(X,Y)}(x, y) dy \right) dx
\end{aligned}$$

$$\begin{aligned}
& \text{(Per Fubini-Tonelli)} & & = \int_{\mathbb{R}^k} \int_{\mathbb{R}^n} \mathbb{I}_{A \cap S_X}(x) \mathbb{I}_B(y) f_{(X,Y)}(x, y) \, dx dy \\
& & & = \int_{\mathbb{R}^k \times \mathbb{R}^n} \mathbb{I}_{A \cap S_X \times B}(x, y) f_{(X,Y)}(x, y) \, dx dy \\
& & & = P^{(X,Y)}(A \cap S_X \times B) \\
& & & = \mathbb{P}(X \in A \cap S_X, Y \in B) \\
(X \in A \cap S_X) = (X \in A) \cap \underbrace{(X \in S_X)}_{\Omega} = X \in A & & = \mathbb{P}(X \in A, Y \in B) \\
& & & = P^{(X,Y)}(A \times B) \quad \checkmark
\end{aligned}$$

E inoltre, $\forall x \in S_x, \forall h \geq 0$ o limitata:

$$E[h(Y) \mid X = x] = \int_{\mathbb{R}^n} h(y) f_{Y|X}(y \mid x) \, dy = \int_{\mathbb{R}^n} h(y) \frac{f_{(X,Y)}(x, y)}{f_X(x)} \, dy$$

PROPOSIZIONE 14.2: Sia $[X, Y]^T$ un vettore aleatorio su $\mathbb{R}^k \times \mathbb{R}^n$ tale che X sia un vettore assolutamente continuo con densità f_X , e $P^{Y|X}(\bullet \mid x) \, \forall x \in S_X$ sia una probabilità assolutamente continua, ossia che:

$$\exists f_{Y|X}(y \mid x) \text{ densità tale che: } P^{Y|X}(B \mid x) = \int_B f_{Y|X}(y \mid x) \, dy \quad \forall B \in \mathcal{B}^n$$

$\Rightarrow \begin{bmatrix} X \\ Y \end{bmatrix}$ è assolutamente continuo, con densità:

$$f_{(X,Y)}(x, y) = \begin{cases} f_{Y|X}(y \mid x) \cdot f_X(x) & \text{se: } x \in S_X \\ 0 & \text{se: } x \in S_X^c \end{cases}$$

14.2.5 Caso Gaussiano

È evidente che il gaso gaussiano è una casistica particolare del caso continuo, ma lo trattiamo separatamente per la sua rilevanza pratica.

Tratteremo prima il caso bidimensionale in cui si abbiamo due variabili aleatorie unidimensionali (caso specifico con $k = n = 1$), per poi affrontare il caso generico vettoriale.

Si considerino le variabili aleatorie unidimensionali X, Y , e si formi il vettore aleatorio gaussiano:

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho \sigma_X \sigma_Y \\ \rho \sigma_X \sigma_Y & \sigma_Y^2 \end{bmatrix} \right)$$

Ci chiediamo, quale è $P^{Y|X}$? Notiamo che abbiamo due casi:

- Se $\sigma_X^2 = 0$, allora $X = \mu_X$ quasi certamente, e di conseguenza $X \perp\!\!\!\perp Y$. Allora, per la trattazione svolta nel capitolo 14.2.1 avremo che:

$$P^{Y|X} = P^Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$$

- Se $\sigma_X^2 > 0$ la trattazione è leggermente più complicata, e viene affrontata con la prossima proposizione.

PROPOSIZIONE 14.3: Sia il vettore gaussiano $\begin{bmatrix} X \\ Y \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix}\right)$, con $\sigma_X^2 > 0$, allora:

$$P^{Y|X}(dy | x) \sim \mathcal{N}(m(x), q^2) \quad \forall x \in \mathbb{R}$$

Dove:

$$m(x) = E[Y | X = x] = \mu_Y + \frac{\text{Cov}(X, Y)}{\sigma_X^2}(x - \mu_X) = \mu_Y + \rho \cdot \frac{\sigma_Y}{\sigma_X}(x - \mu_X)$$

$$q^2 = \text{Var}(Y | X = x) = \int_{\mathbb{R}} (y - m(x))^2 dP^{Y|X}(dy | x) = \sigma_Y^2(1 - \rho^2)$$

Facciamo alcune osservazioni:

- Si denota $y = m(x)$ con *retta di regressione*
- Possiamo notare che q^2 non dipende dall'osservazione $X = x$
- $\rho = 0 \iff X \perp\!\!\!\perp Y$ e $P^{Y|X}(dy | x) \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$
- Si hanno due casi in cui $q^2 = 0$:
 - $|\rho| = 1 \Rightarrow P^{Y|X}(dy | x) \sim \delta_{m(x)}$
 - $\sigma_Y^2 = 0 \Rightarrow Y \sim \delta_{\mu_Y} \Rightarrow X \perp\!\!\!\perp Y \Rightarrow P^{Y|X}(dy | x) \sim \delta_{\mu_Y}$

Come anticipato, possiamo generalizzare il tutto al **caso vettoriale** in cui si abbiano due vettori gaussiani: $X \sim \mathcal{N}(\mu_X, C_X)$ k -dimensionale e $Y \sim \mathcal{N}(\mu_Y, C_Y)$ n -dimensionale. Allora vale la seguente proposizione:

PROPOSIZIONE 14.4 Caso Vettoriale : Siano $X \sim \mathcal{N}(\mu_X, C_X)$ k -dimensionale e $Y \sim \mathcal{N}(\mu_Y, C_Y)$ n -dimensionale. Si costruisca il vettore

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} C_X & C_{XY} \\ C_{YX} & C_Y \end{bmatrix}\right) \quad \text{con} \quad \begin{bmatrix} X \\ Y \end{bmatrix} \in \mathbb{R}^k \times \mathbb{R}^n$$

Dove $C_{XY} = E[(X - \mu_X)(Y - \mu_Y)^\top] = C_{YX}^\top$.

Se $\det(C_X) > 0$ ossia che C_X è invertibile $\Rightarrow$ $P^{Y|X}(dy | x) \sim \mathcal{N}(m(x), Q)$

Dove:

$$m(x) = E[Y | X = x] = \mu_Y + C_{YX}C_X^{-1}(x - \mu_X)$$

$$Q = \text{Var}(Y | X = x) = C_Y - C_{YX}C_X^{-1}C_{XY}$$

14.3 Attesa Condizionata

Nel capitolo precedente è stato introdotto il valore atteso condizionato alla conoscenza di un determinato valore assunto da un'altra variabile. Il passo che affrontiamo ora consiste nel generalizzare tale concetto: invece di fissare un valore specifico della variabile condizionante, trasformeremo il valore atteso condizionato in una nuova variabile aleatoria, detta **attesa condizionata**, che dipende dal valore – questa volta non noto a priori – assunto dalla variabile condizionante.

L'attesa condizionata costituisce uno strumento estremamente potente: gode di numerose proprietà e trova applicazione in contesti molto diversi, dal calcolo di valori attesi e varianze complesse all'approssimazione di variabili aleatorie sulla base di informazioni parziali.

Dalla teoria precedente abbiamo visto che, dato uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ e le variabili aleatorie $X : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}^k, \mathcal{B}^k)$ e $Y : (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B})$ limitata, ossia tale che $|Y(w)| \leq M \quad \forall w \in \Omega$

$\Rightarrow \exists P^{Y|X}(dy | x)$ e, se $X = x$, possiamo calcolare l'attesa come:

$$E[Y | X = x] = \int_{\mathbb{R}} y dP^{Y|X}(dy | x) =: m(x)$$

dove $m : \mathbb{R}^k \rightarrow \mathbb{R}$ è una funzione ben definita per ogni valore x . Per ottenere da $m(x)$ una variabile aleatoria, è sufficiente valutare tale funzione nei valori che la variabile aleatoria X può effettivamente assumere; in altre parole, si considera la composizione $m(X)$.

Formalizziamo la definizione.

DEFINIZIONE 14.5: Il valore atteso (o media) condizionata di Y dato X è la variabile aleatoria $E : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$

$$E[Y | X] = m(X) \quad \text{ovvero} \quad E[Y | X](w) = m(X(w)) \quad \forall w \in \Omega$$

ESEMPIO: Riprendiamo l'esempio già esposto a pagina 111. Avevamo già calcolato che

$$P^{T|D}(\bullet | d) \sim \text{Bin}\left(d, \frac{1}{2}\right)$$

Allora quanto vale $E[T | D]$?

$$E[T | D = d] = \frac{d}{2} = m(d) \quad \Rightarrow \quad E[T | D] = m(D) = \frac{D}{2}$$

Per la trattazione che andremo a fare, si consiglia di avere fresco il concetto di σ -algebra generata da una variabile aleatoria X , precedentemente esposto a pagina 40.

ESEMPIO: Facciamo un esempio per rinfrescare la memoria. Si consideri l'esperimento dove si lanciano due dadi e se ne voglia valutare la somma. Avremo che:

$$\Omega = \{1, \dots, 6\}^2, \quad \mathcal{A} = 2^\Omega, \quad X((h, k)) = h + k$$

Allora avremo che: $\sigma(X) = \{(X = 2), (X = 4), \dots, (X = 12)\} \subsetneq 2^\Omega$.

Intuitivamente (come già avevamo visto) è normale che $\sigma(X) \subset \mathcal{A}$, in quanto l'informazione che conosco da X è sicuramente minore dell'informazione dei due risultati del singolo lancio. Per esempio, se $X = 3$, non so se è uscito $(1, 2)$ oppure $(2, 1)$. Infatti $\{(1, 2)\} \notin \sigma(X)$, ma $\{(1, 2)\} \in 2^\Omega$.

DEFINIZIONE 14.6: Se $(Z \in \mathcal{B}) \in \sigma(X) \quad \forall \mathcal{B} \in \mathcal{B} \Rightarrow Z : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$ è $\sigma(X)$ -misurabile,

Tornando all'esempio appena fatto, se $Z = \text{risultato del primo lancio}$, allora Z non è $\sigma(X)$ -misurabile; ma una qualsiasi funzione deterministica di X lo è. È proprio su questo che si basa il lemma successivo:

LEMMA 14.7 Lemma di Doob : Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità e $(E, \mathcal{E})$ uno spazio misurabile. Siano inoltre $X : (\Omega, \mathcal{A}) \rightarrow (E, \mathcal{E})$ e $Y : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$ due variabili aleatorie, allora:

$$Y \text{ è } \sigma(X)\text{-misurabile} \iff \exists h : E \rightarrow \mathbb{R} \text{ misurabile tale che } Y = h(X)$$

Grazie a questo lemma possiamo affermare che, siccome $E[Y | X] = m(X)$

$$\Rightarrow E[Y | X] \text{ è } \sigma(X)\text{-misurabile}$$

PROPOSIZIONE 14.8: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e siano le variabili aleatorie $X : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}^k, \mathcal{B}^k)$ e $Y : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$ con $|Y| \leq M$ quasi certamente.

Allora la variabile aleatoria $Z = E[Y | X]$ è l'unica V.A. reale $\sigma(X)$ -misurabile tale che:

$$\forall G \in \sigma(X) : \int_G Y d\mathbb{P} = \int_G Z d\mathbb{P} = \int_G E[Y | X] d\mathbb{P} \quad (\blacktriangle)$$

Oppure, scrivendola in modo diverso:

$$\forall G \in \sigma(X) : E[\mathbb{I}_G Y] = E[\mathbb{I}_G Z] = E[\mathbb{I}_G E[Y | X]]$$

Dove $G = (X \in B)$, $B \in \mathcal{B}^k$.

Dimostrazione. Definiamo $E[Y | X] =: Z = m(X)$, dove:

$$m(x) = \int_{\mathbb{R}} y dP^{Y|X}(dy | x) \quad \forall x \in \mathbb{R}^k$$

Allora:

$$\begin{aligned} E[\mathbb{I}_G E[Y | X]] &= E[\mathbb{I}_{X \in B} m(X)] = E[\mathbb{I}_B(X) m(X)] \\ \text{(Per la regola del valore atteso)} &= \int_{\mathbb{R}} \mathbb{I}_B(x) \left(\int_{\mathbb{R}} y P^{Y|X}(dy | x) \right) dP^X(x) \\ \text{(F-T Generalizzato)} &= \int_{\mathbb{R} \times \mathbb{R}} \mathbb{I}_B(x) y dP^{(X,Y)} = \\ &= E[\mathbb{I}_G Y] \end{aligned}$$

□

Facciamo delle osservazioni:

★ Se $\Omega \in \sigma(X)$, allora necessariamente si ha che $(\blacktriangle)$ diventa:

$$E[\mathbb{I}_\Omega Y] = E[\mathbb{I}_\Omega Z] = E[\mathbb{I}_\Omega E[Y | X]] \Rightarrow \boxed{E[Y] = E[E[Y | X]]}$$

ESEMPIO : Nell'esempio ripreso a pagina 117:

$$E[T] = E[E[T | D]] = E\left[\frac{D}{2}\right] = \frac{1}{2}E[D] = \frac{7}{4}$$

★ $E[Y | X]$ dipende da Y e da $\sigma(X)$, “non tanto da X ”.

Per esempio:

$$\sigma(X^3) = \sigma(X) \Rightarrow E[Y | X^3] = E[Y | X]$$

Questo perchè $(X^3 \in [a, b]) = (X \in [\sqrt[3]{a}, \sqrt[3]{b}])$.

In generale possiamo dedurre che: se h è misurabile ed invertibile, con inversa misurabile, allora vale che:

$$\sigma(h(X)) = \sigma(X) \Rightarrow E[Y | h(X)] = E[Y | X]$$

Per questo motivo spesso si usa la notazione $E[Y | \sigma(X)]$ per indicare $E[Y | X]$

★ Se $Y \geq 0$ quasi certamente, allora anche $Z = E[Y | X] \geq 0$ quasi certamente. Inoltre, come già avevamo osservato, vale la relazione $E[Y] = E[E[Y | X]]$. Questo implica che, se $Y \in L^1 \Rightarrow Z \in L^1$.

DEFINIZIONE 14.9 Estensione della Definizione di Attesa Condizionata (14.5) : Sia $\mathcal{G} \subseteq \mathcal{A}$ una sotto σ -algebra. Siano $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità, e $Y : (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B})$ tale che $Y \in L^1$.

Allora l'attesa condizionale di Y dato $\mathcal{G}$, $E[Y | \mathcal{G}]$, è l'unica variabile aleatoria Z tale che:

1. $Z \in L^1(\Omega, \mathcal{A}, \mathbb{P})$
2. Z è $\mathcal{G}$ -misurabile
3. Vale la relazione (▲): $E[\mathbb{I}_G Y] = E[\mathbb{I}_G Z] \quad \forall G \in \mathcal{G}$.

Due Considerazioni molto importanti a riguardo:

★ La Definizione 14.5 fornisce una definizione dell'attesa condizionata nel caso particolare in cui la σ -algebra rispetto alla quale stiamo condizionando è del tipo $\sigma(X)$, dove X è una variabile aleatoria. In questo caso è possibile definire esplicitamente una *legge condizionale* di Y dato X che permette di costruire in modo concreto la quantità

$$\mathbb{E}[Y | X](\omega) = \int_{\mathbb{R}} y P^{Y|X}(dy | X(\omega)).$$

Questa descrizione è quindi *costruttiva* e dipende dall'esistenza della legge condizionale $P^{Y|X}$.

Tuttavia, questa costruzione funziona solo quando la σ -algebra rispetto alla quale si condiziona è effettivamente generata da una singola variabile aleatoria. Nella pratica le σ -algebre rispetto alle quali si condiziona *non* sono necessariamente di questo tipo.

In generale, per una σ -algebra qualunque $\mathcal{G} \subseteq \mathcal{A}$, *non esiste alcuna* variabile aleatoria X tale che $\mathcal{G} = \sigma(X)$, e quindi *non è possibile* definire una legge condizionale $P^{Y|X}$.

Per questi motivi, la Definizione 4.9 introduce una definizione *astratta* e completamente generale di attesa condizionale.

Questa definizione non richiede alcuna legge condizionale e vale sempre, per qualsiasi σ -algebra $\mathcal{G}$.

★ $Z = E[Y | \mathcal{G}] \in L^1$ è una classe di equivalenza: se $\tilde{Z}$ verifica le condizioni della Definizione 14.9 $\Rightarrow \tilde{Z} = Z$ quasi certamente.

Quindi, formalmente parlando, $E[Z | \mathcal{G}]$ non è una VA in senso stretto, bensì una classe di equivalenza di tutte le VA che sono ad essa uguali quasi certamente. Ma questo non causa particolari problemi in quanto leggi, valori attesi, etc. sono invarianti di una classe di equivalenza di variabili aleatorie.

ESEMPIO : Si consideri $X \sim \mathcal{N}(0, \sigma^2)$. Quanto vale $E[X | X^2] = E[X | \sigma(X^2)]$?

Siccome la legge congiunta $P^{(X, X^2)}$ è piuttosto complicata (in quanto il vettore non è congiuntamente continuo), allora anche la legge $P^{X|X^2}$ sarà complicata.

Per questo motivo usiamo la Definizione 14.9: vogliamo ipotizzare un valore per l'attesa condizionata, e se questo soddisfa tutte le condizioni della definizione, allora è unico.

Si consideri un $G \in \sigma(X^2)$, per l'equazione (▲) si ha che: $E[\mathbb{I}_G X] = E[\mathbb{I}_G E[X | \sigma(X^2)]]$. Per definizione si ha che $G \in \sigma(X^2) \iff G = (X^2 \in B)$. Allora:

$$E[\mathbb{I}_{(X^2 \in B)} X] = E[\underbrace{\mathbb{I}_B(X^2)}_{\text{dispari}} \cdot X] = 0$$

Per simmetria dell'equazione (▲), allora dovremo avere che $E[X | \sigma(X^2)] = 0$ quasi certamente. Non abbiamo ancora finito: per ora abbiamo solo ipotizzato che l'attesa condizionale sia zero. Siccome questa rispetta anche le condizioni 1. e 2. della definizione, possiamo affermare con certezza (ed unicità) che

$$E[X | \sigma(X^2)] = 0 \quad \text{q.c.}$$

Andiamo ad elencare in maniera riassuntiva tutte le proprietà dell'attesa condizionale.

TEOREMA 14.10 Proprietà dell'Attesa Condizionale : Sia $Y : \Omega \rightarrow \mathbb{R}$ una variabile aleatoria tale che $Y \in L^1$, e sia $\mathcal{G} \subseteq \mathcal{A}$ sotto σ -algebra. Allora valgono le seguenti proprietà:

0. $\exists E[Y | \mathcal{G}]$ nel senso della Definizione 14.9
1. La mappa $\Gamma : L^1(\Omega, \mathcal{A}, \mathbb{P}) \rightarrow L^1(\Omega, \mathcal{G}, \mathbb{P})$ tale che $Y \mapsto E[Y | \mathcal{G}]$ è lineare e positiva, ossia:
 - $E[aY_1 + bY_2 | \mathcal{G}] = aE[Y_1 | \mathcal{G}] + bE[Y_2 | \mathcal{G}]$
 - $Y \geq 0$ q.c. $\Rightarrow E[Y | \mathcal{G}] \geq 0$ q.c.
2. $E[E[Y | \mathcal{G}]] = E[Y]$
3. Se Y è $\mathcal{G}$ -misurabile $\Rightarrow E[Y | \mathcal{G}] = Y$ q.c.
4. Se $\sigma(Y) \perp \mathcal{G} \Rightarrow E[Y | \mathcal{G}] = E[Y]$ q.c.
5. Date $\mathcal{H} \subseteq \mathcal{G} \subseteq \mathcal{A}$ due sotto σ -algebre $\Rightarrow E[Y | \mathcal{H}] = E[E[Y | \mathcal{G}] | \mathcal{H}]$ q.c.
6. Data W v.a. $\mathcal{G}$ -misurabile tale che $W \cdot Y \in L^1 \Rightarrow E[W \cdot Y | \mathcal{G}] = W \cdot E[Y | \mathcal{G}]$ q.c.
7. Se $Y = \tilde{Y}$ q.c. $\Rightarrow E[\tilde{Y} | \mathcal{G}] = E[Y | \mathcal{G}]$ q.c.
8. Vale il teorema di Convergenza Monotona:
Sia $Y_n \geq 0$ tale che $Y_n \uparrow Y$ q.c. $\Rightarrow E[Y_n | \mathcal{G}] \uparrow E[Y | \mathcal{G}]$ q.c.
9. Vale il teorema di Convergenza Dominata:
Sia Y_n t.c. $Y_n \rightarrow Y$ q.c. e $|Y_n| \leq V$ q.c. con $V \in L^1 \Rightarrow Y_n \in L^1$ e $E[Y_n | \mathcal{G}] \rightarrow E[Y | \mathcal{G}]$ q.c.
10. $Y \in L^p \Rightarrow E[Y | \mathcal{G}] \in L^p \quad \forall p \quad \text{e} \quad \|E[Y | \mathcal{G}]\|_{L^p} \leq \|Y\|_{L^p}$

11. Data $h : \mathbb{R} \rightarrow \mathbb{R}$ boreliana t.c. $h(Y) \in L^1$ e $\mathcal{G} = \sigma(X)$, ipotizzando di conoscere $P^{Y|X}(dy | x)$, allora

$$E[h(Y) | \sigma(X)] = E[h(Y) | X] =: n(X)$$

Dove:

$$n : \mathbb{R} \rightarrow \mathbb{R} \quad ; \quad n(x) = \int_{\mathbb{R}} h(y) dP^{Y|X}(dy | x)$$

Ossia che le Definizioni 14.5 e 14.9 sono consistenti l'una con l'altra.

Se consideriamo la σ -algebra banale $\mathcal{G} = \{\emptyset, \Omega\}$ e $Y \in L^1$ una variabile aleatoria definita sullo spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, allora, per il punto 4. del teorema appena illustrato, possiamo affermare che:

$$E[Y | \mathcal{G}] = E[Y]$$

Questo perché si ha che $\mathcal{G} \perp\!\!\!\perp \sigma(Y)$. Da un punto modellistico si può intuire che conoscere $\mathcal{G}$ non da alcuna informazione aggiuntiva su Y .

Le proprietà appena illustrate valgono (con le dovute modifiche) anche nel caso vettoriale. Ossia quanto $Y : \Omega \rightarrow \mathbb{R}^n$ tale che $Y_k \in L^1(\Omega, \mathcal{A}, \mathbb{P}) \quad \forall k = 1, \dots, n$, e $\mathcal{G} \subseteq \mathcal{A}$ sotto σ -algebra. Allora possiamo costruire il vettore:

$$E[Y | \mathcal{G}] = \begin{bmatrix} E[Y_1 | \mathcal{G}] \\ \vdots \\ E[Y_n | \mathcal{G}] \end{bmatrix}$$

14.3.1 Attesa Condizionata in L^2 e Ottimizzazione


Affrontiamo il caso specifico in cui ci troviamo nello spazio L^2 . Si abbia uno spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$, $\mathcal{G} \subseteq \mathcal{A}$ sotto σ -algebra.

PROPOSIZIONE 14.11: Sia $(\Omega, \mathcal{A}, \mathbb{P})$ uno spazio di probabilità e $\mathcal{G} \subseteq \mathcal{A}$ sotto σ -algebra.

Allora:

$$E[(Y - E[Y | \mathcal{G}])^2] = \min_{Z \in L^2(\mathcal{G})} E[(Y - Z)^2]$$

Grazie a questa proposizione, possiamo vedere $E[Y | \mathcal{G}]$ come la proiezione di Y su $L^2(\Omega, \mathcal{G}, \mathbb{P})$. Questo è possibile perché $L^2(\Omega, \mathcal{A}, \mathbb{P})$ non solo è uno spazio vettoriale, ma è anche uno spazio di Hilbert². Possiamo quindi avere la nozione di prodotto scalare, e quindi di proiezione.



²Senza entrare nel dettaglio: uno spazio di Hilbert è uno spazio vettoriale dotato di prodotto scalare $\langle \bullet, \bullet \rangle$, e completo rispetto alla norma indotta da questo.

Per comprendere a pieno la figura, si immagini $L^2(\mathcal{A})$ come tutto lo spazio tridimensionale; in questo modo $L^2(\mathcal{G}) \subset L^2(\mathcal{A})$. Come si vede Y vive nello spazio $L^2(\mathcal{A})$, mentre la sua proiezione $E[Y | \mathcal{G}]$ vive nel sottospazio $L^2(\mathcal{G})$.

Allora, per un certo $W \in L^2(\Omega, \mathcal{G}, \mathbb{P})$ si avrà che:

$$\begin{aligned} \langle W, Y - E[Y | \mathcal{G}] \rangle_{L^2(\mathcal{G})} = 0 &\Rightarrow \langle W, Y \rangle_{L^2} = \langle W, E[Y | \mathcal{G}] \rangle_{L^2} \\ &\Rightarrow E[W \cdot Y] = E[W \cdot E[Y | \mathcal{G}]] \quad \forall W \in L^2(\Omega, \mathcal{G}, \mathbb{P}) \end{aligned}$$

Se prendiamo $W = \mathbb{I}_G$ otteniamo esattamente la condizione ($\blacktriangle$): $E[\mathbb{I}_G Y] = E[\mathbb{I}_G E[Y | \mathcal{G}]] \quad \forall G \in \mathcal{G}$. Questo dimostra che $E[Y | \mathcal{G}]$ soddisfa la definizione di attesa condizionata, e che questa è la proiezione ortogonale nel senso di Hilbert Y su $L^2(\mathcal{G})$.

14.4 Varianza Condizionata

Estendendo concettualmente i ragionamenti fatti per l'attesa condizionata, possiamo andare a identificare una Varianza Condizionata. È noto che, dato $Y \in L^2$, allora $Var(Y) = E[(Y - E[Y])^2]$. Ipotizzando di sapere la legge condizionale $P^{Y|X}(dy | x)$, possiamo ricavare la varianza condizionata di Y dato $X = x$ come:

$$q^2(x) := Var(Y | X = x) = E[(Y - E[Y | X = x])^2 | X = x] = \int_{\mathbb{R}} (y - m(x))^2 dP^{Y|X}(dy | x)$$

Dove: $m(x) = \int_{\mathbb{R}} y dP^{Y|X}(dy | x)$.

Come abbiamo fatto per l'attesa condizionata, affinché questa sia una variabile aleatoria è sufficiente valutare tale funzione nei valori che la variabile aleatoria X può effettivamente assumere. La definizione diventa allora:

$$q^2(X) = E[(Y - E[Y | X])^2 | X]$$

Diamo quindi la definizione formale ed astratta, anche nel caso in cui Y sia condizionata da una generica σ -algebra, e non per forza da una variabile aleatoria.

DEFINIZIONE 14.12: Sia $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$, e $\mathcal{G} \subseteq \mathcal{A}$ una sotto σ -algebra. Definiamo la Varianza Condizionata di Y dato $\mathcal{G}$, la variabile aleatoria data da:

$$Var(Y | \mathcal{G}) = E[(Y - E[Y | \mathcal{G}])^2 | \mathcal{G}]$$

Osserviamo immediatamente che $Var(Y | \mathcal{G})$ è una variabile aleatoria reale, in quanto:

$$\begin{aligned} Y \in L^2 &\Rightarrow E[Y | \mathcal{G}] \in L^2 \Rightarrow (Y - E[Y | \mathcal{G}]) \in L^2 \Rightarrow (Y - E[Y | \mathcal{G}])^2 \in L^1 \\ &\Rightarrow E[(Y - E[Y | \mathcal{G}])^2 | \mathcal{G}] \in L^1 \end{aligned}$$

TEOREMA 14.13 Proprietà della Varianza Condizionata : Dato $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$, e $\mathcal{G} \subseteq \mathcal{A}$ una sotto σ -algebra, allora valgono le seguenti:

1. $Var(Y | \mathcal{G}) \geq 0$ q.c. (Mappa positiva)
2. $Var(Y | \mathcal{G}) = E[Y^2 | \mathcal{G}] - (E[Y | \mathcal{G}])^2$
3. $E[Var(Y | \mathcal{G})] = E[(Y - E[Y | \mathcal{G}])^2]$

4. Se $\mathcal{G} = \sigma(X) \Rightarrow \text{Var}(Y | \sigma(X)) = \text{Var}(Y | X) = q^2(X)$

5. Vale la formula di scomposizione della Varianza:

$$\boxed{\text{Var}(Y) = \text{Var}(E[Y | \mathcal{G}]) + E[\text{Var}(Y | \mathcal{G})]}$$

Dimostrazione. 1. Deriva primo punto dal Teorema 14.10, ossia che Γ è una mappa positiva.

2. Introduciamo $\hat{Y} := E[Y | \mathcal{G}]$, che è $\mathcal{G}$ -misurabile. Allora avremo che:

$$\begin{aligned} \text{Var}(Y | \mathcal{G}) &= E[(Y - E[Y | \mathcal{G}])^2 | \mathcal{G}] = E[(Y - \hat{Y})^2 | \mathcal{G}] = E[Y^2 - 2Y\hat{Y} + \hat{Y}^2 | \mathcal{G}] \\ &\stackrel{14.10.6}{=} E[Y^2 | \mathcal{G}] - 2\hat{Y}E[Y | \mathcal{G}] + E[\hat{Y}^2 | \mathcal{G}] \\ (\hat{Y}^2 \text{ } \mathcal{G}\text{-misurabile}) &= E[Y^2 | \mathcal{G}] - 2\hat{Y} \cdot \hat{Y} + \hat{Y}^2 \\ &= E[Y^2 | \mathcal{G}] - \hat{Y}^2 \\ &= E[Y^2 | \mathcal{G}] - (E[Y | \mathcal{G}])^2 \end{aligned}$$

3. Si ricava direttamente dal secondo punto del Teorema 14.10, mentre il punto 4. è triviale

5. Definiamo anche in questo caso $\hat{Y} := E[Y | \mathcal{G}]$. Dalla definizione di varianza:

$$\begin{aligned} \text{Var}(Y) &= E[(Y - E[Y])^2] = E[(Y - E[Y])^2 + \hat{Y} - \hat{Y}] = E\left[\left((Y - \hat{Y}) + (\hat{Y} - E[Y])\right)^2\right] \\ &= \underbrace{E[(Y - \hat{Y})^2]}_A + \underbrace{E[(\hat{Y} - E[Y])^2]}_B + \underbrace{2E[(Y - \hat{Y})(\hat{Y} - E[Y])]}_C \end{aligned}$$

$$A : E[(Y - E[Y | \mathcal{G}])^2] = E[E[(Y - E[Y | \mathcal{G}])^2 | \mathcal{G}]] = E[\text{Var}(Y | \mathcal{G})]$$

$$\begin{aligned} B : E[(\hat{Y} - E[Y])^2] &= E\left[E[(\hat{Y} - E[Y])^2 | \mathcal{G}]] \quad \text{Siccome 14.10.2: } E[Y] = E[E[Y | \mathcal{G}]] \\ &= \text{Var}(\hat{Y}) = \text{Var}(E[Y | \mathcal{G}]) \end{aligned}$$

$$C : E[(Y - \hat{Y})(\hat{Y} - E[Y])] \stackrel{14.10.2}{=} E\left[E[(Y - \hat{Y})(\hat{Y} - E[Y]) | \mathcal{G}]]\right]$$

$\mathcal{G}$ -misurabile

$$= E\left[(\hat{Y} - E[Y]) \cdot \underbrace{E[Y - E[Y | \mathcal{G}] | \mathcal{G}]}_*\right]$$

Dove: $* = E[Y | \mathcal{G}] - E[E[Y | \mathcal{G}] | \mathcal{G}] = E[Y | \mathcal{G}] - E[Y | \mathcal{G}] = 0$ q.c.

$= 0$ q.c.

$$\Rightarrow \text{Var}(Y) = A + B = E[\text{Var}(Y | \mathcal{G})] + \text{Var}(E[Y | \mathcal{G}])$$

□

Dal punto 5. del teorema si può ricavare che $Var(Y) \geq Var(E[Y | \mathcal{G}])$. Questo, da un punto di vista modellistico, è ragionevole: nel momento in cui abbiamo informazioni maggiori (quindi conosciamo $\mathcal{G}$) avremo una varianza minore rispetto a non avere nessuna informazione.

Ragionando allo stesso modo, sempre dal punto 5., ricaviamo che:

$$\begin{aligned} Var(Y) &= E[(Y - E[Y])^2] \geq E[Var(Y | \mathcal{G})] \stackrel{3.}{=} E[(Y - E[Y | \mathcal{G}])^2] \\ \Rightarrow E[(Y - E[Y])^2] &\geq E[(Y - E[Y | \mathcal{G}])^2] \end{aligned}$$

Questo è proprio dovuto al fatto che (come avevamo visto nella Proposizione 14.11) la proiezione ortogonale di $Y \in L^2(\Omega, \mathcal{A}, \mathbb{P})$ su $L^2(\mathcal{G})$ è precisamente l'attesa condizionata $E[Y | \mathcal{G}]$. Ciò significa che $E[Y | \mathcal{G}]$ è l'elemento di $L^2(\mathcal{G})$ più vicino a Y in norma L^2 .

In altre parole, $E[Y]$ è un elemento di $L^2(\mathcal{G})$ (in quanto si può vedere come una V.A. costante), ma non è in generale la proiezione ortogonale di Y su $L^2(\mathcal{G})$, e quindi non sarà la variabile che la approssima meglio.

ESEMPIO: Continuiamo l'esempio che avevamo ripreso a pagina 118. Per la formula di scomposizione della varianza abbiamo che:

$$Var(T) = E[Var(T | D)] + Var(E[T | D])$$

Siccome avevamo già calcolato in precedenza che $E[T | D] = D/2$, e che $Var(T | D) \stackrel{Bin}{=} D/4$. Allora:

$$Var(T) = \frac{1}{4}E[D] + \frac{1}{4}Var(D) = \frac{77}{48} \simeq 1.6042$$

15 Convergenze di Variabili Aleatorie

Lo studio del comportamento asintotico delle variabili aleatorie riveste un ruolo centrale nella teoria della probabilità. Molti risultati fondamentali – come la Legge Forte dei Grandi Numeri o il Teorema del Limite Centrale – si basano infatti sul confronto tra successioni di variabili aleatorie e un opportuno limite.

In questo capitolo analizzeremo i diversi tipi di convergenza che si possono definire nello spazio delle variabili aleatorie: la convergenza quasi certa, la convergenza in probabilità, la convergenza in L^p e la convergenza in probabilità. Ciascuna di esse cattura un aspetto distinto del “tendere al limite” e possiede proprietà e implicazioni specifiche, non sempre equivalenti tra loro.

Ricordiamo le definizioni di convergenza puntuale e uniforme:

DEFINIZIONE 15.1 Convergenza puntuale : Una successione di funzioni $\{f_n\}$ converge puntualmente alla funzione f , per $n \rightarrow +\infty$ se:

$$\forall t \in \mathbb{R} \quad \lim_{n \rightarrow +\infty} f_n(t) = f(t)$$

DEFINIZIONE 15.2 Convergenza uniforme : Una successione di funzioni $\{f_n\}$ converge uniformemente alla funzione f , per $n \rightarrow +\infty$ se:

$$\forall t \in \mathbb{R} \quad \lim_{n \rightarrow +\infty} \sup |f_n(t) - f(t)| = 0$$

Si ha ovviamente che: Convergenza Uniforme $\Rightarrow$ Convergenza Puntuale.

Come oramai sappiamo bene, variabili aleatorie differenti possono essere definite su spazi di probabilità differenti. È per questo motivo che andremo a suddividere la nostra analisi in due parti, analizzando prima il caso in cui abbiano stesso dominio, e poi il caso più generico.

15.1 Convergenze per Variabili Reali con lo Stesso Dominio

Avremo quindi una successione di variabili aleatorie reali $(X_n)_{n \geq 1}$ definite sullo stesso spazio $(\Omega, \mathcal{A}, \mathbb{P})$.

15.1.1 Convergenza Quasi Certa

Come vedremo, la convergenza certa risulta spesso una condizione eccessivamente forte e, di conseguenza, tende a non essere soddisfatta in molti casi. Per questo motivo è necessario introdurre una nozione di convergenza “meno stringente”, capace di catturare situazioni in cui la convergenza certa fallisce.

DEFINIZIONE 15.3 Convergenza Certa : Diciamo che X_n tende ad X certamente se:

$$\lim_{n \rightarrow +\infty} X_n(w) = X(w) \quad \forall w \in \Omega$$

E la indicheremo con: $X_n \xrightarrow{c} X$

La convergenza certa risulta essere la medesima della convergenza puntuale per l’analisi. Da un punto di vista modellistico può essere interpretata come segue: ogni sperimentatore osserva lo stesso limite.

DEFINIZIONE 15.4 Convergenza Quasi Certa : Diciamo che X_n tende ad X quasi certamente se:

$$\mathbb{P} \left(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = X(w) \right) = 1$$

E la indicheremo con: $X_n \xrightarrow{\text{qc}} X$

Modellisticamente parlando, si può intendere che *quasi ogni* sperimentatore osserva lo stesso limite. È chiaro che per entrambe le definizioni si ha la necessità che tutte le variabili siano definite sullo stesso spazio.

ESEMPIO : Facciamo qualche esempio per entrare nel concreto:

★ Sia X una V.A. reale, e sia la successione: $X_n(w) = \frac{X(w)}{n} \quad \forall w \in \Omega, \forall n \geq 1$. La successione converge? In che modo?

$$\lim_{n \rightarrow +\infty} X_n(w) = 0 \quad \forall w \in \Omega$$

$$\Rightarrow X_n \xrightarrow{c} 0$$

Avremo inoltre che: $(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = 0) = \Omega$.

$$\Rightarrow X_n \xrightarrow{\text{qc}} 0$$

★ Nel caso in cui si abbia convergenza monotona $X_n \uparrow X \geq 0$ allora per definizione si ha che:

$$\lim_{n \rightarrow +\infty} X_n(w) = X(w); \quad X_n \leq X_{n+1} \quad \forall w \in \Omega$$

$$\Rightarrow X_n \xrightarrow{c} 0 \quad ; \quad X_n \xrightarrow{\text{qc}} 0$$

★ Siano $\Omega = [0, 1]$, $\mathcal{A} = \mathcal{B}([0, 1])$, $\mathbb{P} \sim \mathcal{U}([0, 1])$. Esiste quindi una densità: $f(t) = \mathbb{I}_{[0,1]}(t)$. Definiamo la successione:

$$\forall n \geq 1 : \quad X_n(w) = \mathbb{I}_{[0, \frac{1}{n}]}(w)$$

Abbiamo due situazioni possibili:

- Se $w = 0$, si ha che $X_n(0) = 1 \Rightarrow \lim_{n \rightarrow +\infty} X_n(0) = 1$
- Se $w \neq 0$, si ha che $X_n(w) = 0 \quad \forall n > \frac{1}{w} \Rightarrow \lim_{n \rightarrow +\infty} X_n(w) = 0$

Possiamo quindi dire che:

$$\left(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = 0 \right) = (0, 1]$$

Siccome $\mathbb{P}((0, 1]) = \int_0^1 dt = 1$, possiamo concludere che $X_n \xrightarrow{\text{qc}} 0$. Tuttavia non è verificata la condizione per l'uguaglianza certa per ogni $w \in \Omega \Rightarrow X_n \not\xrightarrow{c} 0$.

Se invece avessimo preso $\mathbb{P} \sim \delta_0$, allora avremmo avuto che:

- $\mathbb{P}((0, 1]) = 0$
- $\mathbb{P}(\{0\}) = 1$

$$\Rightarrow \mathbb{P} \left(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = 1 \right) = 1 \Rightarrow X_n \xrightarrow{\text{qc}} 1$$

Questi esempi mostrano che **la convergenza quasi certa dipende dalla probabilità**, mentre quella certa no.

PROPOSIZIONE 15.5: Se $X_n \xrightarrow{c} X \Rightarrow X_n \xrightarrow{qc} X$.
Il viceversa non è vero (si vedano gli esempi sopra).

Vediamo adesso le proprietà che distinguono la convergenza quasi certa.

TEOREMA 15.6 Proprietà della Convergenza Quasi Certa : Siano $(X_n)_{n \geq 1}$, $(Y_n)_{n \geq 1}$ successioni di variabili aleatorie, X , Y variabili aleatorie, tutte reali e definite sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$. Sia inoltre $a \in \mathbb{R}$ e $h : \mathbb{R} \rightarrow \mathbb{R}$ continua.

Siano le successioni tali che $X_n \xrightarrow{qc} X$ e che $Y_n \xrightarrow{qc} Y$, allora valgono le seguenti:

1. Il limite è unico quasi certamente. Ossia che se $X_n \xrightarrow{qc} X$ e $X_n \xrightarrow{qc} \hat{X} \Rightarrow X = \hat{X}$ q.c.
2. $aX_n \xrightarrow{qc} aX$
3. $h(X_n) \xrightarrow{qc} h(X)$
4. $X_n + Y_n \xrightarrow{qc} X + Y$
5. $X_n Y_n \xrightarrow{qc} XY$
6. $\frac{X_n}{Y_n} \mathbb{I}_{(Y_n \neq 0)} \xrightarrow{qc} \frac{X}{Y} \mathbb{I}_{(Y \neq 0)}$

Dimostrazione. 1. Siano A_1, A_2 tali che $\mathbb{P}(A_1) = \mathbb{P}(A_2) = 1$, definiti come:

$$A_1 := \left(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = X(w) \right)$$

$$A_2 := \left(w \in \Omega : \lim_{n \rightarrow +\infty} X_n(w) = \hat{X}(w) \right)$$

Allora avremo che $\forall w \in A_1 \cap A_2 : \lim_{n \rightarrow +\infty} X_n(w) = X(w) = \hat{X}(w)$, con : $\mathbb{P}(A_1 \cap A_2) = 1$ Le altre dimostrazioni per i punto 2. 3. 4. e 5. si svolgono nella stessa maniera. $\square$

15.1.2 Convergenza in L^p ed in Probabilità

Così come abbiamo introdotto la convergenza quasi certa per gestire in modo rigoroso i casi in cui la convergenza certa fallisce, è necessario introdurre altre due nozioni di convergenza, compaiono naturalmente proprio quando la convergenza quasi certa fallisce e, oltre a ciò, si rivelano strumenti molto utili per dimostrare, in molti casi, la stessa convergenza quasi certa.

DEFINIZIONE 15.7 Convergenza in L^p : Sia $1 \leq p < +\infty$, diciamo che $X_n \xrightarrow{L^p} X$ se:

1. $X_n \in L^p \quad \forall n$
2. $X \in L^p$
3. $\lim_{n \rightarrow +\infty} E[|X_n - X|^p] = 0$ ($\forall n$ avrà una successione numerica, il cui limite deve essere zero)

Dal punto di vista modellistico, la convergenza in L^p ha un'interpretazione completamente diversa rispetto alle convergenze puntuali: ciò che controlliamo non è il comportamento di ciascun singolo osservatore, bensì il comportamento *medio* dell'errore $|X_n - X|^p$.

Questo significa che “in media” le osservazioni di X_n si avvicinano a quelle di X , ma non garantisce affatto che $X_n(w)$ converga a $X(w)$ per ogni w : il singolo osservatore può vedere oscillazioni anche molto grandi.

osservatore 1 $\longrightarrow$ errore medio₁

$\vdots$

osservatore n $\longrightarrow$ errore medio _{n}

Ci aspettiamo quindi che la *successione degli errori medi* converga a zero, mentre non abbiamo alcuna garanzia né informazione sul comportamento delle singole osservazioni punto per punto.

TEOREMA 15.8 Proprietà della Convergenza in L^p : Siano $(X_n)_{n \geq 1}$, $(Y_n)_{n \geq 1}$ successioni di variabili aleatorie, X , Y variabili aleatorie, tutte reali ed appartenenti a L^p . Sia inoltre $a \in \mathbb{R}$.

Siano le successioni tali che $X_n \xrightarrow{L^p} X$ e che $Y_n \xrightarrow{L^p} Y$, allora valgono le seguenti:

1. Il limite è unico quasi certamente. Ossia che se $X_n \xrightarrow{L^p} X$ e $X_n \xrightarrow{L^p} \hat{X} \Rightarrow X = \hat{X}$ q.c.
2. $aX_n \xrightarrow{L^p} aX \quad \forall a \in \mathbb{R}$
3. $X_n + Y_n \xrightarrow{L^p} X + Y$
4. $\lim_{n \rightarrow +\infty} E[|X_n|^p] = E[|X|^p] \quad (E[|X_n|^p] \text{ è una successione numerica})$

DEFINIZIONE 15.9 Convergenza in Probabilità: Diciamo che la successione $(X_n)_{n \geq 1}$ tende ad X in probabilità, per $n \rightarrow +\infty$ se:

$$\forall \varepsilon > 0 \text{ fissato: } \lim_{n \rightarrow +\infty} \mathbb{P}(|X_n - X| > \varepsilon) = 0$$

E la indicheremo con: $X_n \xrightarrow{\mathbb{P}} X$.

Anche in questo caso, come per la convergenza in L^p , non otteniamo alcuna informazione sul comportamento del singolo osservatore.

Da un punto di vista modellistico, possiamo immaginare che ogni osservatore calcoli l'errore $|X_n - X|$. Ciò che analizziamo non è il valore dell'errore per un singolo osservatore, bensì la “proporzione” di osservatori che ottengono un errore superiore a una fissata soglia $\varepsilon > 0$. Se questa proporzione, che è generalmente n -dipendente, tende a zero, allora possiamo dire che vi è convergenza in probabilità.

PROPOSIZIONE 15.10: Vale la seguente:

$$X_n \xrightarrow{\mathbb{P}} X \iff \lim_{n \rightarrow +\infty} E \left[\frac{|X_n - X|}{1 + |X_n - X|} \right] = 0$$

Si noti che la successione di variabili aleatorie $1 + |X_n - X|$ converge in L^1 a 0. Il denominatore rende naturalmente l'oggetto più piccolo, facilitando così la sua convergenza verso zero: potrebbero esserci situazioni in cui $E[|X_n - X|] \not\rightarrow 0$, ma tutta la frazione sì.

PROPOSIZIONE 15.11: Siano $(X_n)_{n \geq 1}$, X e $(Y_n)_{n \geq 1}$, Y variabili aleatorie reali, sia $a \in \mathbb{R}$ e $h : \mathbb{R} \rightarrow \mathbb{R}$ continua.

Allora valgono le stesse proprietà espresse nel Teorema 15.6 per la convergenza quasi certa, anche per la convergenza in probabilità.

Ora che abbiamo visto che esistono vari tipi di convergenza per variabili aleatorie definite sullo stesso spazio di probabilità, vediamo quale è la relazione che intercorre tra di esse.

TEOREMA 15.12: Valgono le seguenti:

1. $X_n \xrightarrow{\text{qc}} X \Rightarrow X_n \xrightarrow{\mathbb{P}} X$
2. $X_n \xrightarrow{L^p} X \Rightarrow X_n \xrightarrow{L^q} X \quad \forall 1 \leq q \leq p \Rightarrow X_n \xrightarrow{\mathbb{P}} X$

Dimostrazione. 1. Se $X_n \xrightarrow{\text{qc}} X$ allora $X_n - X \xrightarrow{\text{qc}} 0$. Allora vale che:

$$\begin{aligned} \frac{|X_n - X|}{1 + |X_n - X|} &=: h(X_n - X) \xrightarrow{15.6} h(X_n - X) \xrightarrow{\text{qc}} h(0) = 0 \\ &\Rightarrow \frac{|X_n - X|}{1 + |X_n - X|} \xrightarrow{\text{qc}} 0 \end{aligned}$$

Inoltre sappiamo che la funzione $h(X_n - X) \leq 1$ quasi certamente, allora per il teorema di convergenza dominata di Lebesgue abbiamo che:

$$\lim_{n \rightarrow +\infty} E \left[\frac{|X_n - X|}{1 + |X_n - X|} \right] = E[0] = 0$$

Per la Proposizione 15.10 abbiamo che: $X_n \xrightarrow{\mathbb{P}} X$.

2. La prima implicazione deriva direttamente dal fatto che gli spazi L^p (nel caso di misure di probabilità) sono “inscatolati”, ossia che $L^1 \supseteq L^2 \supseteq \dots$

Per quanto riguarda la seconda implicazione, si può notare che:

$$\frac{|X_n - X|}{1 + |X_n - X|} \leq \frac{|X_n - X|}{1}$$

Di conseguenza, se $X_n \xrightarrow{L^1} X \Rightarrow \lim_{n \rightarrow +\infty} E[|X_n - X|] = 0$.

Per il teorema del confronto:

$$0 \leq \lim_{n \rightarrow +\infty} E \left[\frac{|X_n - X|}{1 + |X_n - X|} \right] \leq \lim_{n \rightarrow +\infty} E[|X_n - X|] = 0$$

E questo è vero se e solo se $X_n \xrightarrow{\mathbb{P}} X$. □

Questo teorema ci dice che ci sono delle convergenze naturalmente “più forti” di altre, e quindi esistono delle condizioni di implicazione. Si presti molta attenzione a non confondere le implicazioni, per esempio non sono vere le seguenti:

- $X_n \xrightarrow{\mathbb{P}} X \not\Rightarrow X_n \xrightarrow{qc} X$
- $X_n \xrightarrow{L^p} X \not\Rightarrow X_n \xrightarrow{qc} X$
- $X_n \xrightarrow{qc} X \not\Rightarrow X_n \xrightarrow{L^p} X$

TEOREMA 15.13: Sono vere le seguenti:

1. Se $X_n \xrightarrow{\mathbb{P}} X \Rightarrow \exists (n_k)_{k \geq 1}$ tale che la sottosuccessione : $X_{n_k} \xrightarrow{qc} X$
2. Se $X_n \xrightarrow{\mathbb{P}} X$ e $|X_n| \leq Y, \forall n \geq 1$ con $Y \in L^p$. Allora:
 - $X_n \in L^p$ e $X \in L^p$
 - $X_n \xrightarrow{L^p} X$

Osservando che $|EX_n - E[X]| \leq E[|X_n - X|]$, se imponiamo $p = 1$, allora otteniamo il *Teorema di Lebesgue*, ma con condizioni meno stringenti (convergenza in probabilità e non quasi certa). Ossia che:

Se $X_n \xrightarrow{\mathbb{P}} X$ e $|X_n| \leq Y, \forall n \geq 1$ con $Y \in L^1$. Allora:

- $X_n \in L^1$ e $X \in L^1$
- $X_n \xrightarrow{L^1} X$ che è equivalente alla condizione di Lebesgue: $\lim_{n \rightarrow +\infty} E[X_n] = E[X]$

15.2 Teoremi Limite: Legge Debole e Forte dei Grandi Numeri

I teoremi limite rappresentano alcuni dei risultati più profondi e potenti della Teoria della Probabilità. Essi descrivono il comportamento di successioni di variabili aleatorie quando il numero di osservazioni cresce, e forniscono le basi matematiche per molte intuizioni statistiche fondamentali.

Partendo da ipotesi spesso molto deboli, questi risultati gettano le fondamenta concettuali della statistica moderna: mostrano infatti in che modo l'informazione campionaria si “stabilizza” e perché certe approssimazioni diventano affidabili quando il numero di osservazioni cresce. Tutte le dimostrazioni poggiano sulla teoria sviluppata finora — in particolare sulla convergenza di variabili aleatorie — ma, giunti a questo punto della trattazione, appariranno sorprendentemente concise e naturali.

Data $(X_n)_{n \geq 1}$ una successione di variabili aleatorie definite sullo stesso spazio di probabilità, e consideriamo la somma parziale o la media campionaria

$$S_n = \sum_{k=1}^n X_k \quad ; \quad \frac{1}{n} S_n$$

i risultati che descrivono la convergenza di tali quantità, in uno dei sensi di convergenza introdotti nei capitoli precedenti, prendono il nome di *Legge dei Grandi Numeri*.

TEOREMA 15.14 Legge Debole dei Grandi Numeri : Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie reali definite sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ tali che $X_n \in L^2(\Omega, \mathcal{A}, \mathbb{P}) \quad \forall n \geq 1$ e che valgano:

1. $E[X_n] = \mu \quad \forall n$
2. $Var(X_n) = \sigma_n^2 \leq \sigma^2$ per un qualche $0 < \sigma^2 < +\infty$

3. Vale il limite:

$$\lim_{n \rightarrow +\infty} n^{-2} \sum_{1 \leq k < h \leq n} |\rho(X_h, X_k)| = 0$$

Allora si ha che la media campionaria $\bar{X}_n = \frac{(X_1 + \dots + X_n)}{n} \forall n \geq 1$ è tale che:

$$\boxed{\bar{X}_n \xrightarrow{L^2} \mu \quad \text{e} \quad \bar{X}_n \xrightarrow{\mathbb{P}} \mu}$$

Dimostrazione. Ci basta studiare i comportamenti asintotici di media e varianza di $\bar{X}_n$.

$$E[\bar{X}_n] = \frac{E[X_1 + \dots + X_n]}{n} = \frac{n\mu}{n} = \mu$$

Per quanto riguarda la varianza, ricordando che $\rho(X_h, X_k)\sigma_k\sigma_h = \text{Cov}(X_h, X_k)$, si ottiene:

$$\begin{aligned} \text{Var}(\bar{X}_n) &= \frac{\text{Var}(X_1 + \dots + X_n)}{n^2} = \frac{1}{n^2} \left[\sum_{k=1}^n \text{Var}(X_k) + 2 \sum_{1 \leq k < h \leq n} \text{Cov}(X_h, X_k) \right] \\ &= \frac{1}{n^2} \left[\sum_{k=1}^n \sigma_k^2 + 2 \sum_{1 \leq k < h \leq n} \rho(X_h, X_k) \sigma_k \sigma_h \right] \\ &\leq \frac{1}{n^2} \left[n\sigma^2 + 2\sigma^2 \sum_{1 \leq k < h \leq n} \rho(X_h, X_k) \right] \quad (\text{Siccome: } \sigma_k^2 \leq \sigma^2) \\ &= \frac{\sigma^2}{n} + 2\sigma^2 \underbrace{n^{-2} \left[\sum_{1 \leq k < h \leq n} \rho(X_h, X_k) \right]}_{\rightarrow 0 \text{ per ipotesi}} \xrightarrow{n \rightarrow +\infty} 0 \end{aligned}$$

$$\Rightarrow \text{Var}(\bar{X}_n) \rightarrow 0$$

Avremo allora che, siccome $E[\bar{X}_n] = \mu$:

$$\begin{aligned} \|\bar{X}_n - \mu\|_{L^2}^2 &= E[(\bar{X}_n - \mu)^2] = E[\bar{X}_n^2] + \mu^2 - 2\mu E[\bar{X}_n] \\ &= E[\bar{X}_n^2] - E^2[\bar{X}_n] \\ &= \text{Var}(\bar{X}_n) \rightarrow 0 \end{aligned}$$

Abbiamo appena dimostrato che: $\bar{X}_n \xrightarrow{L^2} \mu$, e di conseguenza, avremo che $\bar{X}_n \xrightarrow{\mathbb{P}} \mu$ $\square$

Si osservi che non si chiede che le $(X_n)_{n \geq 1}$ siano una famiglia di variabili indipendenti ed identicamente distribuite (i.i.d.), difatti nel punto 2. le σ_n^2 possono essere diverse.

Si può inoltre notare che il limite nel punto 3. non chiede altro che la successione dipendente da n in sommatoria, sia un $o(n^2)$

Da questo teorema possiamo dedurre due importanti corollari.

COROLLARIO 15.15: Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie identicamente distribuite^a tali che $Cov(X_h, X_k) = 0 \quad \forall h \neq k, X_n \in L^2, E[X_n] = \mu$.

Allora avremo che:

$$\bar{X}_n \xrightarrow{L^2} \mu \quad \text{e} \quad \bar{X}_n \xrightarrow{L^1} \mu \quad \text{e} \quad \bar{X}_n \xrightarrow{\mathbb{P}} \mu$$

Dimostrazione. Il fatto che siano i.d. implica che $Var(X_n) = \sigma^2 < +\infty$. Inoltre essendo la $Cov(X_h, X_k) = 0$, la sommatoria (nella condizione 3.) risulta essere zero, valendo così la legge debole dei grandi numeri. $\square$

^aOssia che $P^{X_n} \sim P^X \quad \forall n$

COROLLARIO 15.16: Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie indipendenti identicamente distribuite, con $X_n \in L^2 \quad \forall n$, tale che $E[X_n] = \mu$ e $Var(X_n) = \sigma^2 \in [0, +\infty)$.

Allora avremo che:

$$\bar{X}_n \xrightarrow{L^2} \mu \quad \text{e} \quad \bar{X}_n \xrightarrow{L^1} \mu \quad \text{e} \quad \bar{X}_n \xrightarrow{\mathbb{P}} \mu$$

Dimostrazione. Essendo indipendenti, la covarianza sarà zero per ogni coppia, valendo così il corollario 15.15. $\square$

Prima di introdurre la legge forte dei grandi numeri, enunciamo un lemma fondamentale che ci aiuterà nella dimostrazione.

LEMMA 15.17: Sia $(Y_n)_{n \geq 1}$ una successione di variabili aleatorie reali tali che $Y_n \geq 0$ q.c. $\forall n$.

Allora:

$$E\left[\sum_{n=1}^{+\infty} Y_n\right] = \sum_{n=1}^{+\infty} E[Y_n]$$

Dimostrazione. Se $Y_n \geq 0 \Rightarrow \sum_{n=1}^k Y_n \uparrow \sum_{n=1}^{+\infty} Y_n$ per $k \rightarrow +\infty$.

Posso usare il Teorema di Beppo Levi:

$$\begin{aligned} E\left[\lim_{k \rightarrow +\infty} \sum_{n=1}^k Y_n\right] &= \lim_{k \rightarrow +\infty} E\left[\sum_{n=1}^k Y_n\right] \\ &= \lim_{k \rightarrow +\infty} \sum_{n=1}^k E[Y_n] && \text{(Per linearità della media)} \\ &= \sum_{n=1}^{+\infty} E[Y_n] \end{aligned}$$

$\square$

Questo assicura la linearità dell'integrale (o del valore atteso) anche per somme infinite, qualora sia rispettata l'ipotesi. Infatti, se avevamo già visto che il valore atteso è una mappa lineare per somme finite, questo non è sempre vero per somme infinite, ma abbiamo la necessità di poter scambiare il segno di limite con quello di integrale; questo è garantito dal teorema di Beppo Levi.

TEOREMA 15.18 Legge Forte dei Grandi Numeri (LFGN) : Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie reali definite sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, \mathbb{P})$ tale che:

1. X_n siano i.i.d.
2. $E[X_n] = \mu$ e $Var(X_n) = \sigma^2 \in [0, +\infty)$

Allora si ha che:

$$\overline{X}_n \xrightarrow{\text{qc}} \mu \quad (\text{e anche in } L^2)$$

Dimostrazione. Senza perdere di generalità poniamo $\mu = 0$ (se si volesse $\mu \neq 0$ basterebbe eseguire la stessa dimostrazione utilizzando $Y_n = X_n - \mu$).

(*) Per il corollario 15.16 si ha che $\overline{X}_n \xrightarrow{L^2} 0$.

(**) Siccome converge in L^2 , allora convergerà anche in probabilità, e quindi esiste una sottosuccessione che converge quasi certamente. Si vuole quindi trovare la sottosuccessione che converge quasi certamente a $\mu = 0$. Definisco allora:

$$Y_n := \overline{X}_{n^2} = \frac{X_1 + \cdots + X_{n^2}}{n^2} \Rightarrow (Y_1, Y_2, Y_3, \dots) = (\overline{X}_1, \overline{X}_4, \overline{X}_9, \dots)$$

Si osserva che:

$$\text{Se: } \sum_{n=1}^{+\infty} Y_n^2(w) < +\infty \text{ q.c.} \Rightarrow \lim_{n \rightarrow +\infty} Y_n^2(w) = 0 = \lim_{n \rightarrow +\infty} Y_n(w)$$

siccome è il termine generale di una serie convergente.

Allora ci basta dimostrare che la serie non diverga:

$$\begin{aligned} E \left[\sum_{n=1}^{+\infty} Y_n^2 \right] &\stackrel{15.17}{=} \sum_{n=1}^{+\infty} E[Y_n^2] = \sum_{n=1}^{+\infty} E[\overline{X}_{n^2}^2] \\ &\stackrel{\mu=0}{=} \sum_{n=1}^{+\infty} Var(\overline{X}_{n^2}) = \sum_{n=1}^{+\infty} \left(\frac{Var(X_1 + \cdots + X_{n^2})}{n^4} \right) \\ &= \sum_{n=1}^{+\infty} \frac{1}{n^4} n^2 \sigma^2 \\ &= \sum_{n=1}^{+\infty} \frac{\sigma^2}{n^2} < +\infty \\ &\Rightarrow \sum_{n=1}^{+\infty} Y_n^2 < +\infty \text{ q.c.} \end{aligned}$$

$$\Rightarrow \mathbb{P} \left(w \in \Omega : \sum_{n=1}^{+\infty} Y_n^2(w) < +\infty \right) = 1 \Rightarrow \lim_{n \rightarrow +\infty} Y_n^2(w) = 0 = \lim_{n \rightarrow +\infty} Y_n(w) \text{ q.c.}$$

(***) Abbiamo quindi trovata la sottosuccessione che converge quasi certamente alla media, tuttavia noi vogliamo dimostrare che tutta la successione converga quasi certamente.

Poniamo $\forall n \geq 1$: $p(n) = \lfloor \sqrt{n} \rfloor$. Allora avremo che:

$$(\sqrt{n} - 1)^2 \leq p(n)^2 \leq n \Rightarrow \frac{(\sqrt{n} - 1)^2}{n} \leq \frac{p(n)^2}{n} \leq \frac{n}{n} = 1 \quad (15.1)$$

Questo prova che $\bar{X}_{p(n)^2}$ è una sottosuccessione di $\bar{X}_{n^2}$: $(\bar{X}_{p(n)^2} : n \geq 1) \subseteq (\bar{X}_{n^2} : n \geq 1)$.
Per esempio abbiamo che:

$$\bar{X}_{p(1)^2} = \bar{X}_1; \quad \bar{X}_{p(2)^2} = \bar{X}_1; \quad \bar{X}_{p(3)^2} = \bar{X}_1; \quad \bar{X}_{p(4)^2} = \bar{X}_4; \quad \dots$$

Allora, per il passo (**), si ha che $\bar{X}_{p(n)^2} \xrightarrow{\text{q.c.}} 0$.

Possiamo riscrivere la media campionaria come:

$$\bar{X}_n = \underbrace{\bar{X}_n - \frac{p(n)^2}{n} \bar{X}_{p(n)^2}}_{:=V_n} + \underbrace{\frac{p(n)^2}{n}}_{\leq 1} \underbrace{\bar{X}_{p(n)^2}}_{\rightarrow 0}$$

Il secondo “pezzo” della media campionaria tende a zero quasi certamente, perché $\bar{X}_{p(n)^2} \xrightarrow{\text{q.c.}} 0$ e $\frac{p(n)^2}{n} \leq 1$. Se riusciamo a dimostrare che anche V_n tende q.c. a 0, allora abbiamo dimostrato la tesi.

Come fatto nel passo (**), se riusciamo a dimostrare che $\sum_{n=1}^{+\infty} E[V_n^2] < +\infty$, allora abbiamo garantito che $V_n \xrightarrow{\text{q.c.}} 0$. Riscriviamo in maniera più comoda V_n :

$$V_n = \bar{X}_n - \frac{p(n)^2}{n} \bar{X}_{p(n)^2} = \frac{1}{n} \sum_{k=1}^n X_k - \frac{p(n)^2}{n} \cdot \frac{1}{p(n)^2} \cdot \sum_{k=1}^{p(n)^2} X_k = \frac{1}{n} \sum_{k=p(n)^2+1}^n X_k$$

Calcoliamo a questo punto $E[V_n^2]$:

$$\begin{aligned} E[V_n^2] &= E \left[\left(\frac{1}{n} \sum_{k=p(n)^2+1}^n X_k \right)^2 \right] = \frac{1}{n^2} \sum_{k=p(n)^2+1}^n E[X_k^2] \\ &= \frac{1}{n^2} \sigma^2 (n - p(n)^2) \\ &\stackrel{(15.1)}{\leq} \frac{\sigma^2}{n^2} (n - (\sqrt{n} - 1)^2) = \frac{\sigma^2}{n^2} (n - n + 2\sqrt{n} - 1) \\ &\leq 2\sigma^2 \frac{\sqrt{n}}{n^2} = n^{-3/2} \end{aligned}$$

$$\Rightarrow \sum_{n=1}^{+\infty} E[V_n^2] \leq 2\sigma \sum_{n=1}^{+\infty} n^{-3/2} < +\infty \Rightarrow V_n^2 \xrightarrow{\text{q.c.}} 0$$

$$\Rightarrow \lim_{n \rightarrow +\infty} V_n = \lim_{n \rightarrow +\infty} \bar{X}_n - \frac{p(n)^2}{n} \bar{X}_{p(n)^2} = 0 \quad \text{q.c.}$$

$$\Rightarrow \bar{X}_n = V_n + \frac{p(n)^2}{n} \bar{X}_{p(n)^2} \xrightarrow{\text{q.c.}} 0$$

□

Questo teorema è definito “forte” proprio perché ci assicura una convergenza quasi certa, che è più forte della convergenza in L^p o in probabilità.




Figura 15.1: Rappresentazione grafica della LFGN

15.2.1 Applicazione: Funzione di Ripartizione Empirica

In quasi tutti i contesti reali, l'unica informazione realmente disponibile su una variabile aleatoria proviene dai campioni osservati. Un problema naturale è dunque capire in che modo le frequenze osservate si comportino rispetto alle probabilità teoriche: *è possibile descrivere la distribuzione di una variabile aleatoria soltanto a partire dai dati?*

La funzione di ripartizione empirica nasce esattamente per rispondere a questa domanda: si tratta quindi di un oggetto interamente costruito sui dati, privo di qualsiasi conoscenza a priori sulla distribuzione teorica.

Supponiamo quindi di avere un campione statistico $(X_n)_{n \geq 1}$ i.i.d. e definiamo la funzione di ripartizione per ogni n come $F_{X_n} = F_X$. Possiamo costruire la successione di funzioni F_n tale che:

$$\forall t \in \mathbb{R} \quad F_n(t) = \frac{1}{n} \sum_{k=1}^n \mathbb{I}_{(-\infty, t]}(X_k) \quad \text{" = " } \frac{\# \text{ Osservazioni in } (-\infty, t]}{n}$$

Questa è proprio detta *Funzione di Ripartizione Empirica*, che rappresenta $\forall w$ la frequenza relativa della classe $(-\infty, t]$. Si presti attenzione che F_n è una funzione aleatoria, difatti dipende anche da w e non solo da t ; per essere formalmente corretti, bisognerebbe definirla come:

$$F_n(t, w) = \frac{1}{n} \sum_{k=1}^n \mathbb{I}_{(-\infty, t]}(X_k(w))$$

Poiché il valore della funzione dipende dall'esito elementare w : la variabile $X_k = X_k(w)$ può essere inclusa oppure no nell'indicatrice $\mathbb{I}_{(-\infty, t]}(X_k)$ e quindi contribuire o meno al conteggio.


Per comprenderne la struttura, consideriamo un singolo osservatore (cioè un singolo w) per il quale le n osservazioni risultino tutte distinte. Ordinando gli X_k dal più piccolo al più grande sull'asse delle ascisse, la funzione empirica presenta esattamente n discontinuità, una in corrispondenza di ciascun valore osservato, e ciascun salto ha ampiezza $1/n$. Se alcune osservazioni coincidono, ad esempio m valori identici, il numero di salti si riduce a $n - m$, mentre il salto in corrispondenza del valore ripetuto diventa più grande, pari a m/n .

In ogni caso, il grafico di F_n dipende sia dall'esito realizzato sia dal numero n di osservazioni disponibili: la famiglia $(F_n)_{n \geq 1}$ costituisce quindi una successione di *funzioni aleatorie*, una per ciascun esperimento effettuato.

ESEMPIO: Si consideri $n = 4$. Supponiamo che si osservino $X_1(w), X_2(w), X_3(w), X_4(w)$. Allora possiamo costruire la funzione di ripartizione empirica come segue:

$$F_4(t)(w) = \begin{cases} 0, & t < X_4(w), \\ \frac{1}{4}, & X_4(w) \leq t < X_3(w), \\ \frac{1}{2}, & X_2(w) \leq t < X_1(w), \\ \frac{3}{4}, & X_1(w) \leq t < X_3(w), \\ 1, & t \geq X_3(w). \end{cases}$$

Il cui grafico risulta essere:



Convinti del fatto, per ogni $t \in \mathbb{R}$ fissato, F_n è una successione di variabili aleatorie, possiamo riconoscergli le seguenti proprietà.

1. Posso definire $Y_k := \mathbb{I}_{(-\infty, t]}(X_k)$, con $(X_n)_{n \geq 1}$ i.i.d., allora la fdr empirica diventa:

$$F_n(t) = \frac{Y_1 + \cdots + Y_n}{n}$$

$$\Rightarrow (Y_n)_{n \geq 1} \text{ è i.i.d. tale che } Y_k \sim Be(F_X(t))$$

2. $E[F_n(t)] = E[Y_1] = F_X(t)$

$$3. \text{Var}(F_n(t)) = \frac{F_X(t)(1 - F_X(t))}{n}$$

4. Per LFGN: $\forall t \quad F_n(t, w) = \bar{Y}_n \xrightarrow{\text{qc}} F_X(t)$

TEOREMA 15.19 Glivenko–Cantelli: Sia $(X_n)_{n \geq 1}$ una successione di variabili aleatorie reali i.i.d. con funzione di ripartizione $F_X(t)$ con $t \in \mathbb{R}$, allora:

$$\sup_{t \in \mathbb{R}} |F_n(t, w) - F_X(t)| \xrightarrow[n]{\text{qc}} 0$$

Possiamo ora cogliere la profonda differenza tra la LFGN (punto 4 dell'elenco precedente) e il Teorema di Glivenko–Cantelli. La LFGN garantisce, per ogni t fissato, una convergenza *punto per punto* con probabilità 1; in altre parole, per ogni valore di soglia considerato singolarmente si ha $F_n(t) \rightarrow F_X(t)$ quasi certamente.

Il Teorema di Glivenko–Cantelli è invece molto più forte: non si limita a fissare un singolo valore di t , ma considera *tutti* i valori reali simultaneamente e afferma che la convergenza è *uniforme*. In questo senso, l'intero grafico della funzione di ripartizione empirica finisce per “aderire” uniformemente a quello della funzione di ripartizione teorica.

⇒ **Passiamo da una convergenza puntuale (LFGN) ad una uniforme (GC)**

È proprio grazie al Teorema di Glivenko–Cantelli che possiamo giustificare teoricamente il perché gli “istogrammi approssimano la distribuzione reale” all’aumentare di n . Infatti, poiché la funzione di ripartizione empirica F_n converge uniformemente a F_X , le frequenze empiriche sugli intervalli — da cui l’istogramma è costruito — convergono alle probabilità teoriche degli stessi intervalli, fornendo così una stima coerente della densità (quando esiste).

15.3 Convergenza in Legge

Fino ad ora abbiamo studiato il caso in cui tutte le variabili aleatorie considerate esistessero sullo stesso dominio. In questo capitolo affronteremo invece il caso in cui siano definite su domini differenti, ossia che si abbiano

$$\begin{aligned} X_n &: (\Omega_n, \mathcal{A}_n, \mathbb{P}_n) \rightarrow (\mathbb{R}, \mathcal{B}) \\ X &: (\Omega, \mathcal{A}, \mathbb{P}) \rightarrow (\mathbb{R}, \mathcal{B}) \end{aligned}$$

È immediato che le convergenze introdotte fino ad adesso non abbiano più alcun senso matematico, in quanto l’espressione “ $X_n(w) - X(w)$ ” perde di significato, siccome gli w sono moralmente diversi.

Dovremo quindi cambiare radicalmente il modo di pensare, ed andare a lavorare sui codomini: la nozione di convergenza, nel caso di domini differenti, coinvolgerà indubbiamente le leggi P^{X_k} e P^X (che ricordiamo essere misure di probabilità sui codomini).

DEFINIZIONE 15.20 Convergenza Debole : Siano $(\mathbb{Q}_n)_{n \geq 1}$ e $\mathbb{Q}$ misure di probabilità su $\mathcal{B}$. Diciamo che $\mathbb{Q}_n$ converge debolmente a $\mathbb{Q}$ se:

$$\forall h \in C_b^0(\mathbb{R}) \quad \text{vale che} \quad \int_{\mathbb{R}} h(x) d\mathbb{Q}_n \xrightarrow{n \rightarrow +\infty} \int_{\mathbb{R}} h(x) d\mathbb{Q}$$

E la indicheremo con: $\mathbb{Q}_n \xrightarrow{D} \mathbb{Q}$.

$$C_b^0(\mathbb{R}) = \{f : \mathbb{R} \rightarrow \mathbb{R} \mid \text{continua e limitata}\}$$

In un certo senso la convergenza debole “cerca di imitare” la convergenza punto per punto. Per capire meglio cosa si intende, si consideri $(x_n)_n$, $x_n \in \mathbb{R}$ tale che $x_n \rightarrow x$. Allora, se definiamo $\mathbb{Q}_n := \delta_{x_n}$ e $\mathbb{Q} := \delta_x$ e ipotizziamo che $\mathbb{Q}_n \xrightarrow{D} \mathbb{Q}$:

$$\int_{\mathbb{R}} h(y) d\mathbb{Q}_n(y) = h(x_n) \xrightarrow{n \rightarrow +\infty} h(x) = \int_{\mathbb{R}} h(y) d\mathbb{Q}(y)$$

Quindi la convergenza debole è una generalizzazione della convergenza dei punti reali: quando le misure sono Dirac, convergere debolmente equivale semplicemente a far convergere i punti dove le Dirac sono concentrate.

DEFINIZIONE 15.21 Convergenza in Legge : Siano X_n, X variabili aleatorie con rispettivamente P^{X_n}, P^X . Diciamo che $X_n \xrightarrow{\mathcal{L}} X$ in Legge se:

$$\begin{aligned} &P^{X_n} \xrightarrow{D} P^X \\ \text{Ossia che: } \forall h \in C_b^0(\mathbb{R}) \quad &\int_{\mathbb{R}} h(x) dP^{X_n} \xrightarrow{n \rightarrow +\infty} \int_{\mathbb{R}} h(x) dP^X \end{aligned}$$

PROPOSIZIONE 15.22:

$$X_n \xrightarrow{\mathcal{L}} X \iff E_n[h(X_n)] \longrightarrow E[h(X)] \quad \forall h \in C_b^0(\mathbb{R})$$

Dimostrazione. L'implicazione ($\Rightarrow$) è banalmente verificata dalla definizione di convergenza in legge. Per quanto riguarda ($\Leftarrow$) si ha che:

$$\begin{aligned} E_n[h(X_n)] &= \int_{\Omega_n} h(X_n) d\mathbb{P}_n = \int_{\mathbb{R}} h dP^{X_n} \\ &\downarrow \forall h \in C_b^0(\mathbb{R}) \\ E[h(X)] &= \int_{\Omega} h(X) d\mathbb{P} = \int_{\mathbb{R}} h dP^X \\ \Rightarrow \quad \int_{\mathbb{R}} h dP^{X_n} &\longrightarrow \int_{\mathbb{R}} h dP^X \quad \forall h \in C_b^0(\mathbb{R}) \end{aligned}$$

Ossia che: $P^{X_n} \xrightarrow{D} P^X \Rightarrow X_n \xrightarrow{\mathcal{L}} X$

□

A Con questa proposizione non stiamo assolutamente dicendo che $E[X_n] \longrightarrow E[X]$. Quindi:

$$X_n \xrightarrow{\mathcal{L}} X \not\Rightarrow E[X_n] \longrightarrow E[X]$$

ESEMPIO: Sia X_n la successione di variabili aleatorie tale che:

$$X_n = \begin{cases} n, & \text{con probabilità } \frac{1}{n} \\ 0, & \text{con probabilità } 1 - \frac{1}{n} \end{cases}$$

Il calcolo dell'attesa è molto semplice: $E[X_n] = n \cdot \frac{1}{n} + 0 \cdot \left(1 - \frac{1}{n}\right) = 1$.

Se consideriamo $h \in C_b^0$: $E[h(X_n)] = h(n)\frac{1}{n} + h(0)\left(1 - \frac{1}{n}\right)$.

La variabile limite, se esiste, deve essere $X \equiv 0$, perché è facile vedere che $X_n \xrightarrow{\mathbb{P}} 0$.

$$\Rightarrow \left| E[h(X_n)] - E[h(X)] \right| = \left| [h(n) - h(0)] \frac{1}{n} \right| \leq \frac{2M}{n} \longrightarrow 0$$

Dove la disuguaglianza finale è stata possibile ricordandoci che h è limitata, ossia che $|h(x)| \leq M \quad \forall x \in \mathbb{R}$.

$$\Rightarrow X_n \xrightarrow{\mathcal{L}} 0 \quad \text{ma} \quad E[X_n] \longrightarrow 1$$

È importante sottolineare che **il limite in legge è unico esclusivamente in legge**, ossia:

$$X_n \xrightarrow{\mathcal{L}} X \quad \text{e} \quad X_n \xrightarrow{\mathcal{L}} \hat{X} \quad \Rightarrow \quad X \sim \hat{X} \quad (\text{Ossia che hanno stessa legge})$$

Ma non è assolutamente vero che $X(w) = \hat{X}(w)$ q.c.

ESEMPIO: Facciamo un controesempio per convincerci di questo fatto. Consideriamo

$$X \sim Be(1/2) \quad Y = 1 - X \sim Be(1/2)$$

Avremo quindi che $\mathbb{P}(w : X(w) = Y(w)) = 0$, in quanto se $X = 1$, allora $Y = 0$. Se introduciamo la successione $X_n = X \forall n$ allora avremo che $X_n \xrightarrow{\mathcal{L}} X$ ma anche $X_n \xrightarrow{\mathcal{L}} Y$.

Abbiamo appena dimostrato che $P^X = P^Y$, ma $X \neq Y \forall w$.

TEOREMA 15.23: Siano $(X_n), X$ variabili aleatorie reali, con rispettivamente F_{X_n}, F_X le loro funzioni di ripartizione.

Allora:

$$X_n \xrightarrow{\mathcal{L}} X \iff F_{X_n}(t) \longrightarrow F_X(t) \quad \forall \text{ Punto di continuit  di } F_X(t)$$

Analizziamo separatamente il caso continuo da quello discreto:

- Se X   assolutamente continua, allora avremo che F_X   continua, quindi:

$$X_n \xrightarrow{\mathcal{L}} X \iff F_{X_n}(t) \longrightarrow F_X(t) \quad \text{puntualmente } \forall t \in \mathbb{R}$$

Allora posso dire che $P^{X_n}(I) \longrightarrow P^X(I) \quad \forall \text{ intervallo } I$.

Inoltre, definite le densit  continue f_{X_n}, f , vale che:

$$\boxed{\text{Se: } f_{X_n}(t) \longrightarrow f_X(t) \text{ q.o. } t \Rightarrow X_n \xrightarrow{\mathcal{L}} X}$$

Non vale il viceversa.

- Date X_n, X variabili aleatorie reali discrete, con supporti S_{X_n}, S_X . Definito $S = (\bigcup_n S_{X_n}) \cup S_X$ (che tipicamente sar  $\mathbb{N}$), allora vale che:

$$\boxed{\text{Se: } \forall s \in S \quad p_{X_n}(s) \xrightarrow{n \rightarrow +\infty} p_X(s) \Rightarrow X_n \xrightarrow{\mathcal{L}} X}$$

Non vale il viceversa.

ESEMPIO: Facciamo due esempi per il caso discreto.

★ Sia $X_n \sim Bin(n, \lambda/n)$ e sia $X \sim Po(\lambda)$. Avremo allora che i supporti sono $S_{X_n} = \{0, \dots, n\}$ e perci  $\bigcup_n S_{X_n} = \mathbb{N} = S_X$.

Si pu  dimostrare che

$$\forall s \in \mathbb{N} : \quad p_{X_n}(s) = \binom{n}{s} \left(\frac{\lambda}{n}\right)^s \left(1 - \frac{\lambda}{n}\right)^{n-s} \longrightarrow \frac{\lambda^s e^{-\lambda}}{s!} = p_X(s)$$


★ Mostriamo con un controesempio che non vale il viceversa. Sia $X_n \sim \delta_{1/n}$ e $X \sim \delta_0$. Siccome $1/n \longrightarrow 0$, possiamo concludere che $X_n \xrightarrow{\mathcal{L}} 0$.

Tuttavia non   vero che $p_{X_n}(s) \xrightarrow{n \rightarrow +\infty} p_X(s)$, banalmente perch  una variabile aleatoria distribuita come una Dirac, non ammette una densit  discreta rispetto alla misura di Lebesgue. Si potrebbe comunque


definire una densità nel *senso delle distribuzioni* (ossia un funzionale, e non una funzione), ma anche in questo caso si dimostra che non si ha convergenza punto per punto.

ESEMPIO : Siano $X_n \sim U\left(-\frac{1}{n}, \frac{1}{n}\right)$. Ci aspettiamo, da intuizione, che convergerà alla massa di Dirac in 0. X_n ha funzione di ripartizione:

$$F_{X_n}(t) = \begin{cases} 0, & s < -1/n \\ \frac{1}{2} + \frac{n}{2}s, & -1/n \leq s < 1/n \\ 1, & s \geq 1/n \end{cases}$$



Si può notare facilmente che $F_{X_k} \rightarrow G(s) := \begin{cases} 0, & s < 0 \\ 1/2, & s = 0 \\ 1, & s \geq 0 \end{cases}$, in maniera puntuale.



Il problema è che $G(s)$ non è continua da destra, e di conseguenza non è una funzione di ripartizione. Non possiamo quindi dire che c'è convergenza in legge.

⇒ Non basta la convergenza punto per punto, ma c'è anche la necessità che la convergenza sia verso una funzione di ripartizione.

Questo problema può essere risolto con uno stratagemma: possiamo modificare $G(s)$ “spostando” ad 1 il valore $1/2$, in modo da avere la funzione di ripartizione della Dirac centrata in zero:

$$F(s) = \begin{cases} 0 & s < 0 \\ 1 & s \geq 0 \end{cases}$$

Si potrebbe argomentare che in questo modo perdiamo la convergenza puntuale di F_{X_n} a F ; questo è vero, ma non importa!! Non importa perché, grazie al Teorema 15.23 la convergenza deve avvenire per ogni punto di continuità di $F(s)$!!

Allora, siccome F è una fdr, e $F_{X_k} \rightarrow F$ per ogni punto di continuità, abbiamo che $X_n \xrightarrow{\mathcal{L}} 0$

ESEMPIO ▲: Andiamo a vedere che è possibile che una discreta $\xrightarrow{\mathcal{L}}$ ad una continua. (FOLLIA!)

Sia $X_n \sim \mathcal{U}\left(\left\{\frac{1}{n}, \frac{2}{n}, \dots, \frac{n-1}{n}, 1\right\}\right)$. La sua funzione di ripartizione risulterà essere:


$$F_{X_n}(s) = \begin{cases} 0, & s < 1/n \\ \frac{k}{n}, & \frac{k}{n} \leq s < \frac{k+1}{n} \\ 1, & s \geq 1 \end{cases}$$

Andando a studiare la convergenza puntuale per $n \rightarrow +\infty$:

$$F_{X_n}(s) \longrightarrow \begin{cases} 0, & s < 0 \\ s, & 0 \leq s < 1 \\ 1, & s \geq 1 \end{cases}$$

In quanto la lunghezza dell'intervallo $\left[\frac{k}{n}, \frac{k+1}{n}\right]$ tende a zero per n che tende ad infinito. Si tenga presente che $k = k(n)$, ossia che è dipendente da n : è falso che $\frac{k}{n} \rightarrow 0$, ma invece è vero che $\frac{k}{n} \rightarrow s$.

Ci si può convincere di questo fatto andando visualizzarlo graficamente:



Al crescere di n , la lunghezza degli intervalli

$$a = \frac{k+1}{n} - \frac{k}{n} = \frac{1}{n}$$

tende a zero, e contemporaneamente anche il salto in ordinata tra un gradino e il successivo diminuisce con la stessa velocità $1/n$. In altre parole, i gradini di $F_n(s)$ diventano via via più fitti e più bassi, e nel limite l'intero grafico di F_n si "appoggia" sulla bisettrice, dando origine a una relazione continua che realizza la mappa $s \mapsto s$.

Ecco quindi che abbiamo dimostrato che $X_n \xrightarrow{\mathcal{L}} X$, dove $X \sim \mathcal{U}([0, 1])$.

TEOREMA 15.24 Teorema di Continuità di Levy: Sono vere le seguenti:

1. Siano $(X_n)_{n \geq 1}$ e X variabili aleatorie reali, allora:

$$X_n \xrightarrow{\mathcal{L}} X \iff \varphi_{X_n}(u) = E_n[e^{iuX_n}] \longrightarrow \varphi_X(u) = E[e^{iuX}] \quad \forall u \in \mathbb{R}$$

2. Date $(X_n)_{n \geq 1}$ variabili aleatorie reali, se $\varphi_{X_n}(u) \rightarrow \Psi(u) \quad \forall u \in \mathbb{R}$, e Ψ è continua in zero:

$$\Rightarrow \Psi \text{ è la funzione caratteristica di } P^X, \text{ e } X_n \xrightarrow{\mathcal{L}} X$$

Questo teorema è molto utile nelle applicazioni reali, in quanto ci permette di dimostrare alcune convergenze in legge in maniera semplice, passando dalle convergenze puntuali delle funzioni caratteristiche. Si noti inoltre che il secondo punto ha delle ipotesi che sono più forti del primo, in quanto Ψ non è chiesto che sia una funzione caratteristica, ma solo che sia continua in zero.

Il Teorema di continuità di Levy ci permette di dimostrare con facilità che, date $(X_n)_{n \geq 1}$ tali che $X_n \sim \mathcal{N}(\mu_n, \sigma_n^2)$, dove $\mu_n \rightarrow \mu$ e $\sigma_n^2 \rightarrow \sigma^2$, allora si ha che;

$$X_n \xrightarrow{\mathcal{L}} X \sim \mathcal{N}(\mu, \sigma^2)$$

ESEMPIO: Possiamo usare il Teorema di Levy anche per dimostrare che $X_n \sim \mathcal{U}([-n, n])$ non tende in legge a nessuna variabile aleatoria. Calcolando la funzione caratteristica di X_n :

$$\varphi_{X_n}(u) = E[e^{iuX_n}] = \int_{\mathbb{R}} e^{iux_n} \cdot \frac{1}{2n} \mathbb{I}_{[-n, n]} dx = \frac{\sin(un)}{un} \rightarrow \begin{cases} 0 & u \neq 0 \\ 1 & u = 0 \end{cases}$$

Si presti attenzione che la funzione caratteristica è definita in zero, perché $E[e^{i \cdot 0 \cdot X_n}] = 1$; quando calcoliamo l'integrale, lo facciamo per $n \neq 0$, quindi la funzione che ci risulta dal calcolo non è la vera φ_{X_n} . Per questo motivo bisogna esplicitare il valore in $u = 0$.

In ogni caso φ_{X_n} non è continua in $u = 0$, e inoltre non converge alla funzione caratteristica di nessuna variabile aleatoria:

$$X_n \not\xrightarrow{\mathcal{L}} X$$

TEOREMA 15.25 Proprietà della Convergenza in Legge: Siano $X_n \xrightarrow{\mathcal{L}} X$, $Y_n \xrightarrow{\mathcal{L}} c$, con $c \in \mathbb{R}$. Allora valgono le seguenti:

1. P^X è unica
2. $a \in \mathbb{R} : aX_n \xrightarrow{\mathcal{L}} aX$
3. $\forall g \in C^0 : g(X_n) \xrightarrow{\mathcal{L}} g(X)$
4. $X_n + Y_n \xrightarrow{\mathcal{L}} X + c$
5. $X_n Y_n \xrightarrow{\mathcal{L}} Xc$
6. $\frac{X_n}{Y_n} \xrightarrow{\mathcal{L}} \frac{X}{c}$

Dimostrazione. Dimostreremo solamente i primi 3 punti.

1. Grazie al teorema di continuità di Levy, sappiamo che:

$$X_n \xrightarrow{\mathcal{L}} X \iff \varphi_{X_n}(u) \rightarrow \varphi_X(u) \quad \forall u \in \mathbb{R}$$

Per unicità del limite puntuale, se $X_n \xrightarrow{\mathcal{L}} \hat{X}$, allora $\varphi_{X_n} \rightarrow \varphi_{\hat{X}}$, e di conseguenza che $\varphi_X = \varphi_{\hat{X}}$. Siccome

la funzione caratteristica caratterizza univocamente la probabilità (Teorema 12.3), si ha che

$$\varphi_X = \varphi_{\hat{X}} \iff P^X = P^{\hat{X}}$$

2. È un caso particolare del terzo punto, quindi ci basterà dimostrare quello.

3. Affinche sia vero, devo mostrare (Proposizione 15.22) che $\forall h \in C_b^0 : E[h(g(X_n))] \longrightarrow E[h(g(X))]$. Notando che $h(g(X_n)) = (h \circ g)(X_n)$, dove $h \circ g \in C_b^0$, essendo la composizione tra $g \in C^0$ e $h \in C_b^0$, allora si ha che:

$$\begin{aligned} E[(h \circ g)(X_n)] &\longrightarrow E[(h \circ g)(X)] \\ &\equiv \\ E[h(g(X_n))] &\longrightarrow E[h(g(X))] \end{aligned}$$

Dimostrando così che $g(X_n) \xrightarrow{\mathcal{L}} g(X)$. □

Dove i punti 4. 5. e 6. sono conosciuti come il *Teorema di Slutsky*. Si tenga ben presente che, affinché siano veri, una delle due successioni deve convergere in legge ad una costante.

15.4 Relazione tra le Convergenze

Abbiamo già osservato, ad esempio nel Teorema 15.12, che può esistere un legame implicativo tra diverse nozioni di convergenza.

Ma esistono legami tra le convergenze nel caso di unico dominio, e la convergenza in legge?

Ovviamente per rispondere a questa domanda dobbiamo porci nel caso in cui $(\Omega_n, \mathcal{A}_n, \mathbb{P}_n) = (\Omega, \mathcal{A}, \mathbb{P})$

TEOREMA 15.26:

$$X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{\mathcal{L}} X$$

Dimostrazione. Data una successione $X_n \xrightarrow{\mathbb{P}} X$, per la Proposizione 15.22 è sufficiente dimostrare che $\forall h \in C_b^0(\mathbb{R})$ si ha che $E[h(X_n)] \longrightarrow E[h(X)]$ per avere convergenza in legge.

Si osserva che, grazie alla Proposizione 15.11, $\forall h \in C_b^0$, se $X_n \xrightarrow{\mathbb{P}} X$ allora $h(X_n) \xrightarrow{\mathbb{P}} h(X)$. Inoltre, dato che $h \in C_b^0$, per definizione si ha che $\exists M > 0$ tale che $|h(x)| \leq M \quad \forall x \in \mathbb{R}$:

$$\implies h(X_n) \leq M \quad \forall w \in \Omega$$

Dato che M è una costante, allora $M \in L^p$ per ogni $1 \leq p \leq +\infty$, e perciò vale il Teorema 15.13, ricavando che:

$$E[|h(X_n) - h(X)|^p] \xrightarrow{n \rightarrow +\infty} 0 \implies E[h(X_n)] \longrightarrow E[h(X)]$$

□

Questo teorema è potentissimo: **qualora vi sia una convergenza del primo tipo¹, avremo per forza anche convergenza in legge**. Questo perché sia la convergenza qc, che la quella in $\mathcal{L}^p$, implicano la convergenza in probabilità, potendo così applicare il teorema appena visto.

¹Quasi certa, $\mathcal{L}^p$, o in probabilità

Si osservi che l'implicazione è solo in un verso, difatti:

$$X_n \xrightarrow{\mathbb{P}} X \not\iff X_n \xrightarrow{\mathcal{L}} X$$

Questo è ovvio in quanto, se la convergenza in legge implicasse la convergenza in probabilità, allora il limite in legge sarebbe unico quasi certamente, il che è falso!

Esiste però un caso particolare in cui la convergenza in legge implica quella in probabilità: le costanti.

TEOREMA 15.27: Data $c \in \mathbb{R}$, allora

$$X_n \xrightarrow{\mathcal{L}} c \implies X_n \xrightarrow{\mathbb{P}} c$$

Dimostrazione. Se $X_n \xrightarrow{\mathcal{L}} c$, allora $\forall h \in C_b^0(\mathbb{R})$ si ha che: $E[h(X_n)] \rightarrow E[h(c)] = h(c)$, in quanto deterministica e non stocastica. Possiamo definire in maniera intelligente $h(x)$, ed avere che:

$$h(x) := \frac{|x - c|}{1 + |x - c|} \in C_b^0(\mathbb{R}) \implies E\left[\frac{|X_n - c|}{1 + |X_n - c|}\right] \rightarrow h(c) = 0$$

Grazie alla Preposizione 15.10, abbiamo assicurato la convergenza in probabilità. $\square$

Arriviamo adesso ad uno dei più importanti (se non il più importante!) di tutta la Teoria della Probabilità: il **Teorema Centrale del Limite**.

Il Teorema Centrale del Limite rappresenta uno dei risultati più impressionanti dell'intera teoria della probabilità. A partire da un'ipotesi sorprendentemente semplice e minimale, esso permette di dedurre conclusioni estremamente precise. Per questo motivo, questo teorema costituisce la base concettuale di gran parte della Statistica moderna.

L'idea alla base è semplice: si consideri una successione X_n di variabili aleatorie i.i.d. con varianza finita, allora, per n grande, la distribuzione della media campionaria centrata e normalizzata può essere approssimata da una distribuzione normale standard.

L'osservazione cruciale è che *non si assume assolutamente nulla* sulla distribuzione delle variabili X_j , se non che abbiano varianza finita. Pertanto, se una variabile aleatoria può essere modellata come la somma di molte variabili i.i.d. con varianza finita, allora la sua distribuzione sarà approssimativamente gaussiana.

A questo punto, è sufficiente utilizzare i dati per stimare μ e σ^2 tramite metodi statistici: una volta ottenuti questi due parametri, si conosce praticamente tutto ciò che serve!

TEOREMA 15.28 Teorema Centrale del Limite: Siano $(X_n)_{n \geq 1}$ variabili aleatorie i.i.d. tali che $X_n \in L^2(\Omega, \mathcal{A}, \mathbb{P})$, con $E[X_n] = \mu$ e $Var(X_n) = \sigma^2 > 0$.

Allora si ha che:

$$T_n := \frac{\bar{X}_n - E[\bar{X}_n]}{\sqrt{Var(\bar{X}_n)}} = \frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}}} \xrightarrow{\mathcal{L}} Z \sim \mathcal{N}(0, 1)$$

Ovvero che:

$$F_{T_n}(t) \xrightarrow{n \rightarrow +\infty} \Phi(t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}x^2\right\} dx \quad \forall t \in \mathbb{R}$$

Dimostrazione. Senza perdere di generalità si consideri $\mu = 0$. (Altrimenti si può eseguire la stessa dimostrazione sostituendo $Y_n = X_n - \mu$). Dovendo dimostrare un convergenza in legge, conviene andare a ragionare sulle funzioni caratteristica ed applicare il Teorema di Levy.

Grazie al Teorema 12.4, siccome $X_n \in L^2$ allora $\varphi_{X_n} \in C^2$ ed è tale che:

- $\varphi_{X_n}(0) = 1 \quad \forall n$
- $\varphi'_{X_n}(0) = -iE[X_n] = -i \cdot 0 = 0$
- $\varphi''_{X_n}(0) = -E[X_n^2] = -Var(X_n) = -\sigma^2$

Pur non conoscendo ancora φ_{X_n} , possiamo farne lo sviluppo di Taylor per $u \rightarrow 0$:

$$\begin{aligned}\varphi_{X_n}(u) &= \varphi_{X_n}(0) + \varphi'_{X_n}(0)u + \frac{1}{2}\varphi''_{X_n}(0)u^2 + o(u^2) \\ &= 1 - \frac{1}{2}\sigma^2 u^2 + o(u^2)\end{aligned}$$

Allora la funzione caratteristica di T_n risulta essere:

$$\begin{aligned}\forall v \in \mathbb{R} : \quad \varphi_{T_n}(v) &= E[e^{ivT_n}] = E\left[e^{iv\left(\frac{X_1+\dots+X_n}{n}\right)\frac{\sqrt{n}}{\sigma}}\right] \\ &= E\left[e^{\frac{iv}{\sqrt{n}\sigma^2}(X_1+\dots+X_n)}\right] \\ &= E\left[e^{\frac{iv}{\sqrt{n}\sigma^2}X_1+\dots+\frac{iv}{\sqrt{n}\sigma^2}X_n}\right] \\ &= \left[E\left[e^{\frac{iv}{\sqrt{n}\sigma^2}X_1}\right]\right]^n && (X_n \text{ i.i.d.}) \\ &= \left[\varphi_{X_1}\left(\frac{v}{\sqrt{n}\sigma^2}\right)\right]^n \\ &= \left[1 - \frac{1}{2}\sigma^2 \frac{v^2}{\sigma^2 n} + o\left(\frac{v^2}{\sigma^2 n}\right)\right]^n && (Taylor: v/\sqrt{n}\sigma^2 \rightarrow 0 \quad \forall v) \\ &= \left[1 - \frac{v^2}{2n} + o\left(\frac{v^2}{\sigma^2 n}\right)\right]^n\end{aligned}$$

Se si definisce $\frac{-v^2}{n} =: z_n$, allora, grazie alle proprietà del logaritmo complesso (si vedano i richiami di analisi a riguardo più avanti) possiamo concludere che:

$$\varphi_{T_n}(v) \xrightarrow{n \rightarrow +\infty} e^{\frac{-v^2}{n}} = \varphi_Z(v)$$


Di conseguenza, grazie al Teorema di Levy, abbiamo dimostrato che $T_n \xrightarrow{\mathcal{L}} Z$. □

Per concludere, possiamo fare delle osservazioni sulla potenza di questo risultato.

★ Le varie X_n devono appartenere tutte allo stesso spazio di probabilità, ma Z può essere definito su uno diverso! È questo il caso di variabili aleatorie discrete, che convergono ad una continua.

★ Le X_n hanno legge che è *incognita*. Come per quando abbiamo studiato la LGN, la tesi era a proposito della media campionaria $\bar{X}_n$, e non alle singole X_n :

⇒ Non possiamo approssimare qualsiasi variabile aleatoria con una gaussiana, possiamo però fare l'approssimazione per le medie campionarie!



★ Il caso degenere in cui $\sigma^2 = 0$ non può essere trattato usando il TCL, in quanto cadono le ipotesi. È però un caso di facile trattazione, infatti avere varianza nulla implica che $X_n \equiv \mu$, e di conseguenza $\bar{X}_n \equiv \mu$.

★ Il TCL è chiaramente valido anche nel caso in cui non si abbia la media campionaria normalizzata: basta semplicemente fare la normalizzazione:

$$\mathbb{P}(\bar{X}_n \leq x) = \mathbb{P}\left(\frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}}} \leq \frac{x - \mu}{\sqrt{\frac{\sigma^2}{n}}}\right) \approx \Phi\left(\frac{x - \mu}{\sqrt{\frac{\sigma^2}{n}}}\right)$$

Indirettamente conosciamo pure la legge della media campionaria!

★ Ragionando in maniera molto simile all'osservazione precedente, possiamo conoscere anche la legge della somma parziale $S_n := (X_1 + \dots + X_n) = n\bar{X}_n$. Basta effettuare una normalizzazione del tipo:

$$\begin{aligned} \frac{S_n - n\mu}{\sqrt{n\sigma^2}} &= \frac{n(\bar{X}_n - \mu)}{n\sqrt{\frac{\sigma^2}{n}}} = \frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}}} = T_n \\ \Rightarrow \quad \mathbb{P}(S_n \leq x) &= \mathbb{P}\left(\frac{S_n - n\mu}{\sqrt{n\sigma^2}} \leq \frac{x - n\mu}{\sqrt{n\sigma^2}}\right) \stackrel{\text{TCL}}{\approx} \Phi\left(\frac{x - n\mu}{\sqrt{n\sigma^2}}\right) \end{aligned}$$

★ Dato un qualsiasi campione di variabili aleatorie $X_n \in L^2$, abbiamo visto che, per la LFGN, $\bar{X}_n \xrightarrow{\text{qc}} \mu$, e che la varianza della media campionaria tende a zero. Di conseguenza, la distribuzione di $\bar{X}_n$ si concentra sempre più attorno a μ e converge alla misura di Dirac δ_μ .

Normalizzando, impediamo (grazie al Teorema del Limite Centrale) che la distribuzione collassi in una Dirac:

$$\frac{\bar{X}_n - \mu}{\sqrt{\sigma^2/n}} \xrightarrow{\mathcal{L}} Z \neq 0.$$

In un certo senso, è come se stessimo “intercettando” la velocità di convergenza in legge. Infatti, dalla LFGN si ha $\bar{X}_n - \mu \xrightarrow{\text{qc}} 0$, ma poiché la normalizzazione $\sqrt{n}(\bar{X}_n - \mu)$ non converge a una Dirac, e anzi ammette un limite non degenere, ciò implica che lo scostamento $\bar{X}_n - \mu$ converge a zero con ordine

$$\bar{X}_n - \mu = O_p\left(\frac{1}{\sqrt{n}}\right).$$

In altre parole, il fattore $\sqrt{n}$ rivela esattamente la velocità con cui la media campionaria si avvicina alla sua media.

Parte II

Appendici

A Dispense Integrative

A.1 Calcolo Combinatorio

Cercheremo di evitare le definizioni eccessivamente formali, e ci concentreremo sull'effettivo uso pratico dei vari strumenti.

A.1.1 Permutazioni

La permutazione semplice risponde alla domanda: “*quanti sono i modi possibili di ordinare n elementi distinti?*”.

Si ha che questo numero è

$$P_n = n!$$

Nel caso si abbiano oggetti non distinti ma con ripetizioni, allora

$$P_n^* = \frac{n!}{k_1! \cdots k_n!} \quad \text{dove} \quad n = \begin{cases} k_1 & \text{tipo 1} \\ \vdots \\ k_n & \text{tipo } n \end{cases}$$

Se gli oggetti non distinti fossero solo di due tipi, allora si ricadrebbe nel coefficiente binomiale:

$$P_n = \frac{n!}{k_1! k_2!} = \frac{n!}{k_1! (n - k_1)!}$$

A.1.2 Disposizioni

Le disposizioni semplici rispondono alla domanda: “*In quanti modi posso ordinare n oggetti distinti (presi una sola volta) in k posti differenti?*”

$$D_{n,k} = \frac{n!}{(n - k)!}$$

Nel caso in cui volessimo contare gli n oggetti con ripetizione, allora avremmo:

$$D_{n,k}^* = n^k$$

⇒ In tutti i tipi di disposizioni, l'ordine degli oggetti è rilevante!

A.1.3 Combinazioni

Le combinazioni semplici rispondono a: “*in quanti modi posso scegliere n oggetti (presi una volta) di classe k , prescindendo dall'ordine?*”

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k! (n - k)!}$$

Nel caso in cui gli oggetti si possano prendere con ripetizione:

$$C_{n,k}^* = \binom{n + k - 1}{k}$$


⇒ In tutti i tipi di combinazione, l'ordine degli oggetti non è rilevante!

A.2 Logaritmo Complesso

Sia $z \in \mathbb{C}$ con $z \neq 0$. Cercare il logaritmo di z significa determinare un numero complesso $w \in \mathbb{C}$ tale che $e^w = z$. Nel contesto complesso, tuttavia, l'esponenziale non è iniettivo: di conseguenza, l'equazione precedente ammette *infinite soluzioni*, tutte della forma

$$w = \ln |z| + i \operatorname{Arg}(z) + i 2\pi k, \quad k \in \mathbb{Z},$$

poiché moltiplicare z per $e^{i2\pi k}$ equivale a ruotare il vettore di un angolo $2\pi k$, riportandolo esattamente su se stesso.



Per trattare in modo univoco il logaritmo complesso, è necessario selezionare una delle sue infinite determinazioni e definirne una come *logaritmo principale*. Si introduce dunque la funzione $\operatorname{Log} : \mathbb{C} \setminus \{0\} \rightarrow \mathbb{C}$ definita da

$$\operatorname{Log}(z) = \ln |z| + i \operatorname{Arg}(z), \quad \operatorname{Arg}(z) \in [0, 2\pi)$$

dove si fissa l'argomento nel semintervallo $[0, 2\pi)$ per garantire l'unicità della determinazione.

Il logaritmo complesso ha le seguenti proprietà:

- $\operatorname{Log}(e^z) = z$
- $e^{\operatorname{Log}(z_1 \cdot z_2)} = e^{\operatorname{Log}(z_1) + \operatorname{Log}(z_2)}$; NON vale che $\operatorname{Log}(z_1 \cdot z_2) = \operatorname{Log} z_1 + \operatorname{Log} z_2$
- Sul disco di convergenza $D = \{z \in \mathbb{C} : |z| < 1\}$ vale che: $\operatorname{Log}(1+z) = z - \frac{1}{2}z^2 + \frac{1}{3}z^3 + \dots$. Allora avremo che:

$$- \lim_{z \rightarrow 0} \frac{\operatorname{Log}(1+z)}{z} = 1$$

- Data una successione convergente $z_n \rightarrow z$, allora:

$$\begin{aligned} \left(1 + \frac{z_n}{n}\right)^n &= e^{n \operatorname{Log}(1 + \frac{z_n}{n})} = e^{n[\frac{z_n}{n} + o(\frac{z_n}{n})]} \\ &= e^{z_n} \cdot e^{o(\frac{z_n}{n})} \rightarrow e^z \end{aligned}$$

$$\Rightarrow \left(1 + \frac{z_n}{n}\right)^n \rightarrow e^z$$

ESEMPIO : Nell'esempio a pagina 140 abbiamo detto che $X_n \sim \operatorname{Bin}(n, \lambda/n) \xrightarrow{\mathcal{L}} X \sim \operatorname{Po}(\lambda)$. Grazie al logaritmo principale possiamo dimostrarlo:

$$\varphi_{X_n}(u) = \left[e^{iu \frac{\lambda}{n}} + \left(1 - \frac{\lambda}{n}\right) \right]^n = \left[1 + \left(e^{iu} - 1 \right) \frac{\lambda}{n} \right]^n \rightarrow e^{(e^{iu} - 1)\lambda} = \varphi_X(u)$$

A.3 Radice Quadrata di una Matrice

In molte applicazioni, in particolare nello studio delle distribuzioni gaussiane multivariate, compare l'espressione $\sqrt{C}$, dove C è una matrice. In questa appendice spieghiamo con precisione cosa significhi "fare la radice quadrata" di una matrice e perché questo concetto è utile.

DEFINIZIONE A.1 Radice Quadrata : Sia C una matrice quadrata $d \times d$. Una matrice A si dice *radice quadrata* di C se soddisfa

$$A^2 = AA = C.$$

Questa non è in generale univoca: possono esistere molte matrici diverse A tali che $A^2 = C$. Tuttavia, quando C è simmetrica e definita positiva, la situazione diventa molto più semplice.

Sia C simmetrica definita positiva. Allora:

- tutti gli autovalori di C sono reali e positivi,
- C è diagonalizzabile ortogonalmente:

$$C = Q\Lambda Q^T,$$

dove $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$ con $\lambda_i > 0$, e Q è ortogonale.

DEFINIZIONE A.2 Radice Principale : In questo caso possiamo definire la *radice quadrata principale* come:

$$\sqrt{C} := Q \sqrt{\Lambda} Q^T,$$

dove

$$\sqrt{\Lambda} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_d}).$$

È immediato verificare che:

$$\sqrt{C} \sqrt{C} = C.$$

Questa radice quadrata è univoca, simmetrica e definita positiva.

Se C non è definita positiva o non è simmetrica, possono esistere molte radici diverse. Ad esempio:

$$I_2 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \Rightarrow \quad A = \begin{pmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{pmatrix}$$



soddisfa $A^2 = I_2$ per ogni θ .

B Distribuzioni Discrete

B.1 Uniforme Discreta

Distribuisce uniformemente la probabilità per tutti gli n elementi: hanno tutti la stessa probabilità di realizzarsi.

$$\mathcal{U}(a, b)$$




Supporto	$\{a, a + 1, \dots, b\} \subset \mathbb{Z}$
Funzione di Densità	$\mathbb{P}(X = k) = \frac{1}{n}, \quad k = a, \dots, b$
Funzione di Ripartizione	$F(k) = \begin{cases} 0, & k < a, \\ \frac{k - a + 1}{n}, & a \leq k \leq b, \\ 1, & k > b \end{cases}$
Valore atteso	$\mathbb{E}[X] = \frac{a + b}{2}$
Varianza	$Var(X) = \frac{n^2 - 1}{12}$
Funzione caratteristica	$\varphi_X(u) = \frac{1}{n} \sum_{k=a}^b e^{iuk}$

B.2 Bernoulli

Modella un esperimento con due soli esiti: successo (1) e insuccesso (0). La probabilità di successo è $p \in [0, 1]$.

$$Be(p)$$




Supporto	$\{0, 1\}$
Funzione di Massa di Probabilità	$\mathbb{P}(X = 1) = p, \quad \mathbb{P}(X = 0) = 1 - p$
Funzione di Ripartizione	$F(k) = \begin{cases} 0, & k < 0, \\ 1 - p, & 0 \leq k < 1, \\ 1, & k \geq 1. \end{cases}$
Valore atteso	$\mathbb{E}[X] = p$
Varianza	$Var(X) = p(1 - p)$
Funzione caratteristica	$\varphi_X(u) = \mathbb{E}[e^{iuX}] = (1 - p) + p e^{iu}$

B.3 Binomiale

Modella la somma di successi in $n \in \mathbb{N}$ esperimenti di Bernoulli con identica probabilità p di successo. Risulta essere quindi la somma di n Bernoulliane.

$$\text{Bin}(n, p) = \sum_1^n \text{Be}(p)$$





Supporto	$\{0, 1, \dots, n\} \subset \mathbb{Z}$
Funzione di Densità	$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n$
Funzione di Ripartizione	$F(k) = \sum_{j=0}^{\lfloor k \rfloor} \binom{n}{j} p^j (1-p)^{n-j}$
Valore atteso	$\mathbb{E}[X] = np$
Varianza	$\text{Var}(X) = np(1-p)$
Funzione caratteristica	$\varphi_X(u) = [(1-p) + pe^{iu}]^n$

B.4 Poisson

Chiamata anche legge degli eventi rari, descrive la distribuzione del numero di eventi che si verificano in modo indipendente all'interno di un dato intervallo di tempo (o spazio), assumendo che il numero medio di eventi sia pari a $\lambda > 0$. Essa può essere ottenuta come limite in legge di una successione di distribuzioni binomiali $\text{Bin}(n, p)$ quando $n \rightarrow +\infty, p \rightarrow 0$ e $\lambda = np$ rimane costante.

$$Po(\lambda)$$





Supporto	$\{0, 1, 2, \dots\} \subset \mathbb{Z}$
Funzione di Densità	$\mathbb{P}(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$
Funzione di Ripartizione	$F(k) = \mathbb{P}(X \leq k) = \sum_{j=0}^{[k]} e^{-\lambda} \frac{\lambda^j}{j!}$
Valore atteso	$\mathbb{E}[X] = \lambda$
Varianza	$\text{Var}(X) = \lambda$
Funzione caratteristica	$\varphi_X(u) = \exp(\lambda(e^{iu} - 1))$

B.5 Geometrica

Modella il numero di prove necessarie per ottenere il primo successo in una sequenza di prove di bernoulli indipendenti, ciascuna con probabilità di successo p .

$$\mathcal{G}(p)$$



Supporto	$\{1, 2, 3, \dots\} \subset \mathbb{Z}$
Funzione di Densità	$\mathbb{P}(X = k) = p(1 - p)^{k-1}, \quad k = 1, 2, 3, \dots$
Funzione di Ripartizione	$F(k) = \mathbb{P}(X \leq k) = 1 - (1 - p)^k$
Valore atteso	$\mathbb{E}[X] = \frac{1}{p}$
Varianza	$Var(X) = \frac{1 - p}{p^2}$
Funzione caratteristica	$\varphi_X(u) = \frac{pe^{iu}}{1 - (1 - p)e^{iu}}$

La Geometrica è l'unica variabile aleatoria discreta che gode della *proprietà di assenza di memoria*. Ciò significa che la probabilità di dover attendere ancora un certo numero di prove non dipende dal numero di insuccessi già osservati.


Formalmente per ogni $m, n \in \mathbb{N}$ vale:

$$\mathbb{P}(X > m + n \mid X > m) = \mathbb{P}(X > n).$$

B.6 Ipergeometrica

La distribuzione ipergeometrica descrive il numero di successi ottenuti estraendo senza reinserimento un campione di dimensione n da una popolazione finita di N elementi, di cui K sono classificati come successi e $N - K$ come insuccessi.

$$\mathcal{H}(N, K, n)$$



Supporto $\{\max(0, n - (N - K)), \dots, \min(n, K)\} \subset \mathbb{Z}$

Funzione di Densità $\mathbb{P}(X = k) = \frac{\binom{K}{k} \binom{N-K}{n-k}}{\binom{N}{n}}$

Funzione di Ripartizione $F(k) = \sum_{j=0}^{[k]} \frac{\binom{K}{j} \binom{N-K}{n-j}}{\binom{N}{n}}$

Valore atteso $\mathbb{E}[X] = n \frac{K}{N}$



Varianza $Var(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}$

C Distribuzioni Continue

C.1 Uniforme Continua

La distribuzione *Uniforme continua* assegna la stessa densità di probabilità a tutti i valori appartenenti all'intervallo $[a, b]$. In altre parole, ogni sottointervallo di uguale lunghezza ha la stessa probabilità di realizzarsi.

$$\mathcal{U}(a, b)$$





Supporto	$[a, b] \subset \mathbb{R}$
Funzione di densità	$f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{altrimenti} \end{cases}$
Funzione di ripartizione	$F_X(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b \end{cases}$
Valore atteso	$\mathbb{E}[X] = \frac{a+b}{2}$
Varianza	$\text{Var}(X) = \frac{(b-a)^2}{12}$
Funzione caratteristica	$\varphi_X(u) = \frac{e^{iub} - e^{iua}}{iu(b-a)}$

C.2 Esponenziale

Modella il tempo di attesa tra eventi in un processo di Poisson di intensità $\lambda > 0$ (ad esempio, il tempo fino al prossimo arrivo).

$$\mathcal{E}(\lambda)$$



Supporto	$[0, +\infty) \subset \mathbb{R}$
Funzione di Densità	$f(x) = \lambda e^{-\lambda x} \mathbb{I}_{(0, +\infty)}(x)$
Funzione di Ripartizione	$F(x) = (1 - e^{-\lambda x}) \mathbb{I}_{(0, +\infty)}(x)$
Valore atteso	$\mathbb{E}[X] = \frac{1}{\lambda}$
Varianza	$Var(X) = \frac{1}{\lambda^2}$
Funzione caratteristica	$\varphi_X(u) = \frac{\lambda}{\lambda - iu}$

La distribuzione esponenziale è l'unica distribuzione continua non degenera a possedere la *proprietà di assenza di memoria*. Essa afferma che, per ogni $s, t \geq 0$,



$$\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t).$$

Dal punto di vista probabilistico, questa relazione implica che il tempo di attesa residuo non dipende dal tempo già trascorso: il processo “riparte da zero” in ogni istante, indipendentemente dalla sua storia passata. Questo la rende perfetta per modellizzare il tempo di vita di oggetti che non invecchiano.

C.3 Normale

Modella variabili aleatorie continue che risultano dalla somma di molti effetti indipendenti e di piccola entità (teorema centrale del limite). È la distribuzione di riferimento in statistica e probabilità.

$$\mathcal{N}(\mu, \sigma^2)$$





Supporto	$\mathbb{R}$
Funzione di Densità	$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$
Funzione di Ripartizione	$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right) = \frac{1}{2} \left[1 + \operatorname{erf}\left(\frac{x-\mu}{\sigma\sqrt{2}}\right)\right]$
Valore atteso	$\mathbb{E}[X] = \mu$
Varianza	$\operatorname{Var}(X) = \sigma^2$
Funzione caratteristica	$\varphi_X(u) = \exp\left\{i\mu u - \frac{1}{2}\sigma^2 u^2\right\}$

C.4 Gamma

La distribuzione Gamma generalizza le distribuzioni esponenziale e chi-quadro. Essa coincide con la distribuzione della somma di α variabili aleatorie indipendenti e identicamente distribuite, ciascuna con legge esponenziale di parametro β , con $\alpha > 0$ e $\beta > 0$.

$$\Gamma(\alpha, \beta)$$



Supporto	$[0, +\infty)$
Funzione di Densità	$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \mathbb{I}_{(0, +\infty)}(x)$
Funzione di Ripartizione	$F(x) = \frac{\gamma(\alpha, \beta x)}{\Gamma(\alpha)}$ (dove γ è la gamma incompleta inferiore)
Valore atteso	$\mathbb{E}[X] = \frac{\alpha}{\beta}$
Momento k-esimo	$\mathbb{E}[X^k] = \frac{\beta^\alpha}{\Gamma(\alpha)} \frac{\Gamma(\alpha + k)}{\beta^{\alpha+k}}$
Varianza	$Var(X) = \frac{\alpha}{\beta^2}$
Funzione caratteristica	$\varphi_X(u) = \left(\frac{\beta}{\beta - iu} \right)^\alpha$

Si ricorda che la funzione Gamma di Eulero è definita, per ogni $\alpha > 0$, come

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx,$$

e generalizza il fattoriale al continuo, nel senso che

$$\Gamma(n) = (n-1)! \quad \forall n \in \mathbb{N}.$$